CS4303 大数据处理理

丁玥
上海交通大学计算机学院
dingyue@sjtu.edu.cn

2026年秋

饮 水 思 源 • 爱 国 荣 校

课程介绍

- 课程教学2学分，上机答疑（虚拟排课）1学分
- 课程微信群
- 助教
  - 黄顺阳 syhuang123@sjtu.edu.cn



- 参考教材
  - 《Hadoop+Spark+Python大数据处理从算法到实战》，朱春旭
  - 《大数据技术原理与应用》，林子雨





群聊：26秋_大数据处理_CS4303

该二维码7天内（9月21日前）有效，重新进入将更新

课程介绍

- **大数据技术简介**
- **数据预处理方法**
- **大数据平台容器化**
  - 虚拟机、docker和Linux基础
- **大数据底层架构**
  - Hadoop、分布式文件系统HDFS、MapReduce计算框架
- **大数据分析与处理技术**
  - HBase、Hive和Spark
- **数据挖掘与机器学习方法**
  - 聚类、K最近邻、频繁模式挖掘与关联规则分析、线性回归、逻辑回归
- **前沿技术讲座**
  - 大模型、多模态、Agent

课程介绍

成绩组成

- **无书面考试**
- 平时成绩（**10%**）：出勤
- 作业（**20%**）：2次上机练习
- 课程项目（**70%**）

注意事项：**按时提交、杜绝抄袭**

上机作业20分：

- **共两次，每次满分10分，按作业要求提交（报告、截屏、录屏等）**
  - 第一次上机作业内容为hadoop环境搭建，第二次上机作业为Hbase+Hive。
  - **提供完整的上机练习操作说明**
- **评分方式：**
  - **完成（10分）：** 显示可运行，有作业说明
  - **基本完成（6）：** 存在明显问题未能解决
  - **未完成（0分）：** 过了截止时间不提交作业
  - **抄袭（0分）：** 直接复制别人的作业
    - **如遇特殊情况请详细通过邮件沟通并酌情考虑作业分数**

课程介绍

- **课程项目70分，鼓励单独完成，也可以组队完成**
  - **小组人数最多3人。考虑到工作量和公平性，在完成质量相当的情况下，单独完成的分数更高**
  - **需要明确组长及成员的分工作为每个成员得分的依据**
- **课程项目的提交截止时间：第9周周日24点前**
- **主题：基于大数据架构的数据处理和分析系统（具体内容可以自拟）**
  - 例如，基于Spark MIlib的回归预测/协同过滤推荐，大数据架构下的数据处理及可视化
- **评分准则：工作量（50%）、质量（40%）、PPT报告（10%）**
  - **留有一定的灵活性，有额外加分项，例如集成了课程外的其他模块、实现和应用了较难的机器学习/数据挖掘算法、或使用其他Linux系统（比如Ubuntu）搭建**
- **过截止期不提交0分，课程总分参考教务处及学院相关规定**