大数据技术简介

丁玥

上海交通大学计算机学院

dingyue@sjtu.edu.cn

2026年秋

饮 水 思 源 • 爱 国 荣 校

大数据的表象概念

数据总量	• 100~1000PB
数据处理量	• 10~100PB/天
网页	• 千亿~万亿
索引	• 百亿~千亿
更新量	• 十亿~百亿/天
请求	• 十亿~百亿/天
日志	• 100TB~1PB/天

某Web网站的数据量



数据的意义



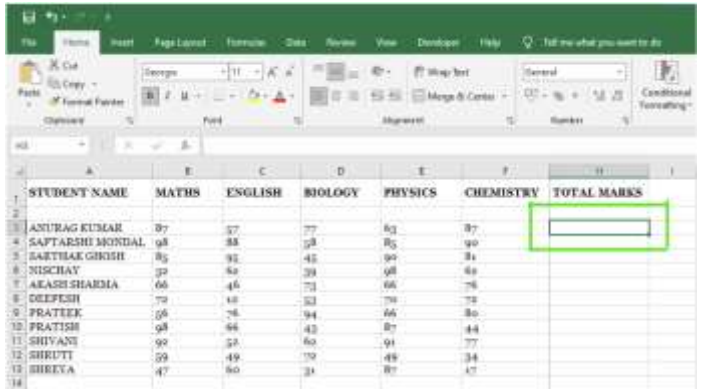
电商平台 首页 分类 社区 社区 消息

姓名	范范	钱丽	莫莫	张帅	刘勇	顾磊
无线鼠标	√			√	√	
Linux编程思想	√		√	√		
面膜		√				
乐高		√				√
情趣用品	√			√		
皮鞋	√	√		√		
小米手环	√		√			√

通过数据分析发现偏好，支撑推荐与决策

大数据的具象概念

- 大数据（big data）指的是传统数据处理应用软件不足以处理的大或复杂的数据集的术语
  - 通常所包含的数据超出传统软件在可接受的时间内处理的能力
  - 但是，数据的“大”是相对的



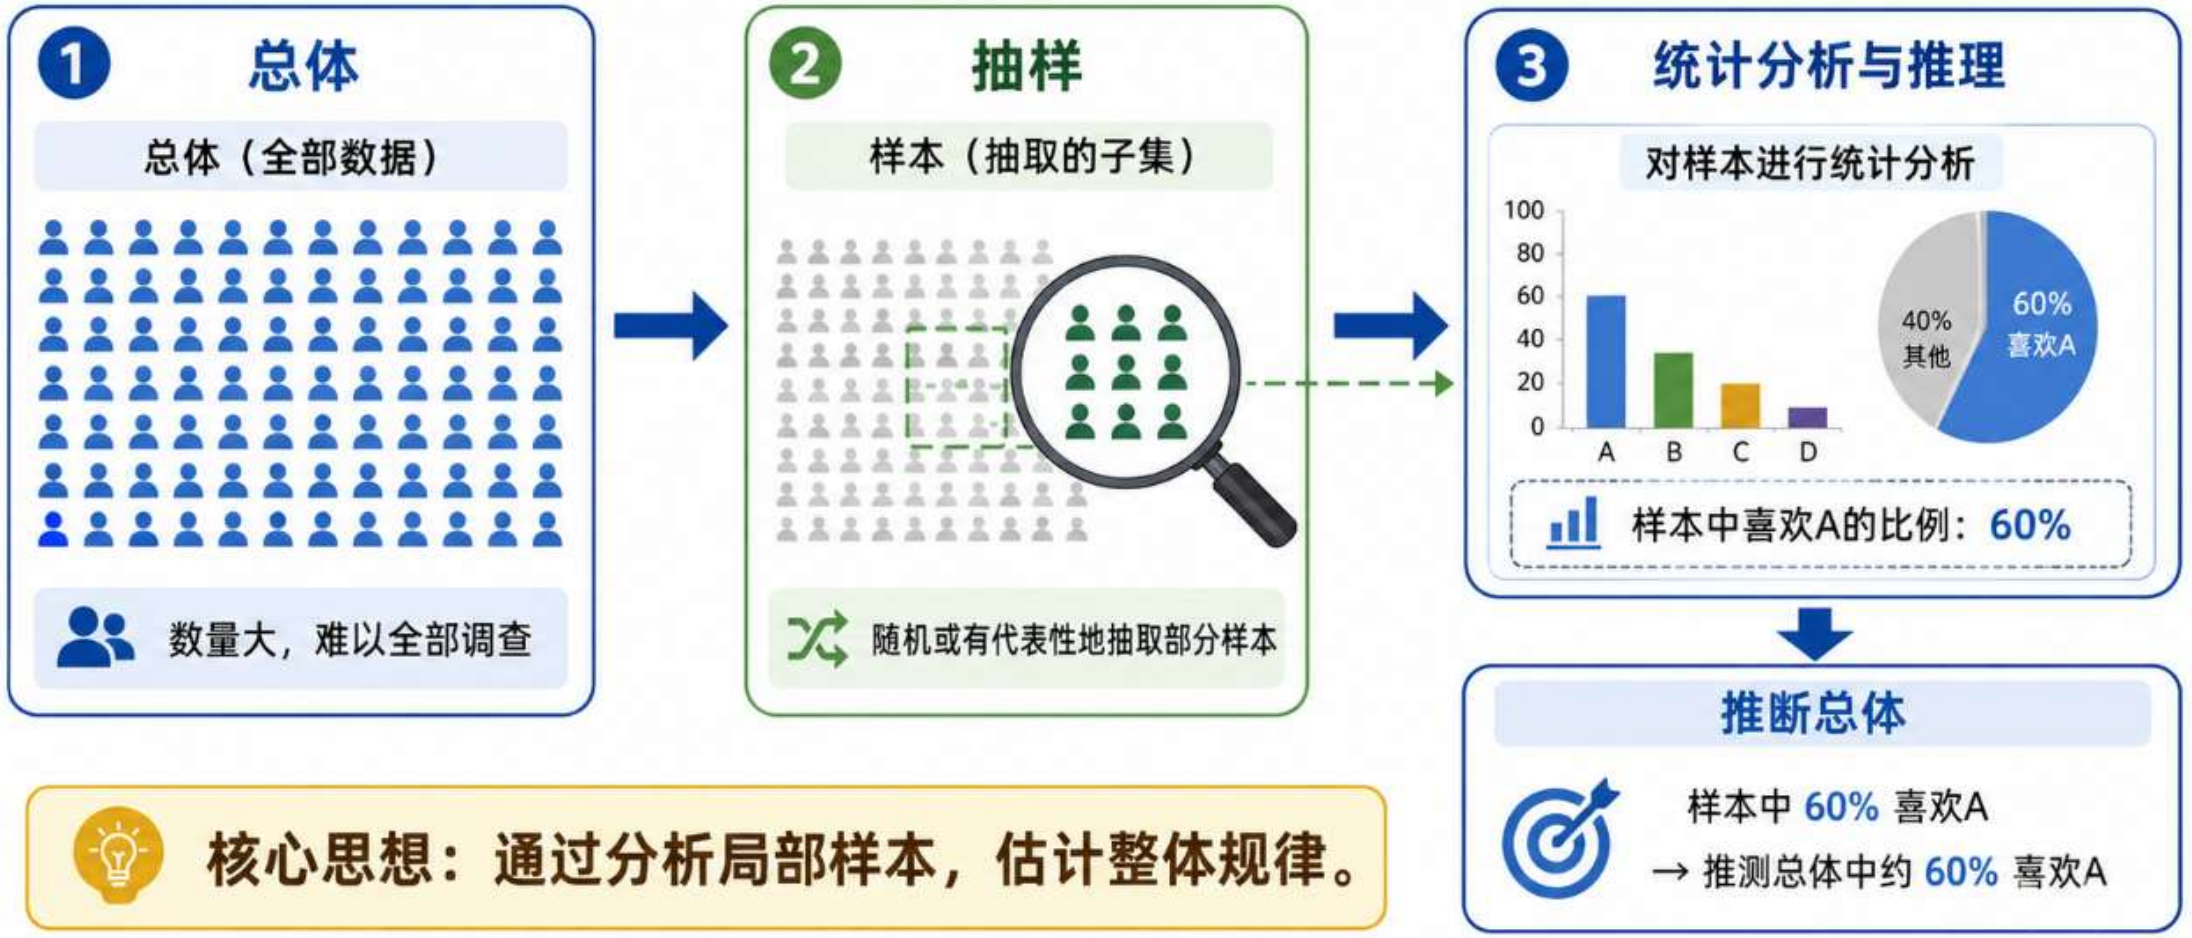
STUDENT NAME	MATHS	ENGLISH	BIOLOGY	PHYSICS	CHEMISTRY	TOTAL MARKS
ANURAG KUMAR	87	57	77	63	87	
SAPTARSHI MONDAL	98	88	58	85	90	
SARTHAK GIRISH	85	93	45	99	81	
NISCHAY	32	62	39	98	62	
AKASH SHARMA	66	46	73	66	76	
DEEPESH	72	42	53	79	72	
PRATEEK	58	76	94	66	80	
PRATISH	98	66	43	87	44	
SHIVANI	90	52	60	91	77	
SHRUTI	59	49	79	49	34	
SHREYA	47	80	31	87	47	



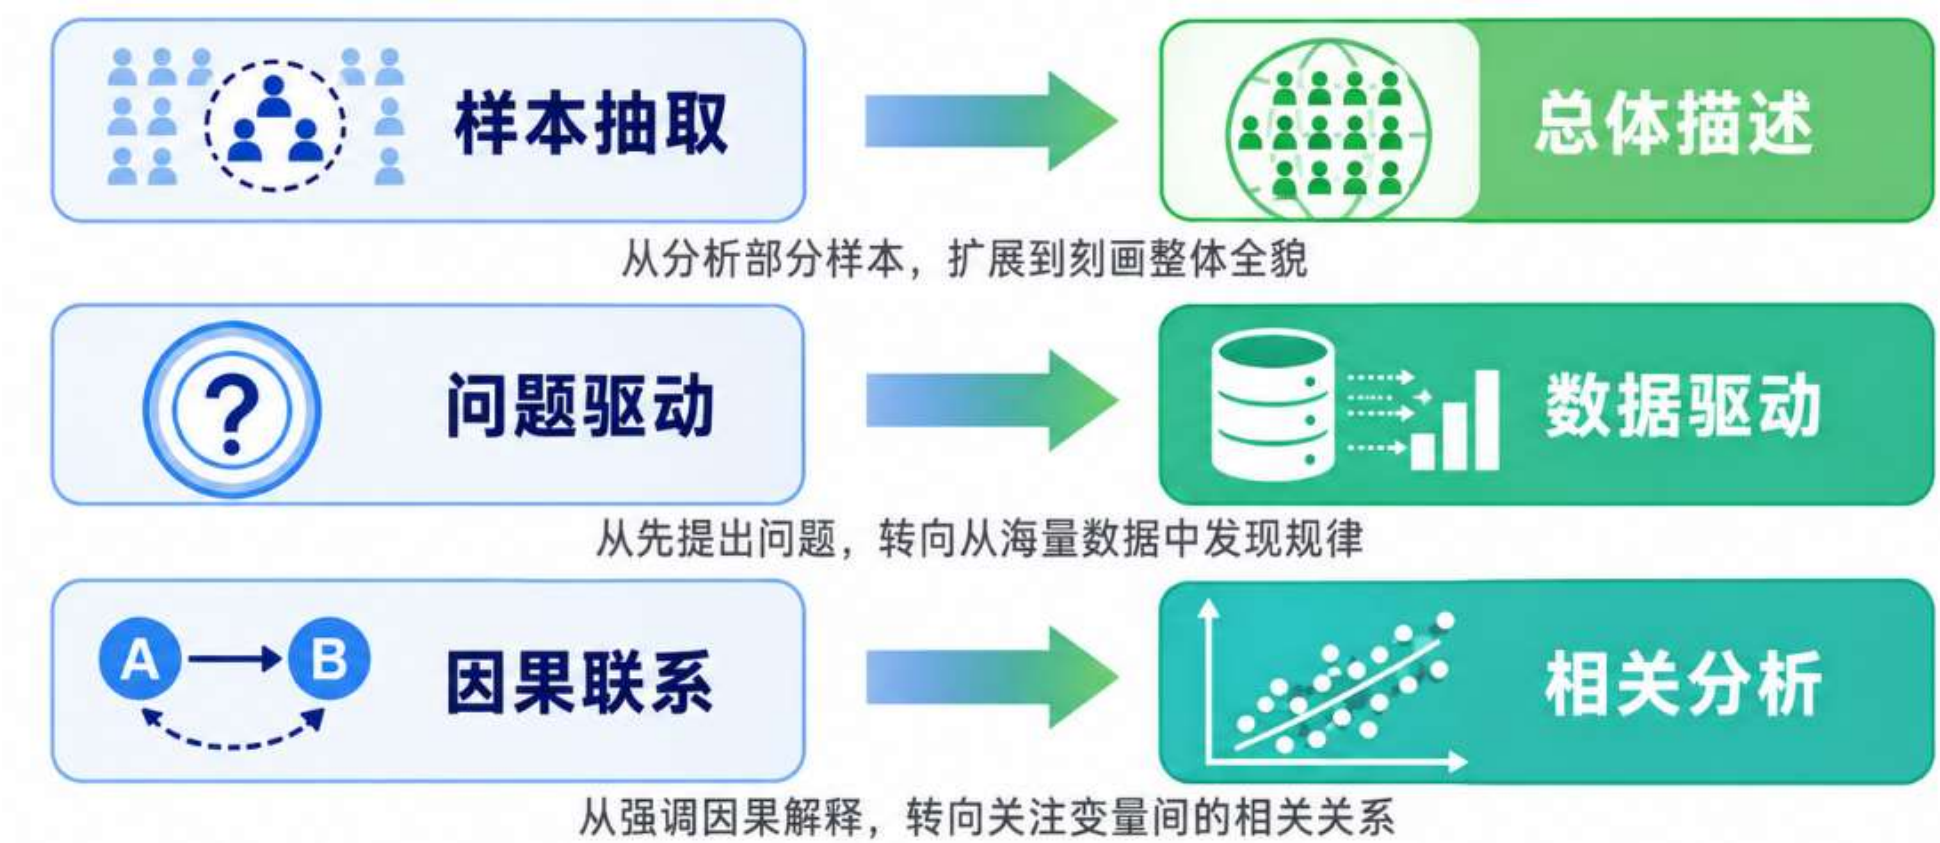


对“大”数据的定义取决于持有数据的机构之能力，以及其处理分析数据的软件的能力

抽样统计：从整体中选择子集进行分析和推理，从局部估计整体



大数据催生统计创新：与传统统计学方法不同，大数据更关注对所发生事情的观察和追踪



神奇的大数据——TED演讲

如果你要演讲，你要用什么字句当做演讲的标题?

- 著名科学家伍尼奇(**Sebastian Wernicke**)通过**对TED演讲的大数据统计分析**后得到的一些有趣的发现：





如果你的演讲标题字眼有“氧气、女孩、飞机、建筑、材料、男人”这些字眼，大数据统计告诉你，十之八九曲高和寡



简单又深入，像是快乐、我们的身体、食物和情绪等主题，最容易引起共鸣

发表演说的人，头发留得比一般人长一些、戴眼镜、穿得正式一点、用PPT等影视辅助，会让演讲比较受欢迎

“如果你用《法国咖啡如何在我们的大脑里传播快乐》这个题目演讲，保证一定受欢迎。”

被评为引人入胜的演讲，主色调都采用这种蓝色



如果你想被认为机智，那么建议你采用绿色





神奇的大数据——Netflix《纸牌屋》的成功

你以为《纸牌屋》的叫好叫座，是因为神创意和神编剧？不，是大数据



Kevin Spacey



David Fincher



英国同名小说《纸牌屋》



大数据分析



风靡全球的美剧《纸牌屋》

《纸牌屋》的诞生是**从3000万付费用户的数据中总结收视习惯，并根据对用户喜好的精准分析进行创作。**

√ *《纸牌屋》的数据库包含了**3000万用户的收视选择、400万条评论、300万次主题搜索。***

√ ***如何成片，演员和导演怎么选，在哪个时间段进行播出，都由广大受众的客观喜好统计决定。***

神奇的大数据——Netflix《纸牌屋》的成功

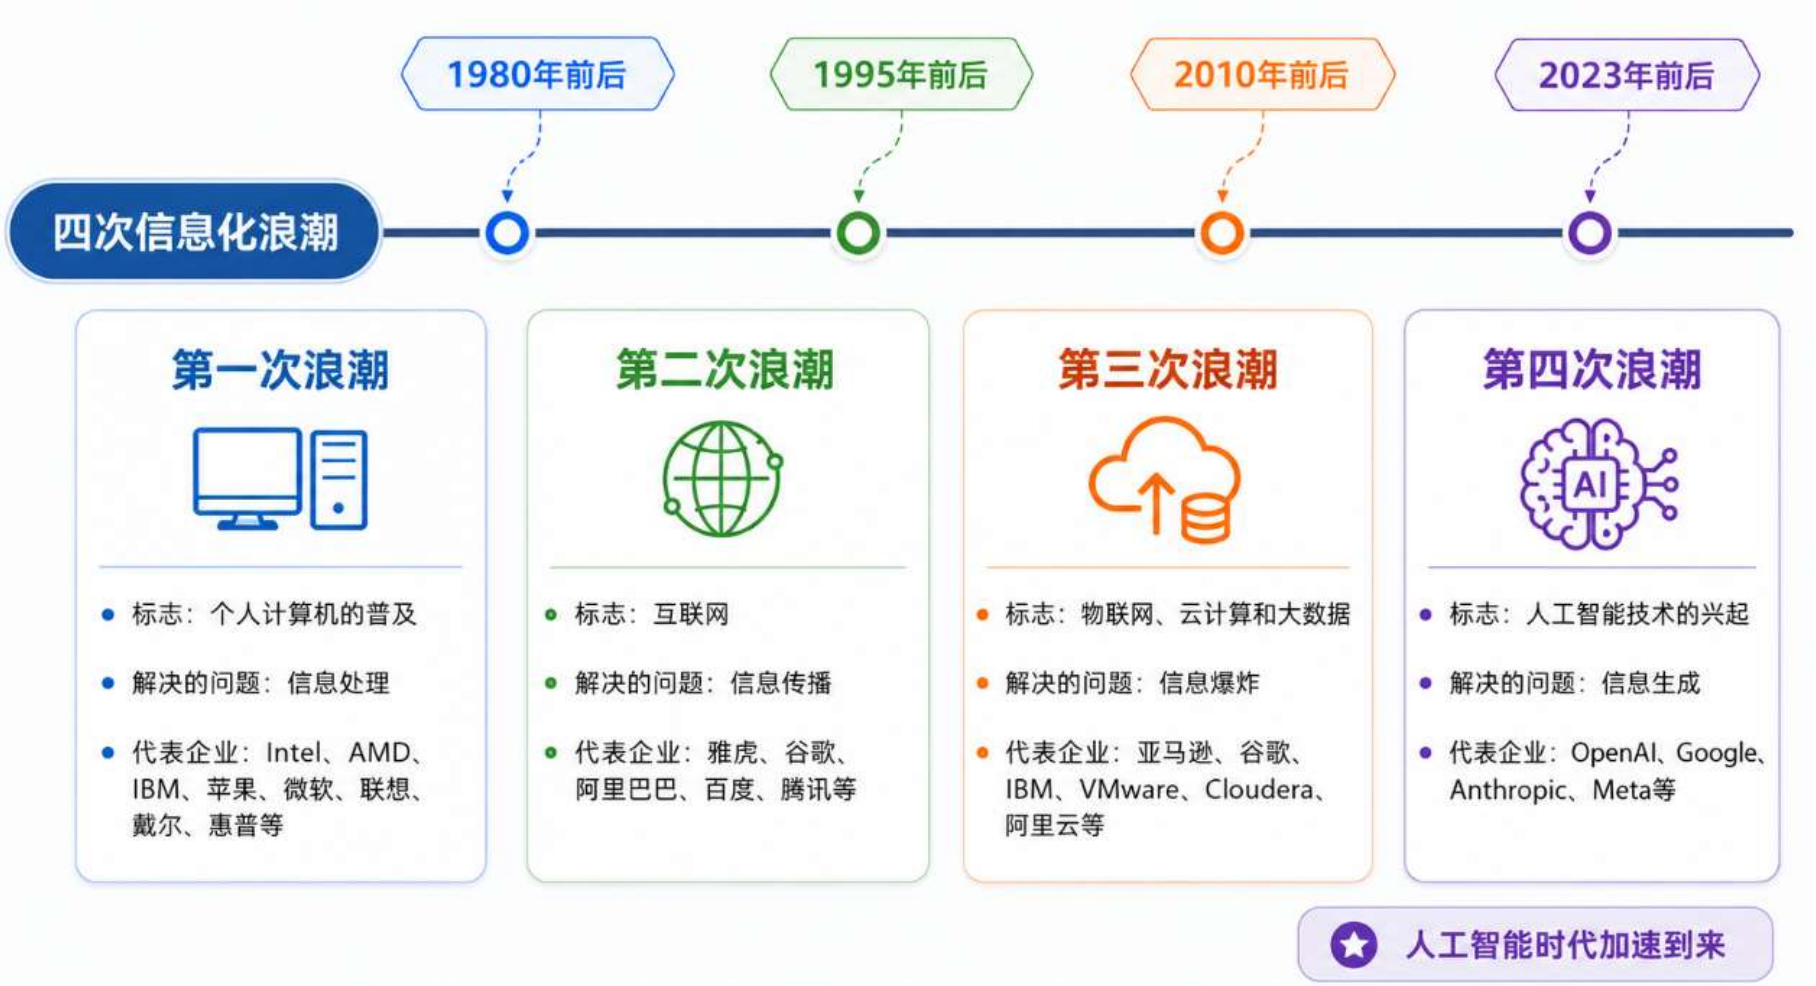
- **如果我们更深入地去分析《纸牌屋》的成功会发现：**
  - Netflix的成功，是因为他们不但在过程中使用了“大数据”，**更重要的是，他们使用了“大脑”**
  - Netflix从2000年就开始研发自己的推荐系统，2007年-2008年更是举办了推荐系统比赛



- **Amazon效仿Netflix拍摄的《阿尔法屋》并不成功**



IT领域每隔十五年就会迎来一次重大变革（郭士纳， IBM前CEO）



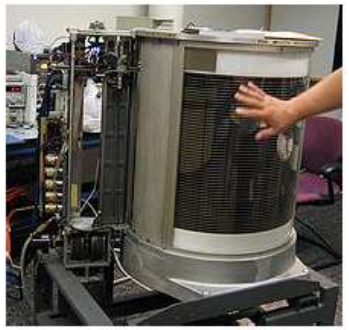




大数据的发展历程

信息科技为大数据时代提供技术支撑

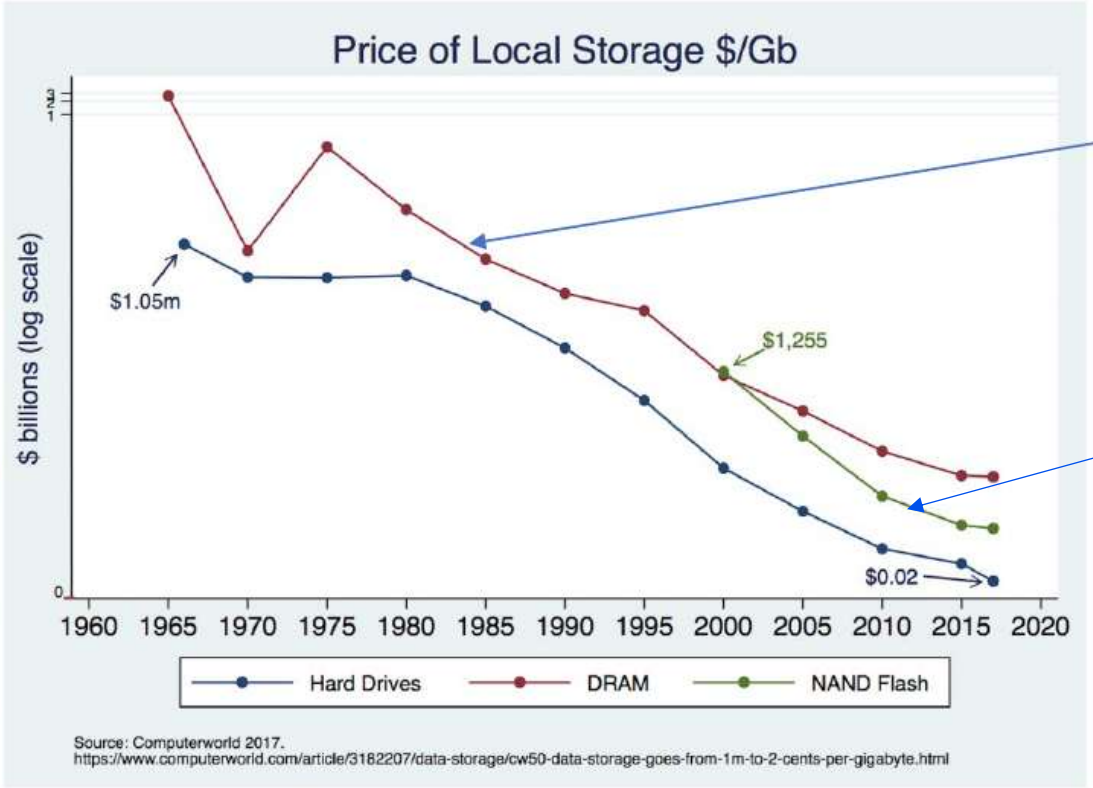
- 存储设备容量不断增加、单位价格不断下降



3.7M硬盘IBM



1kb内存IBM



640K is more memory than anyone will ever need on a computer.
Bill Gates?





来自斯威本科技大学的研究团队在**2013**年**6**月**29**日刊出的《自然通讯》杂志的文章中，描述了一种全新的数据存储方式，可将**1PB**（**1024TB**）的数据存储到一张仅**DVD**大小的聚合物碟片上。

大数据的发展历程

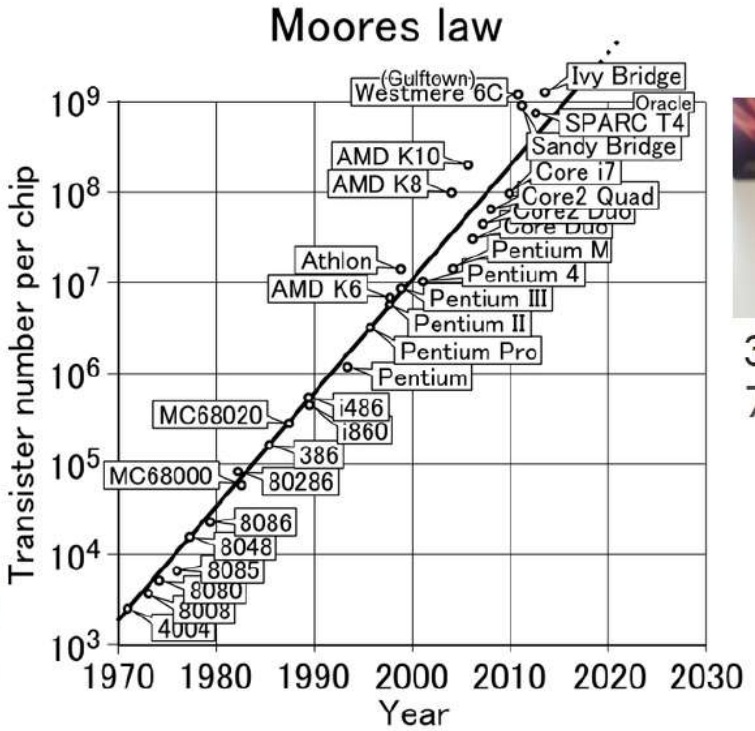
信息科技为大数据时代提供技术支撑

- **CPU处理能力**大幅提升，**网络带宽**不断增加

摩尔定律：由英特尔创始人之一戈登·摩尔提出的。其内容为：集成电路上可容纳的晶体管数目，约每隔两年便会增加一倍；而经常被引用的"18个月"，则是由英特尔首席执行官大卫·豪斯提出：预计18个月会将芯片的性能提高一倍，是一种以倍数增长的观测。——维基百科



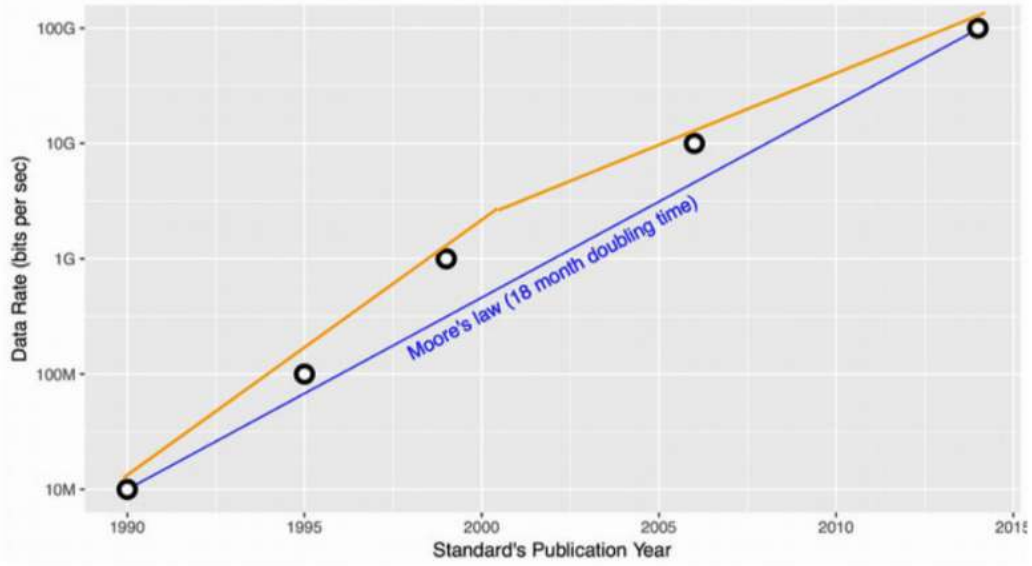
2,300 晶体管,
60,000 OPS,
1971



CPU晶体管数目随时间变化情况

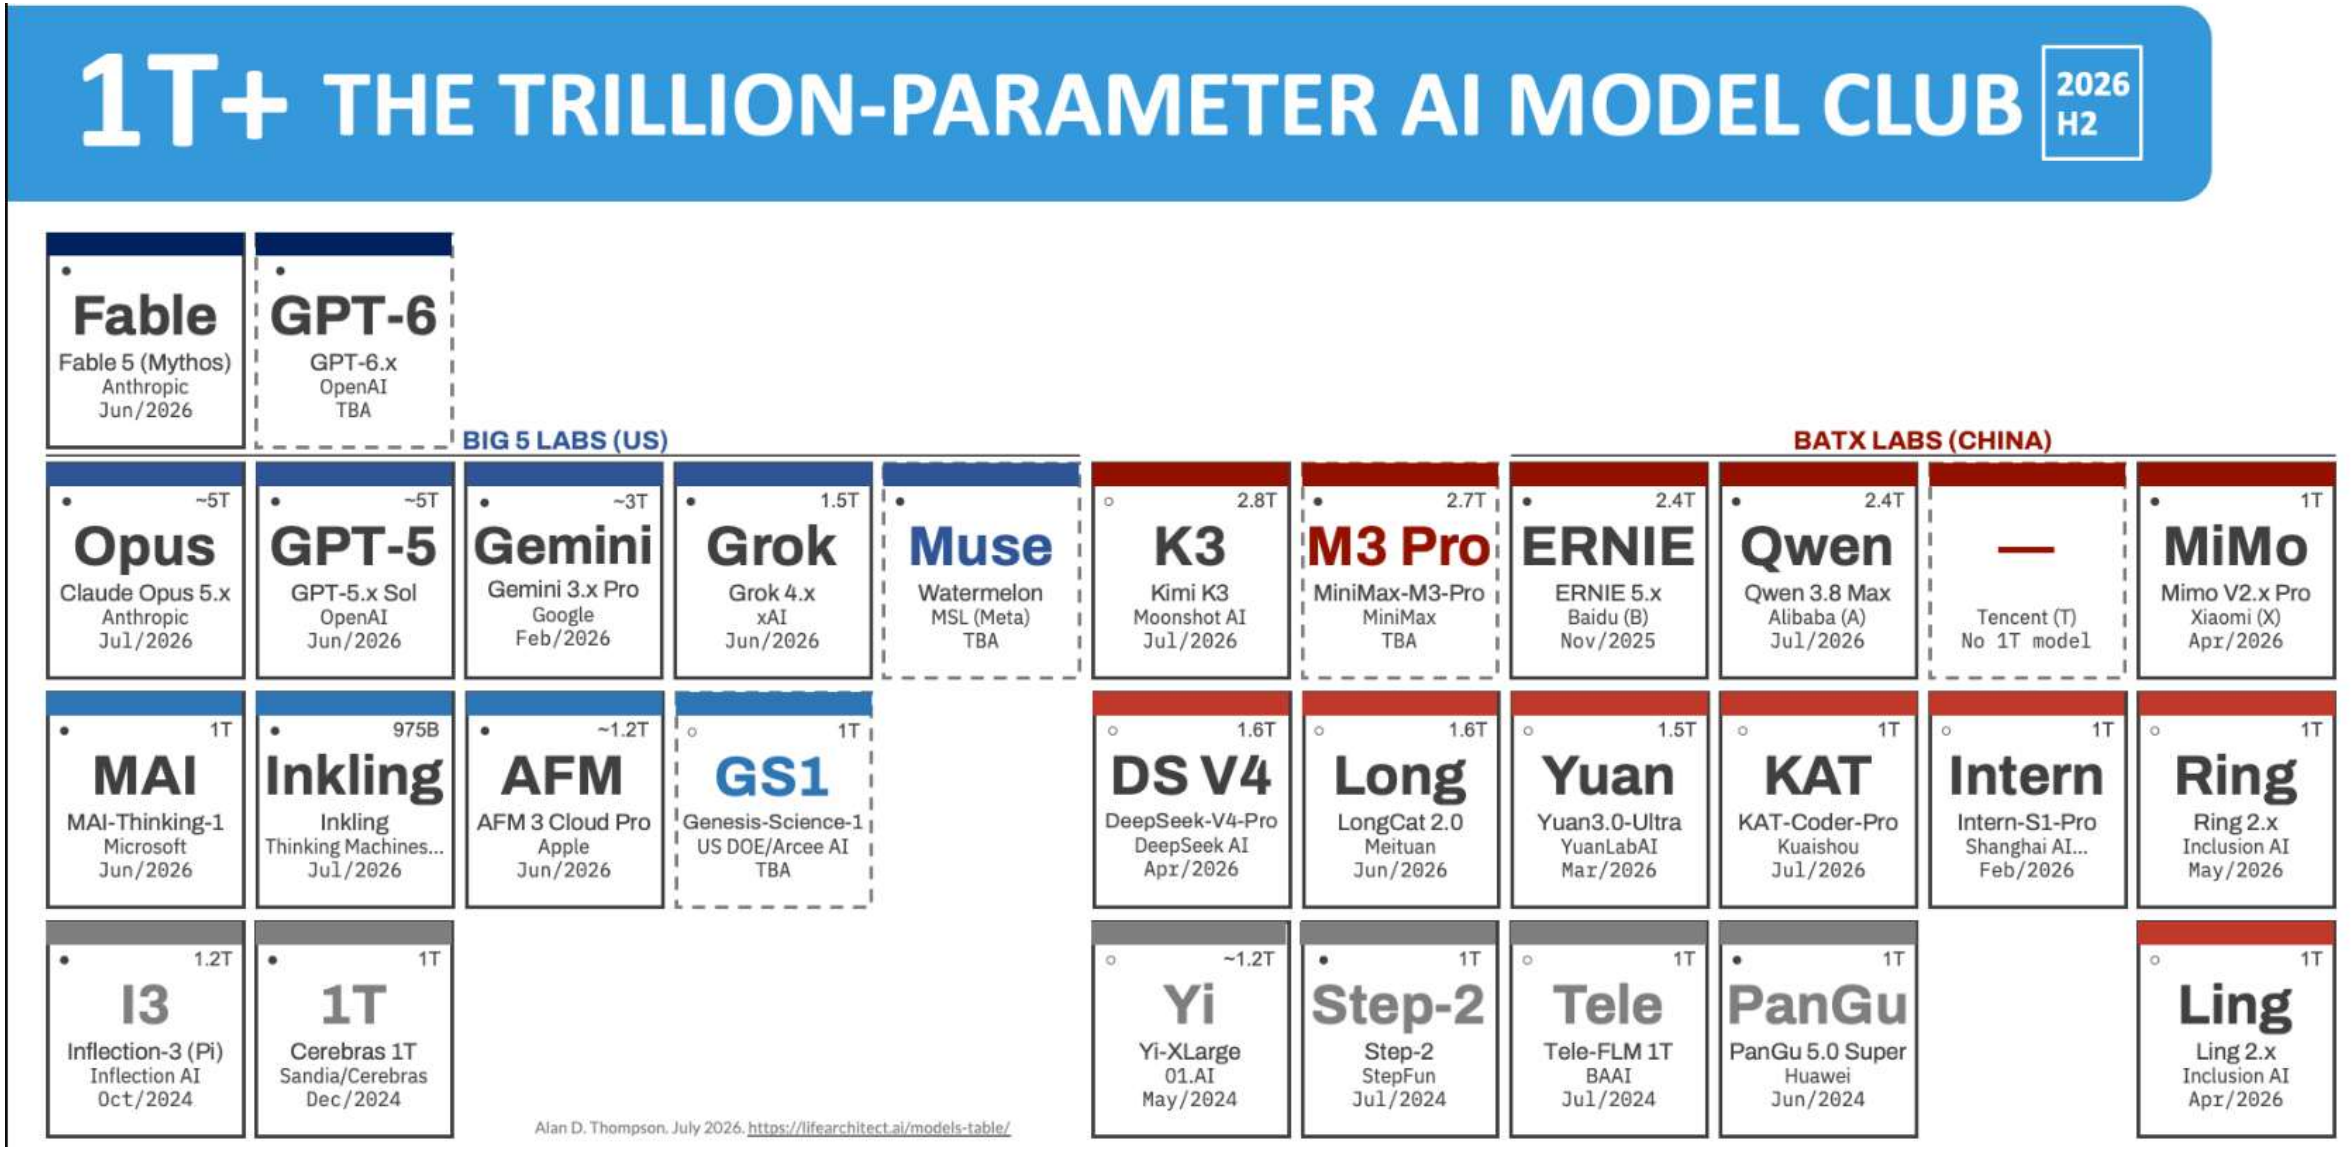


395亿 晶体管,
7nm, 3GHz, 2019

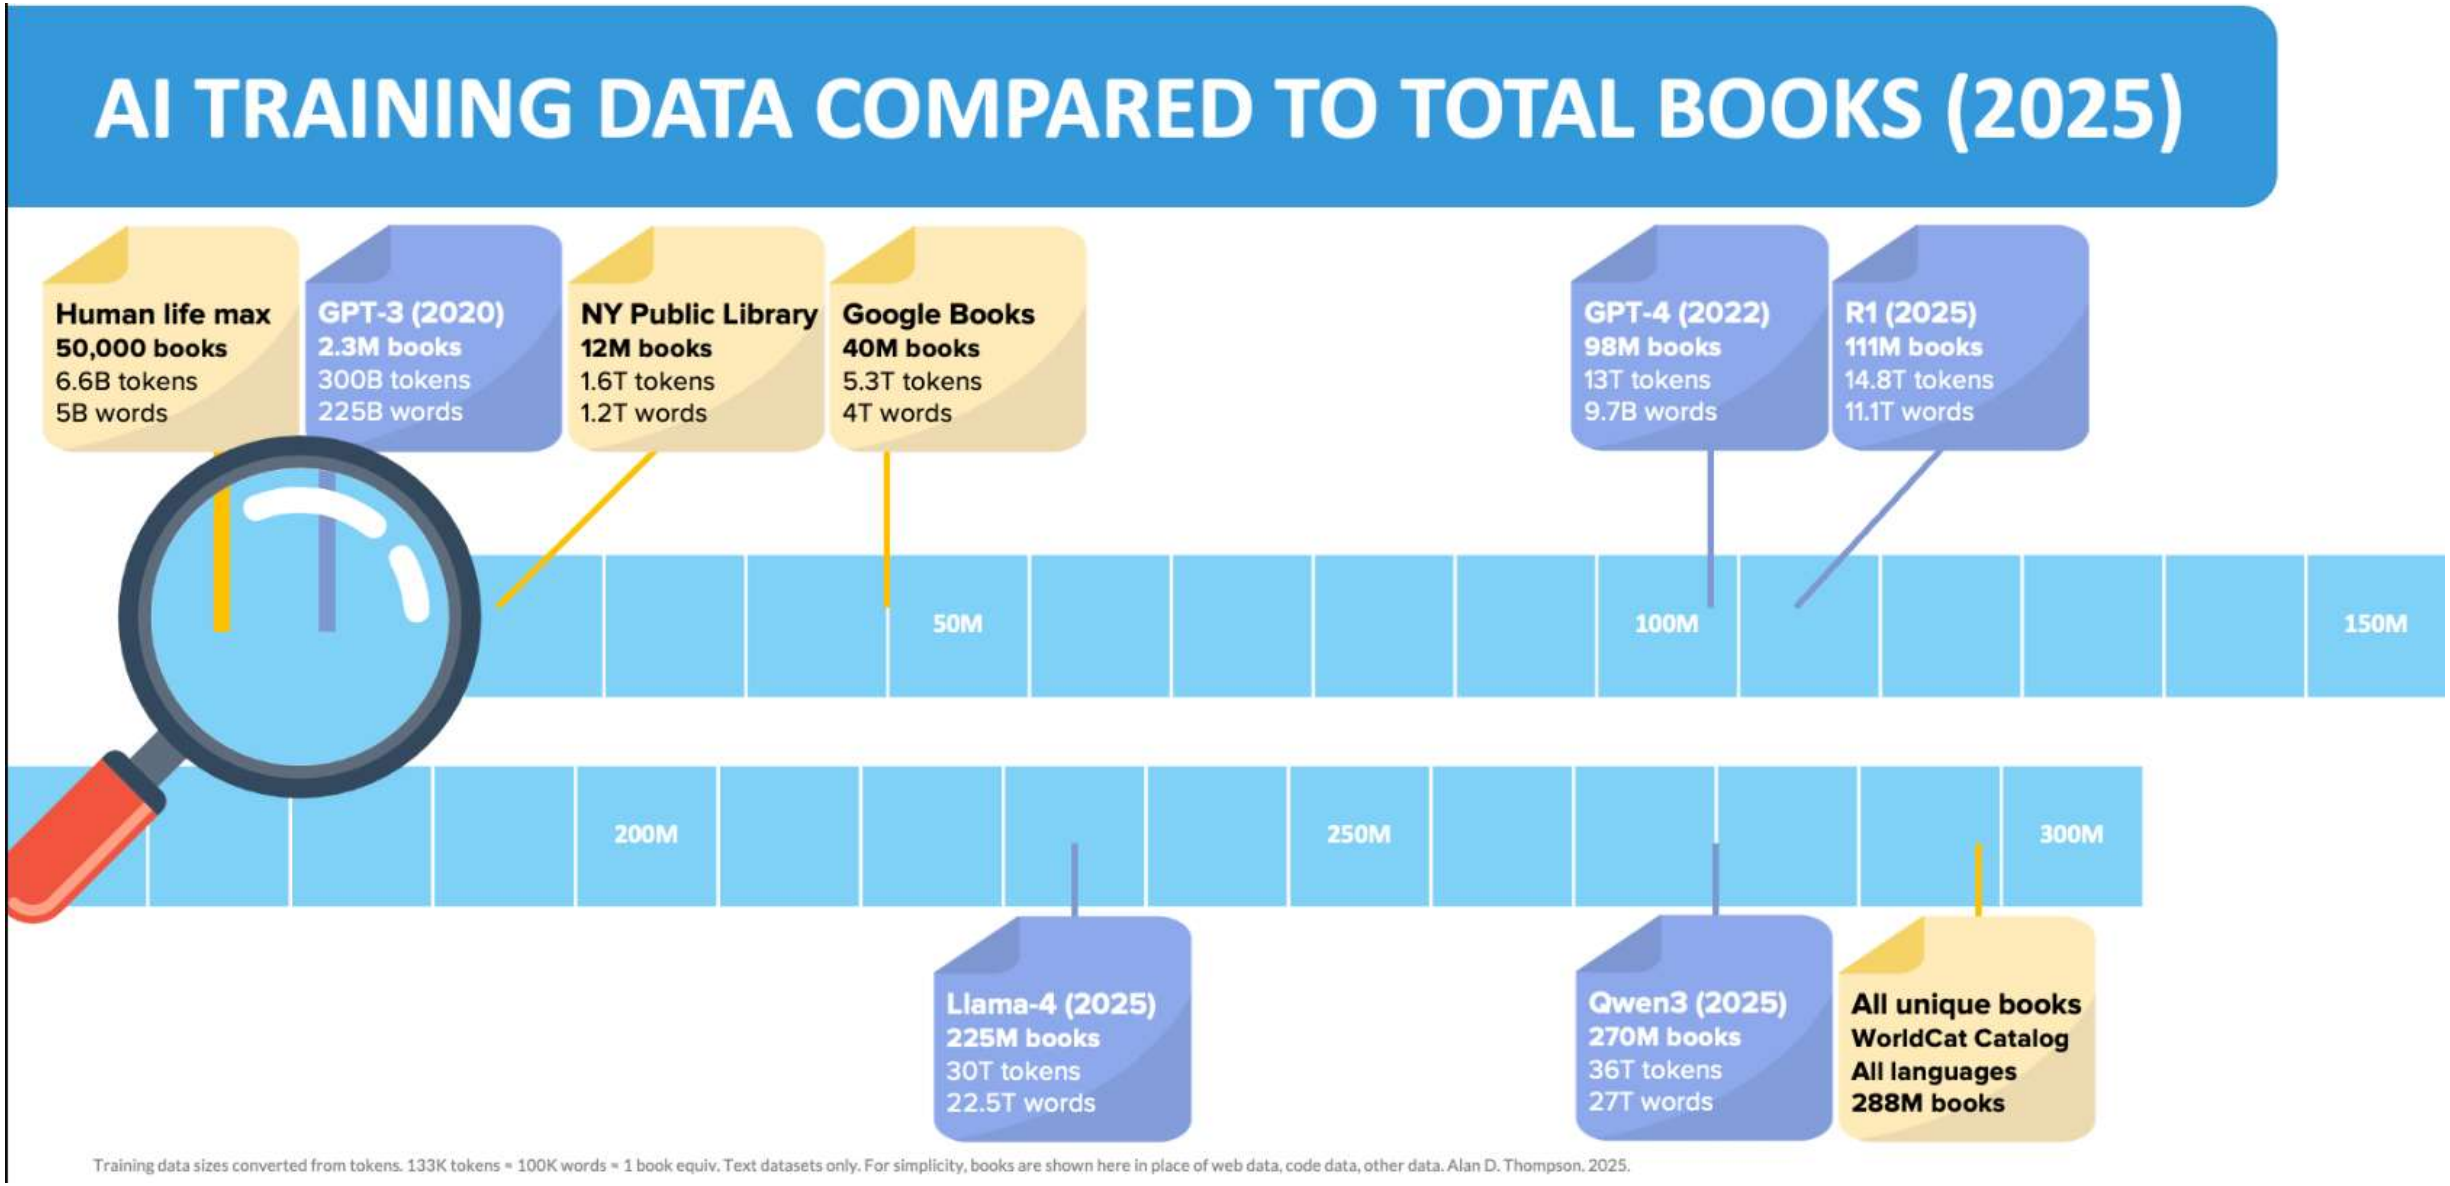


真实以太网演进速率与摩尔定律理论速率

AI时代的模型和训练数据规模

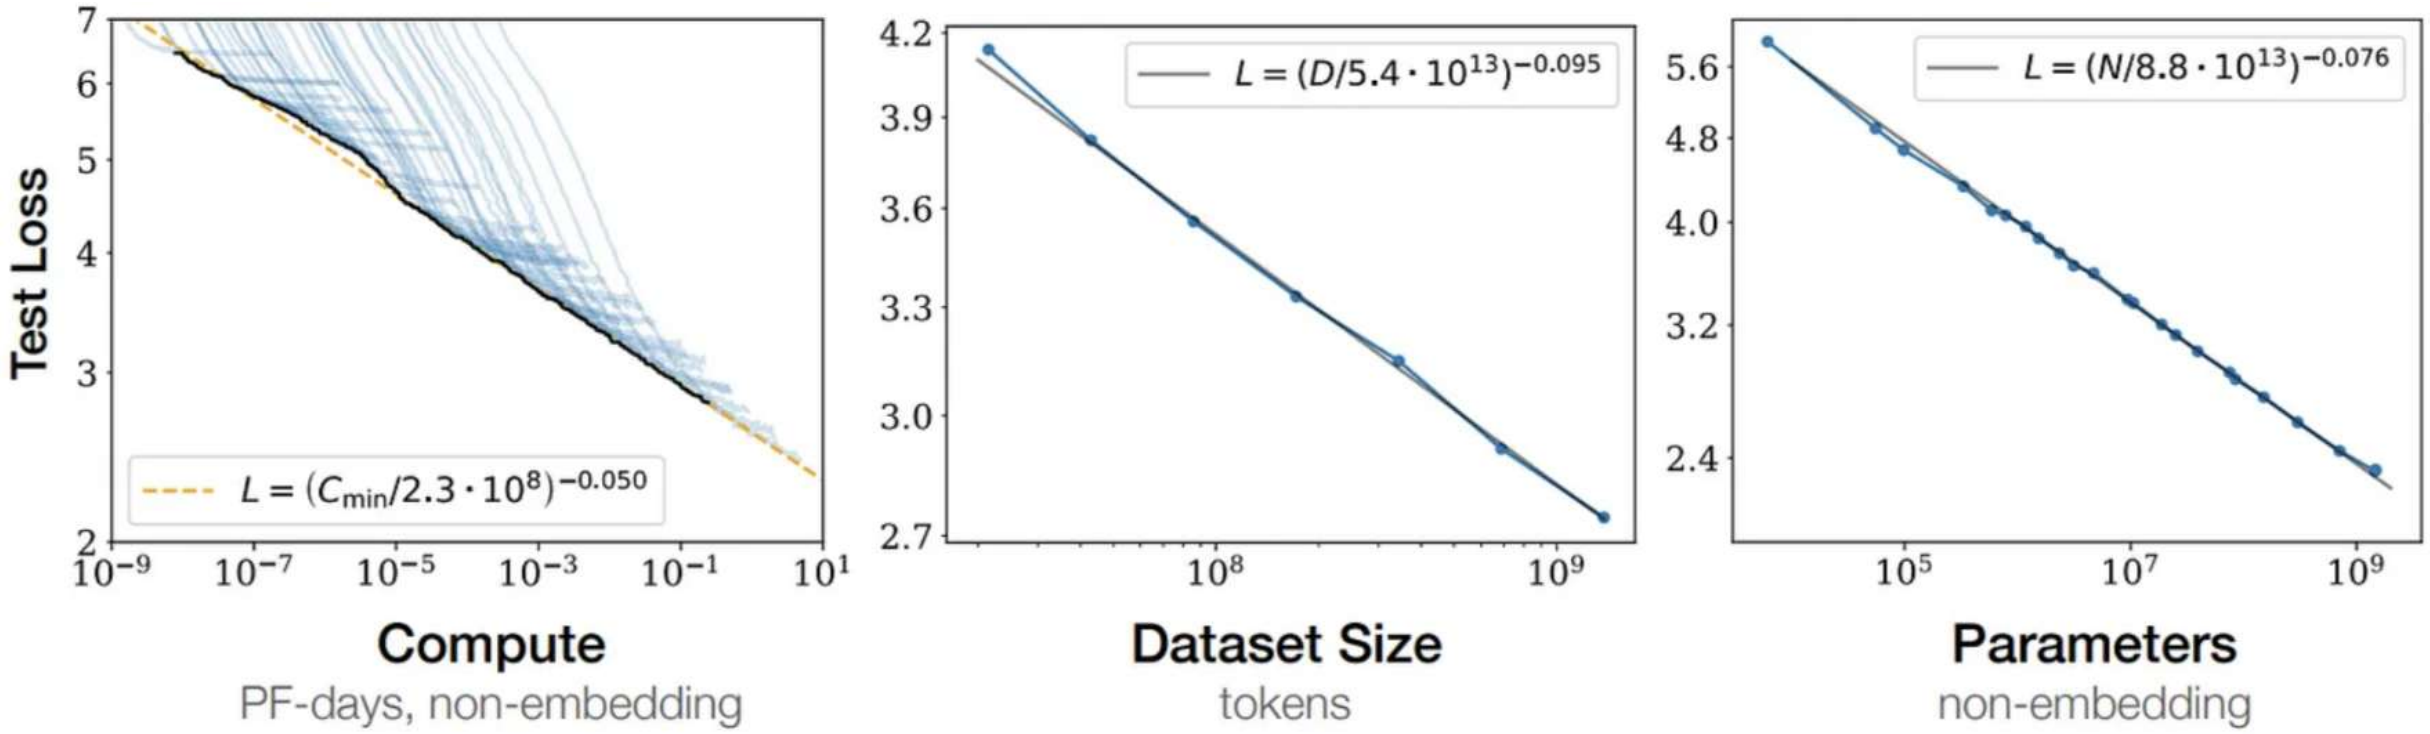


AI时代的模型和训练数据规模



AI时代的模型和训练数据规模

大模型和Scaling Laws

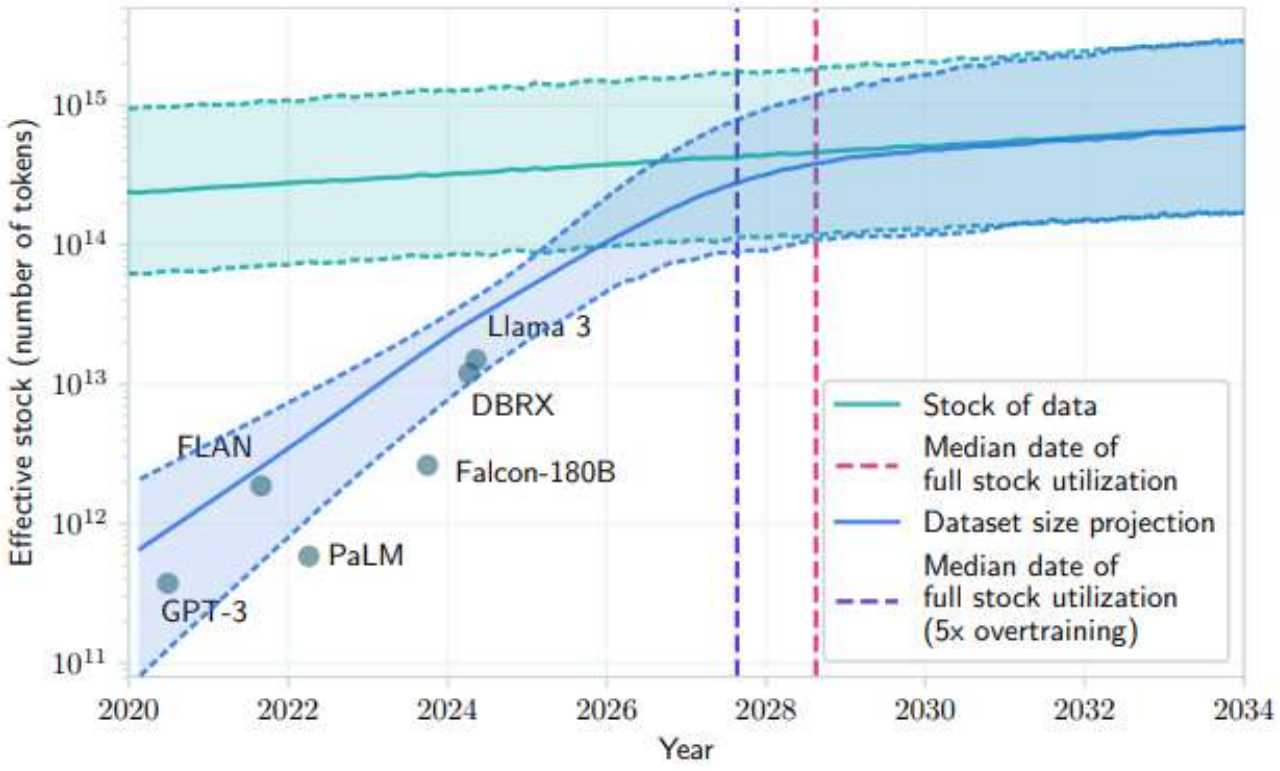


PF-days: OpenAI定义神经网络中的一次乘法或者一次加法为一个操作，1 peta flops (1PF) 等于每秒10的15次方运算，一天（1 PF-day）的计算量为10的20次方。ChatGPT的训练总消耗为3640 PF-days。

模型的性能与计算量、数据集和参数量之间都呈现幂律关系。
数据量应该要约等于模型参数量的20倍，并且数据量要和模型参数量同比放大。

大数据的发展历程

- 大模型时代，模型和数据哪个重要?
- 2026年，高质量训练数据可能会用光

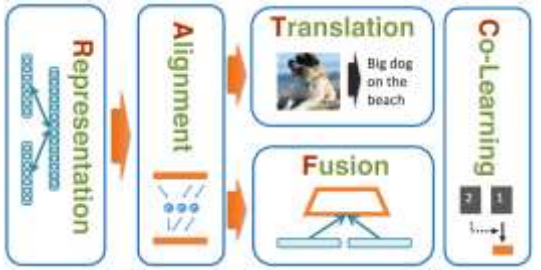


公开的训练数据没有了怎么办?

（1）合成数据



（2）跨模态和跨领域数据学习

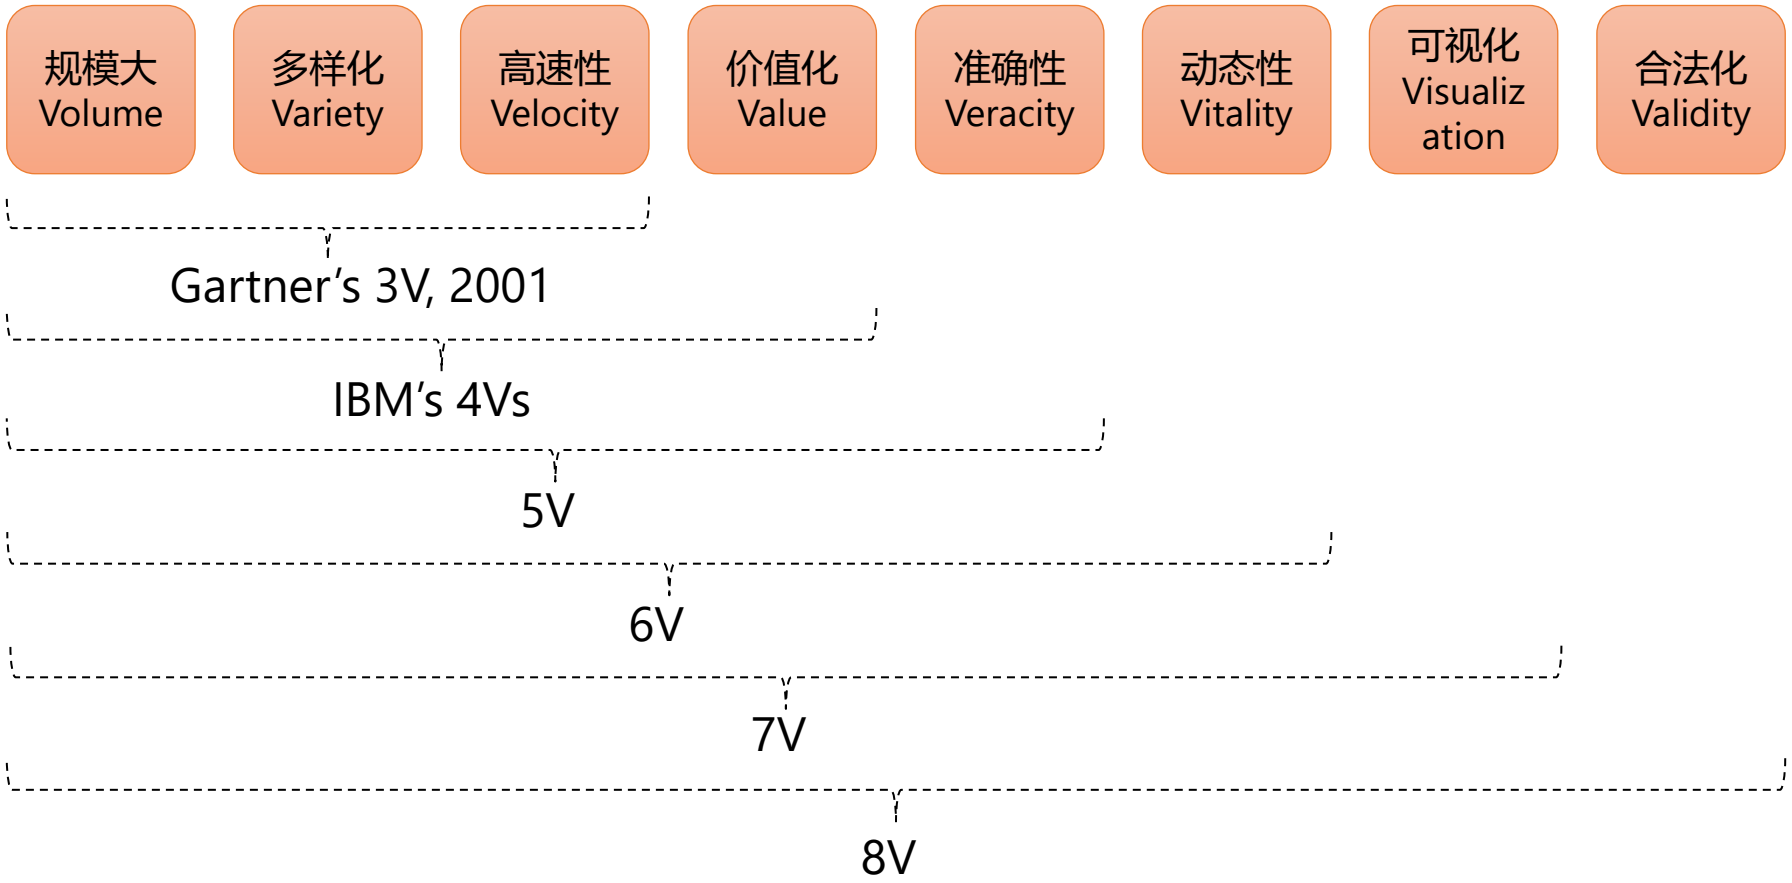


（3）私有数据：占数据总量的90%

（4）与真实世界实时交互学习：通过模型主动地探索环境，与人类交互来获得知识和技能

大数据的特点

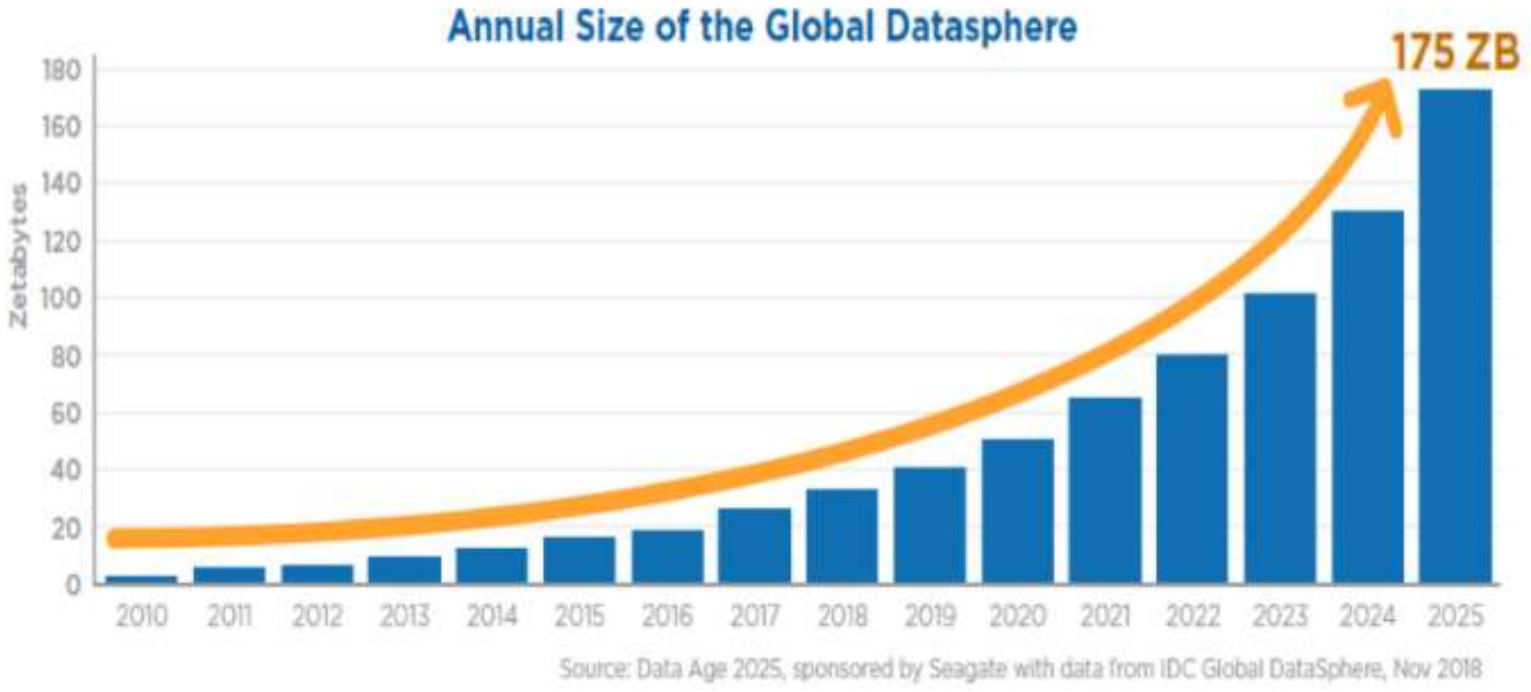
大数据不仅仅是数据的“大量化”，还包括其他特性



大数据的特点

Volume：规模大

- 自2010年以来，数据每年都在保持增长，而人类在最近两年产生的数据量相当于之前产生的全部数据量

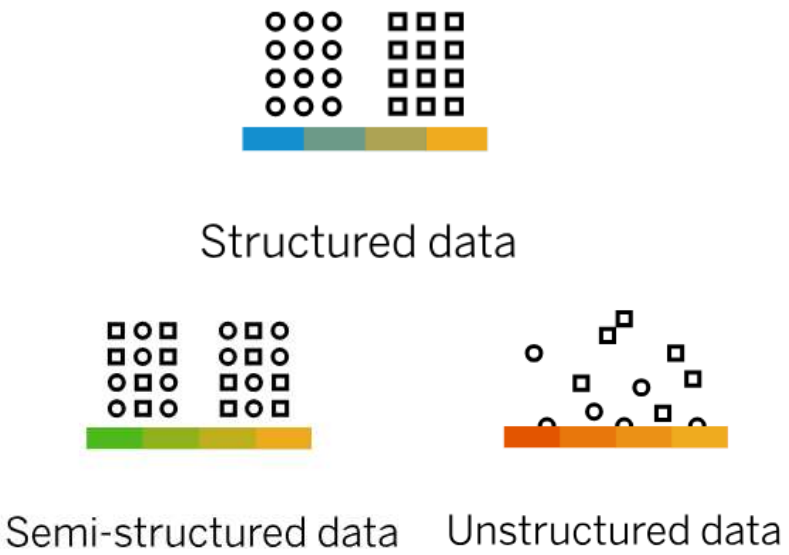


Units of Computer Memory Measurements		
1 Bit	=	Binary Digit
8 Bit	=	1 Byte
1024 Bytes	=	1 KB (Kilo Byte)
1024 KB	=	1 MB (Mega Byte)
1024 MB	=	1 GB (Giga Byte)
1024 GB	=	1 TB (Terra Byte)
1024 TB	=	1 PB (Peta Byte)
1024 PB	=	1 EB (Exa Byte)
1024 EB	=	1 ZB (Zetta Byte)
1024 ZB	=	1 YB (Yotta Byte)
1024 YB	=	1(Bronto Byte)
1024 Brontobyte	=	1 (Geop Byte)

Geop Byte is The Highest Memory

Variety：多样化

- 结构化：数据库中的数据，约10%
- 非结构化：没有特定的结构，约80%
- 半结构化：类似JSON/XML的文档描述，存储在文件或文档型数据库中





大数据的特点

Velocity：高速性

- 从数据的生成到消耗，时间窗口非常小，可用于生成决策的时间非常少
- **1秒定律**：在视频网站或者手机APP被打开的瞬间，从获取历史数据、用户喜好挖掘、个性化广告匹配并竞价、到最后的广告内容弹出，都是在秒级的时间内处理和分发出去

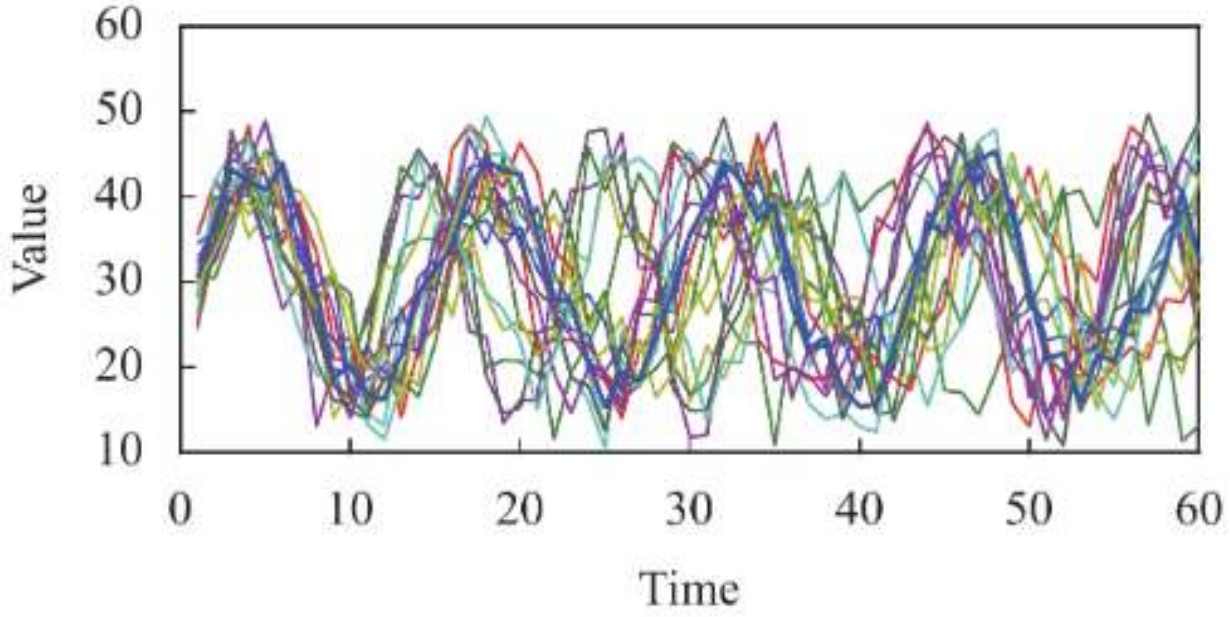


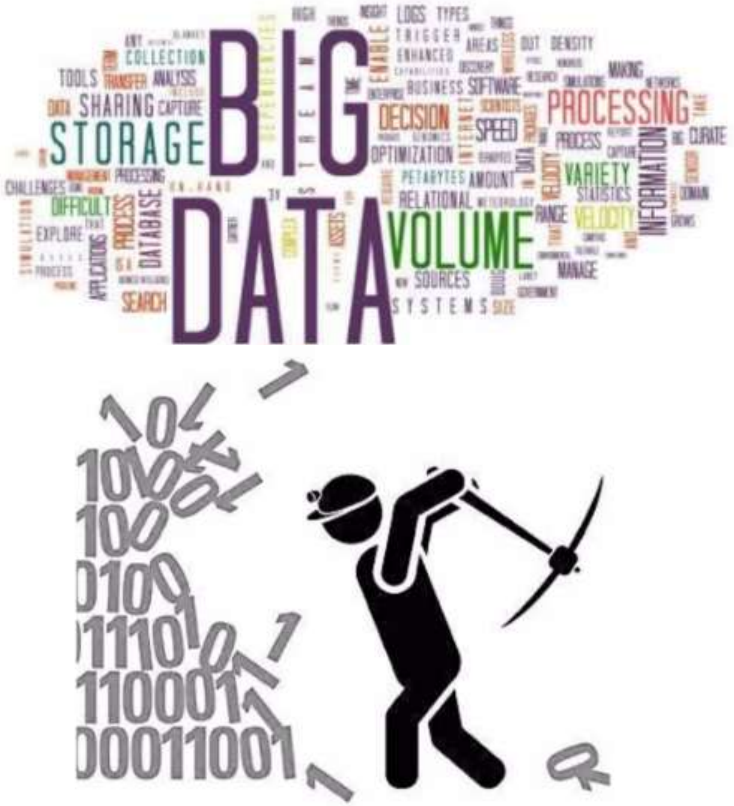




Value：价值化

- 大数据的商业价值高，但高价值往往集中在很少的数据中——**大数据价值密度低**





大数据的特点

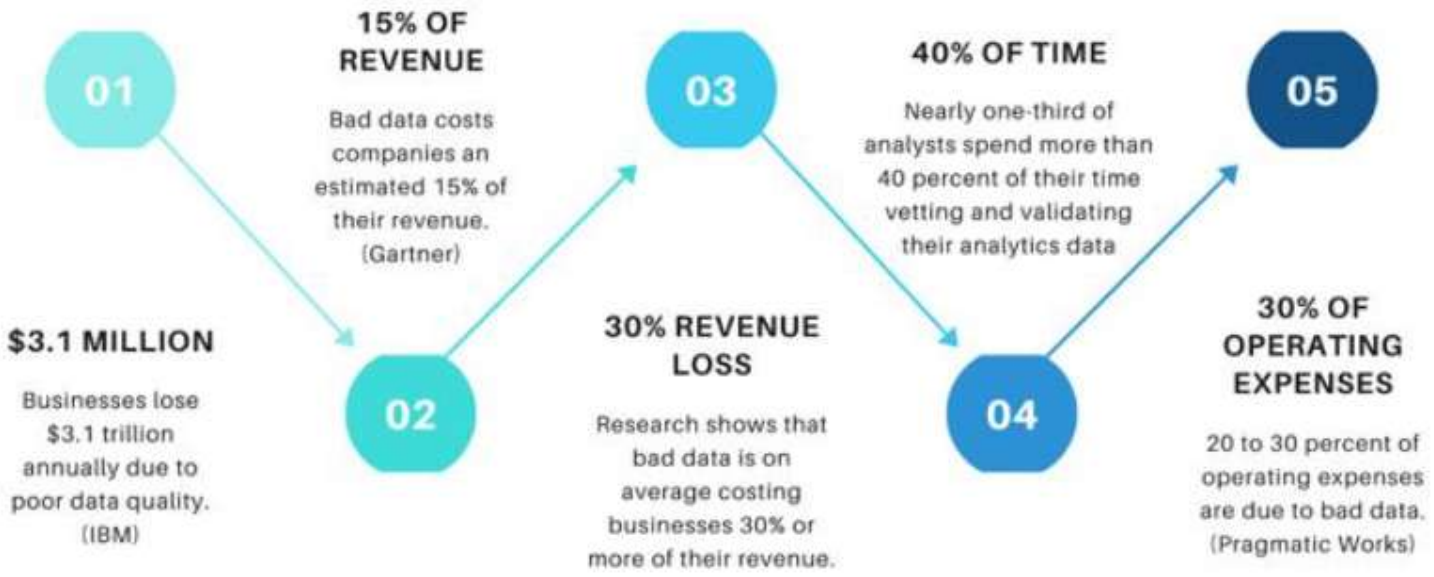
Veracity：准确性

- 数据准确性是指可以作为可靠信息来源的无错误记录

下面是一个例子：
在美国数据库中，日期遵循 MM/DD/YYYY 格式，而在欧盟数据库和世界其他国家/地区中，日期格式为 DD/MM/YYYY。如果将11/10/2020 转换为内容，你认为两者中哪一个是准确的?

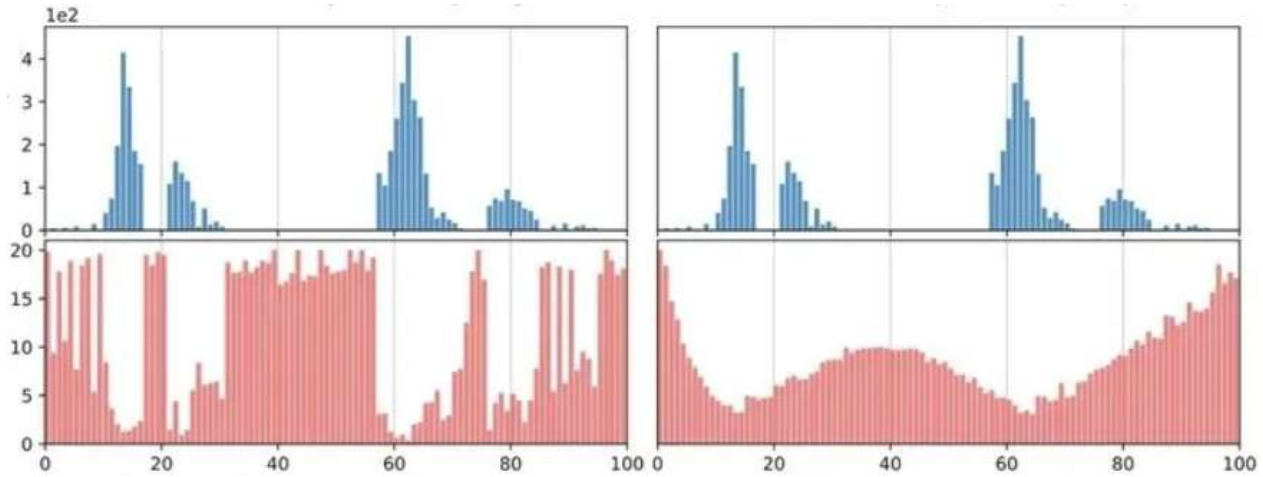
11月10日还是10月11日？这是威胁数据准确性的经典意义与形式问题。而这通常是由于缺乏数据标准化和规则而发生的。

- 错误数据会给我们决策带来巨大的影响



- 不良数据使公司损失了大约 15% 的收入。(Gartner)
- 数据质量不佳对组织造成的平均财务影响为每年 970 万美元。（Gartner)
- 仅在美国，由于数据质量差，企业每年损失 3.1 万亿美元。(IBM)
- 知识工作者将 50% 的时间浪费在隐藏的数据工厂中，寻找数据、查找和纠正错误，以及为他们不信任的数据搜索确认来源。(哈佛商业评论)

Vitality：动态性



数据的分布不均匀，
数据质量存在波动

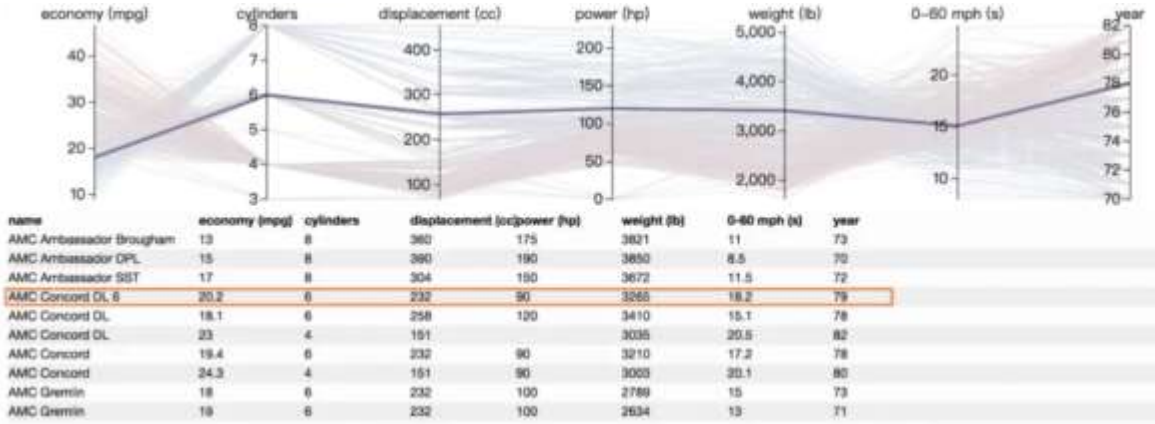
数据的状态不断在变化，容易受环境影响



Visualization：可视化

- 利用图形化、图像化的方式呈现大数据，以更直观、易理解的方式展示数据的模式、趋势和关系。可视化在大数据分析中起到重要作用





name	economy (mpg)	cylinders	displacement (cc)	power (hp)	weight (lb)	0-60 mph (s)	year
AMC Ambassador Brougham	13	8	360	175	3821	11	73
AMC Ambassador DPL	15	8	390	190	3850	8.5	70
AMC Ambassador SST	17	8	304	150	3672	11.5	72
AMC Concord DL 6	20.2	6	232	90	3265	18.2	79
AMC Concord DL	18.1	6	258	120	3410	15.1	78
AMC Concord DL	23	4	151		3035	20.5	82
AMC Concord	19.4	6	232	90	3210	17.2	78
AMC Concord	24.3	4	151	90	3003	20.1	80
AMC Gremlin	18	6	232	100	2789	15	73
AMC Gremlin	19	6	232	100	2634	13	71

大数据的特点

Validity：合法化

- 强调数据采集和应用的合法性，特别是对于个人隐私数据的合理使用





大数据的影响

- 在思维方式方面，大数据完全颠覆了传统的思维方式

01 总体性思维

02 容错性思维



03 关联性思维

04 智能化思维

大数据的影响

总体性思维

以往的采样方法一直是主要数据获取手段，这是人类在无法获得总体数据信息条件下的无奈选择。

在大数据时代，人们可以获得与分析更多的数据，甚至是与之相关的所有数据，而不再依赖于采样。

因此可以带来更全面的认识，可以更清楚地发现样本无法揭示的细节信息。

大数据简单算法比小数据的复杂算法更有效

谷歌的翻译之所以好并不是因为它拥有一个更好的算法机制，而是在翻译的过程中增加了很多数据，并接受有错误的数据。

容错性思维

以往样本信息量比较少，所以必须确保记录下来的数据尽量结构化、精确化。

在大数据时代，海量的数据能够得到存储、处理、计算和分析。

当拥有海量即时数据时，绝对的精准不再是追求的主要目标，适当忽略微观层面上的精确度，容许一定程度的错误与混杂，反而可以在宏观层面拥有更好的知识和洞察力。

允许不精确性：2+2=3.9

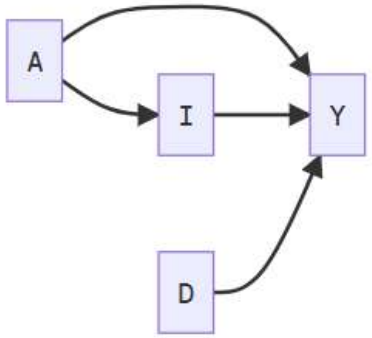
只有10%的数据是结构化的，适用于传统的数据库，只有接受不精确性，剩下的90%数据才可以利用。

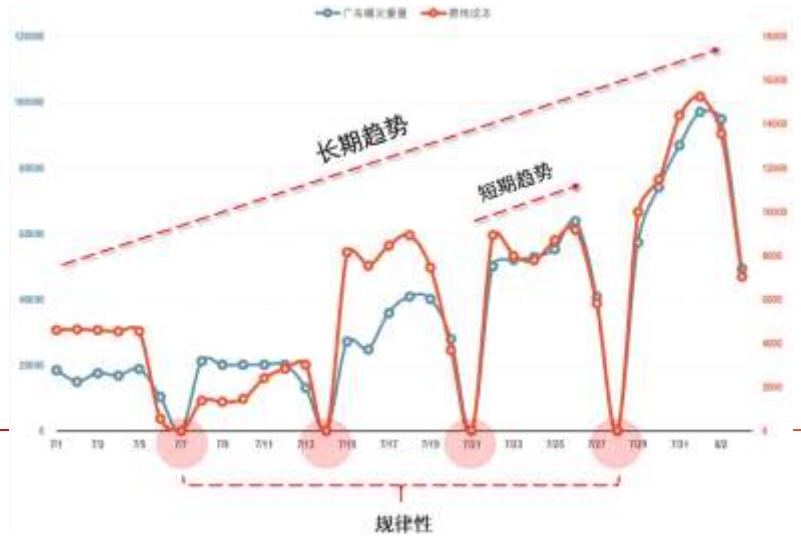
关联性思维

大数据未出现时，人们往往执着于现象背后的因果关系，试图通过有限样本数据来剖析其中的内在关联关系。缺陷：有限的样本数据无法反映出事物之间的普遍性的关联关系。

大数据时代，人们可以通过大数据挖掘技术挖掘与分析出事物之间隐蔽的关联关系，获得更多的认知与洞见，运用这些认知与洞见就可以帮助我们捕捉现在和预测未来。

通过发现线性的和复杂非线性的关联关系，可以看到很多以前不曾注意的数据之间存在的某些联系，关联性关系甚至可以超越因果关系，成为了解这个世界的更好视角。





智能化思维

- 通过机器学习可以从数据中获取有价值的信息，大数据将有效的推进机器思维方式由自然思维转向智能化思维，这是大数据思维转变的关键所在与核心内容



迪斯尼公司最近投资了10亿美元开发出MagicBand手环，进行线下顾客跟踪和数据采集

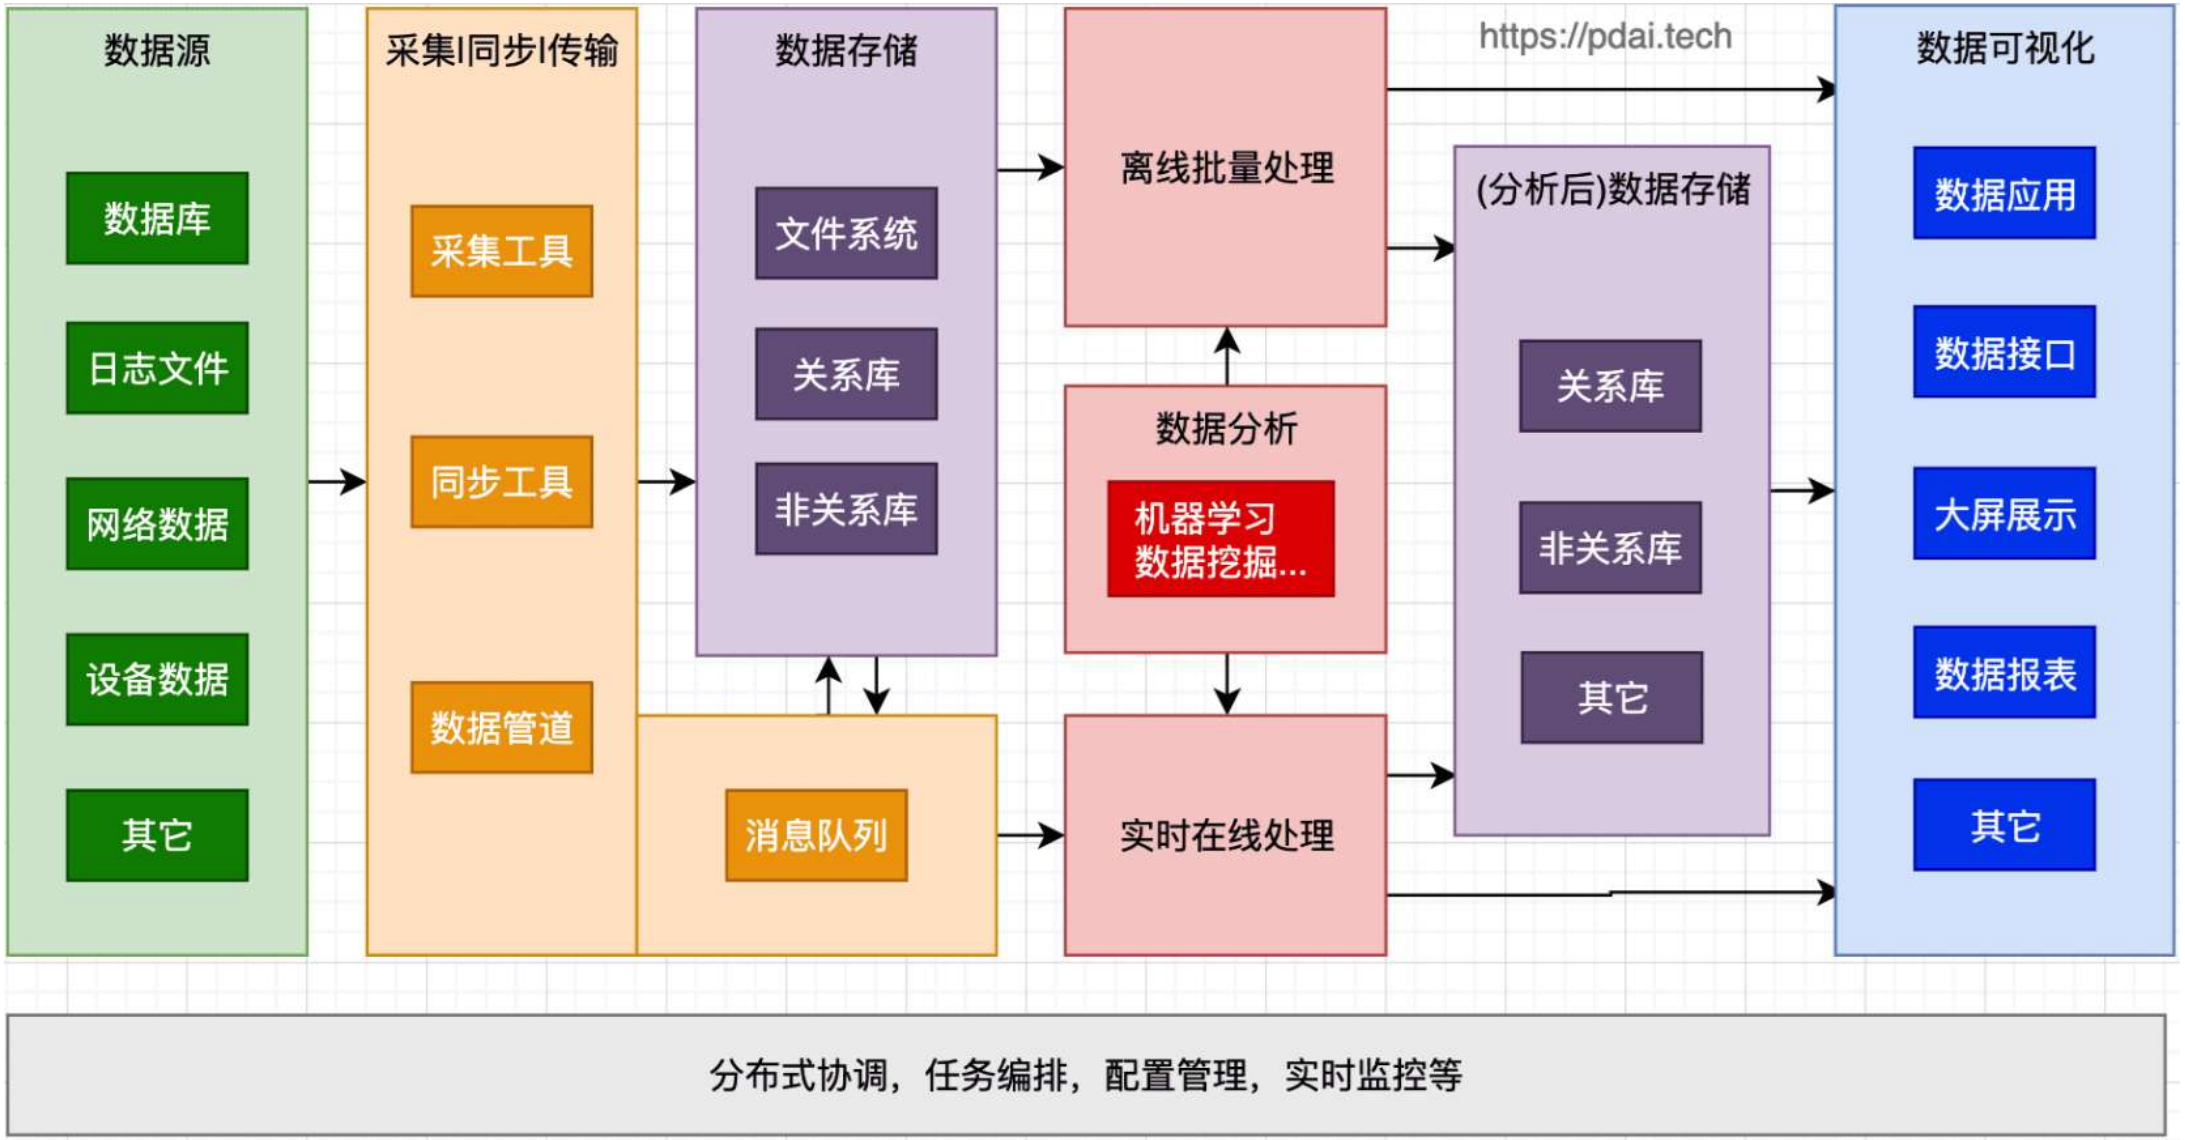


从配送外卖中采集了大量数据，而通过对数据的分析，可以得出哪家餐馆的什么外卖比较受欢迎，最快捷的路径是那一条等



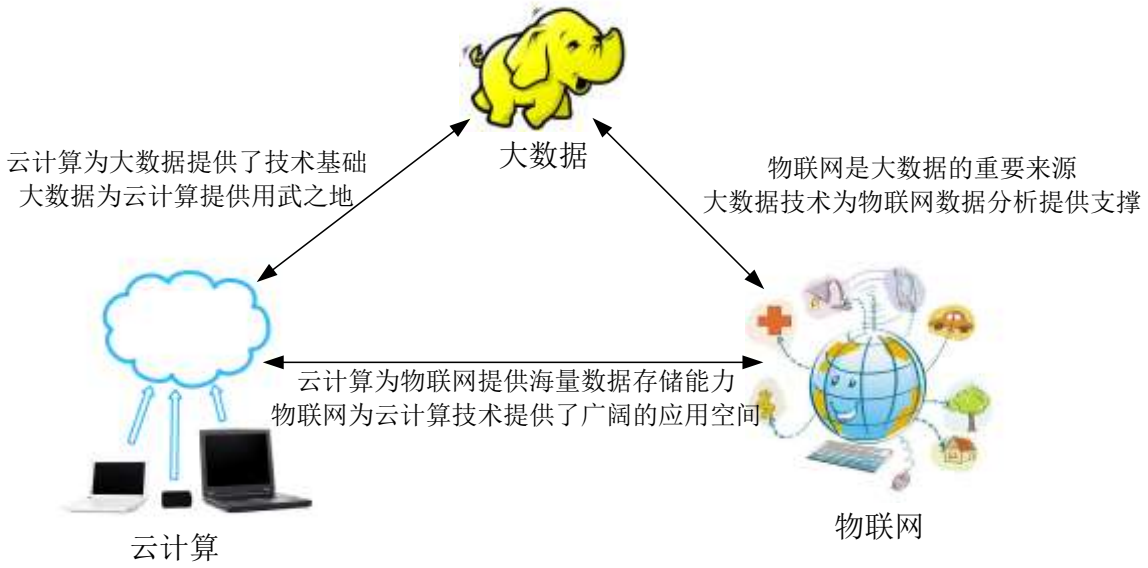
社交网络分析跟踪，将消费者社交网络上的关键词频率转化为可视化表达，对消费者进行分类，进而做针对目标客群的精准营销

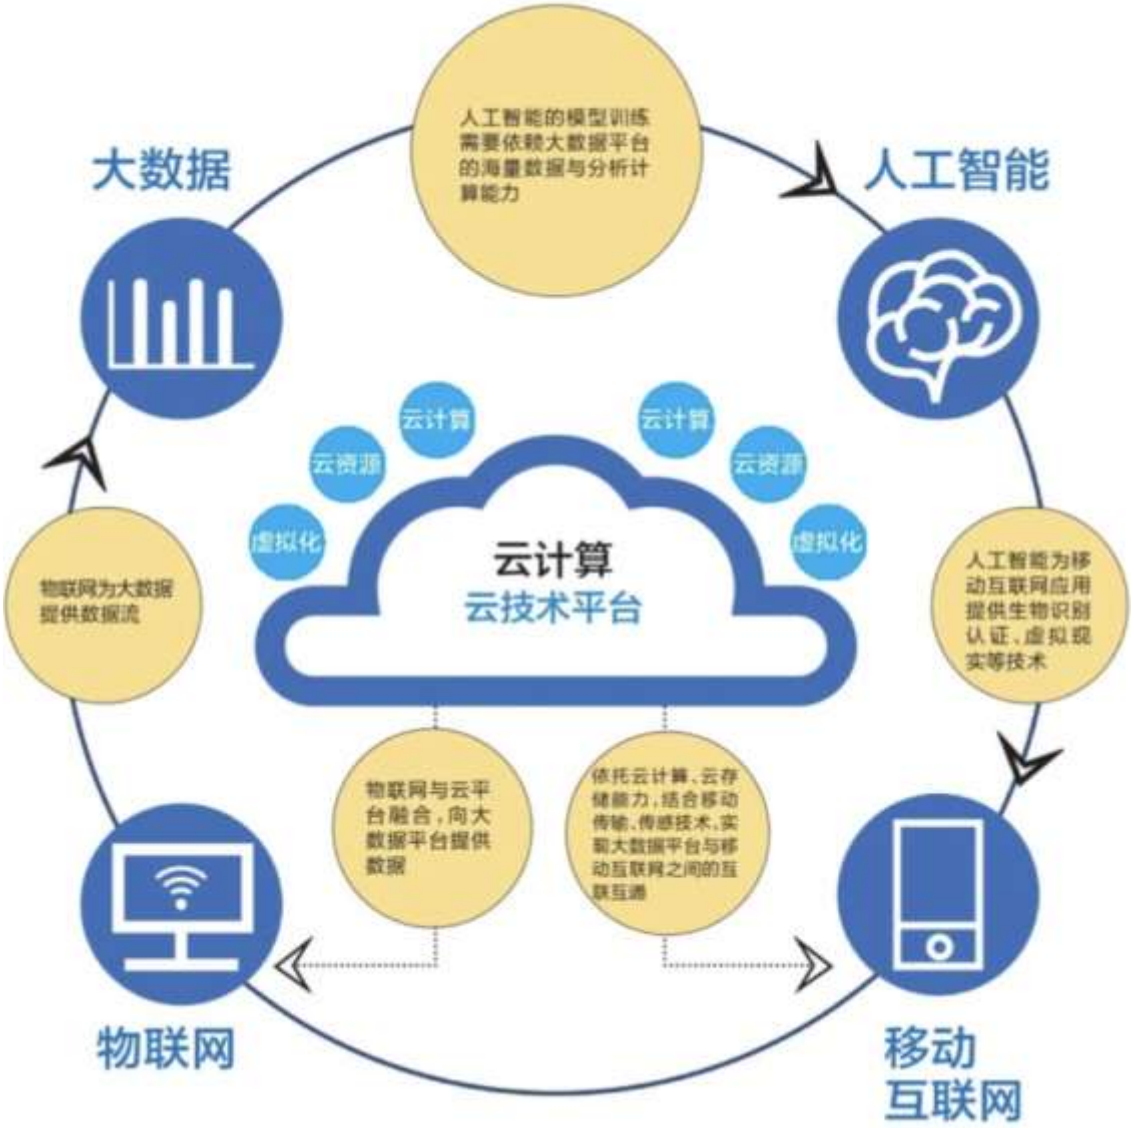
大数据应用架构示例图


数据源
数据库
日志文件
网络数据
设备数据
其它
采集|同步|传输
采集工具
同步工具
数据管道
数据存储
文件系统
关系库
非关系库
消息队列
离线批量处理
数据分析
机器学习
数据挖掘...
实时在线处理
https://pdai.tech
(分析后)数据存储
关系库
非关系库
其它
数据可视化
数据应用
数据接口
大屏展示
数据报表
其它
分布式协调，任务编排，配置管理，实时监控等

大数据与物联网、云计算

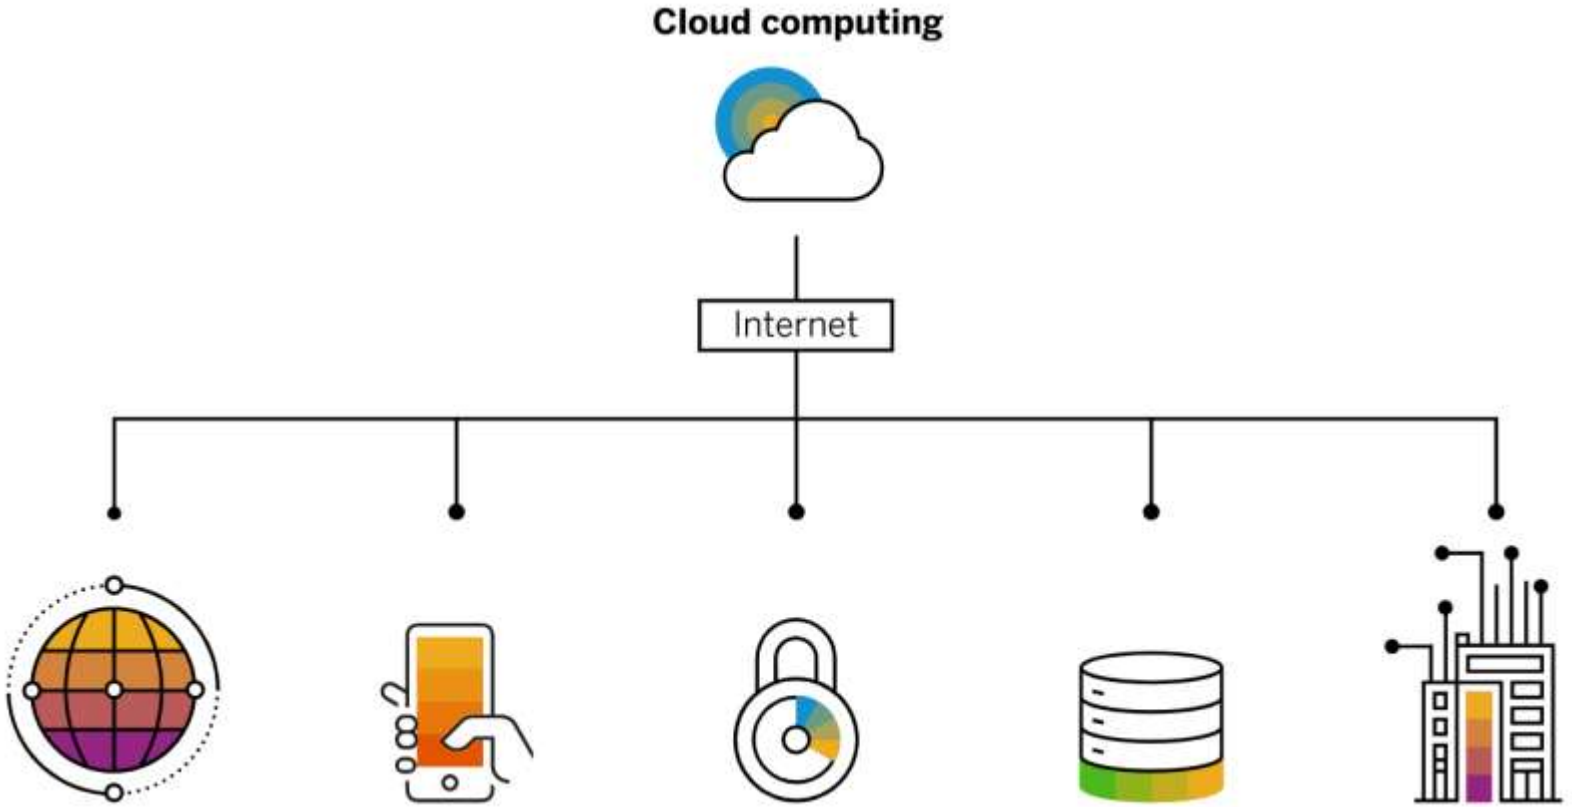
- 云计算、大数据和物联网代表了IT领域最新的技术发展趋势，三者相辅相成，既有联系又有区别





云计算

- 云计算以订阅的方式，通过互联网提供数据存储、安全、网络连接、软件应用和商业智能等服务



云部署模式主要分三类

- 在**公有云**部署模式中，服务通过提供商面向客户开放的网络交付给客户。公有云具有经济高效的特点，云提供商在共享环境中运行服务。
- 在**私有云**部署模式中，服务通过受防火墙保护的私有网络交付。企业既可以在自己的数据中心构建私有云，也可以订阅由提供商管理的私有云，拥有最高级别的安全性和控制措施。
- **混合云**综合了公有云、私有云和本地基础架构。在混合云部署模式中，企业既可以使用传统数据中心或私有云保存敏感信息，又可以充分利用公有云资源。



Public cloud



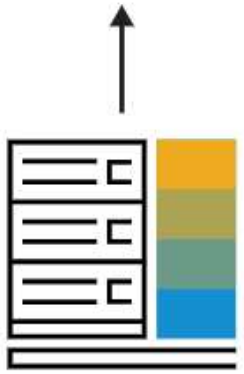
Private cloud



Hybrid cloud

云计算服务主要分为三类：SaaS、PaaS 和 IaaS

SaaS
Software as a service



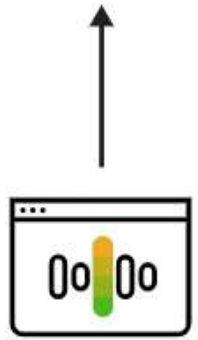
Software on remote server

PaaS
Platform as a service



Application development and deployment

IaaS
Infrastructure as a service



Servers, storage, and operating systems

SaaS（软件即服务）：云中宾馆

- SaaS 是指软件即服务，即将软件托管在远程服务器上，客户可以随时随地通过 Web 浏览器或标准 Web 集成进行访问。SaaS 服务提供商负责软件的备份、维护和更新。SaaS 解决方案涵盖ERP、客户关系管理 (CRM) 和项目管理等领域。

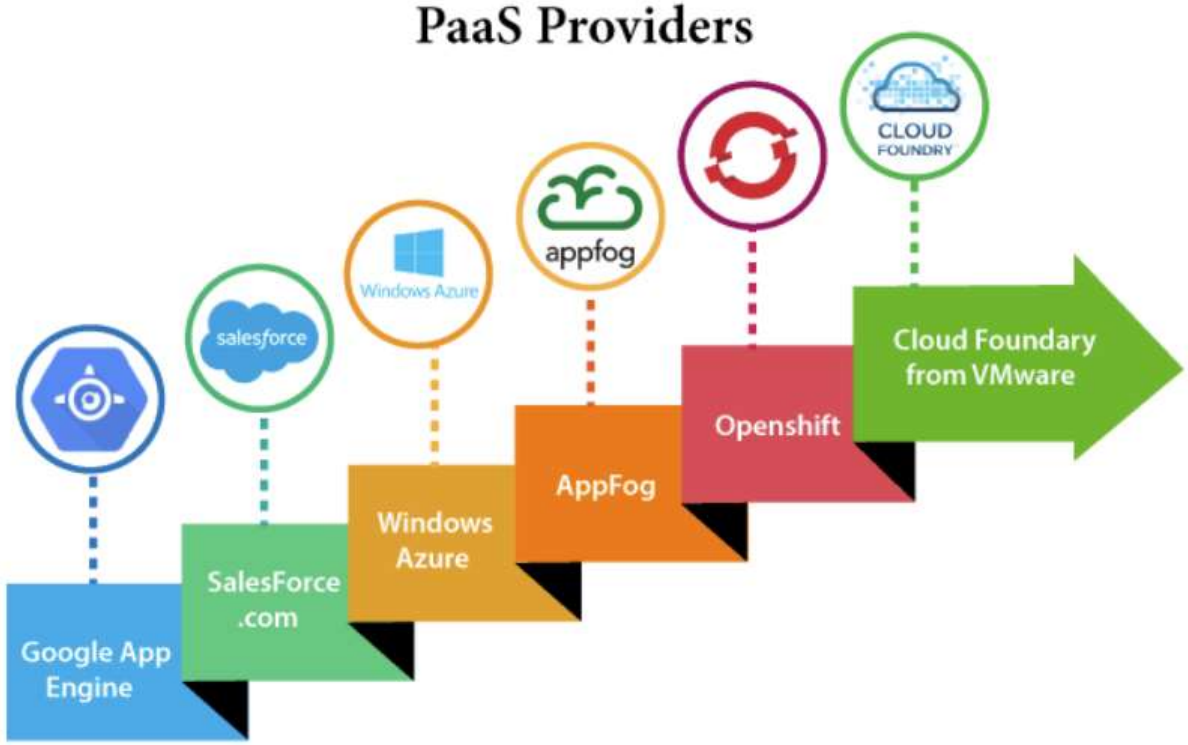




PaaS（平台即服务）：云中商厦

- PaaS 是指平台即服务。这是一种基于云的应用开发环境，能够全方位支持开发人员构建和部署应用。借助 PaaS，开发人员可以通过订阅或按使用付费的方式选择所需的功能和云服务。

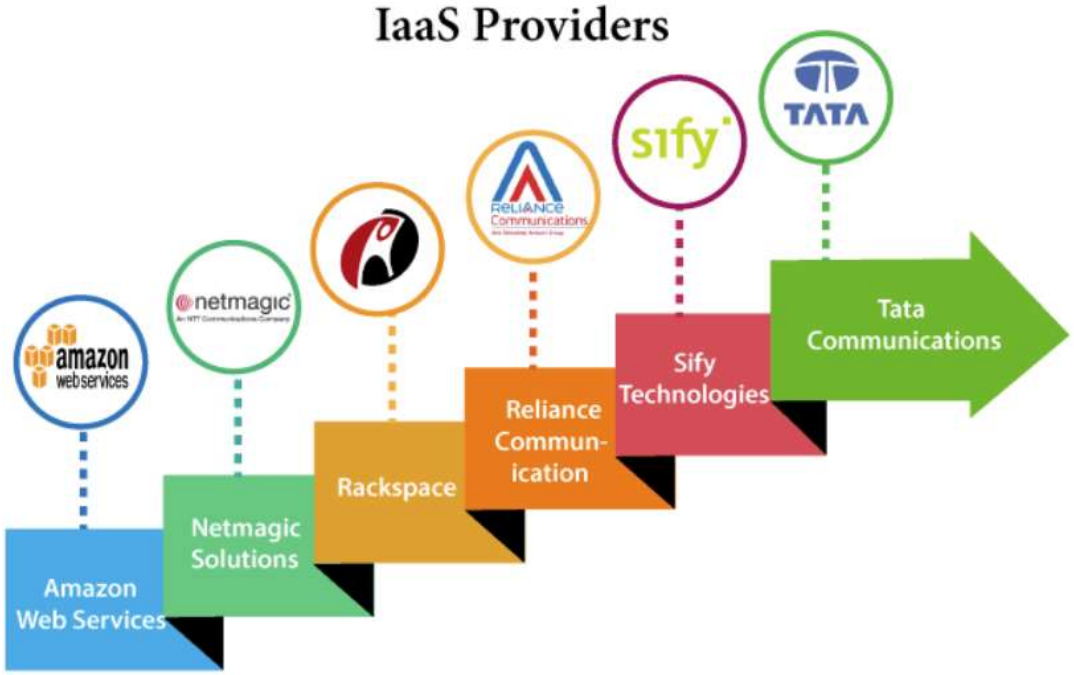




IaaS（基础设施即服务）：云中厂房

- IaaS 是指基础架构即服务。借助 IaaS 服务，企业可以通过按使用付费的方式，“租用”服务器、网络、存储器和操作系统等计算资源。而且，基础架构会不断扩展，客户无需投资硬件。

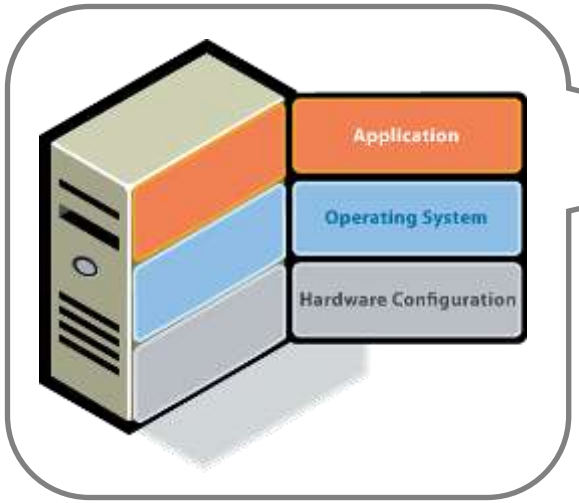




云计算核心技术——虚拟化

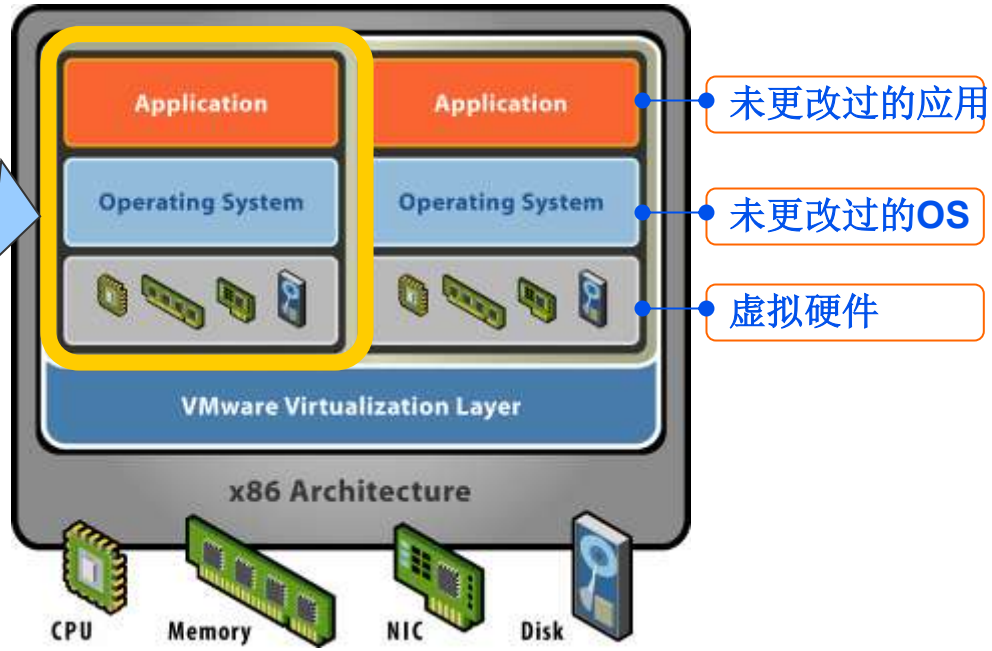
- 虚拟化是将硬件、操作系统和应用程序一同装入一个可迁移的虚拟机档案文件中

虚拟化前



- 软件必须与硬件相结合
- 每台机器上只有单一的操作系统镜像
- 每个操作系统只有一个应用程序负载

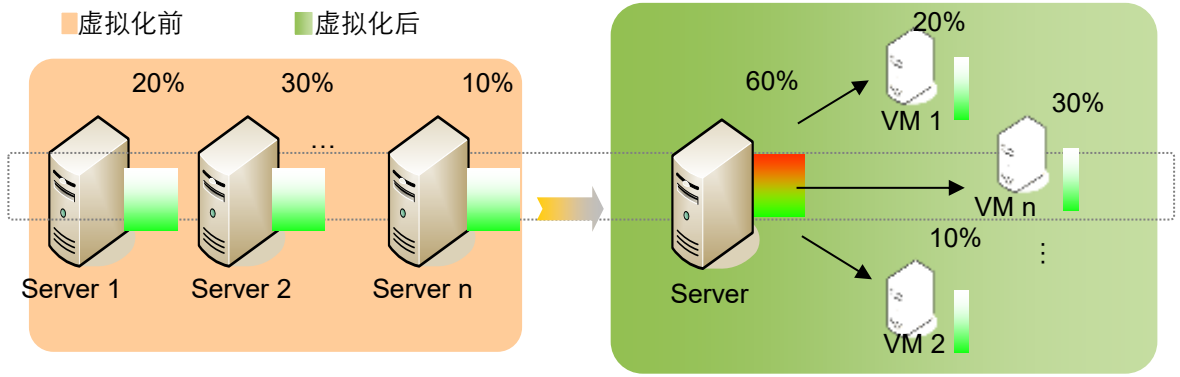
虚拟化后



- 每台机器上有多个负载
- 软件相对于硬件独立

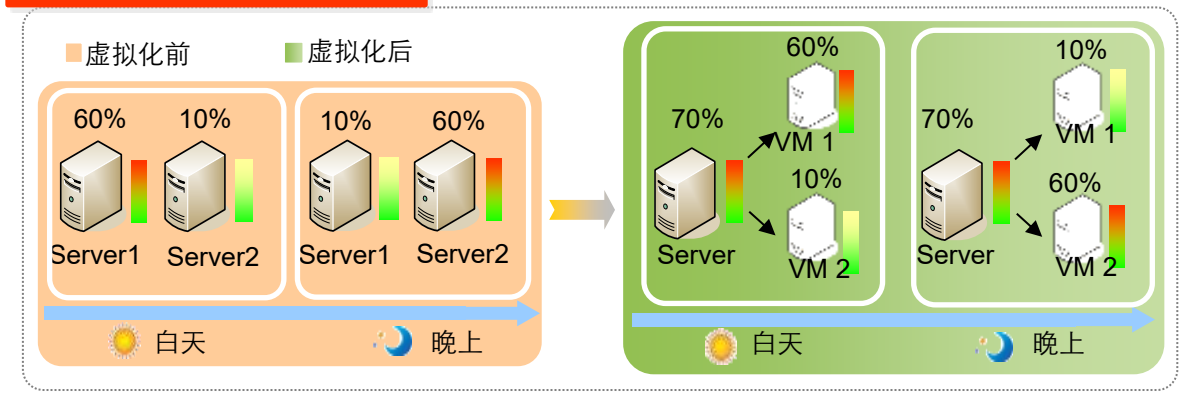
虚拟化提高了资源利用率

资源共享



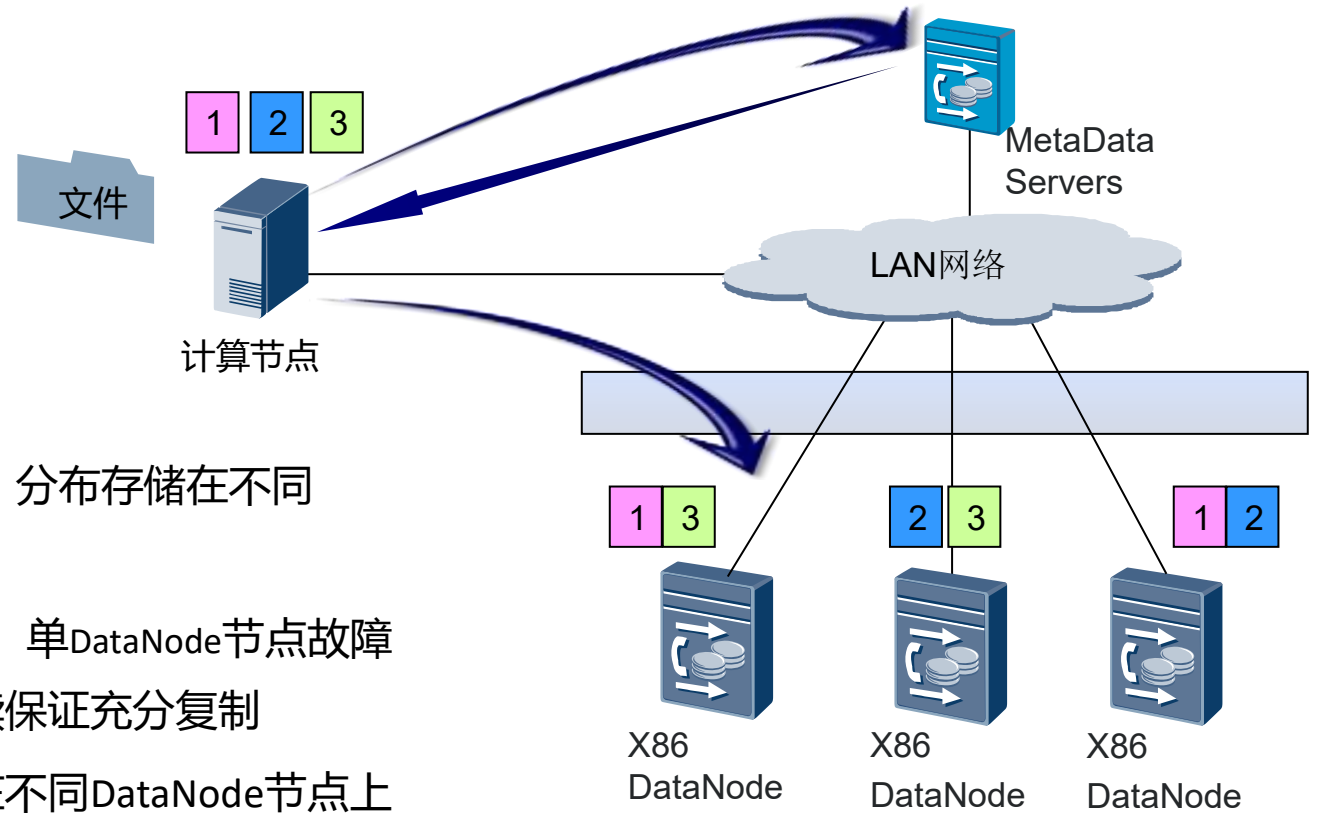
- 虚拟化前
  - 服务器利用率通常仅5%~10%
- 虚拟化后
  - 虚拟服务器的整合比常为1:5~1:10
  - 服务器利用率提升到60%以上

分时共享



	峰值时间	谷底时间
Wap网关服务器	9时	22时
彩信服务器	18时	6时

云计算核心技术——分布式存储

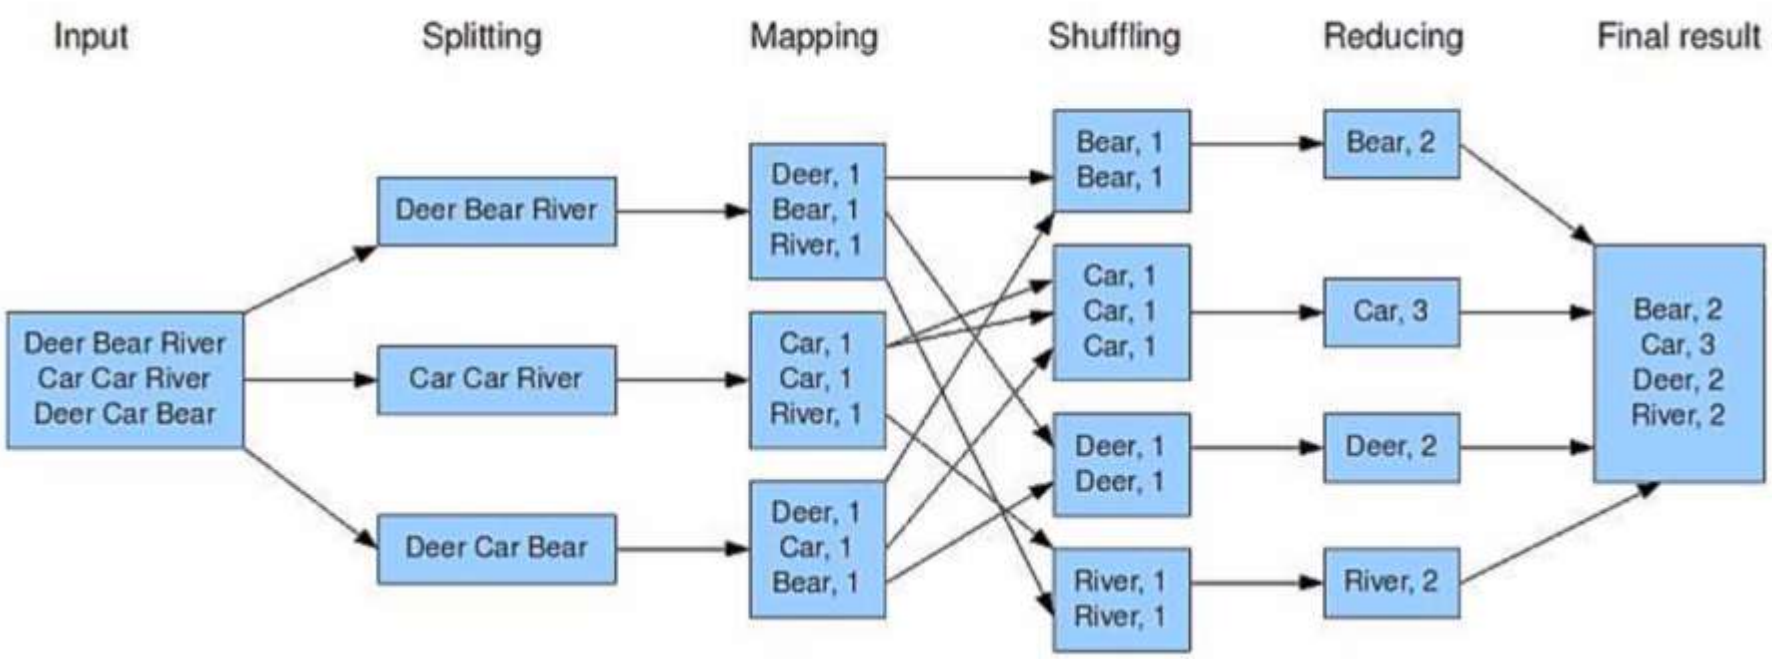


- 分布式存储技术
  - 存储数据时，文件被分块， 分布存储在不同DataNode节点上
  - 容错：数据副本数不小于2，单DataNode节点故障时文件分块完整保存，后续保证充分复制
  - 并发读写：读写数据时，在不同DataNode节点上实现并发读写

云计算核心技术——分布式计算

- 分而治之，并行计算

➢ 示例：WordCount

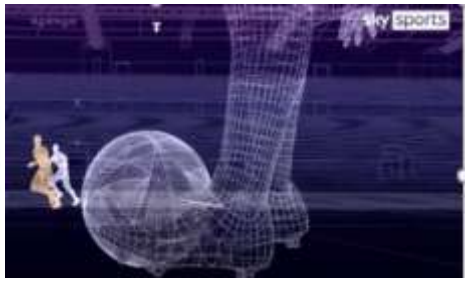


大数据的应用——卡塔尔世界杯

基于物联网技术的感知式系统与大数据—世界杯的黑科技







2022 年卡塔尔世界杯用球 Al Rihla，传感器由悬挂系统固定在球内部的中间，传感器通过充电电池供电，充满后在球场上可连续使用六个小时。通过使用UWB传感器获取位置数据、IMU传感器获得精细的三维运动数据，当足球被踢、被顶、被扔，甚至轻击时，传感器都会以每秒500次的速度获取相关数据，再通过人工智能系统整合分析，准确判断足球落点与传球点







2026 年美加墨世界杯用球 Trionda，将一枚仅重约 14 克的芯片直接嵌入球体外壳的四个面板之一中，

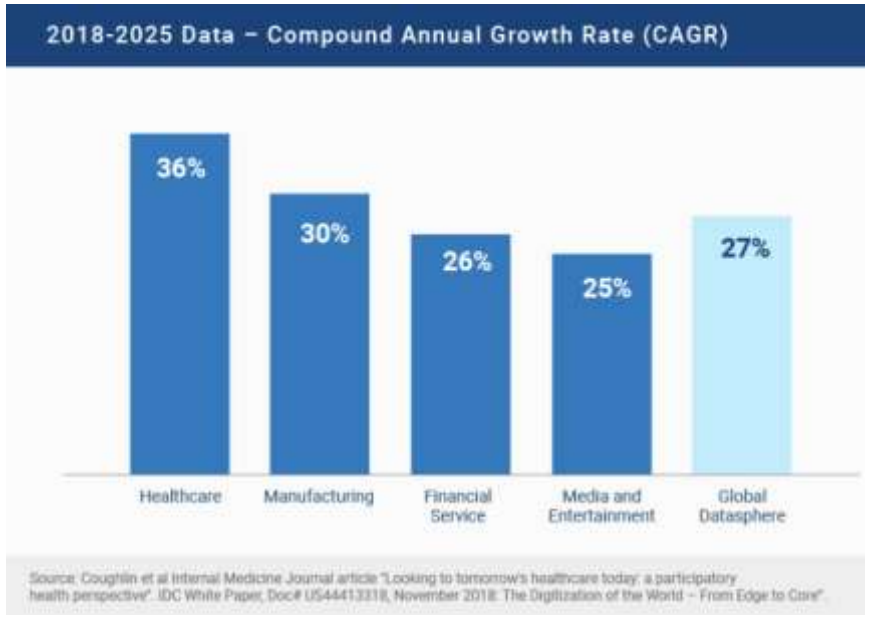




卡塔尔世界杯亮相半自动越位识别技术SAOT（半自动越位识别技术，Semi-automated offside）
在小组赛第一场，阿根廷爆冷输给沙特阿拉伯，有3次进球因越位被判无效是主因。这些越位犯规被球迷戏称“毫米级越位”，因这些越位判断来自SAOT技术——这远超裁判肉眼判罚的极限

2026 年美加墨世界杯，为全部48支球队的1263名球员建立高精度3D数字模型，当越位发生时，AI在3秒内生成3D动画投送至现场与转播画面

大数据的应用——医疗物联网



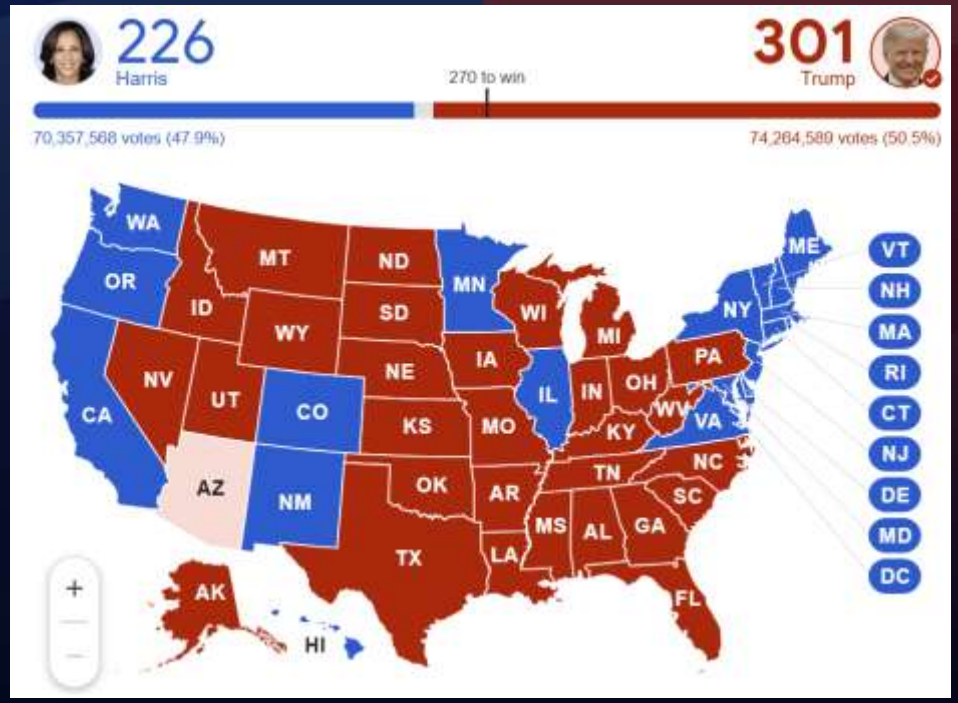
目前医疗保健行业产生的数据增长率为36%





大数据与美国总统大选







大数据助选：社交网络与舆情分析

√ 通过网络舆情分析，更好的判断摇摆州的动态

√ 通过多种形式的分析，将有效的竞选资源投向最值得争取的人群

大数据与美国总统大选



众所周知，2020年的大选，是拜登胜出

如果细看选票的统计的话，会发现，从全美普选票来看，在计票率为97%时，拜登以50.8%的得票率超过特朗普的47.4%，拜登的优势并不是特别大。

据称，特朗普团队和拜登团队仅仅用于Facebook的“政治广告精准投放“花费，分别高达9770万美元、8210万美元。

三年前，Meta便开始着手研究Facebook和Ins对2020年选举的影响。

现在，发表在Science和Nature上的4篇同行评议论文中，Meta首次向公众展示了研究结果。

这些研究为Facebook和Ins的算法，如何影响用户在2020年总统大选前夕看到的内容提供了一个有趣的新视角。



大数据的应用——智慧城市




人口分析域
流动人口分析、房屋空置分析、人口结构分析
城市综治域
机动车乱停乱放、非机动车乱停乱放、行人违规整治、电动车违规行驶、小微商户管理、出店经营整治
营商环境域
区域客流量分析、小商户门前三包、规上企业运营
政务服务域
低保资格核验、学龄前儿童分析、老年人口服务、留守儿童关爱、教育资源匹配
城市管理域
机动车乱停乱放、非机动车乱停乱放、行人违规整治、电动车违规行驶、小微商户管理、出店经营整治
城交通运输
车站乱停乱放、出站客流量统计、公路卡口拥堵、城区车流分析、公交站人数统计


视频分析系统


禁区监测
非机动车占用机动车道
行人横穿马路
车辆违停
消防通道占用
出店经营
垃圾监测
烟火监测
流动摊贩占道经营

大数据的应用——金融欺诈





信用卡欺诈会对银行造成巨大损失，信用卡公司一直研究如何预防潜在的欺诈。然而，2018年度信用卡诈骗数目仍然超过**284亿**。

信用卡欺诈检测

传统方式：基于统计学的孤立点分析

利用统计学的方法，发现目标数据集中的目标特征与整个集合的特征呈现出巨大差别的数据对象

YX66AJ9U	1025	20.47	XX药店
98ZCM6B1	1910	55.50	XX餐馆
XXXX7362	**0100**	**1875.40**	**XX商场**

- 仅使用信用卡交易记录很难分别真正的诈骗行为和突发购买行为
  - 灵敏度：低灵敏度使得银行承受大量经济损失
  - 特异度：低特异度牺牲了信用卡用户的便利性

利用大数据技术提升信用卡欺诈检测的*灵敏度和特异度*

更广泛的交易元数据和用户信息



更准确的行为建模和分析模型

元数据检测 多数据源关联 | 机器学习 评价算法 | 链接分析 图模式分析

更高效的数据处理分析技术

hadoop GraphLab Storm Spark

VISA新投入使用的大数据交易分析系统，可以收集、分析多方面的交易元数据和持卡人信息（**500个不同来源的数据**），并利用多个预测模型（**16个分析模型**），成功识别出高达**20亿美元**的潜在信用卡欺诈，并保证了**90%**的用户交易不需要额外的验证！

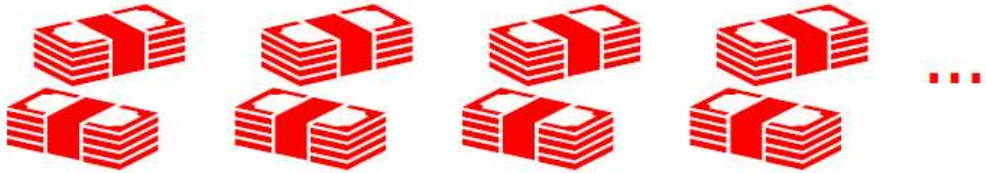
大数据的应用——用户忠诚度提升

用户忠诚度

客户忠诚度，又可称为客户粘度，是指客户对某一特定产品或服务产生了好感，形成了“依附性”偏好，进而重复购买的一种趋向。



忠诚客户





普通客户



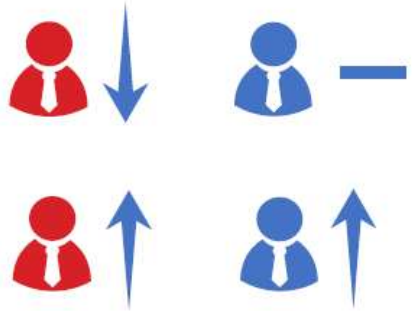
据统计，忠诚度高的客户消费水平是普通客户7.6倍！



AMERICAN EXPRESS

过去（无大数据预测）

现在（大数据预测系统）



美国运通信用卡公司使用大数据分析预测系统，提前发现用户忠诚度降低的客户，并及时采取措施提升忠诚客户比例。



使用用户忠诚度预测模型，预测到4个月后的澳洲用户流失，经后期验证，识别率达**24%**

单用户年均信用卡消费 **25000** 澳元

避免损失信用卡消费 **7.5亿** 澳元

大数据杀熟





其实就是杀熟啊 对于我们这样经常点外卖的老油条 美团和饿了么的会员都买了 经常会发现 家里人不是会员的 比我这个是会员并且用了会员券的点的同一家一样的东西 不是会员的明显便宜多了

很早就发现了，大概都两年前了，买电影票就是这样，我是会员，朋友不是，他的号买比我还便宜，当时致电客服，就说是系统错误，嘴硬着呢

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

Thank You

