02-数据预处理和数据可视化

丁玥
上海交通大学计算机学院
dingyue@sjtu.edu.cn

2026年秋

饮 水 思 源 • 爱 国 荣 校

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

目 录

1 认识数据

2 数据预处理

3 数据可视化



上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

目 录

1 认识数据

2 数据预处理

3 数据可视化



记录数据（Record data）

Projection of x Load	Projection of y load	Distance	Load	Thickness
10.23	5.27	15.22	2.7	1.2
12.65	6.25	16.22	2.2	1.1

数据矩阵，由数值属性组成

TID	*Items*
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

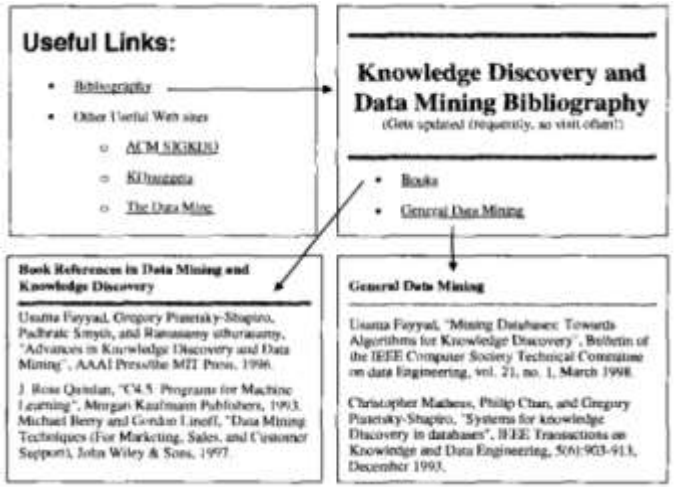
事务数据或购物篮数据

图和网络数据（Graph and network data）

- 万维网
- 社交网络
- 分子结构

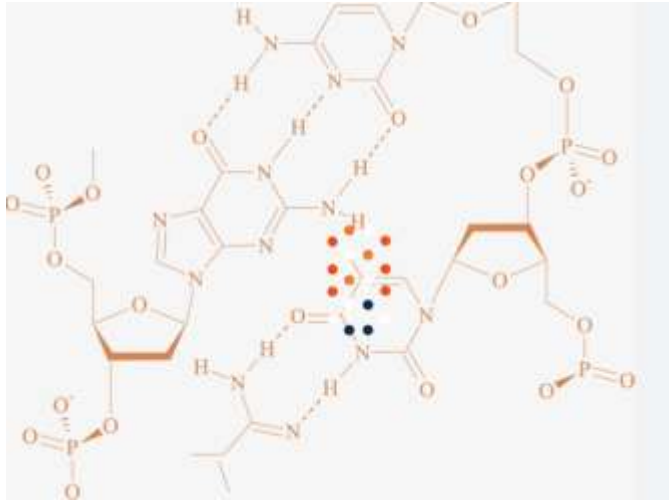


✓社交网络
✓异构连接



✓对象之间的联系常常携带重要信息，比如网页，页面上包含文本和指向其他页面的链接

```
<a href="papers/papers.html#bbbb">
Data Mining </a>
<li>
<a href="papers/papers.html#aaaa">
Graph Partitioning </a>
<li>
<a href="papers/papers.html#aaaa">
Parallel Solution of Sparse Linear System of Equations </a>
<li>
<a href="papers/papers.html#ffff">
N-Body Computation and Dense Linear System Solvers
```

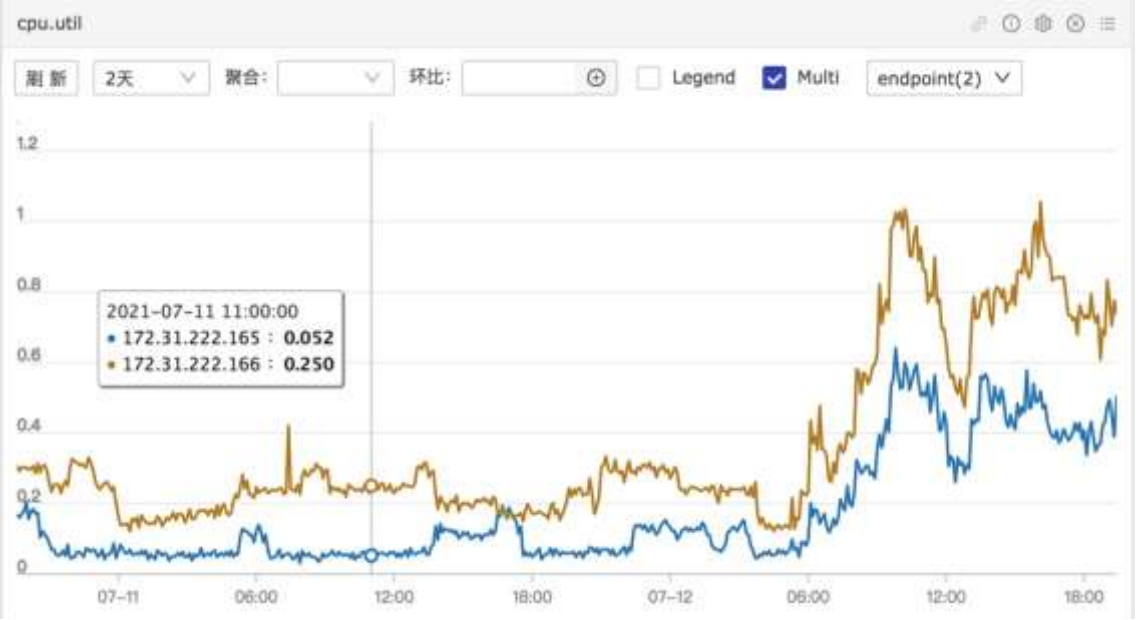


✓如果对象具有结构，即对象包含具有联系的子对象，则这样的对象常用图形表示。例如，化合物的结构可以用图形表示，其中结点是原子，结点之间的链是化学键

时间序列数据（Time series data）

- 每个记录都是一个时间序列，即一段时间以来的测量序列
  - 金融数据集可能包含各种股票每日价格
- 在分析时间数据时，重要的是要考虑时间自相关（temporal autocorrelation），即如果两个测量的时间很接近，则这些测量的值通常非常相似

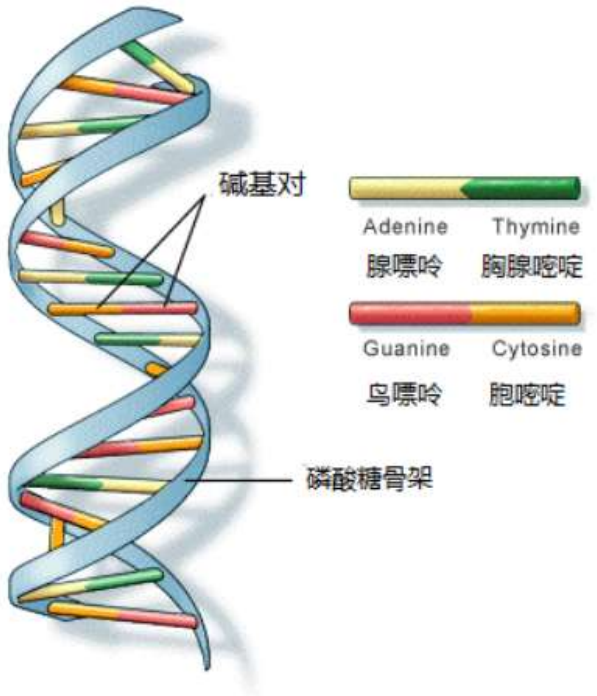




基因序列数据（Genetic sequence data）

- 各个实体的序列，如词或字母的序列。除没有时间戳之外，它与时序数据非常相似。
- 用4 种核苷酸表示的一段人类基因码(Genomic sequence data 基因组序列数据)，所有DNA都可以用A、T、G和C 四种核苷酸构造

DNA的双螺旋结构




```
CTGGTGGTGCTCAGCTGCAAGTCAAGCTGCTCTCTGGGCTGTGATCTCCCTGAGACC
CACAGCCTGGATAACAGGAGGACCTTGATGCTCCTGGCACAAATGAGCAGAATCTCT
CCTTCCTCCTGTCTGATGGACAGACATGACTTTGGATTTCCCCAGGAGGAGTTTGAT
GGCAACCAGTTCCAGAAGGCTCCAGCCATCTCTGTCCTCCATGAGCTGATCCAGCAG
ATCTTCAACCTCTTTACCACAAAAGATTCATCTGCTGCTTGGGATGAGGACCTCCTA
GACAAATTCTGCACCGAACTCTACCAGCAGCTGAATGACTTGGAAGCCTGTGTGATG
CAGGAGGAGAGGGTGGGAGAAACTCCCCTGATGAATGCGGACTCCATCTTGGCTGTG
AAGAAATACTTCCGAAGAATCACTCTCTATCTGACAGAGAAGAAATACAGCCCTTGT
GCCTGGGAGGTTGTCAGAGCAGAAATCATGAGATCCTCTCTTTATCAACAAACTTGC
AAGAAAGATTAAGGAGGAAGGAATAA, TGTGATCTCCCTGAGACCCACAGCCTGGA
TAACAGGAGGACCTTGATGCTCCTGGCACAAATGAGCAGAATCTCTCCTTCCTCCTG
TCTGATGGACAGACATGACTTTGGATTTCCCCAGGAGGAGTTTGATGGCAACCAGTT
CCAGAAGGCTCCAGCCATCTCTGTCCTCCATGAGCTGATCCAGCAGATCTTCAACCT
```

ATGC编码

结构化、非结构化和半结构化数据



结构化数据：具有标准化格式，可以通过键值获取相应信息

User Age	Ad Id	···	Click
41	93242		1
80	93287		0
18	87312		1
⋮	⋮		⋮
27	71244		1

半结构化数据：具有一定的结构性，但是结构变化很大，不能通过建立键值来对应

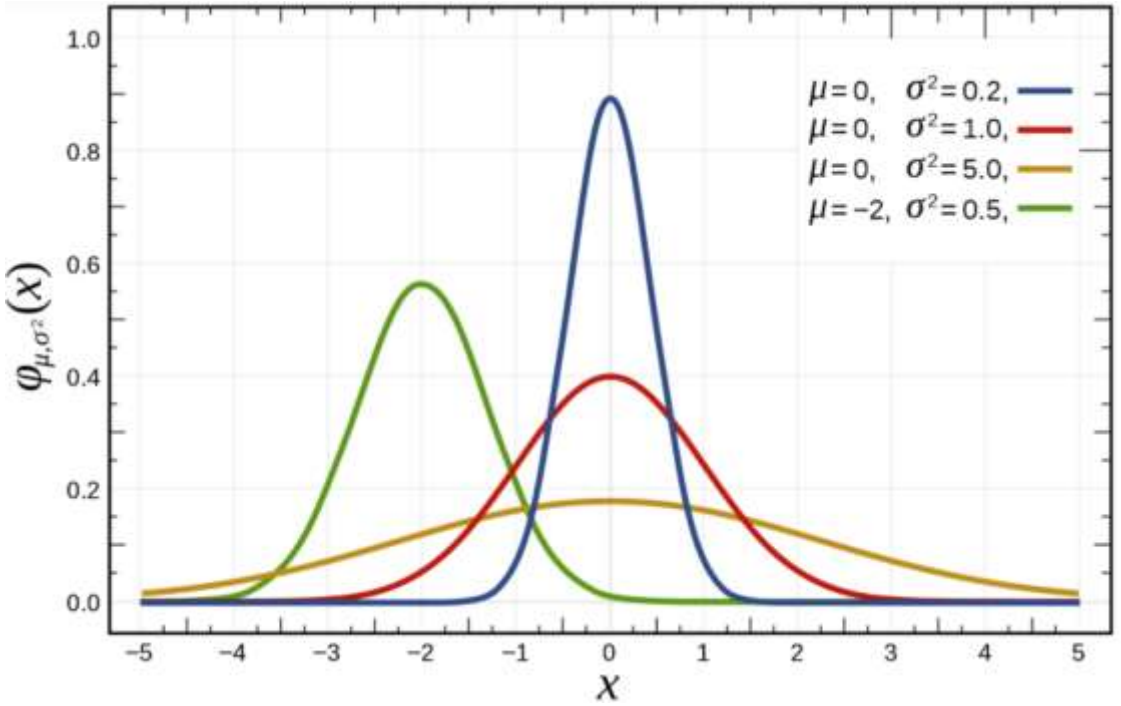
```
{
"ID": "002",
"Name": "內湖草莓宴",
"Address": "台北縣內湖路五寮彎1-3號6樓",
"Tel": "02-9123456",
"info": "觀光果園有兩大園區，冬天採草莓，夏天採紅
  棗，不同季節都能體驗採果樂趣！由公館鄉農會草莓班
  輔導，品質優、口感佳，頗受遊客好評",
"Price": "1000"
}
```

非结构化数据：文本、图像、视频和音频等，不可通过键值获取

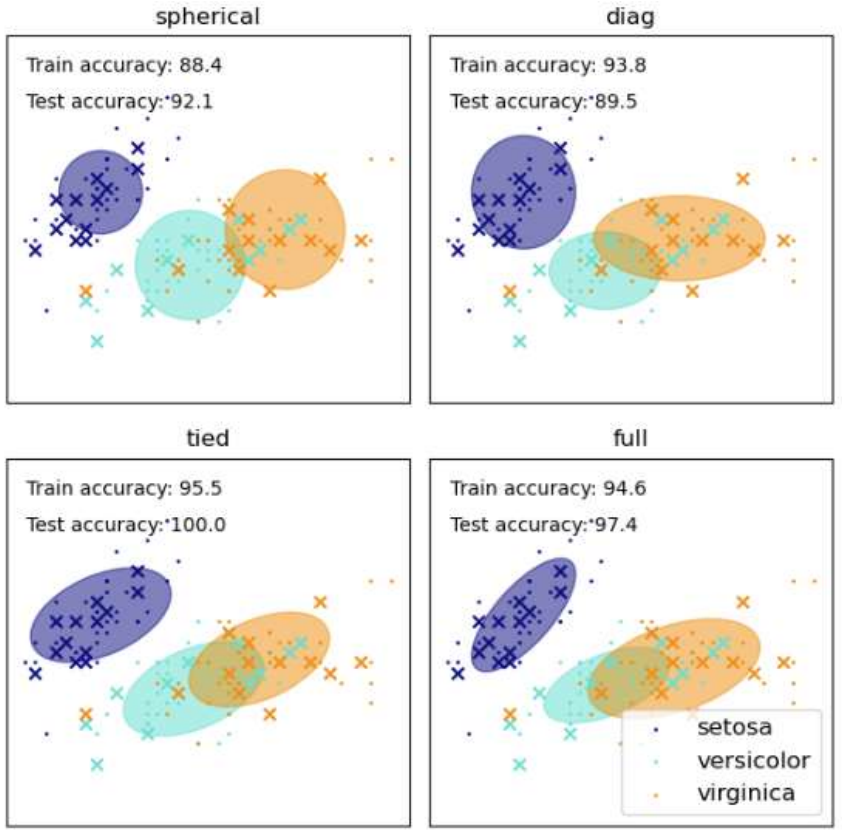
认识数据——数据分布

研究数据的分布能够更好的理解数据的特点——对于机器学习模型非常重要

为什么数据科学家都喜欢用高斯分布？

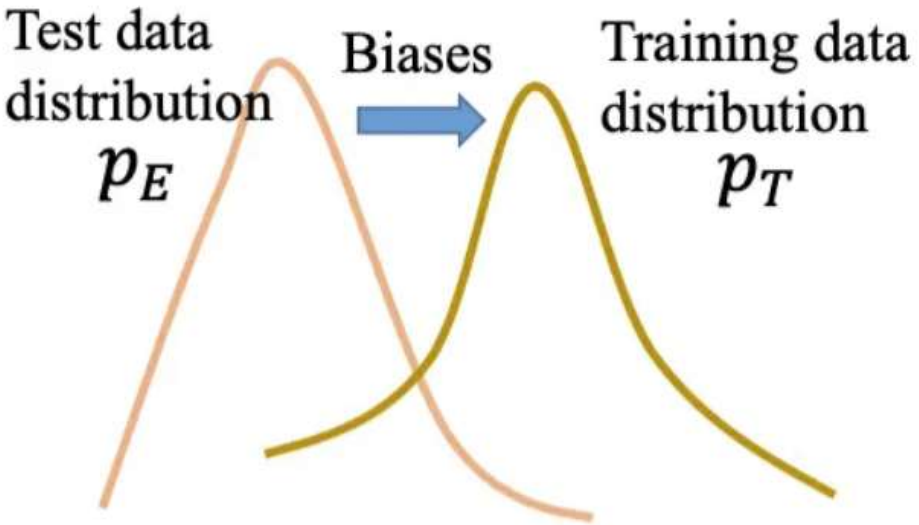


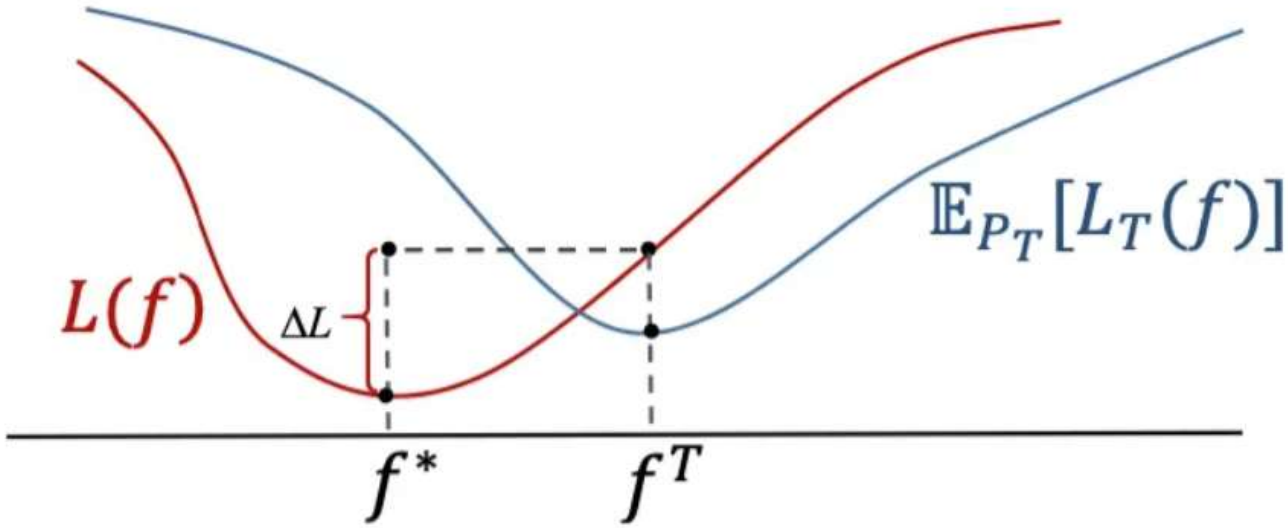
中心极限定理表明，满足一定条件时，大量相互独立的随机变量经适当标准化后，收敛于高斯分布。



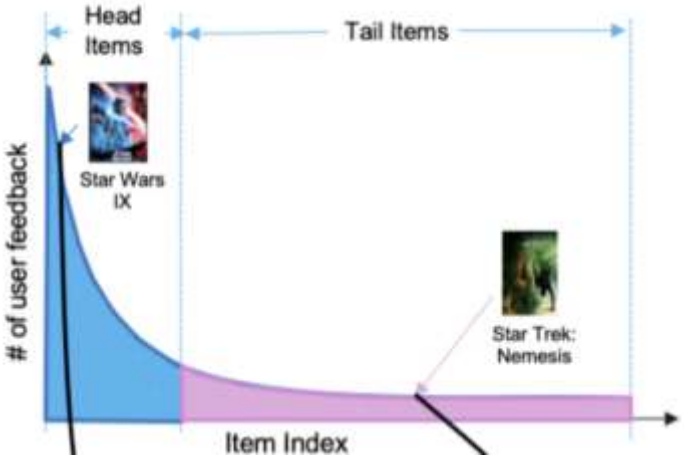
例：用若干个不同高斯分布的混合来估计数据的分布

数据分布对机器学习模型的影响——数据漂移现象

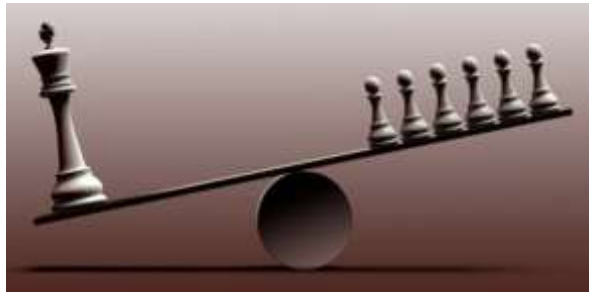


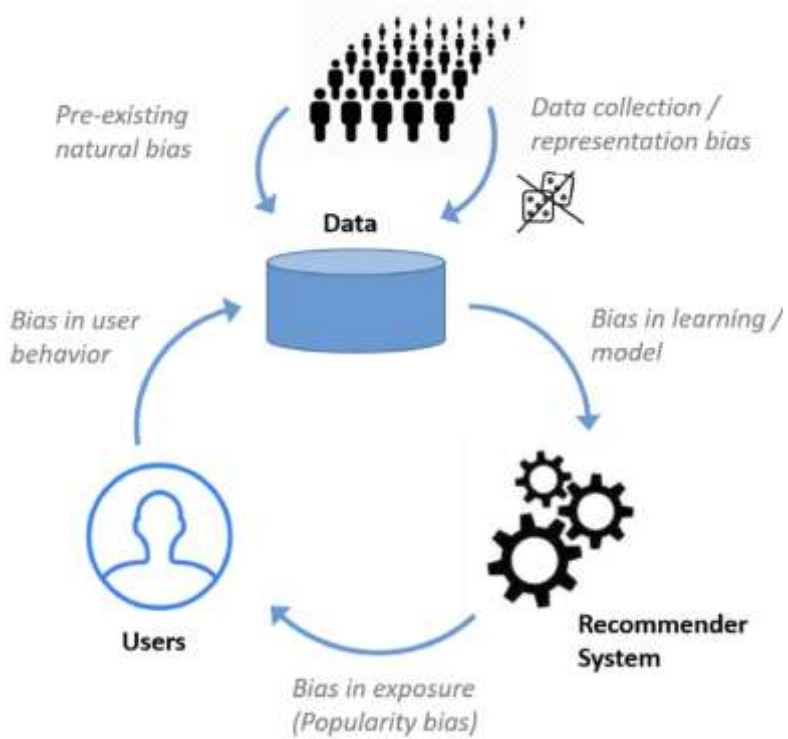


数据分布对机器学习模型的影响——长尾分布、样本不均衡问题

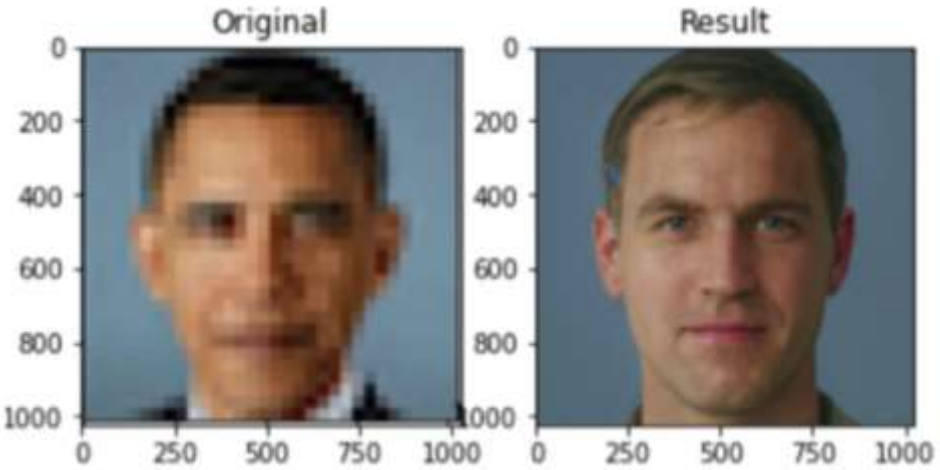


马太效应：强者越强



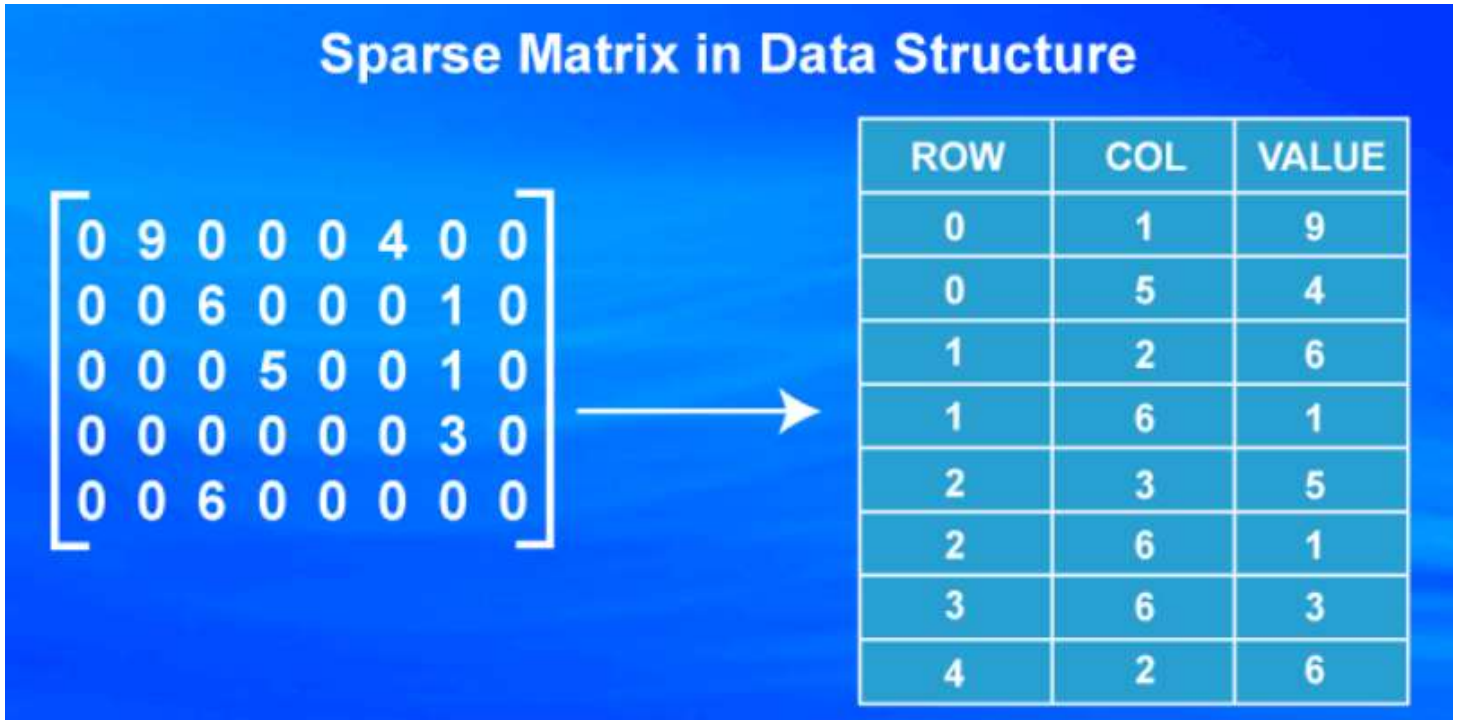


生成式AI模型的偏见，
对数据集多样性的考验



稀疏性

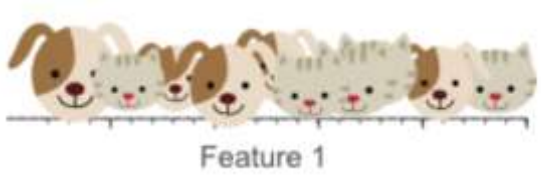
- 有些数据集在大部分属性上的值都为0，在许多情况下，非零项还不到1%
- 稀疏性是一个优点，因为只有非零值才需要存储和处理。这将节省大贵的计算时间和存储空间



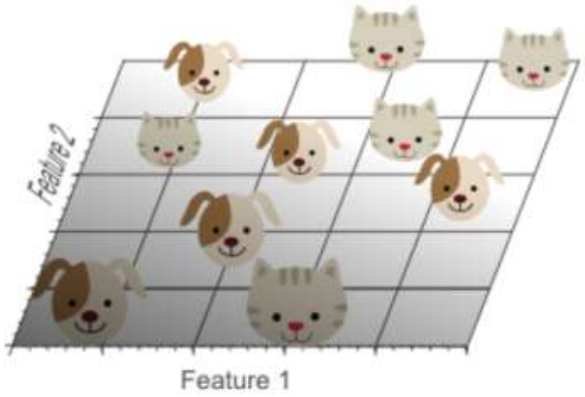
维度（Dimensionality）

- 维度是数据属性的数量。低维度数据往往与中、高维度数据有质的不同。
- 分析高维数据有时会陷入所谓维灾难。数据预处理的一个重要动机就是减少维度，称为维归约（dimensionality reduction）

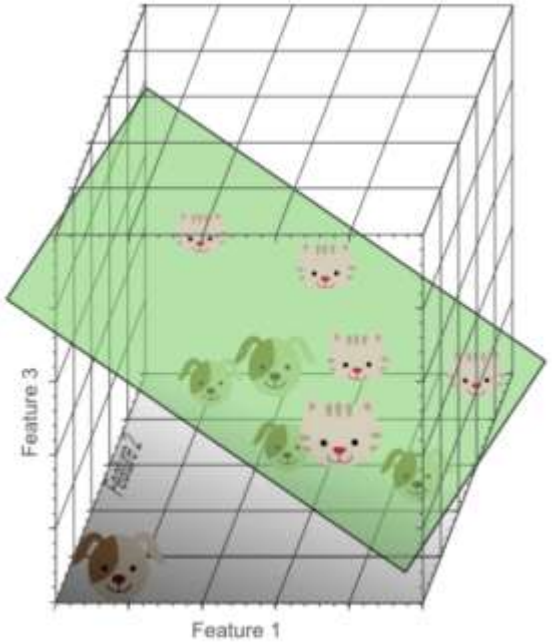
维度的诅咒



一维情况下无法分类



在二维空间中，虽然能够找到一个线性分类结果，但是不理想

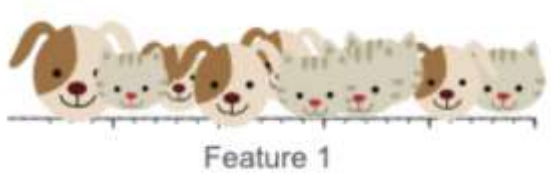


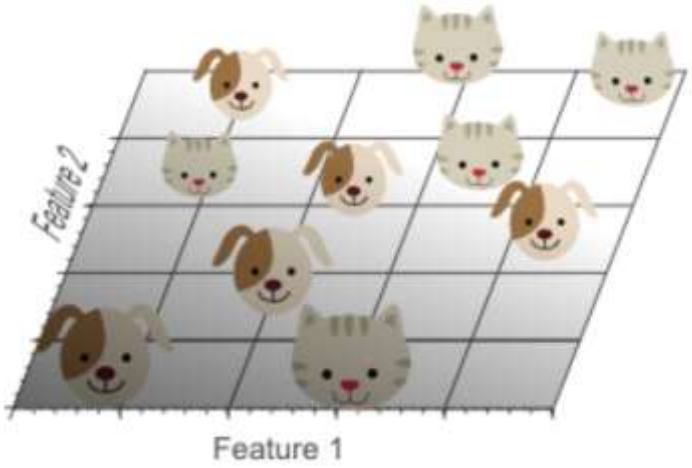
在三维空间中可以找到一个相对比较理想的平面

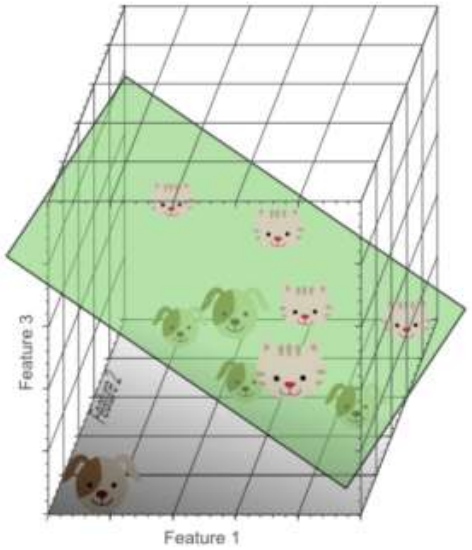
这似乎表明增加特征数量是训练分类器的最佳方法?

维度的诅咒

- 在一维情况下，假设宽度为5个单位区间，样本密度为**10/5 = 2**个样本/区间。
- 在二维情况下，10个训练实例覆盖一个5×5 = 25个单位平方的面积，样本密度为**10/25 = 0.4**个样本/区间。
- 在三维情况下，10个样本必须覆盖一个5x5x5 = 125个单位立方的特征空间体积，样本密度为**10/125 = 0.08**个样本/区间。



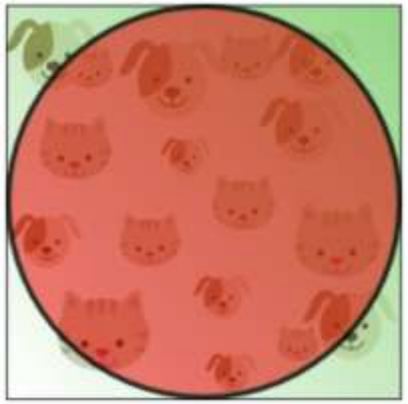




然而问题是，训练样本的密度呈指数下降！

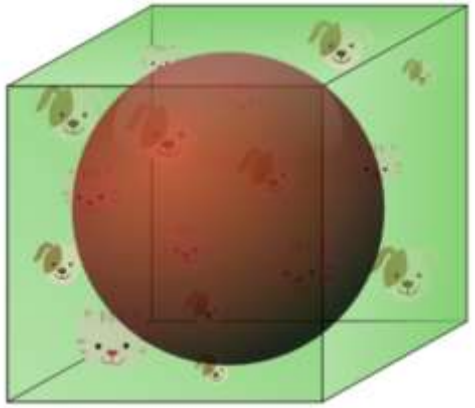
维度的诅咒

- 维度诅咒导致训练数据变得稀疏，这种稀疏性在搜索空间中并不是均匀分布的



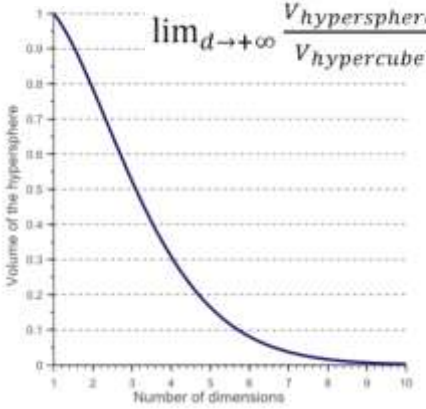
设想一个代表二维特征空间的单位正方形。特征空间的平均值位于单位正方形的中心

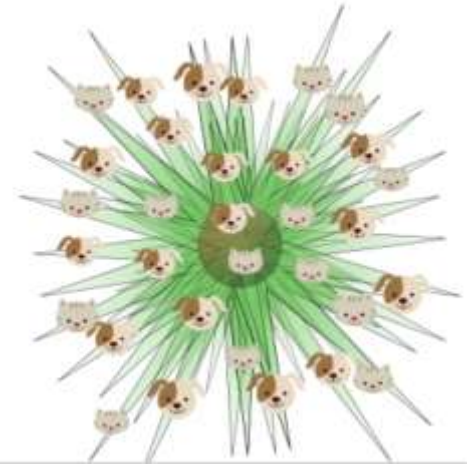
落在单位圆外的训练样本位于特征空间的角落里，**比接近特征空间中心的样本更难分类**



随着维度的增加，**超球体的体积趋于零**

$$\lim_{d \to +\infty} \frac{V_{hypersphere}}{V_{hypercube}} = 0$$

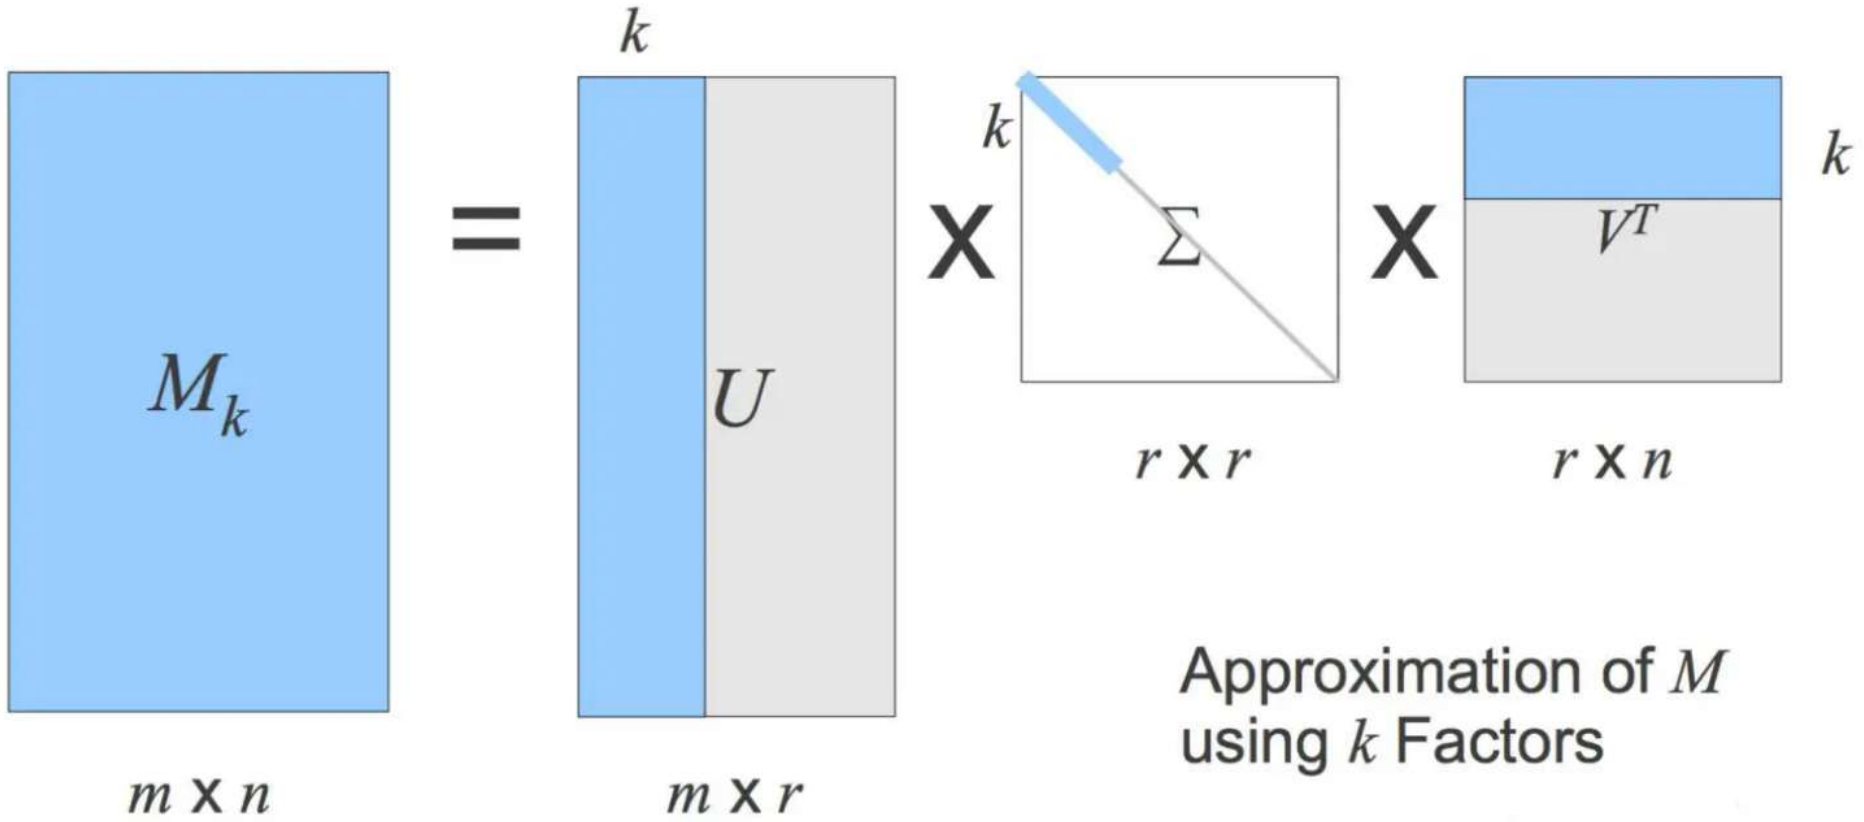


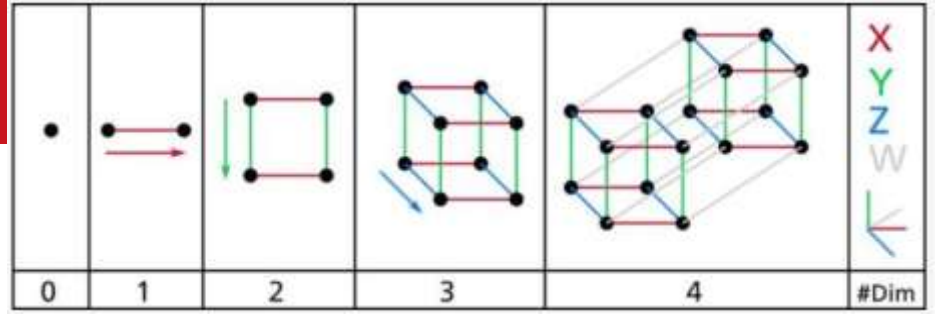


在高维空间中，大多数训练数据驻留在定义特征空间的超立方体的角落中。

随着维度的增加，更大比例的训练数据驻留在特征空间的角落中。**对于8维超立方体，大约98%的数据集中在其256(2^8)个角上**

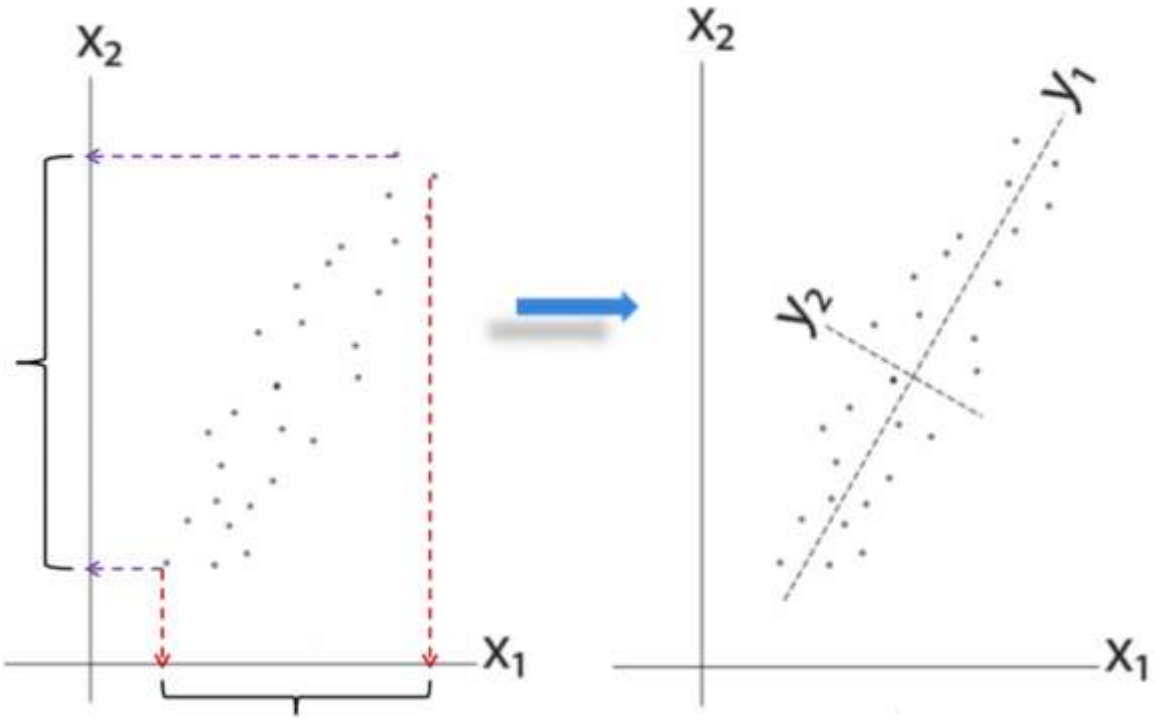
SVD分解用于数据压缩存储

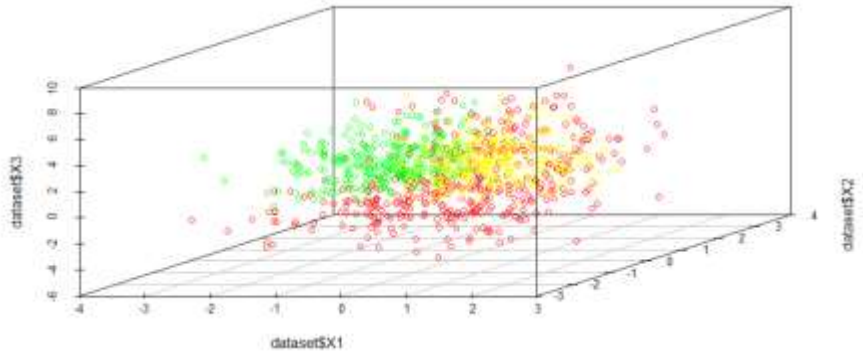


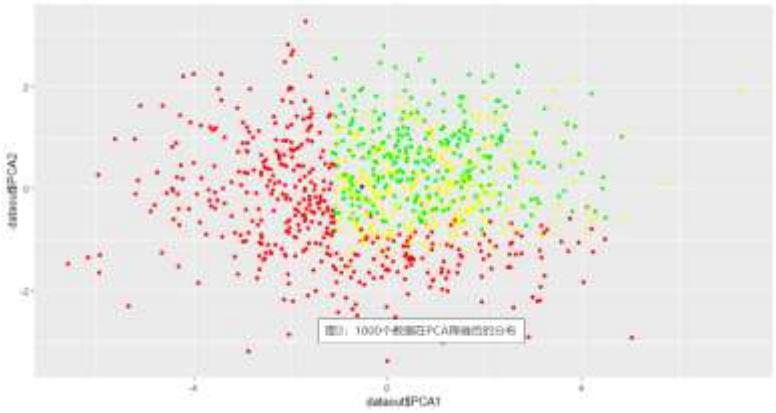


PCA 主成分分析

- 主成分可以显示出样本在某个特征上的最大差异（方差最大的直线为主方向）



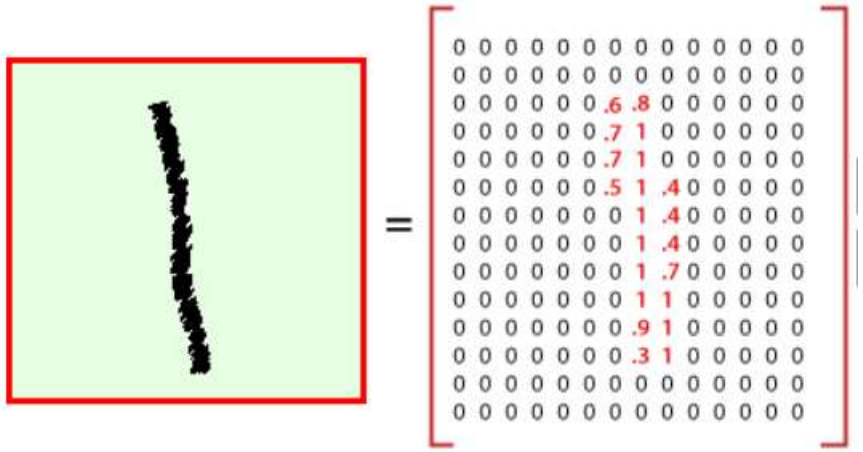


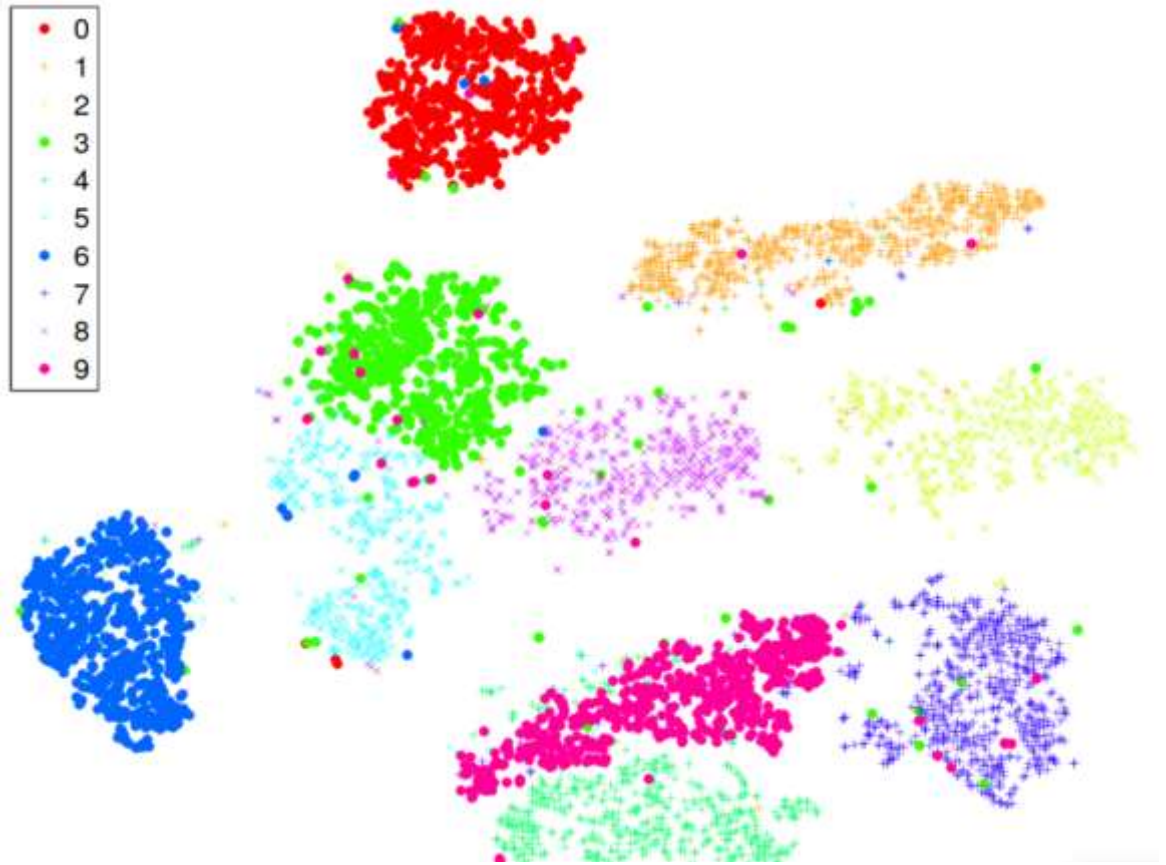


t-SNE（t-Distributed Stochastic Neighbor Embedding）

- MNIST数据集
  - 包含60000张28*28的图片







MNIST数据集的t-SNE投影结果

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

目 录

1 认识数据

2 数据预处理

3 数据可视化



- **现实世界的数据一般都是“脏”的：许多潜在的不正确的数据对于业务的影响很大，如何处理这些数据非常关键**
  - 数据有缺失incomplete: 缺少属性值或者某些感兴趣的属性，或仅包含聚集数据
    - e.g., *Occupation* = “ ” (missing data)
  - 噪声数据noisy: 包含错误或存在偏离期望的值
    - e.g., *Salary* = “−10” (an error)
  - 不一致inconsistent: 在编码或名称上存在差异, e.g.,
    - *Age* = “42”, *Birthday* = “03/07/2010”
    - Was rating “1, 2, 3”, now rating “A, B, C”
    - 重复的记录有出入
  - 人为因素Intentional (e.g., *disguised missing* data)
    - Jan. 1 as everyone’s birthday?

ETL的概念

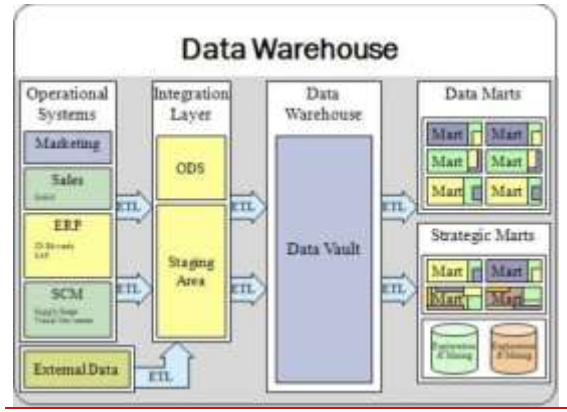
- ETL是英文Extract-Transform-Load的缩写，分别表示用来描述将数据从源端经过抽取（extract）、转换（transform）、加载（load）至目的端的过程，它能够对各种分布的、异构的源数据（如关系数据）进行抽取，按照预先设计的规则将不完整数据、重复数据以及错误数据等脏数据内容进行清洗，得到符合要求的“干净”数据，并加载到数据仓库中进行存储。
- ETL是实现商务智能（Business Intelligence，即BI）的核心和灵魂，**一般情况下ETL会花费掉整个BI项目三分之一的时间，因此ETL设计的好坏直接影响到BI项目的成败。**

数据清洗工具ETL

ETL的体系结构

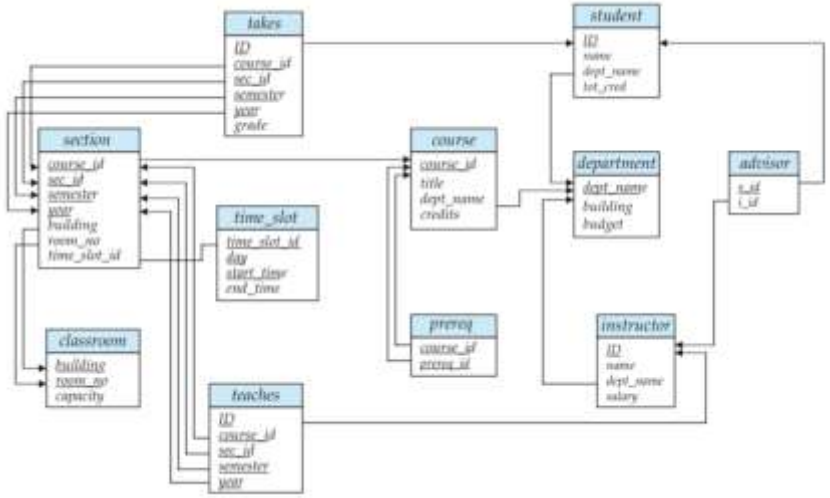


ETL主要是用来实现异构数据源数据集成的。多种数据源的所有原始数据大部分未作修改就被载入到ETL，因而，无论数据源在关系型数据库、非关系型数据库还是外部文件，集成后的数据都将被置于数据库的数据表或数据仓库的维度表中，以便在数据库内或数据仓库中作进一步地转换。



数据仓库是来自一个或多个不同源的集成数据的中央存储库，是用于报告和数据分析的系统，被认为是商业智能的核心组件

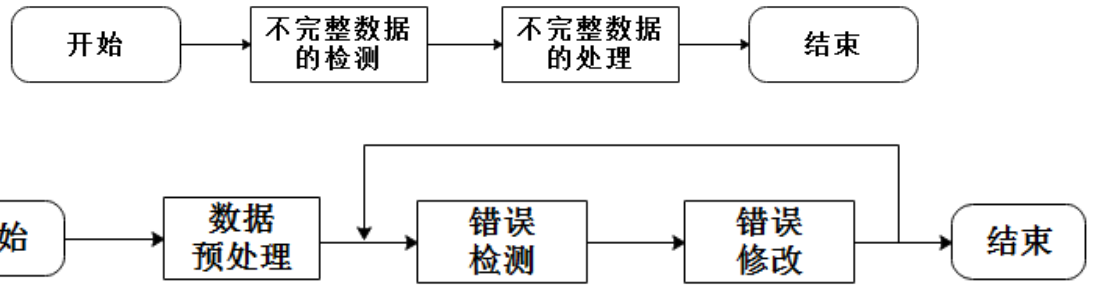
关系型数据库：由一组表组成，每个表分配一个唯一的名称。SQL（Structured query language）常用来管理关系型数据库



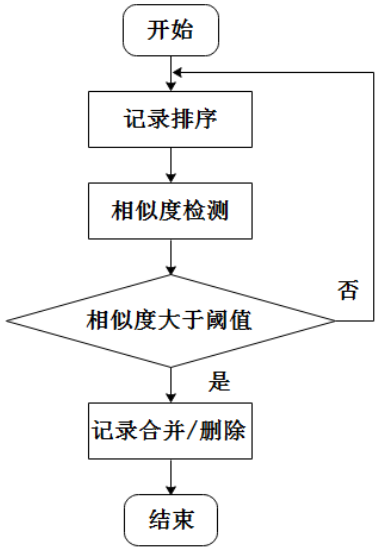
非关系型数据库：NoSQL (Not only SQL)

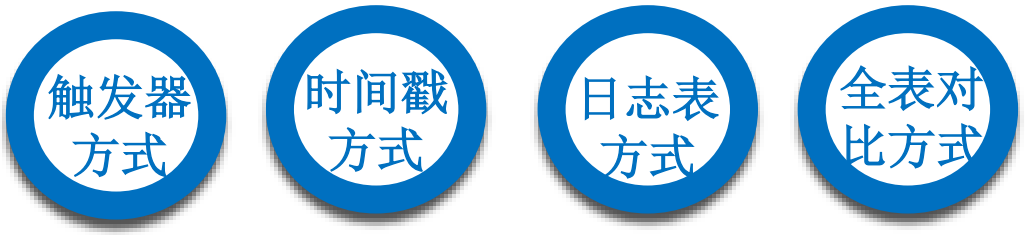


ETL的关键技术











1. 全量加载
2. 批量加载
3. 增量加载

常见ETL工具介绍

1. Pentaho Kettle

Kettle是一款国外免费开源的ETL工具，纯java语言编写，可以在Windows、Linux、Unix系统上运行，并且是绿色无需安装的。Kettle设计理念是希望把来自不同数据库中的数据放到一个“壶”里，然后以一种指定的格式流出。

2. Hawk

Hawk依据GPL协议开源，基于C#语言编写的，并且其前端界面是使用WPF开发，支持插件扩展。Hawk能够灵活、有效地采集来自网页、数据库和文件等来源的数据，并通过可视化地拖拽操作，快速地进行生成、过滤及转换等操作。Hawk主要应用于爬虫和数据清洗等领域。

3. Informatica PowerCenter

Informatica PowerCenter是Informatica公司开发的世界级的企业数据集成平台，也是业界领先的ETL工具。Informatica PowerCenter用于访问和集成几乎任何业务系统、任何格式的数据，它可按任意速度在企业内交付数据，具有高性能、高可扩展性、高可用性的特点。

4. DataStage

IBM的InfoSphere DataStage是可跨多个企业系统集成数据。DataStage利用高性能并行框架，可根据项目需求，在云中或者本地部署ETL环境，它支持HBase、Hive、Amazon以及MongoDB等数据库的连接，可以灵活、有效的更新和管理数据继承的基础架构。

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

目 录

1 认识数据

2 数据预处理

3 数据可视化



数据可视化

- 数据可视化是指信息和数据的图形化表示
- 数据可视化是查看和了解数据中趋势、异常值和模式的便利方式
  - 在大数据领域，数据可视化工具和技术对于分析海量信息并制定数据驱动型决策而言至关重要



大数据可视化的常用图表

- https://echarts.apache.org/examples/zh/index.html#chart-type-line



du.cn

- **可视化不仅仅是简单地对图表进行装饰好让它看起来更美观，也不是突出显示信息图的“信息”部分。有效的数据可视化需要在形式和功能之间找到微妙的平衡**
  - 最朴素的图表可能太过乏味而无法吸引人的注意，也可能会表达出强有力的观点
  - 最华丽的可视化可能完全无法传达正确的信息，也可能会含有丰富的信息

不同类型数据的可视化

- **时序数据的可视化**
  - 数据集中的每一项包含时间信息，如开始和结束时间
- **层次数据的可视化**
  - 层次数据具有等级或层级关系
- **网络数据的可视化**
  - 网络数据表现为更加自由、更加复杂的关系网络
- **多维数据的可视化**
  - 将多维数据信息降维投影

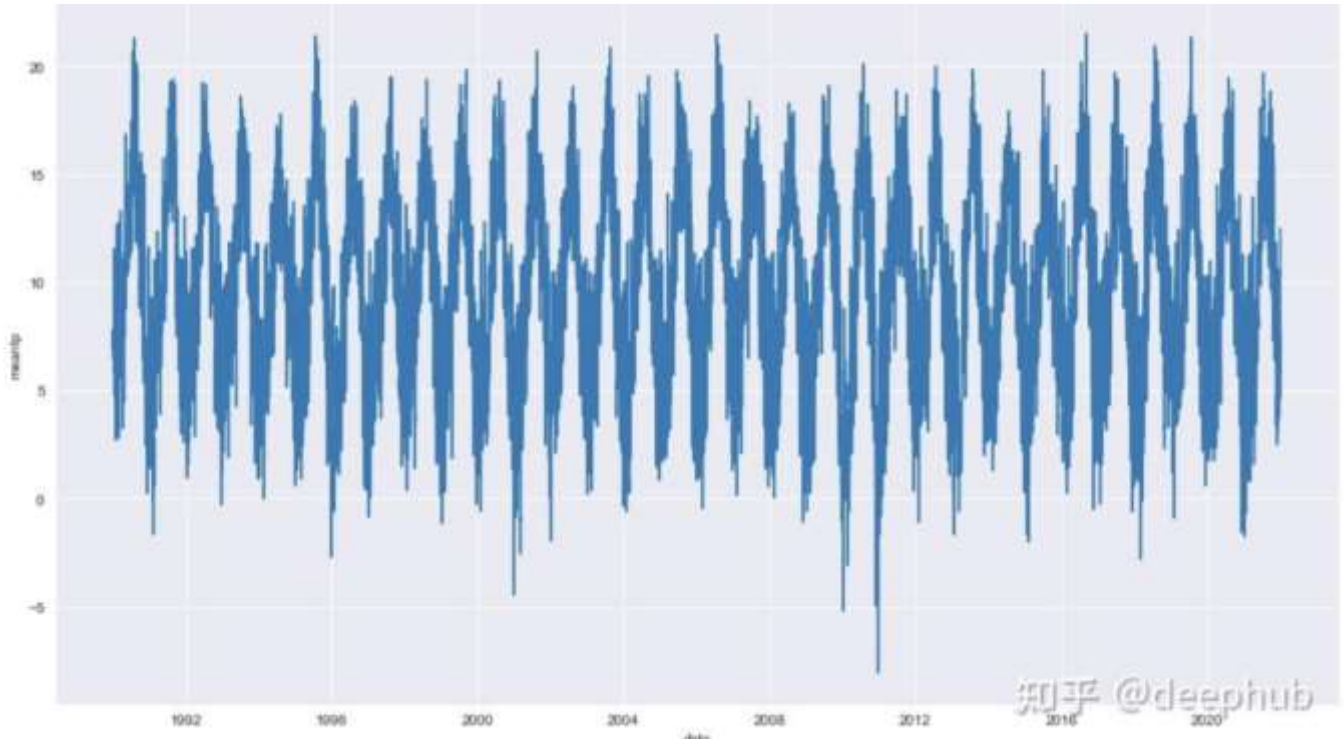
时序数据的可视化

- 例：都柏林机场每日数据，包含自1942年以来在都柏林机场测量的气象数据。数据集包含每日天气信息，如温度、风速、气压等

	date	ind	maxtp	ind.1	mintp	igmin	gmin	ind.2	rain	cbl	...	hg	sun
29458	2022-08-27	0	19.9	0	6.6	0	3.7	3	0.0	1011.2	...	16	11.5
29459	2022-08-28	0	17.8	0	9.8	0	6.7	2	0.0	1012.8	...	17	0.0
29460	2022-08-29	0	21.5	0	12.0	0	9.6	3	0.0	1014.3	...	19	7.7
29461	2022-08-30	0	19.1	0	10.5	0	9.2	3	0.0	1016.8	...	19	8.1

时序数据的可视化

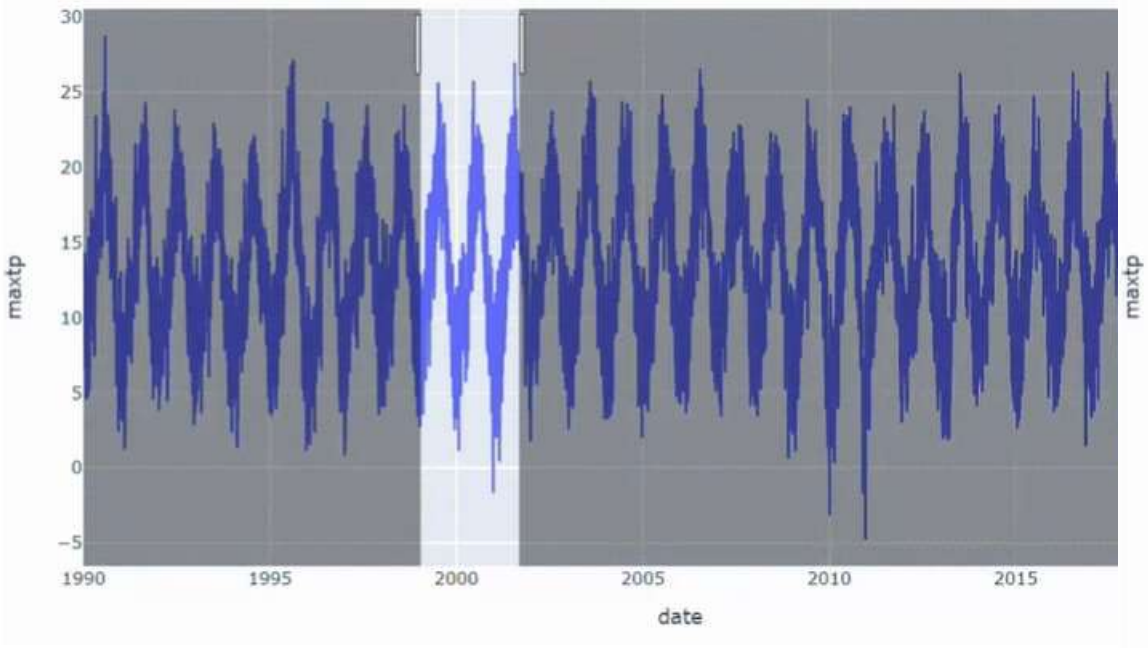
- 选择数据范围：1990-2021年；选择属性：最高和最低温度
- 绘制基本的时序图

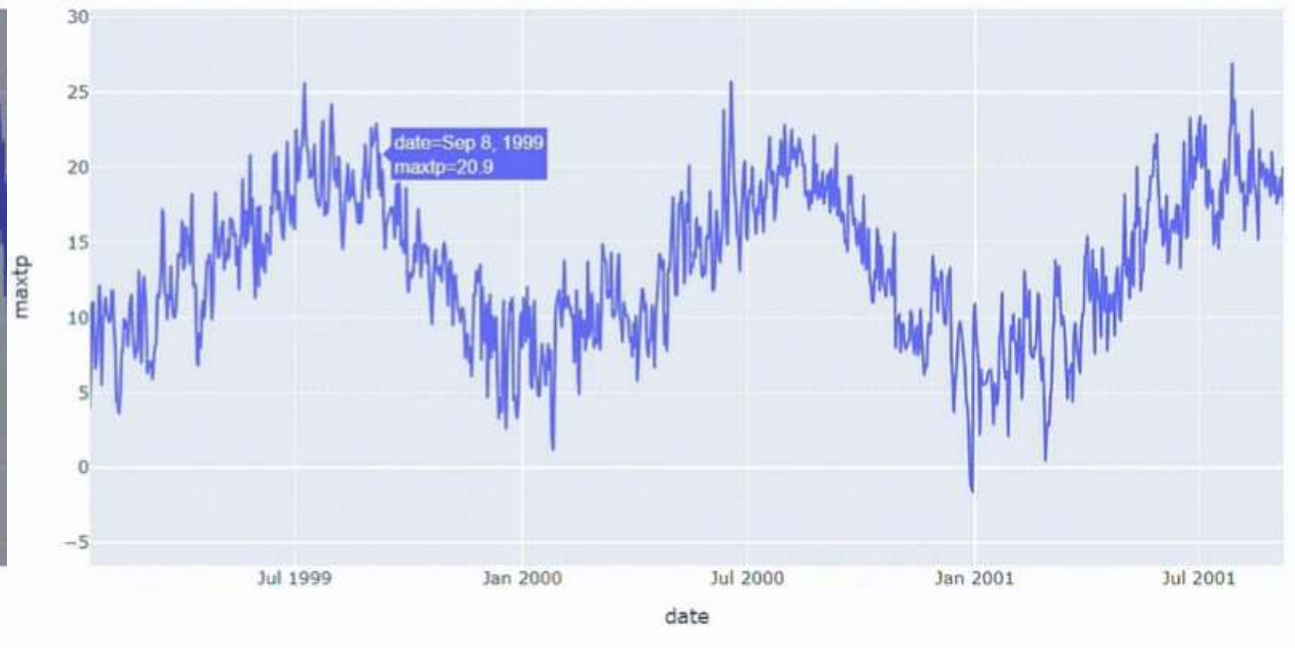


	date	maxtp	mintp	meantp
0	1990-01-01	9.7	4.3	7.00
1	1990-01-02	10.0	5.6	7.80
2	1990-01-03	8.3	4.6	6.45
3	1990-01-04	11.7	3.7	7.70
4	1990-01-05	11.1	4.6	7.85

时序数据的可视化

- 处理超长时间序列数据的可视化：**创建交互式图表，结果可以放大或缩小以查看更多细节**



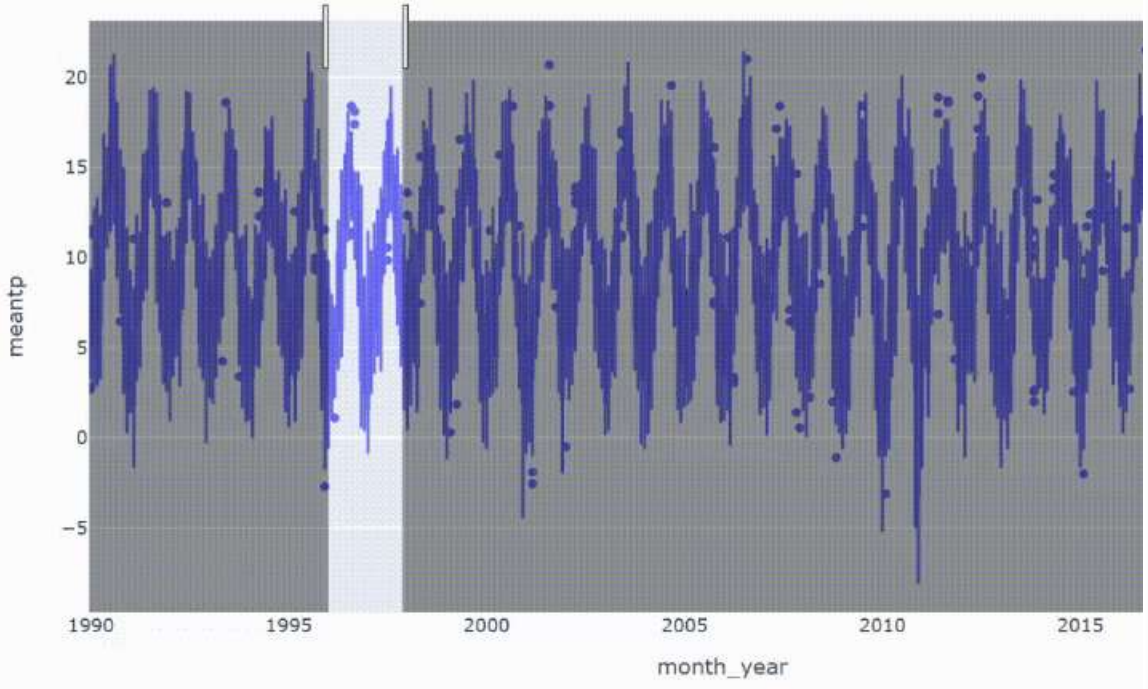


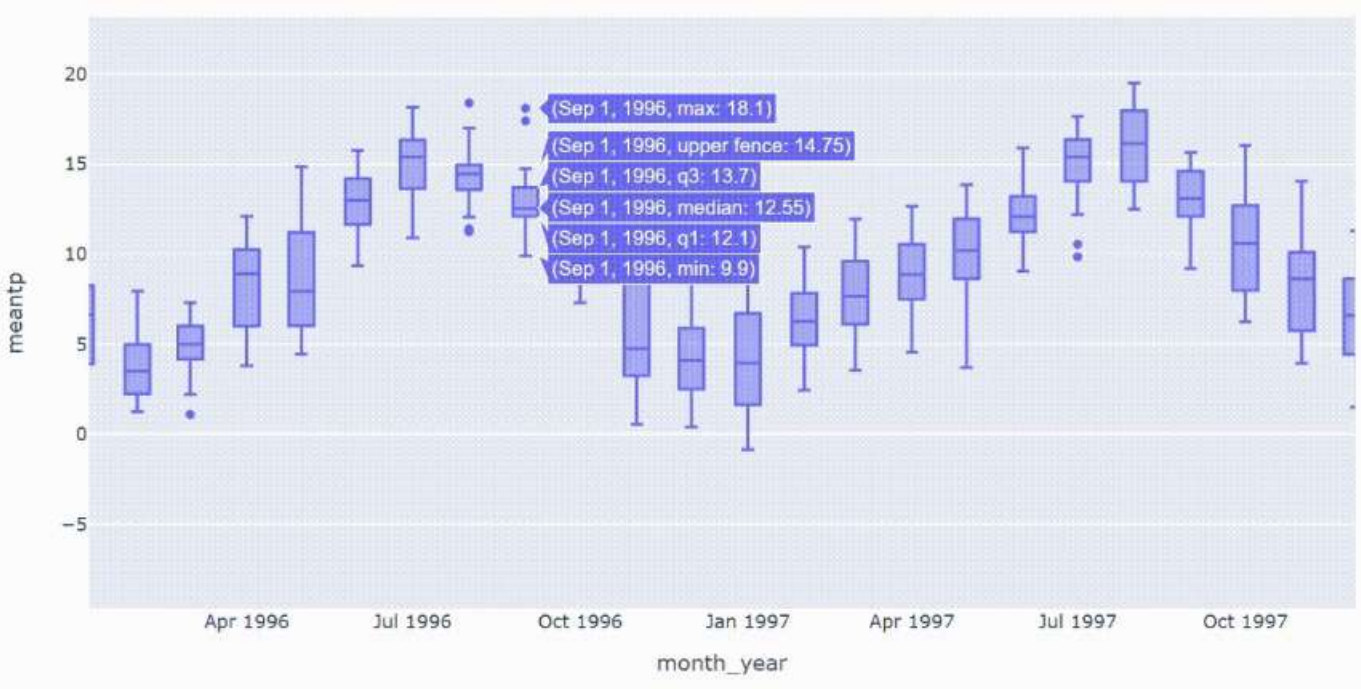




时序数据的可视化

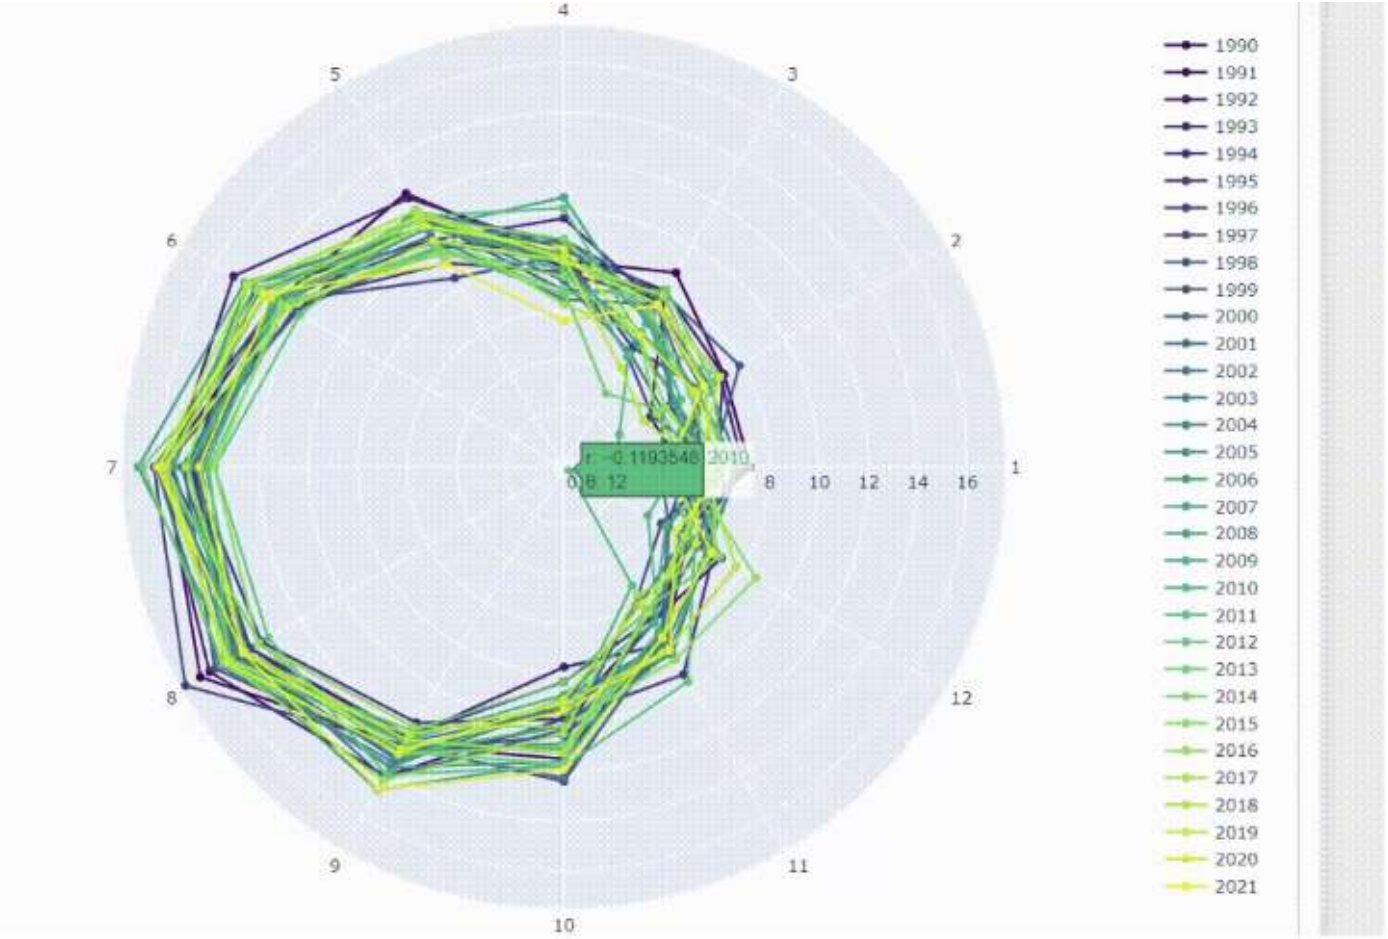
- 处理超长时间序列数据的可视化：查看数据分布
  - **箱形图**是一种通过四分位数展示数据分布的方法。箱形图上的信息显示了局部性、扩散性和偏度，它还有助于区分异常值，即从其他观察中显著突出的数据点。



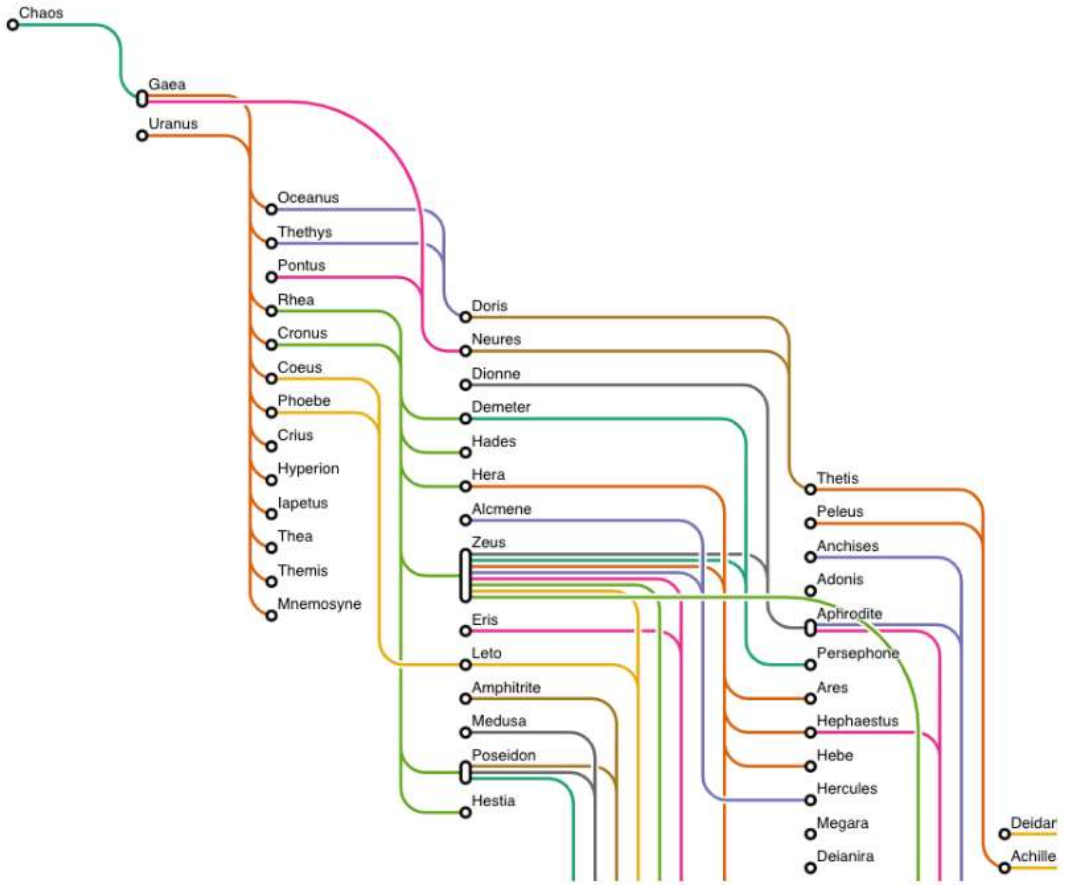


时序数据的可视化

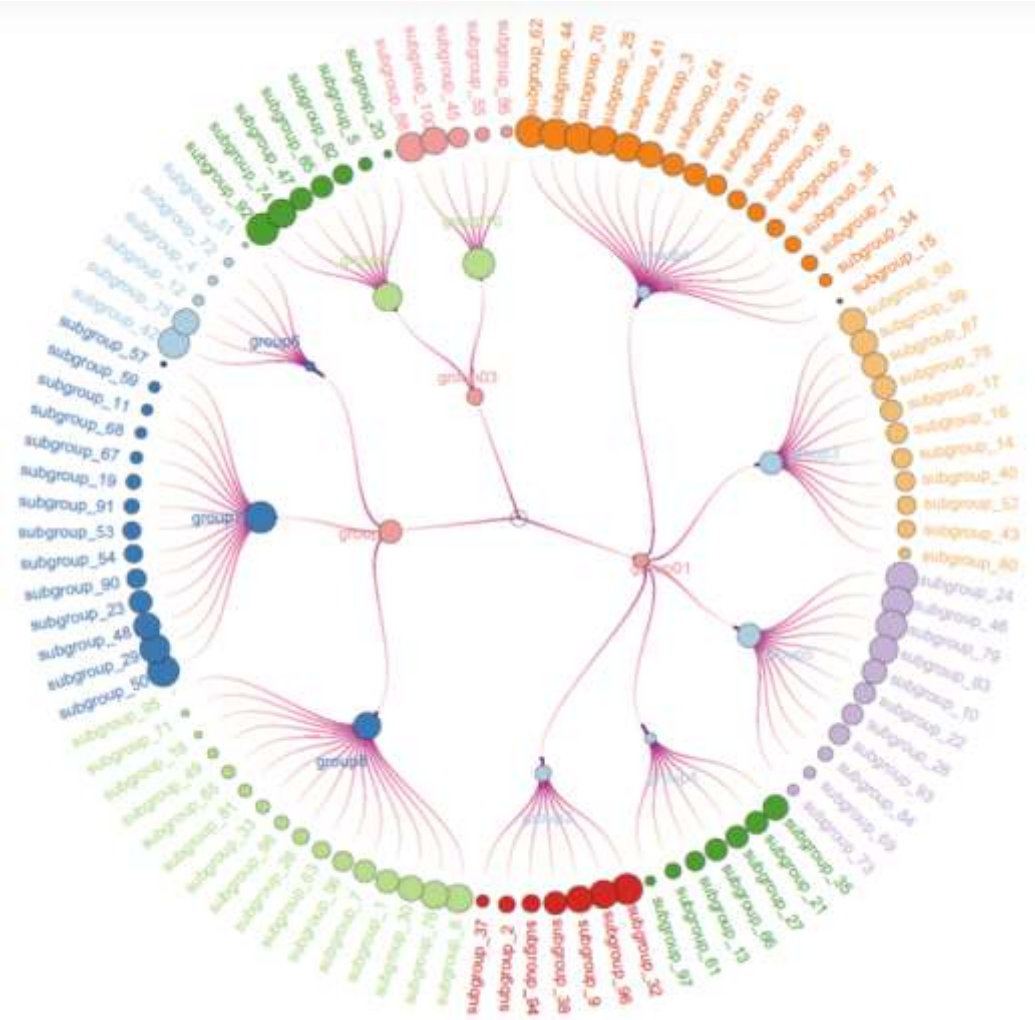
- 处理超长时间序列数据的可视化：用雷达图比较月份
  - 在可视化时间序列数据时，通常会考虑随时间移动的连续线。我们可以改变一下观测方式，将这些线画在圆形中，就像在时钟上移动它们一样。雷达图可以用于比较同一类别数据的可视化图。我们可以通过在圆上绘制月份来比较年份同期的数据值。



层次数据的可视化



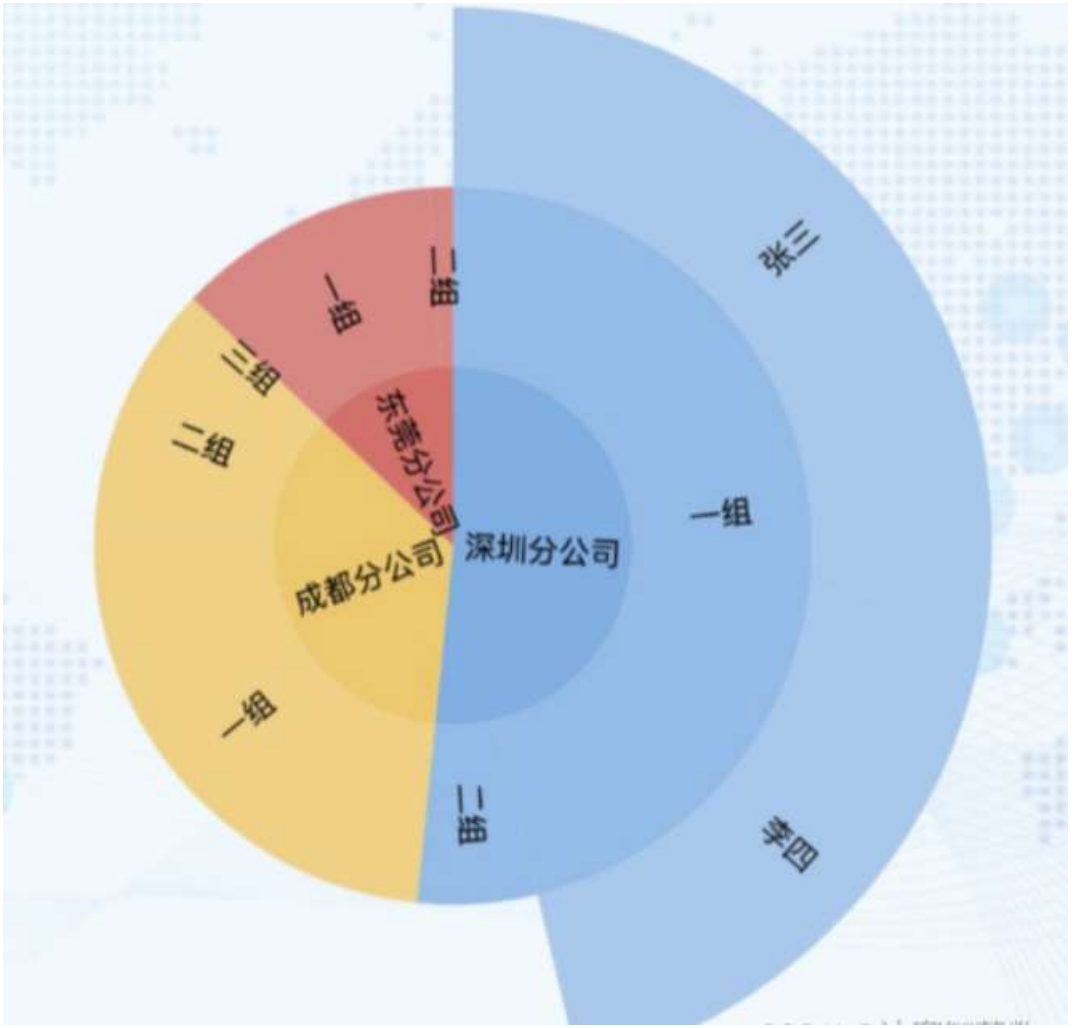
树形结构



节点链接图

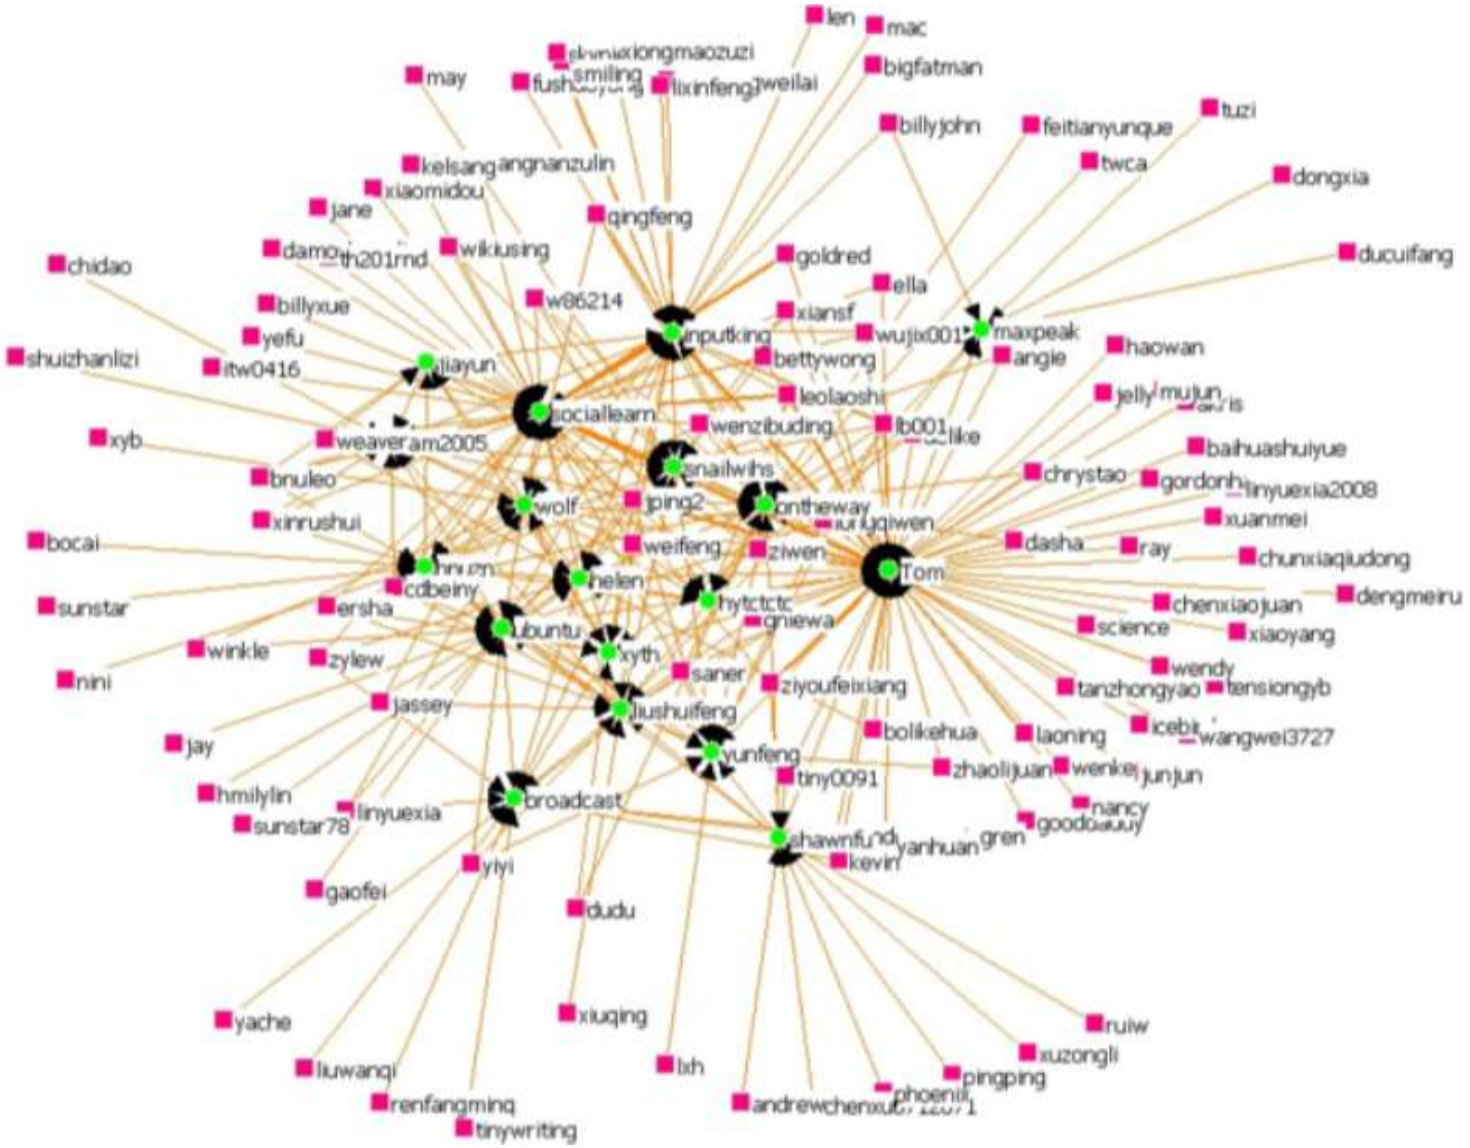
层次化数据的可视化

- 旭日图中每个级别的数据通过1个圆环表示，离原点越近代表圆环级别越高，最内层的圆表示层次结构的顶级，然后一层一层去看数据的占比情况。越往外，级别越低，且分类越细。



旭日图

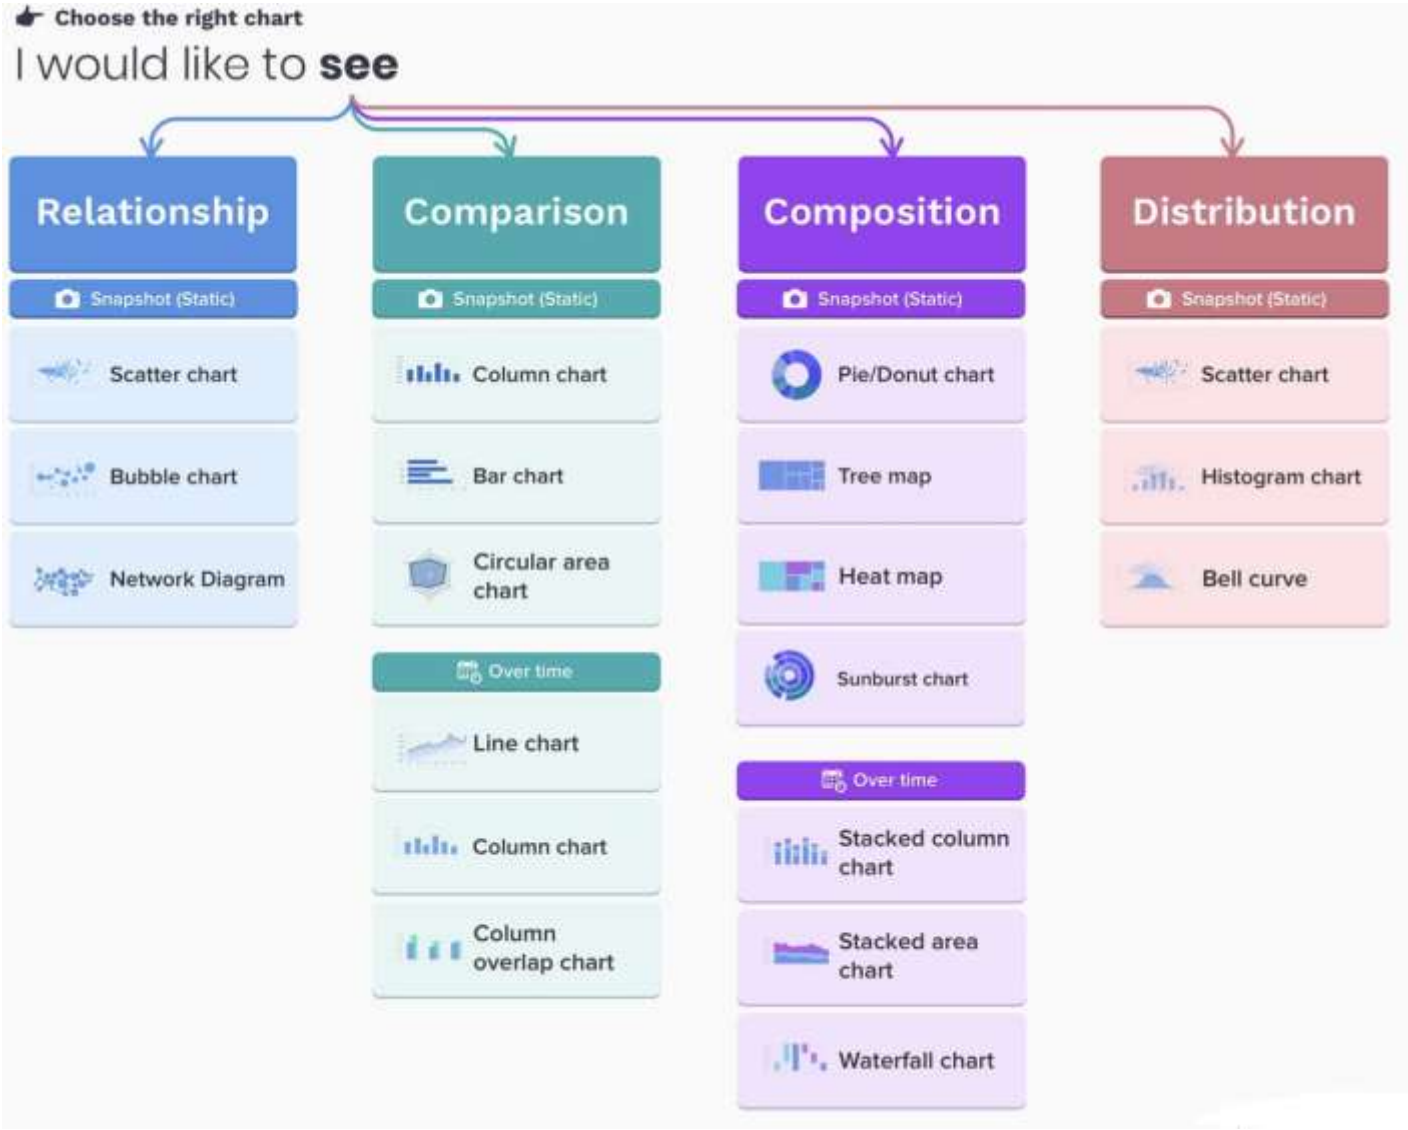
网络数据的可视化


len
mac
bigfatman
may
smiling
lixinfeng
weilai
billyjohn
feitianyunque
tuzi
twca
dongxia
kelsang
angnanzulin
xiaomidou
jane
qingfeng
damo
th201rnd
wikiusing
goldred
ducuifang
chidao
ella
billyxue
w86214
xiansf
yefu
inputking
wujx001
maxpeak
haowan
shuizhanlizi
itw0416
liayun
bettywong
angie
leolaoshi
jelly
mujun
sociallearn
wenzibuding
lb001
xyb
weaveram2005
snailwihs
baihuashuiyue
bnuleo
chrystao
gordonh
tinyuexia2008
wolf
jping2
ontheway
xuanmei
xinrushui
weifeng
ziwen
Tom
dasha
ray
chunxiaqiudong
bocai
cdbeiny
helen
hytctctc
chenxiaojuan
dengmeiru
sunstar
ersha
gniewa
science
xiaoyang
ubuntu
xyth
winkle
zylew
saner
wendy
ziyoufeixiang
tanzhongyao
tensiongyb
nini
jassey
liushuifeng
icebit
wangwei3727
bolikehua
laoning
jay
yunfeng
zhaolijuan
wenke
junjun
tiny0091
hmilylin
broadcast
nancy
linyuexia
sunstar78
shawnfu
yanhuan
gren
kevin
yiyi
gaofei
dudu
yache
xiuqing
ruiw
xuzongli
liuwanqi
lxh
pingping
renfangming
tinywriting

数据可视化的一些Tips

选择正确的图表类型

- 不同的图表类型所承担的功能是截然不同的
- 不合理的数据呈现会容易让用户误读。同样的数据可以使用不同的图表呈现出不同方面特征
- 因此，在设计信息图之前，先理清需求，再来选择使用哪种图表能够更好地呈现



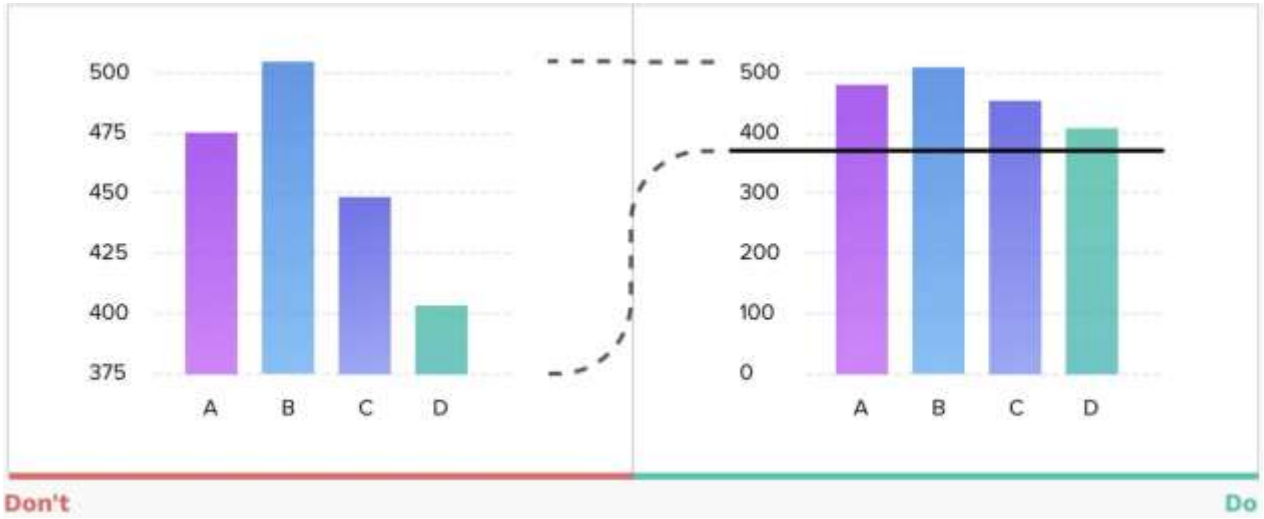
根据数据的正负值选择正确的绘图方向

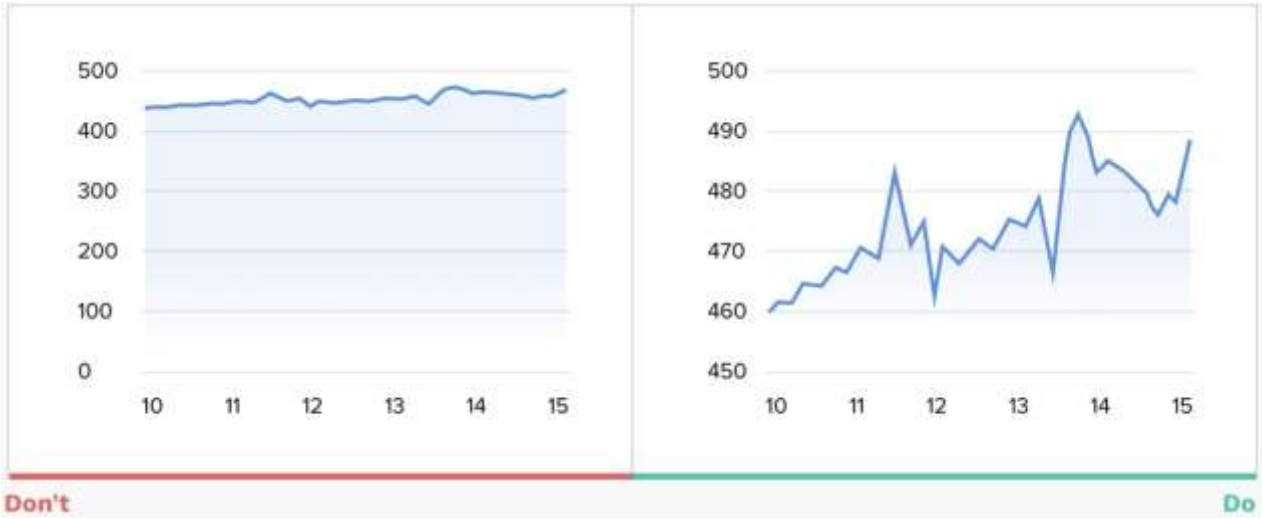
- 当使用数据在0的左右波动，产生正负差异的时候，请使用基线来正确反映正负关系，不要在同一侧来呈现数据，这样很容易带来误读。



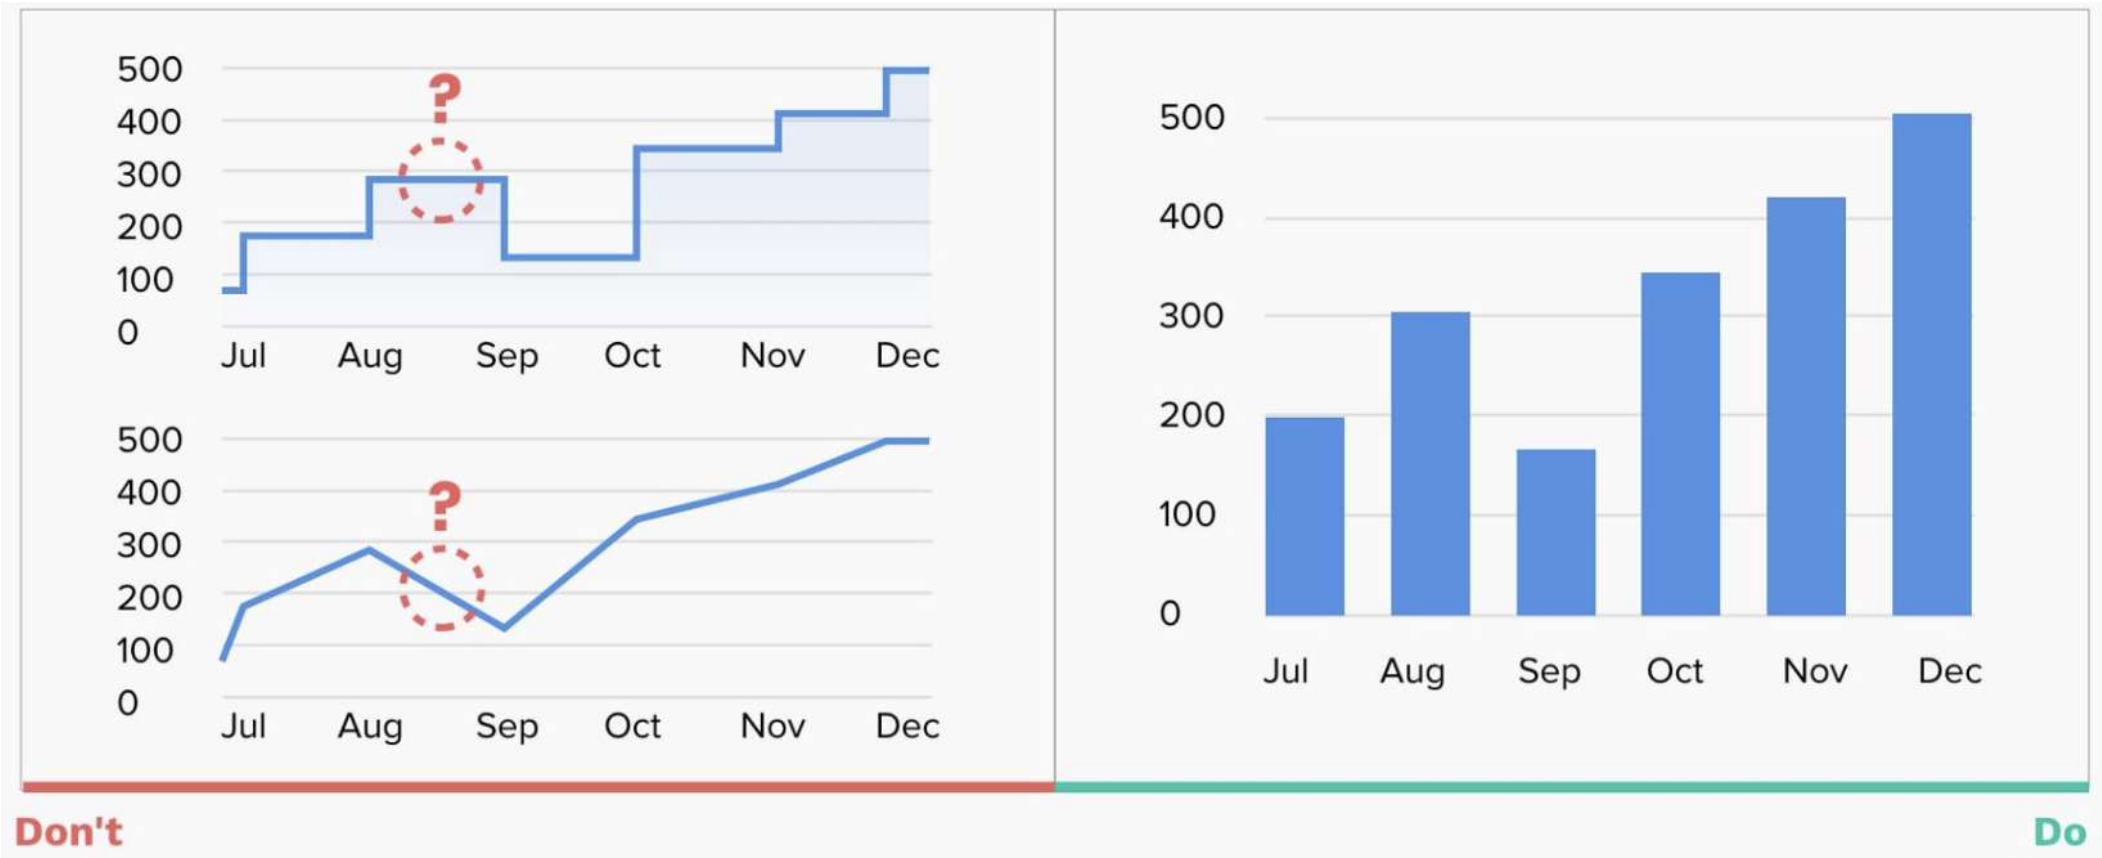
刻度的影响：条形图和折线图

根据图例选择合适的刻度范围



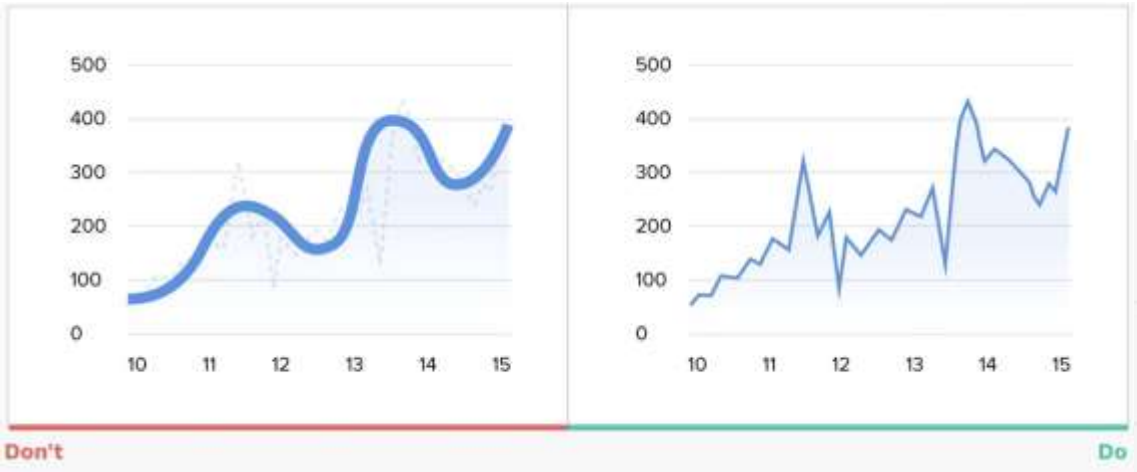


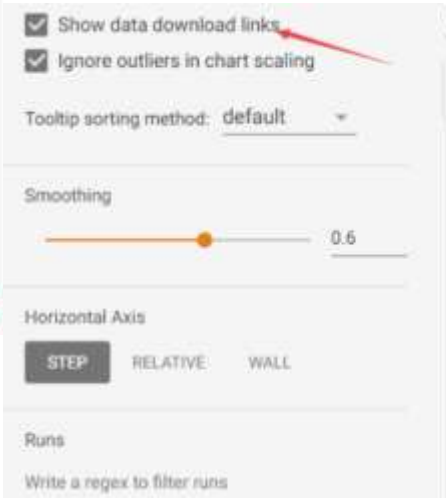
使用折线图的时候注意时间刻度

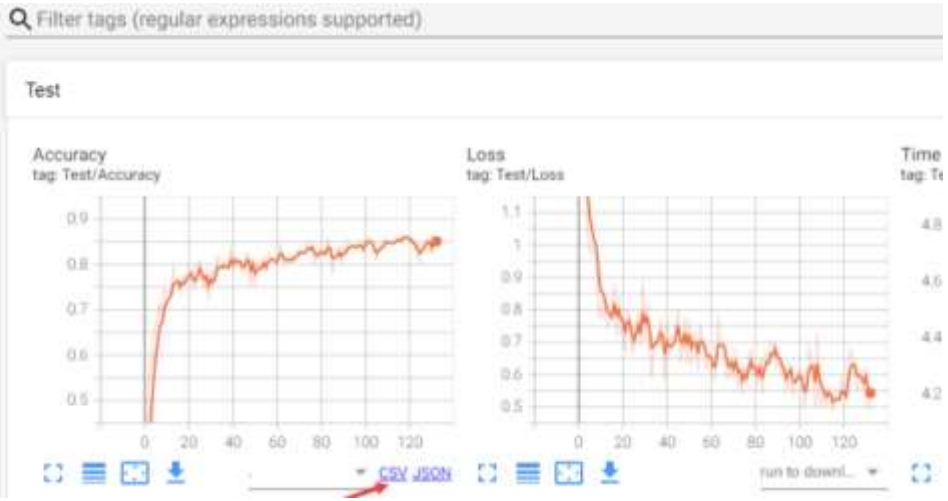


折线图的平滑

- 平滑的折线在视觉上看起来是愉悦，但是它歪曲了背后的实际数据，也很难读到关键的转折点数据。
- 但有的时候我们关注的是趋势，比如机器学习的训练曲线

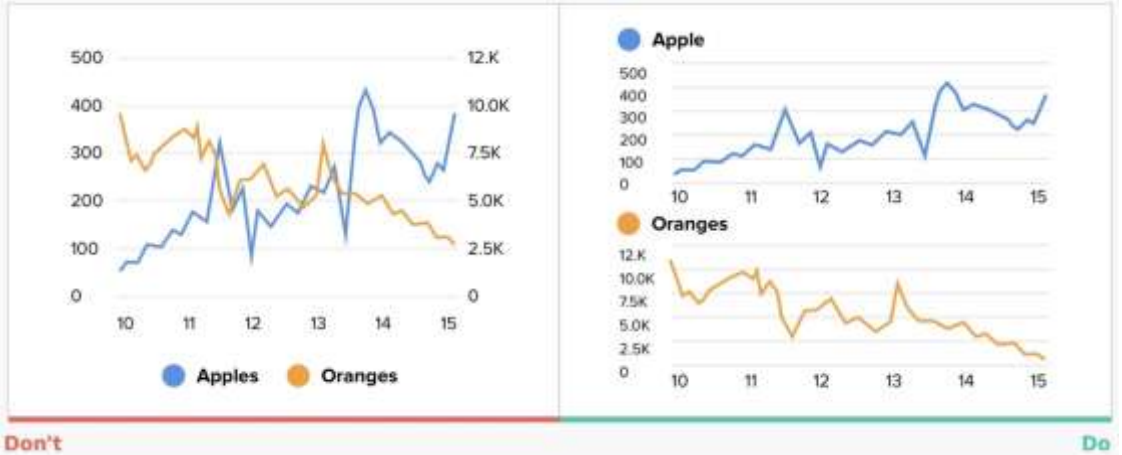




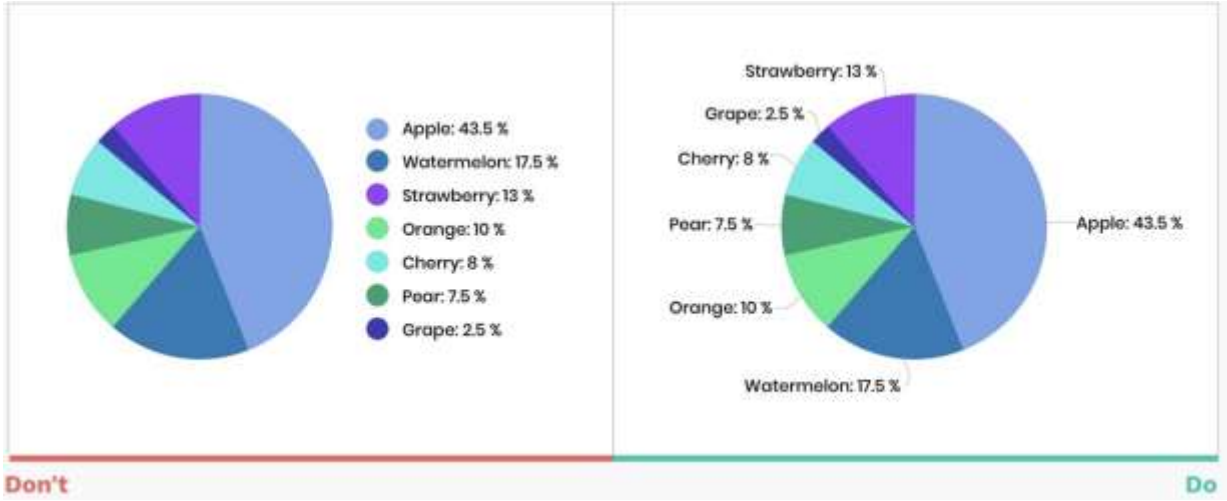


数据可视化的一些Tips

- 避免让双折线互相交叉
- 限制饼图中的扇形的数量
  - 不要超过7个不同的扇区，让饼图尽量简单
  - 可以将额外的片段分组到「其他」的扇区中
- 在饼状图中直接标注对应的数据

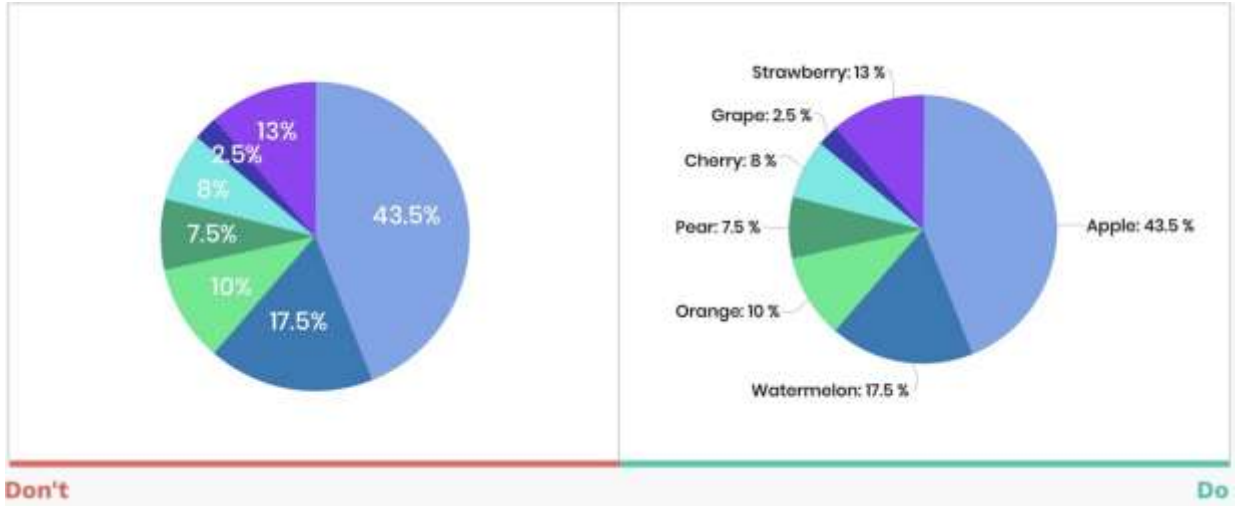






数据可视化的一些Tips

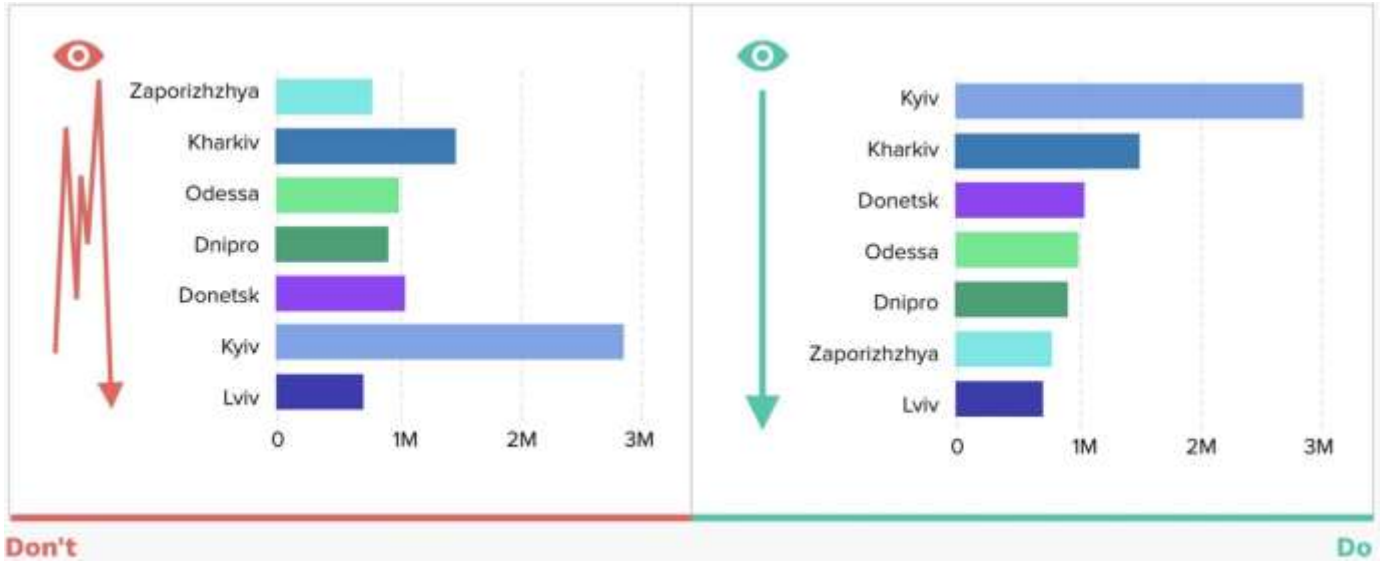
- 不要在扇面上做标注
- 控制饼图中扇面的排序让其方便阅读

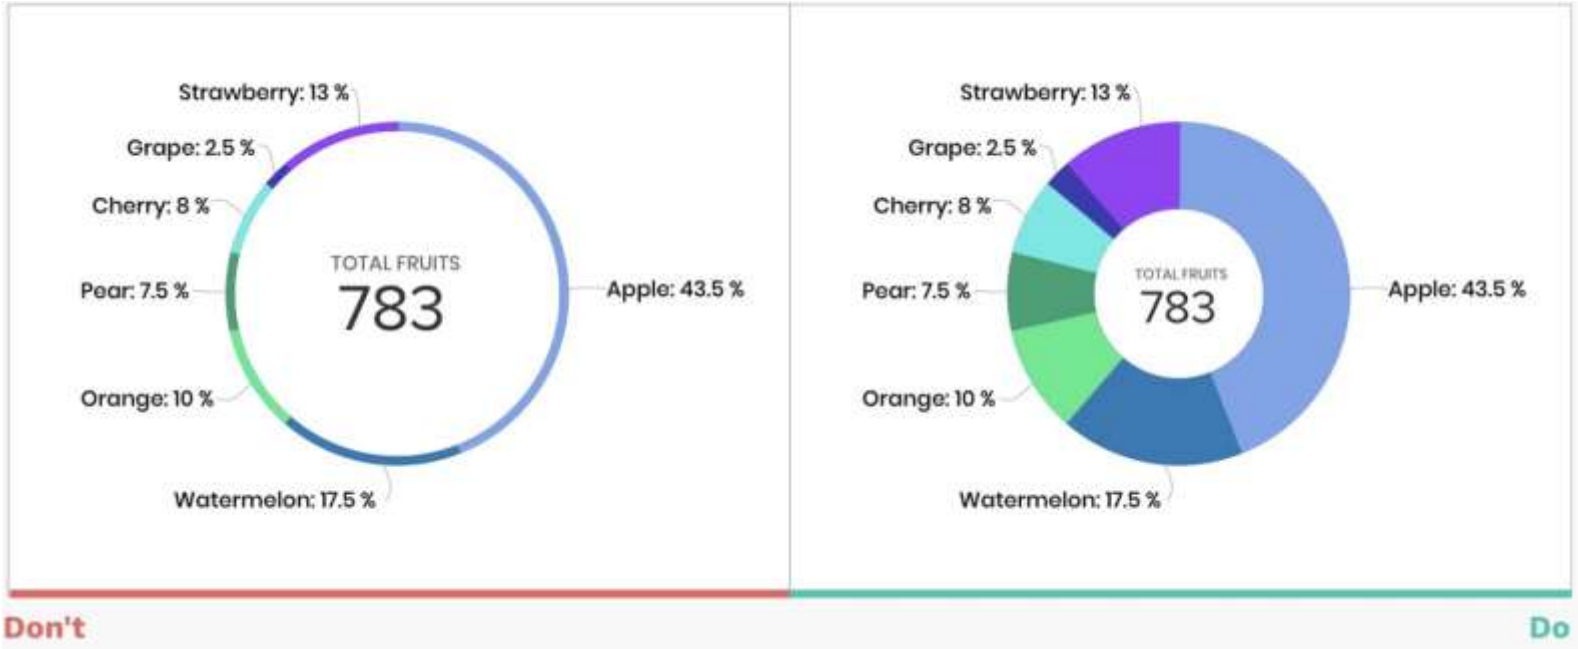




数据可视化的一些Tips

- 避免随机排列
- 不要牺牲信息图的可读性





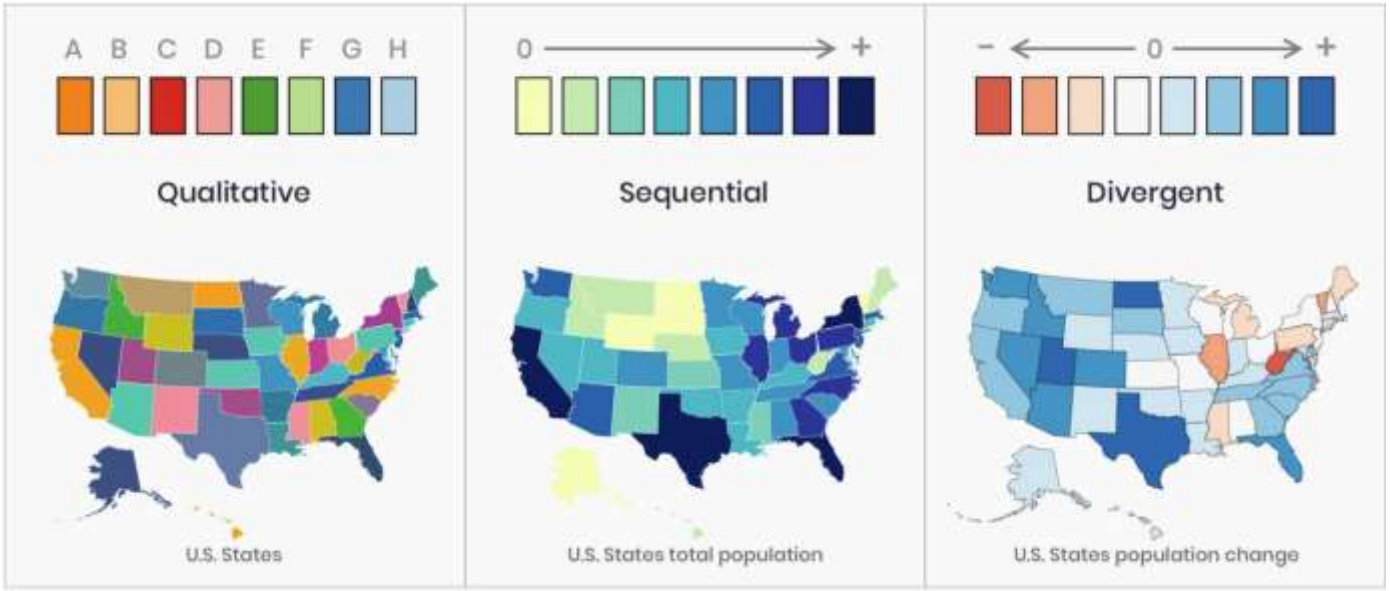
视觉效果不要影响数据的呈现

- 不要让不必要的视觉效果来分散用户的注意力，这可能会导致用户对于数据产生误解，通常你应该**避免使用**：
  - 3D元素和阴影
  - 渐变和失真的色彩
  - 斑马纹或者过多的网格线
  - 装饰性过强的字体



选择和数据属性匹配的配色

- 配色是可视化设计的重要部分，在设计的时候可以考虑以下三种不同的配色方案：
  - **定性的配色方案**，不同的色相对应不同的元素，确保在整体配色的可访问性
  - **符合一定顺序（比如明暗）的近似色的配色**，呈现出一种连续的色彩变化
  - **横跨冷暖色调的配色方案**，将中性色置于中间，用来呈现存在正负关系的数据变化



关注内容的易读性

- 选择清晰的非衬线字体，避免使用衬线体和过度装饰的字体
- 避免使用斜体、粗体和全大写字体
- 确保和背景之间的信息对比度
- 不要旋转文本



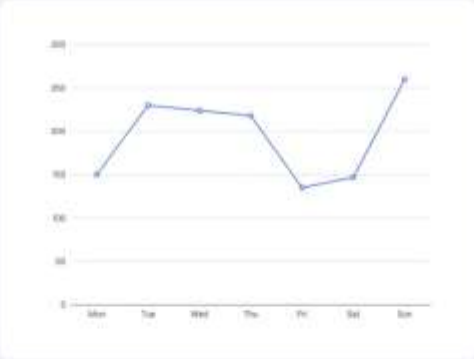
常用的大数据可视化工具

开源工具	商业工具
Processing	Tableau
Many Eyes	Spotfire（TIBCO）
D3.js	QlikView
R（基础包、lattice、ggplot2）	FineBI
ECharts	SAS Visual Analytics
Google Charts	Adobe Illustrator
Flot	HighCharts
Gephi	iCharts
Envision.js	Jolicharts
Prefuse	Dundas Chart
Arbor.js	LightningChart
Chart.js	Microsoft Excel
Paper.js	
NodeBox	

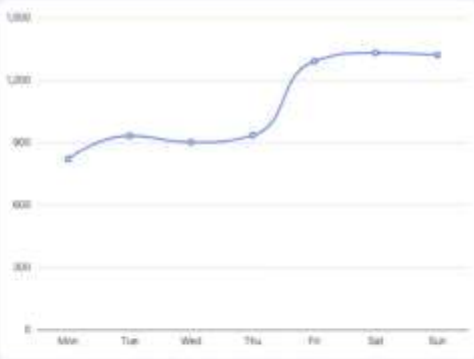
折线图
柱状图
饼图
散点图
地理坐标/地图
K 线图
雷达图
盒须图
热力图
关系图
路径图
树图
矩形树图
旭日图
平行坐标系

折线图 line

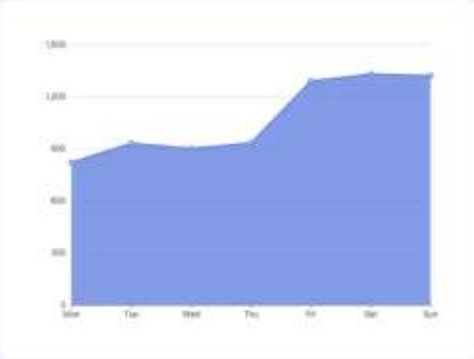
深色模式



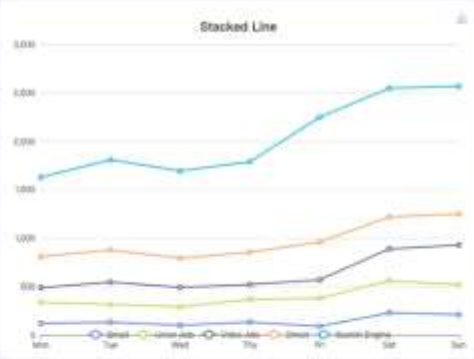
基础折线图
Basic Line Chart



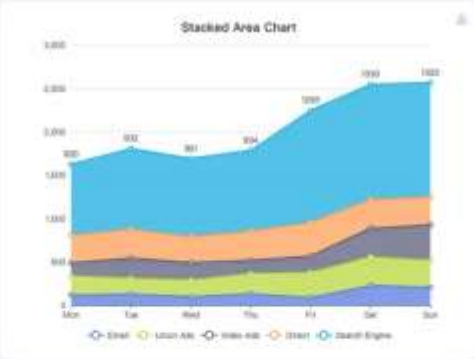
基础平滑折线图
Smoothed Line Chart



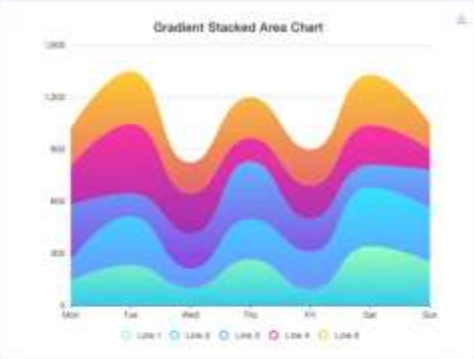
基础面积图
Basic area chart



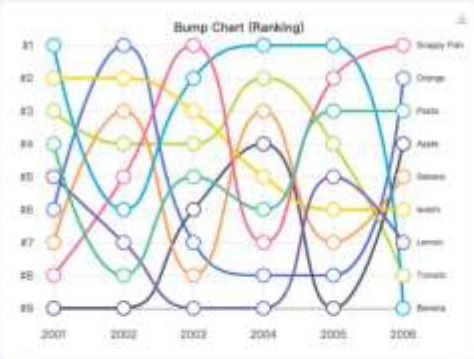
堆叠折线图
Stacked Line Chart



堆叠面积图
Stacked Area Chart



渐变堆叠面积图
Gradient Stacked Area Chart

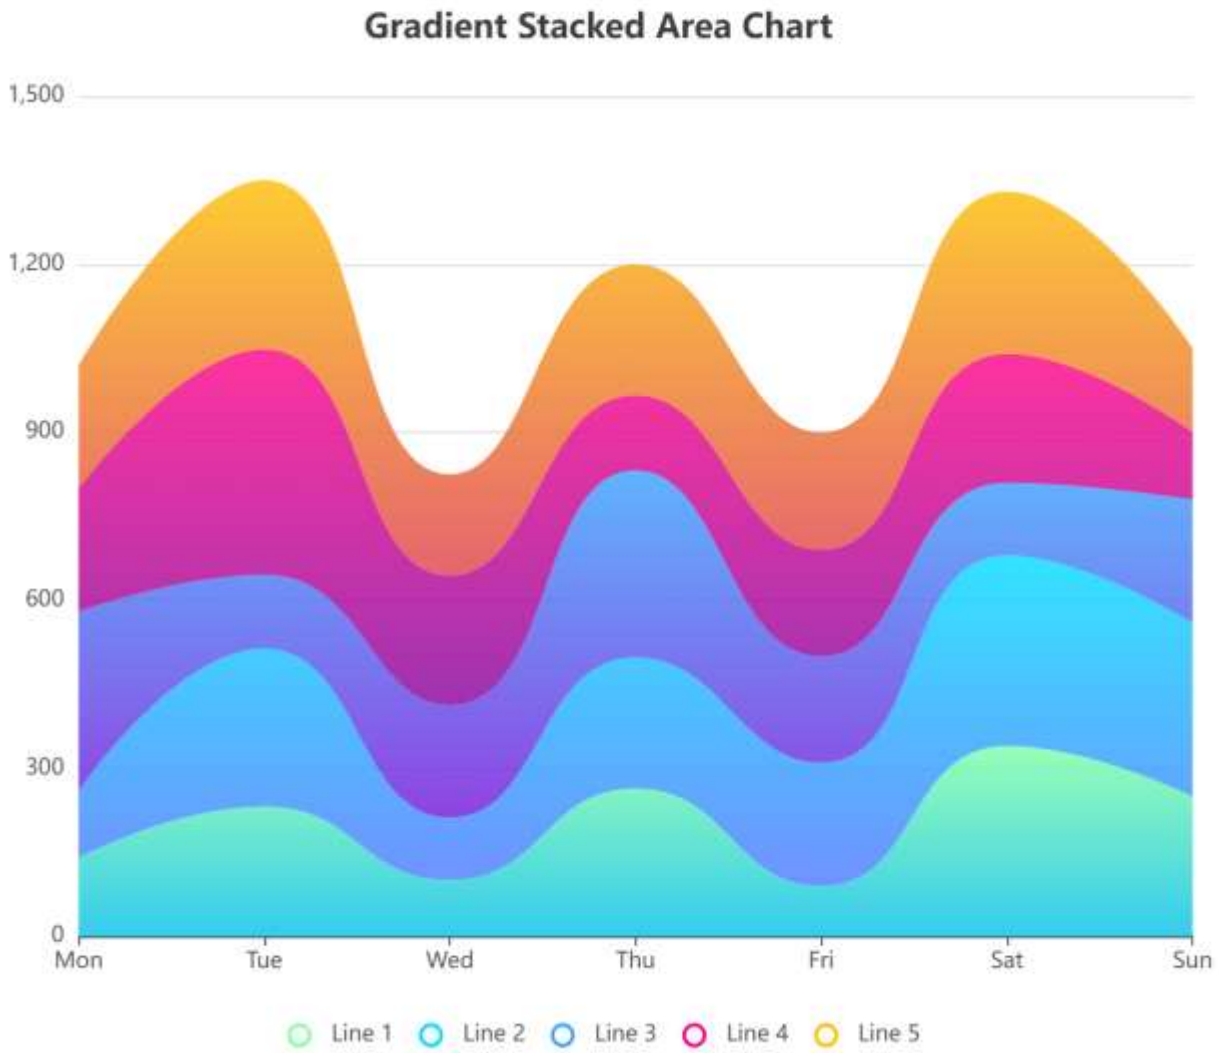


凹凸图
Bump Chart (Ranking)



未来一周气温变化
Temperature Change in the Coming Week

```
option = {
  color: ['#80FFA5', '#00DDFF', '#37A2FF', '#FF0087', '#FFBF00'],
  title: {
    text: 'Gradient Stacked Area Chart'
  },
  tooltip: {
    trigger: 'axis',
    axisPointer: {
      type: 'cross',
      label: {
        backgroundColor: '#6a7985'
      }
    }
  },
  legend: {
    data: ['Line 1', 'Line 2', 'Line 3', 'Line 4', 'Line 5']
  },
  toolbox: {
    feature: {
      saveAsImage: {}
    }
  },
  xAxis: [
    {
      type: 'category',
      boundaryGap: false,
      data: ['Mon', 'Tue', 'Wed', 'Thu', 'Fri', 'Sat', 'Sun']
    }
  ],
  yAxis: [
    {
      type: 'value'
    }
```

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

Thank You

