Hive数据仓库

丁玥
上海交通大学计算机学院
dingyue@sjtu.edu.cn

2026年秋季

饮 水 思 源 • 爱 国 荣 校

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

目 录



1 数据仓库的概念

2 HIVE简介

3 HIVE工作原理

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

目 录



1 数据仓库的概念

2 HIVE简介

3 HIVE工作原理

数据湖、数据仓库和数据集市

- 数据湖（Data Lake）：集中式存储库，允许存储任意规模的原始数据，可以是非结构化、半结构化和结构化数据——无需定义结构，保留数据原貌
- 数据仓库（Data Warehouse）：专为企业级分析、报告和商业智能（BI）设计的核心数字化存储系统——是“仓库”而不是“工厂”，不生产也不消费数据
- 数据集市（Data Mart）：数据仓库的一个子集——针对特定部门或业务场景（如财务、销售）优化
- 数据的流向一般为：数据源 -> 数据湖（原始数据） -> 数据仓库（整合加工） -> 数据集市（特定应用）

数据湖、数据仓库和数据集市

① 数据源

订单表格
（结构化数据）

用户日志
（半结构化数据）

商品图片
（非结构化数据）

采集

② 数据湖
Data Lake



原始数据，保留原貌

先存下来，使用时再解析

ETL / ELT
清洗 · 转换 · 整合

③ 数据仓库
Data Warehouse



统一口径，集中存储

整合后的订单、客户、商品数据
支撑企业级分析与报表

④ 数据集市
Data Mart



销售集市
销售额 · 商品销量

BI 报表



财务集市
收入 · 成本 · 利润

BI 报表

按部门或业务主题组织

数据湖： 原始资料库

数据仓库： 整理好的总仓库

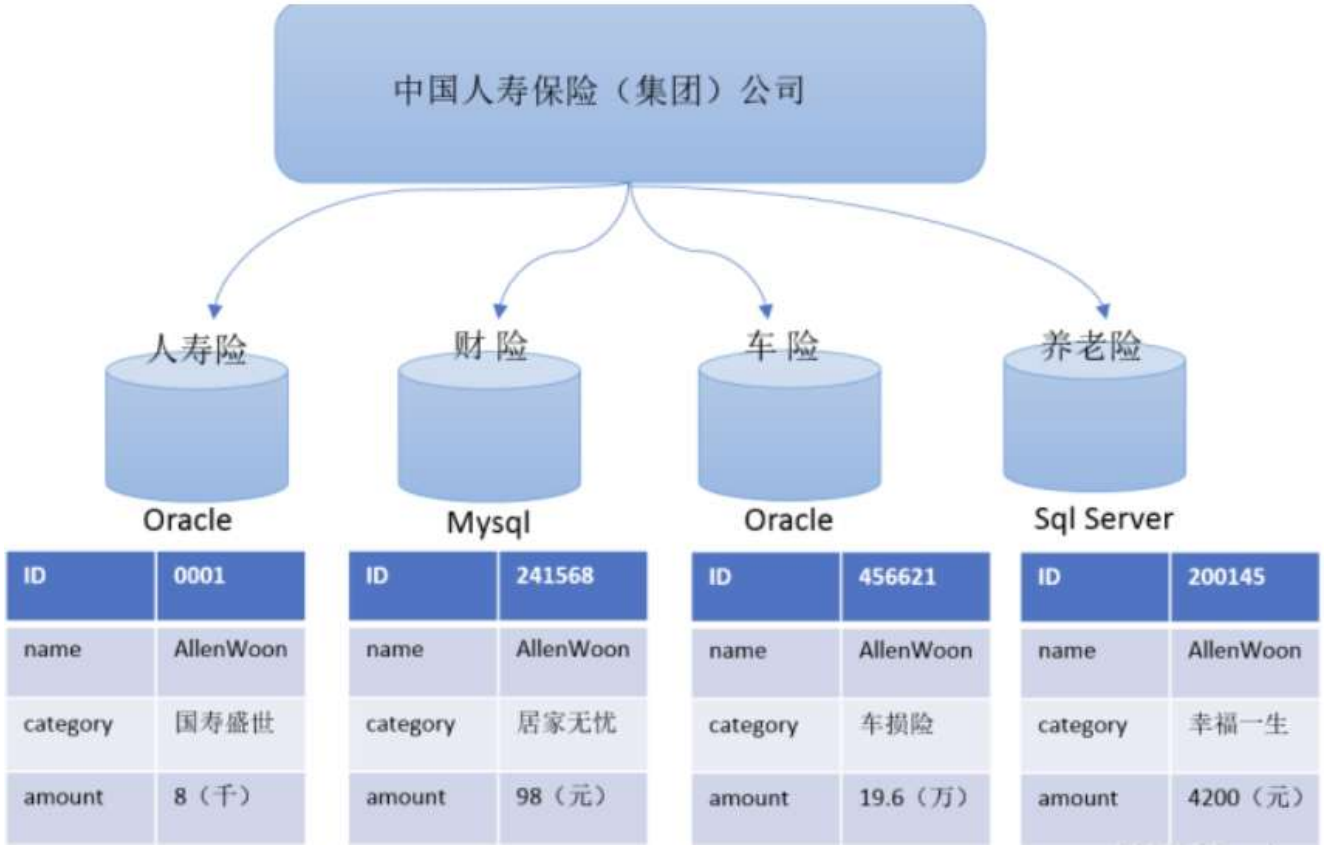
数据集市： 部门专用数据区

为什么要建数据仓库?

- 构建面向分析的集成化数据环境，为企业提供决策支持

案例场景：中国人寿集团

- 面向操作型事务，各业务线的业务正常运营需要记录维护包括客户、保单、收付费、核保、理赔等信息
- 前台接收的用户数据可以立即传送到后台进行处理，并在很短的时间内给出处理结果
- **此类业务是典型的联机事务处理和查询（OnLine Transaction Processing, OLTP）**



问题：随着集团业务的持续运营，业务数据将会越来越多。由此产生出的运营相关困惑

- 能够确定哪些险种正在恶化或已成为不良险种吗?
- 能够用有效的方式制定新增和续保的政策吗?
- 理赔过程有欺诈的可能吗?
- 现在得到的报表是否只是某条业务线的？集团整体层面数据如何?

解决办法：数据驱动决策的制定。基于业务数据开展数据分析，基于分析的结果给决策提供支撑

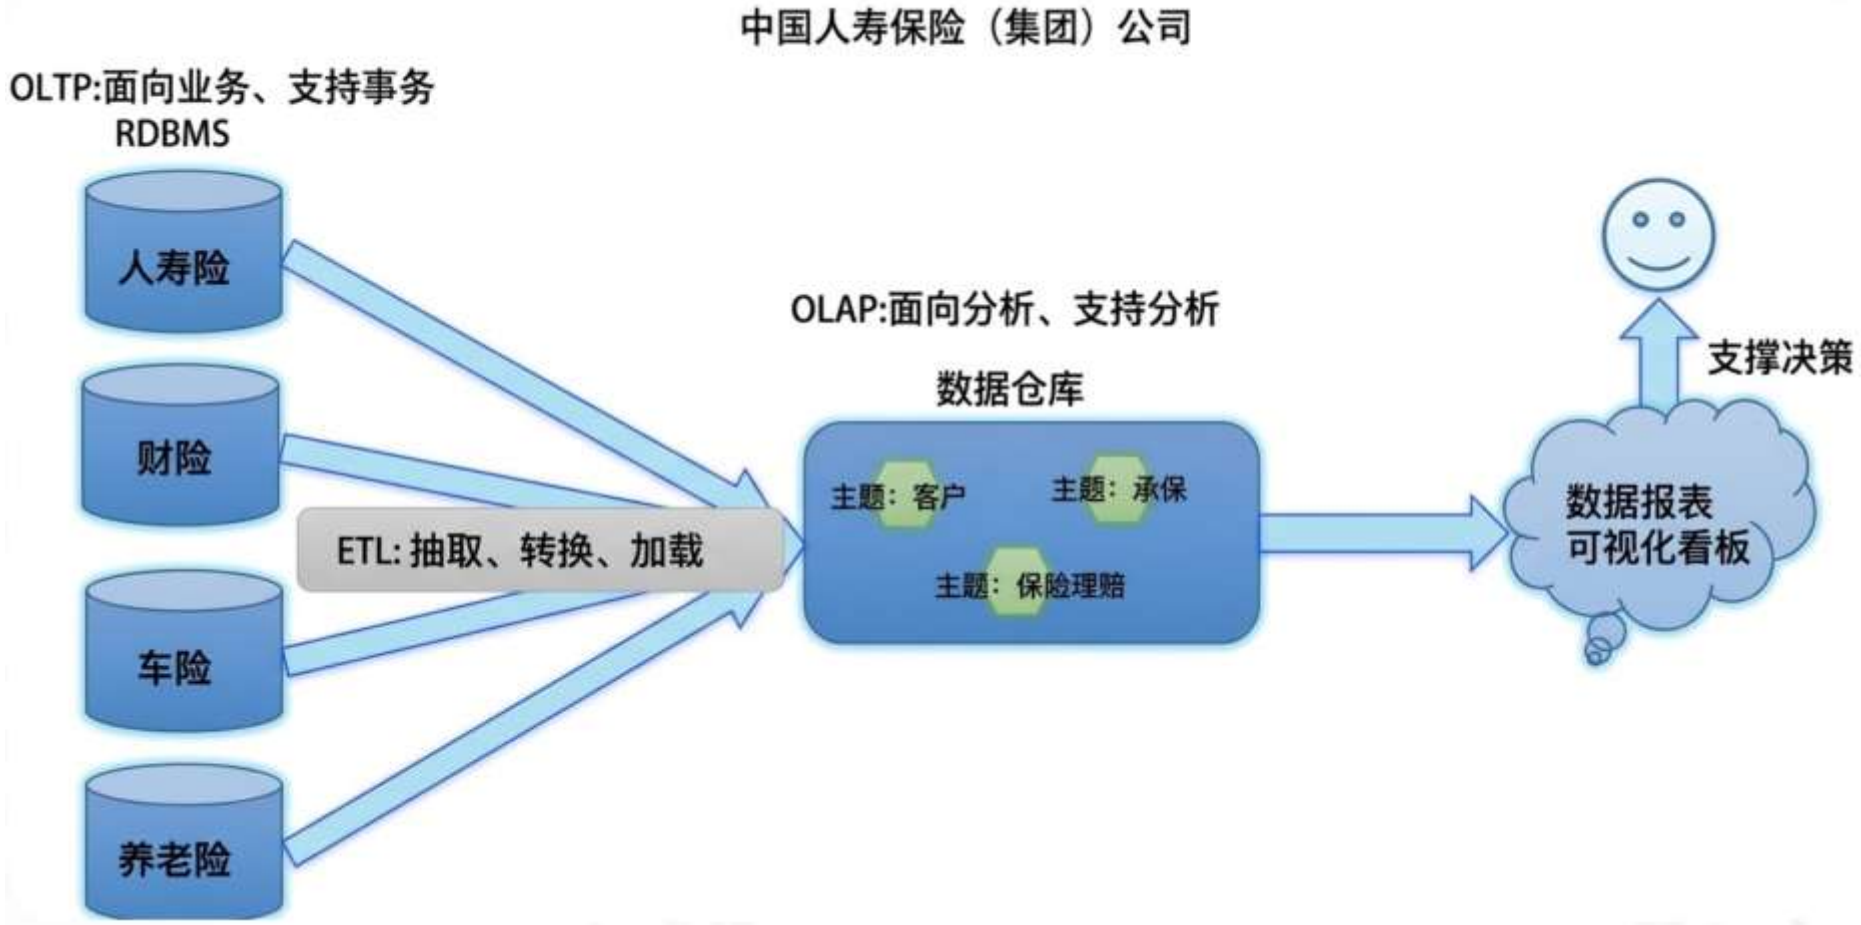


问题：可以直接在OLTP开展分析吗？

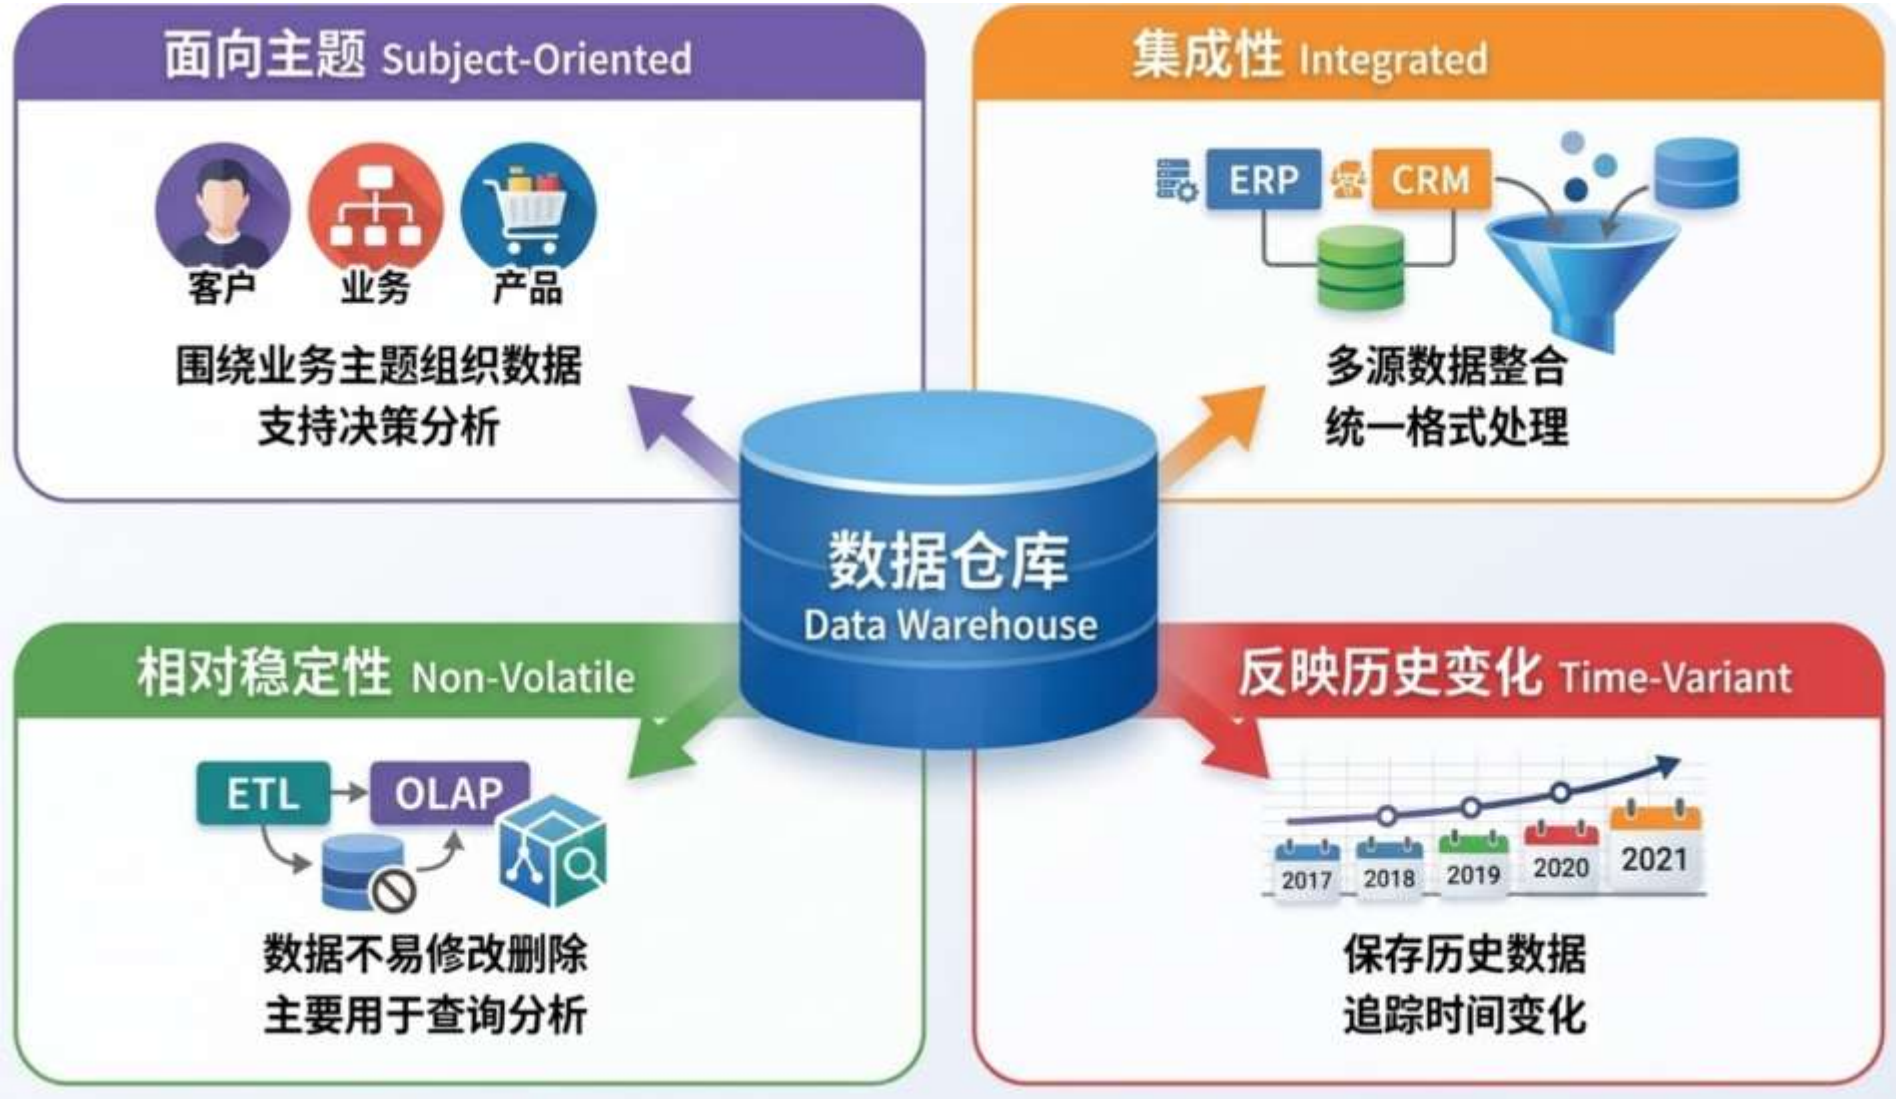
- 可以，但不合适
  - 数据分析也是对数据进行读取操作，会让读取压力倍增
  - OLTP仅存储数周或数月的数据
  - 数据分散在不同系统不同表中，字段类型属性不统一
- OLTP主要面向业务，支持事务。当面向分析时，我们希望能够有另外一个和OLTP解耦的平台，在分析数时不影响OLTP系统的运行

基于这种需求，数据仓库的雏形开始出现

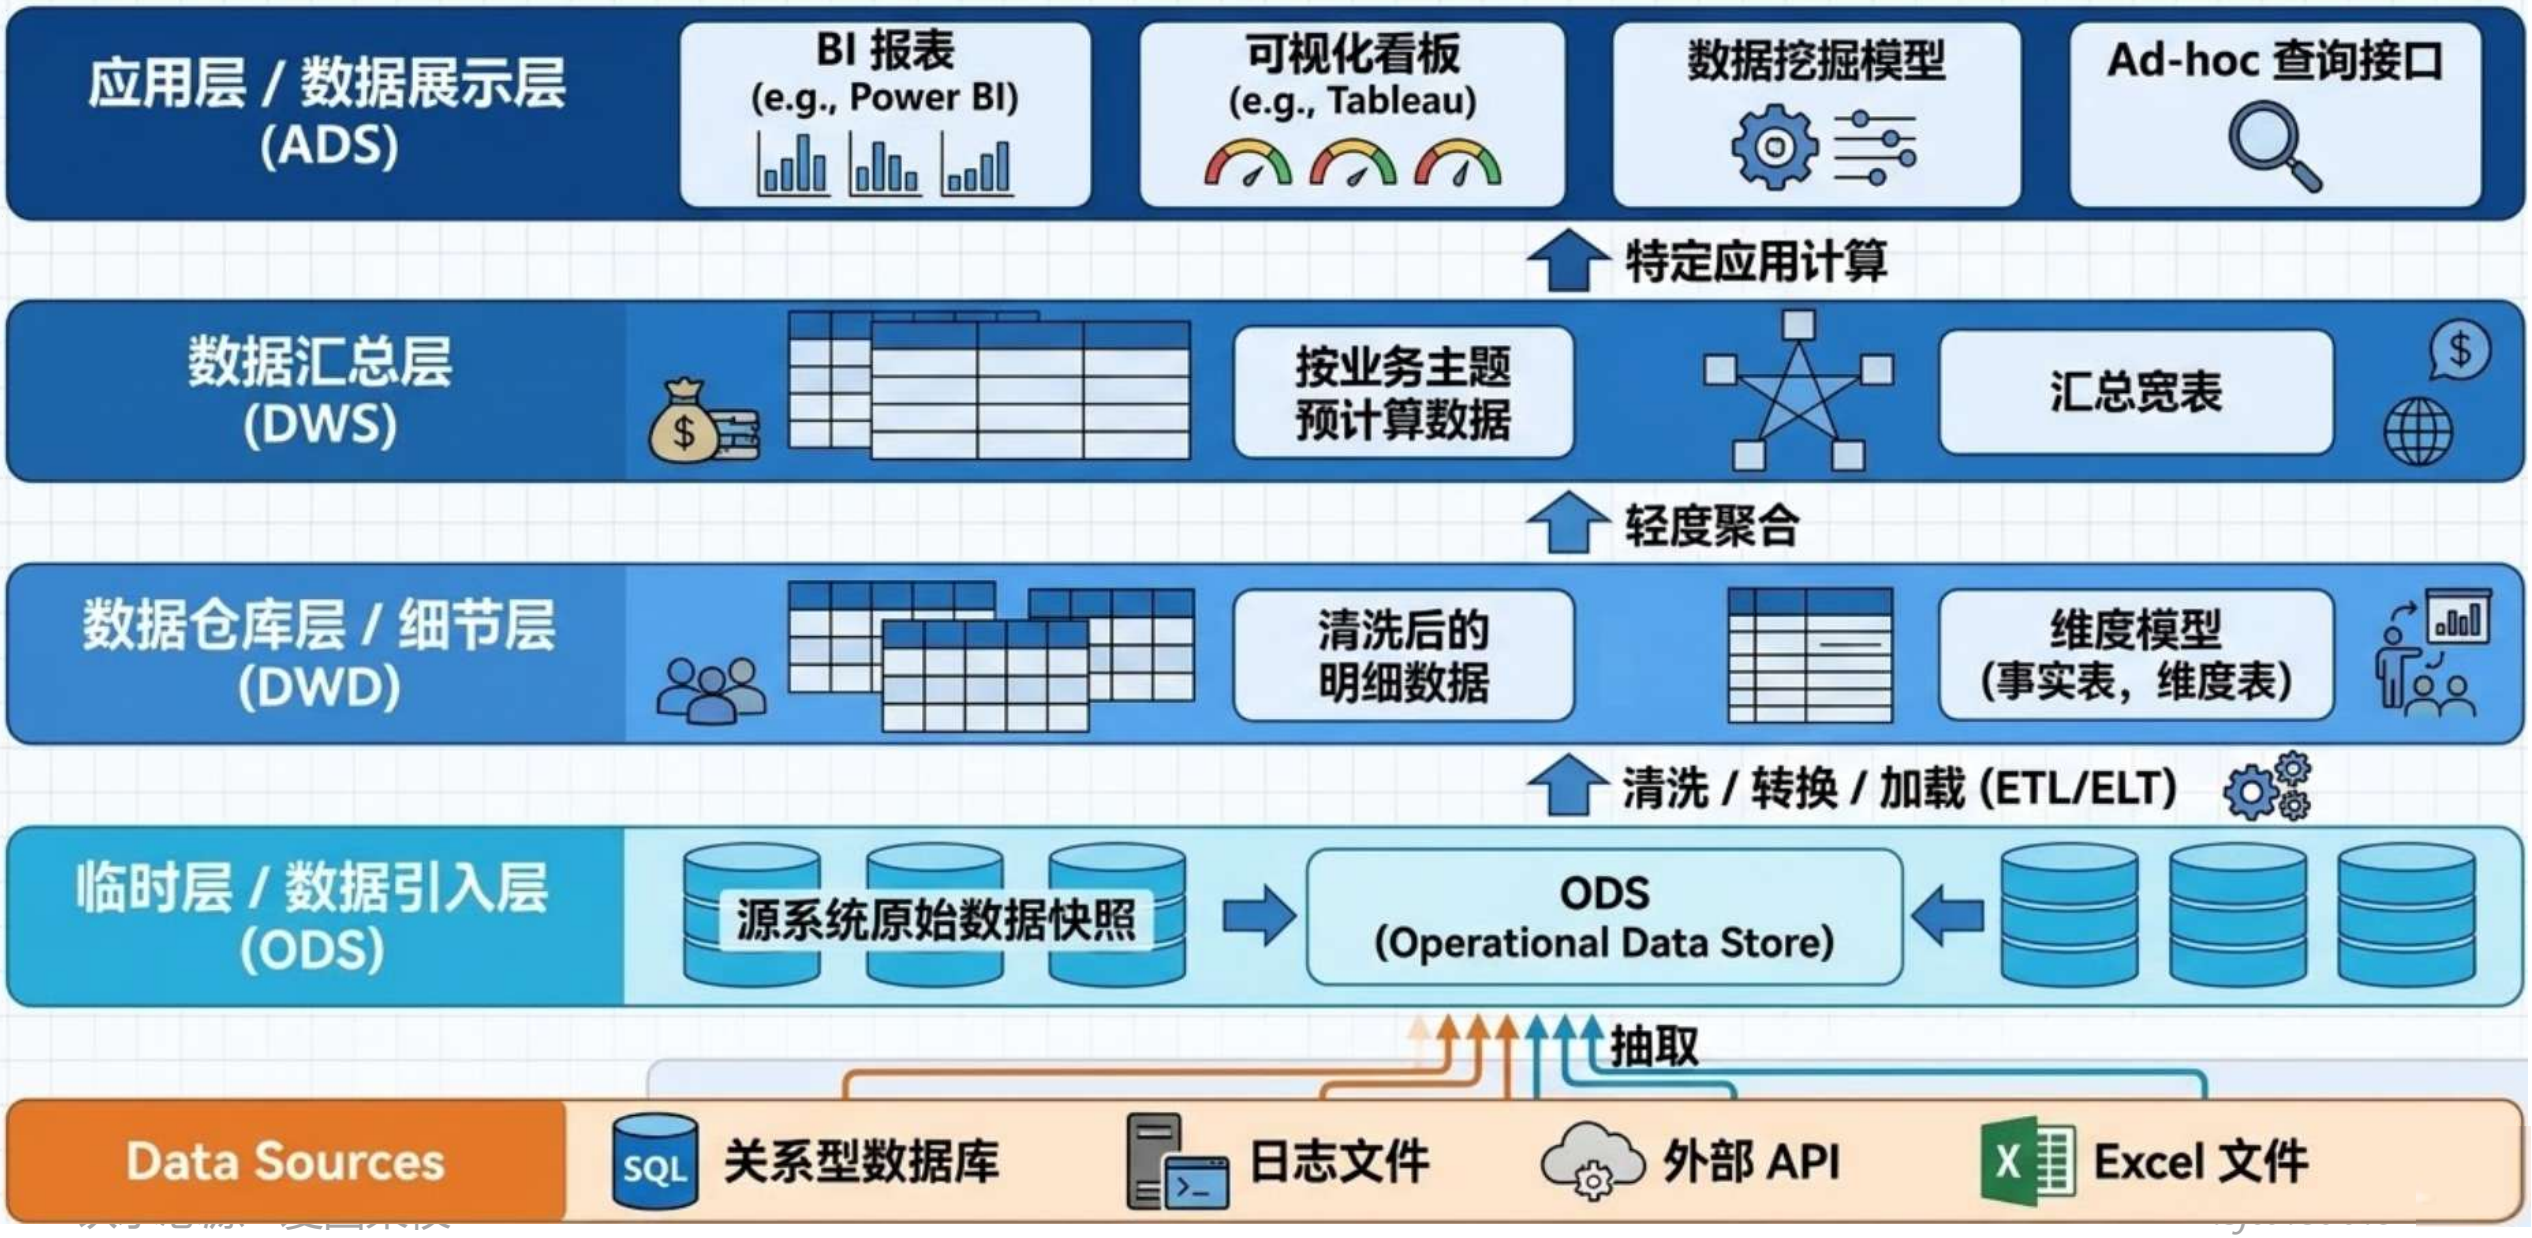
- 把面向分析、支持分析的系统称之为联机分析处理系统OLAP，数据仓库是OLAP的一种



数据仓库的主要特征


面向主题 Subject-Oriented
客户
业务
产品
围绕业务主题组织数据
支持决策分析
集成性 Integrated
ERP
CRM
多源数据整合
统一格式处理
数据仓库
Data Warehouse
相对稳定性 Non-Volatile
ETL
OLAP
数据不易修改删除
主要用于查询分析
反映历史变化 Time-Variant
2017
2018
2019
2020
2021
保存历史数据
追踪时间变化

数据仓库的分层架构


应用层 / 数据展示层
(ADS)
BI 报表
(e.g., Power BI)
可视化看板
(e.g., Tableau)
数据挖掘模型
Ad-hoc 查询接口
特定应用计算
数据汇总层
(DWS)
按业务主题
预计算数据
汇总宽表
轻度聚合
数据仓库层 / 细节层
(DWD)
清洗后的
明细数据
维度模型
(事实表，维度表)
清洗 / 转换 / 加载 (ETL/ELT)
临时层 / 数据引入层
(ODS)
源系统原始数据快照
ODS
(Operational Data Store)
抽取
Data Sources
SQL
关系型数据库
日志文件
外部 API
Excel 文件

- **随着大数据时代的全面到来，传统数据仓库也面临了如下挑战：**
  - 无法满足快速增长的海量数据存储需求
  - 无法有效处理不同类型的数据
  - 计算和处理能力不足

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

目 录

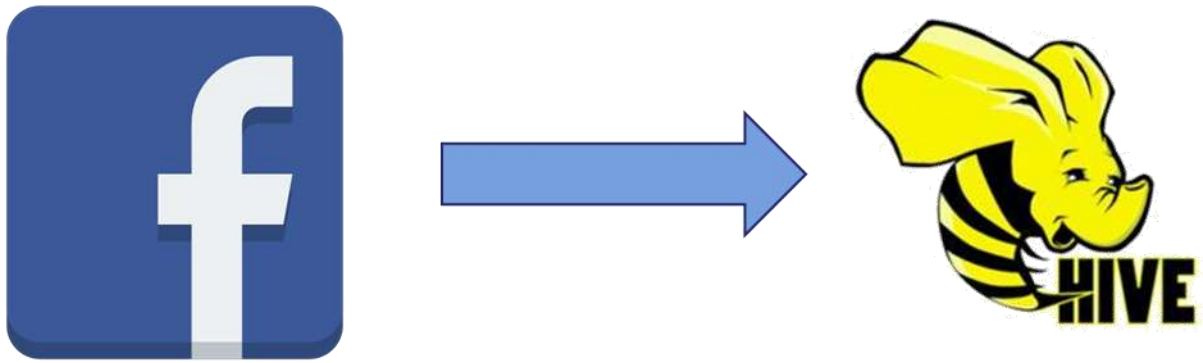


1 数据仓库的概念

2 HIVE简介

3 HIVE工作原理

- Hive是Facebook开发的，构建于Hadoop集群之上的数据仓库应用。2008年Facebook将Hive项目贡献给Apache，成为开源项目



HIVE简介

- Hive将结构化、半结构化的数据文件**映射为一张数据库表**，基于数据库表，提供了一种**类似SQL的查询模型（HQL）**，用于访问和分析存储在Hadoop文件中的大型数据集
- Hive本身并不具备存储功能，其核心是**将HQL转换为MapReduce程序**，**然后将程序提交到Hadoop集群中执行**



Hive的产生背景

- MapReduce的使用成本高
- 建立分析型数据仓库的需求



基于Hadoop和Hive组建Facebook数据仓库的发展史



随着数据量增加某些查询需要几个小时甚至几天才能完成。当数据达到1T时，MySql进程跨掉。



可以支撑几个T的数据，但每天收集用户点击流数据（每天约400G）时,Oracle开始撑不住。



有效解决了大规模数据的存储与统计分析的问题，但是MapReduce程序对于普通分析人员的使用过于复杂和繁琐。



对外提供了类似于SQL语法的HQL语句数据接口，自动将HQL语句编译转化为MR作业后在Hadoop上执行。降低了分析人员使用Hadoop进行数据分析的难度。

HIVE的优势

- 解决了传统关系数据库在大数据处理上的瓶颈。适合大数据的批量处理。
- 充分利用集群的CPU计算资源、存储资源，实现并行计算。
- Hive支持标准SQL语法，免去了编写MapReduce程序的过程，减少了开发成本。
- 具有良好的扩展性，拓展功能方便。

HIVE的优势：上百行MapReduce程序与一条HQL的对比



```
/**
 * Licensed to the Apache Software Foundation (ASF) under one
 * or more contributor license agreements.  See the NOTICE file
 * distributed with this work for additional information
 * regarding copyright ownership.  The ASF licenses this file
 * to you under the Apache License, Version 2.0 (the
/**
 * The main dr
 * Invokes this
 * @throws IOE
 *
 */
public int run
  JobConf conf
  conf.setJobN
  // the keys
  conf.setOutp
  // the value
  conf.setOutp
  conf.setMapp
  conf.setComb
  conf.setRedu
  List<String>
  for(int i=0;
    try {
      if ("-m"
        conf.s
      } else i
        conf.s
      } else {
        other_
      }
    } catch (I
      System.o
      return 2
    } catch (E
      System.o
    return 2
  }
}
// Make sure
if (other_ar
  System.out
  return printUsage();
}
FileInputFormat.setInputPaths(conf, other_args.get(0));
/**
 * This is an example Hadoop Map/Reduce application.
 * It reads the text input files, breaks each line into words
 * and counts them. The output is a locally sorted list of words and the
 * count of how often they occurred.
 *
 * To run: bin/hadoop jar build/hadoop-examples.jar wordcount
 *            [-m <i>maps</i>] [-r <i>reduces</i>] <in-dir> <out-dir>
 */
public class WordCount extends Configured implements Tool {

  /**
   * Counts the words in each line.
   * For each line of input, break the line into words and emit them as
   * (<b>word</b>, <b>1</b>).
   */
  public static class MapClass extends MapReduceBase
    implements Mapper<LongWritable, Text, Text, IntWritable> {

    private final static IntWritable one = new IntWritable(1);
    private Text word = new Text();

    public void map(LongWritable key, Text value,
                    OutputCollector<Text, IntWritable> output,
                    Reporter reporter) throws IOException {
      String line = value.toString();
      StringTokenizer itr = new StringTokenizer(line);
      while (itr.hasMoreTokens()) {
        word.set(itr.nextToken());
        output.collect(word, one);
      }
    }
  }

                other_args.size() + " instead of 2.");
```

```
select word, count(*)
from (
select
explode(split(sentence. ' '))
word
from article
) t
group by word
```

HIVE的缺点

- Hive的HQL表达能力有限：有些复杂运算用HQL不易表达。
- Hive效率低：Hive自动生成MapReduce作业，通常不够智能
- HQL调优困难，粒度较粗；可控性差。
- 针对Hive运行效率低下的问题，促使人们去寻找一种更快，更具交互性的分析框架。SparkSQL 的出现则有效的提高了Sql在Hadoop 上的分析运行效率。

适用场景

- 海量数据的存储处理
- 数据挖掘
- 海量数据的离线分析

不适用场景

- 复杂的机器学习算法
- 复杂的科学计算
- 联机交互式实时查询

Hive和HBase的联系与区别

- Hive是一个构建在Hadoop平台上的**数据仓库**，可以**使用HQL语言查询，对存放在HDFS上的数据实现大规模离线处理**
- HBase是基于HDFS的支持随机读写的**NoSql数据库**，基于列的存储，具有分布式、可扩展、海量存储的特点。在Hadoop上设计HBase是为了实现**大数据的实时查询和海量存储**
- **Hive 像是一个巨大的档案库**，适合定期进去翻阅所有资料并总结报告；**HBase 像是一个超大型的快递柜**，每个人凭取件码（RowKey）都能在瞬间取走自己的包裹

Hive和HBase的联系与区别

- Hive**通过HQL运行MapReduce任务**。运行Hive查询会花费较长时间，因为Hive的默认计算引擎是Hadoop的MapReduce。当然Hive也可以将底层计算引擎更换为Spark等其他组件
- HBase主要支持如增加行、更新行、查看一个范围内的cell等操作，不支持复杂的查询
- 所以，**HBase与Hive的功能是互补的**

Hive和HBase的集成

在Hive中启动HBase处理器

HBase表Users

	Info		Contact	
Rowkey	name	age	phone	email
user1	Alice	25	1234567890	
user2	Bob	30		bob@mail.com

Row Key	Column Family: Qualifier	Value
user1	info:name	Alice
user1	info:age	25
user1	contact:phone	1234567890
user2	info:name	Bob
user2	info:age	30
user2	contact:email	bob@mail.com

使用Hive创建一个外部表，并将其映射到HBase表users

```
CREATE EXTERNAL TABLE hbase_users (
    rowkey STRING,
    name STRING,
    age INT,
    phone STRING,
    email STRING
)
STORED BY 'org.apache.hadoop.hive.hbase.HBaseStorageHandler'
WITH SERDEPROPERTIES (
    "hbase.columns.mapping" = ":key,info:name,info:age,contact:phone,contact:email"
)
TBLPROPERTIES (
    "hbase.table.name" = "users"
);
```

通过标准SQL 查询语句对HBase数据进行操作

```
SELECT * FROM hbase_users WHERE age > 26;
```

```
SELECT * FROM hbase_users WHERE name LIKE 'A%';
```

通过HiveQL直接查询HDFS

- 假设有一个CSV文件 employee_data.csv并上传到HDFS

```
id,name,age,department,salary
1,Alice,30,HR,50000
2,Bob,25,Engineering,70000
3,Charlie,35,Marketing,60000
4,Diana,28,Engineering,75000
```

- 使用HiveQL创建一个外部表，指向HDFS上的数据文件，并使用HiveQL查询

```
CREATE EXTERNAL TABLE IF NOT EXISTS employee (
    id INT,
    name STRING,
    age INT,
    department STRING,
    salary FLOAT
)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY ','
STORED AS TEXTFILE
LOCATION '/user/hive/warehouse/employee';
```

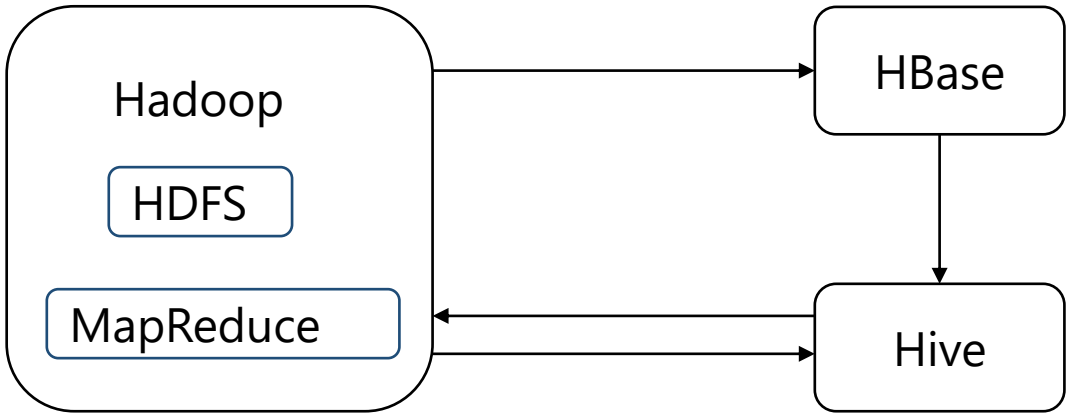
```
-- 查询所有员工信息
SELECT * FROM employee;

-- 查询工资大于60000的员工
SELECT name, department, salary
FROM employee
WHERE salary > 60000;

-- 按部门统计平均工资
SELECT department, AVG(salary) AS avg_salary
FROM employee
GROUP BY department;
```

HDFS，HBase和Hive

Hadoop提供基础架构，其中HDFS解决如何存的问题，MapReduce解决如何算的问题



HBase解决如何查的问题，但是**不能直接访问HDFS的接口**，只能通过**构建自己的数据库，其存储仍然依赖HDFS**，可以进行简单查询，但是要实现类似SQL的复杂查询需要配合其他组件

Hive可以直接**通过构建外部表和HiveQL对HDFS查询**，**也可以在HBase的基础上实现标准SQL查**询，适用于复杂的数据仓库分析和查询

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

目 录



1 数据仓库的概念

2 HIVE简介

3 HIVE工作原理

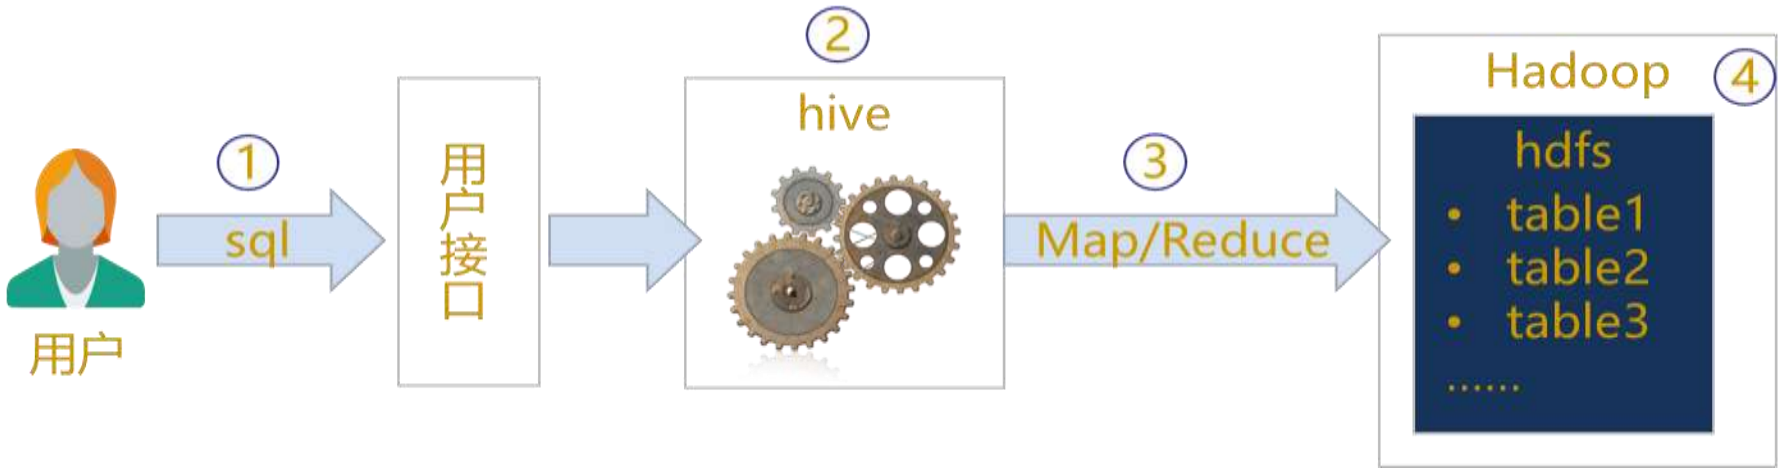
HIVE的运行机制

① 用户通过用户接口连接Hive,发布Hive SQL

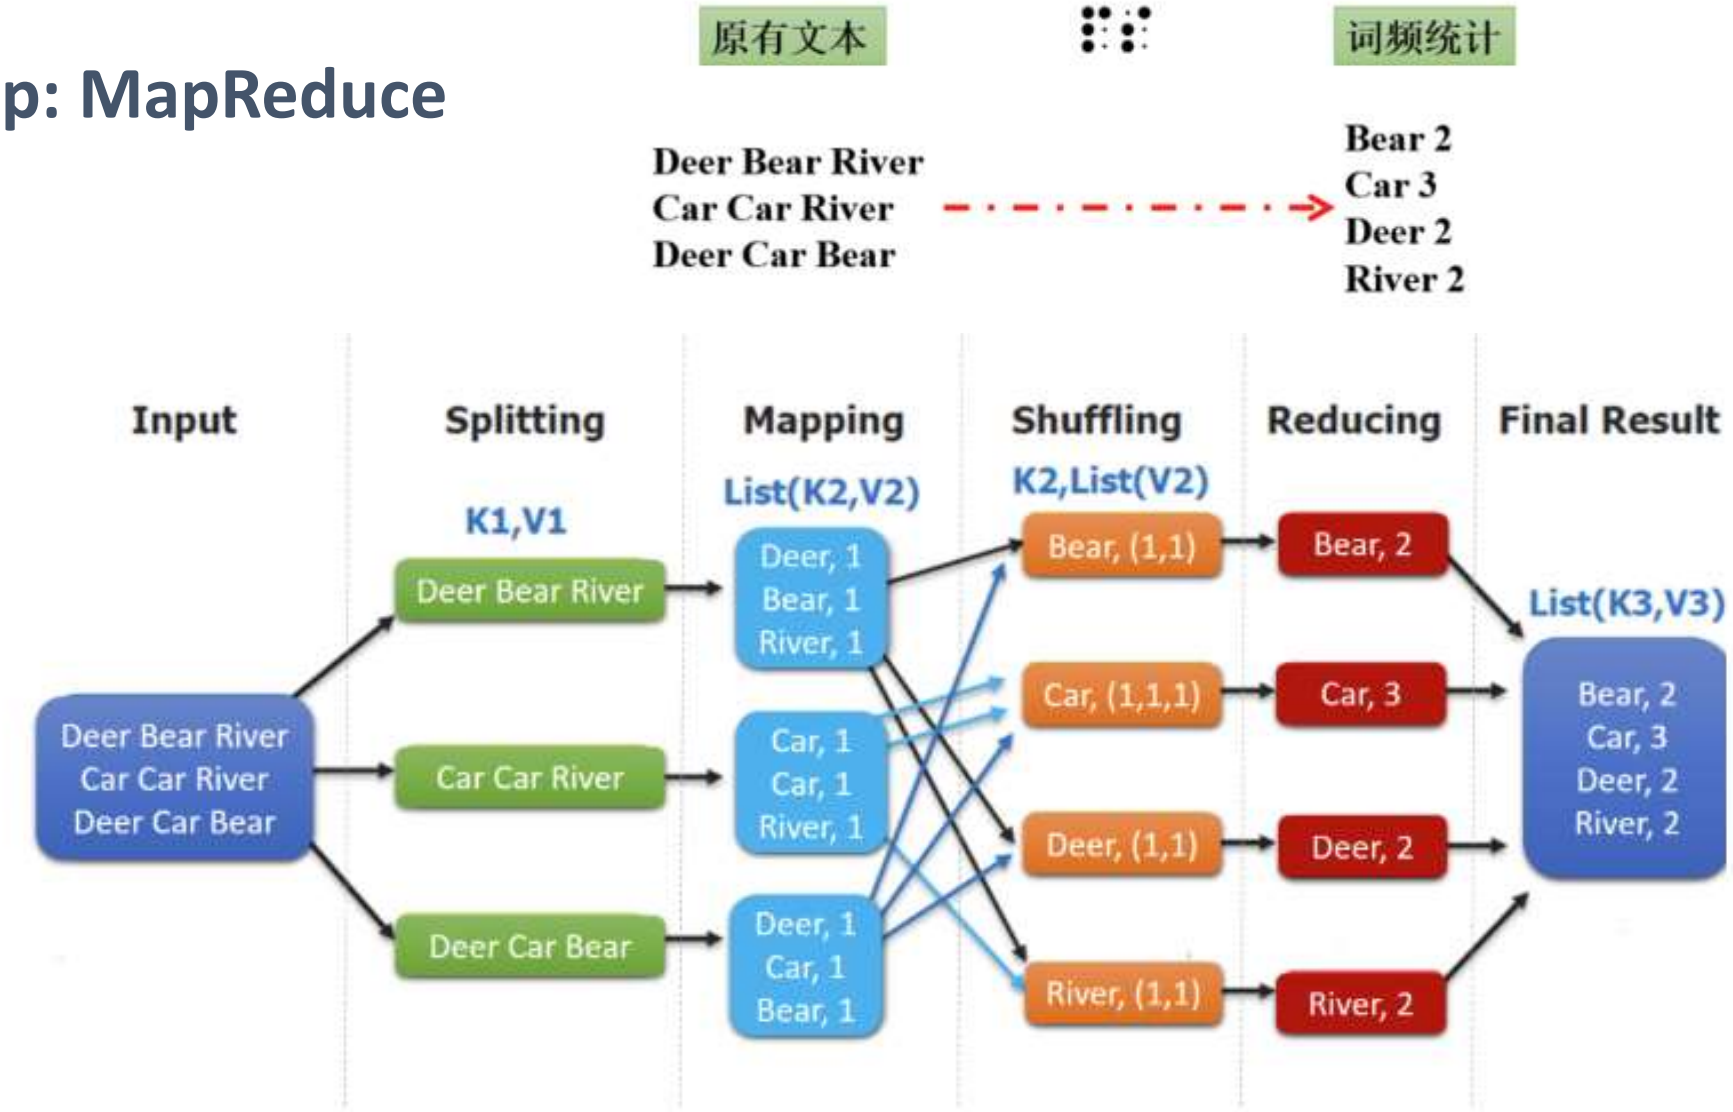
② Hive解析查询并制定查询计划

③ Hive将查询转换成MapReduce作业

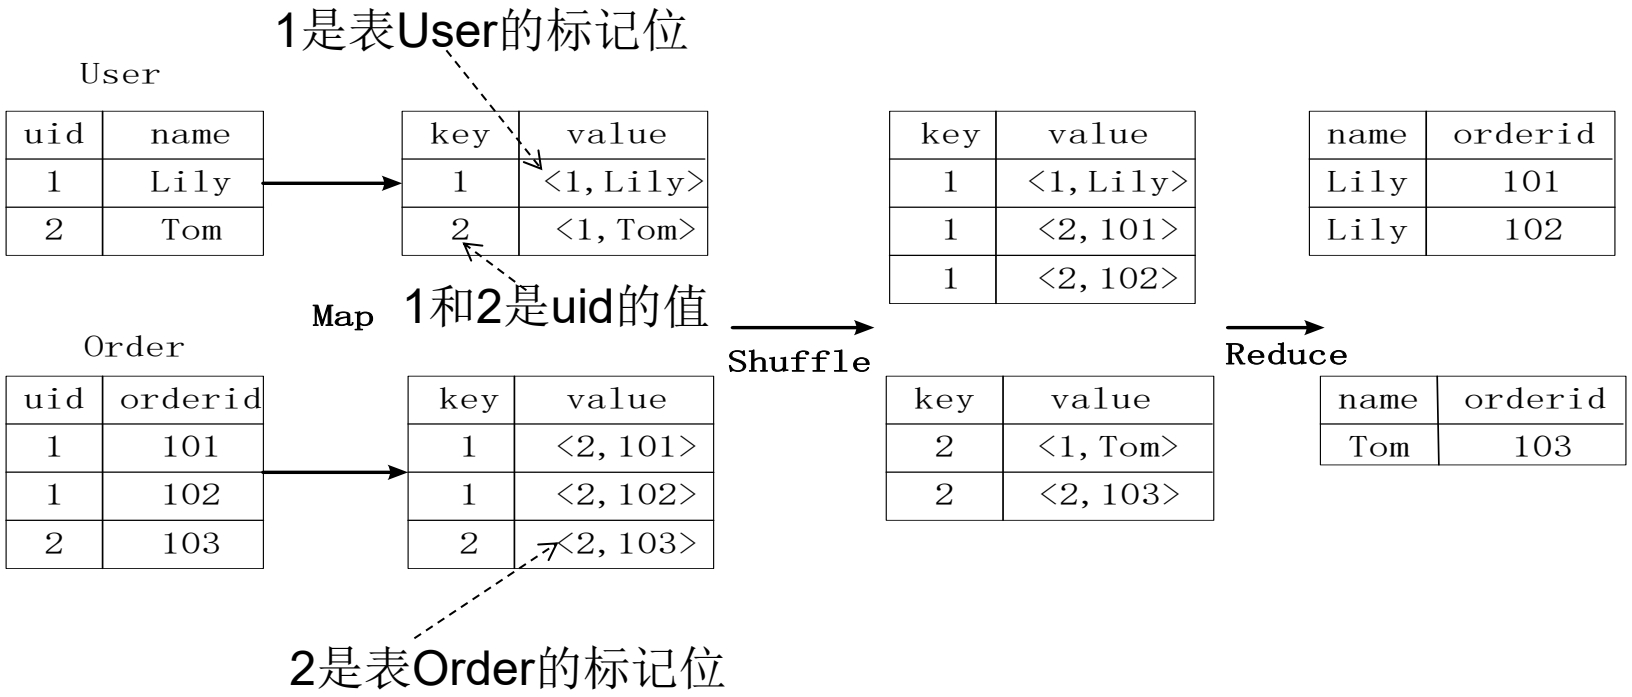
④ Hive在Hadoop上执行MapReduce作业



Recap: MapReduce

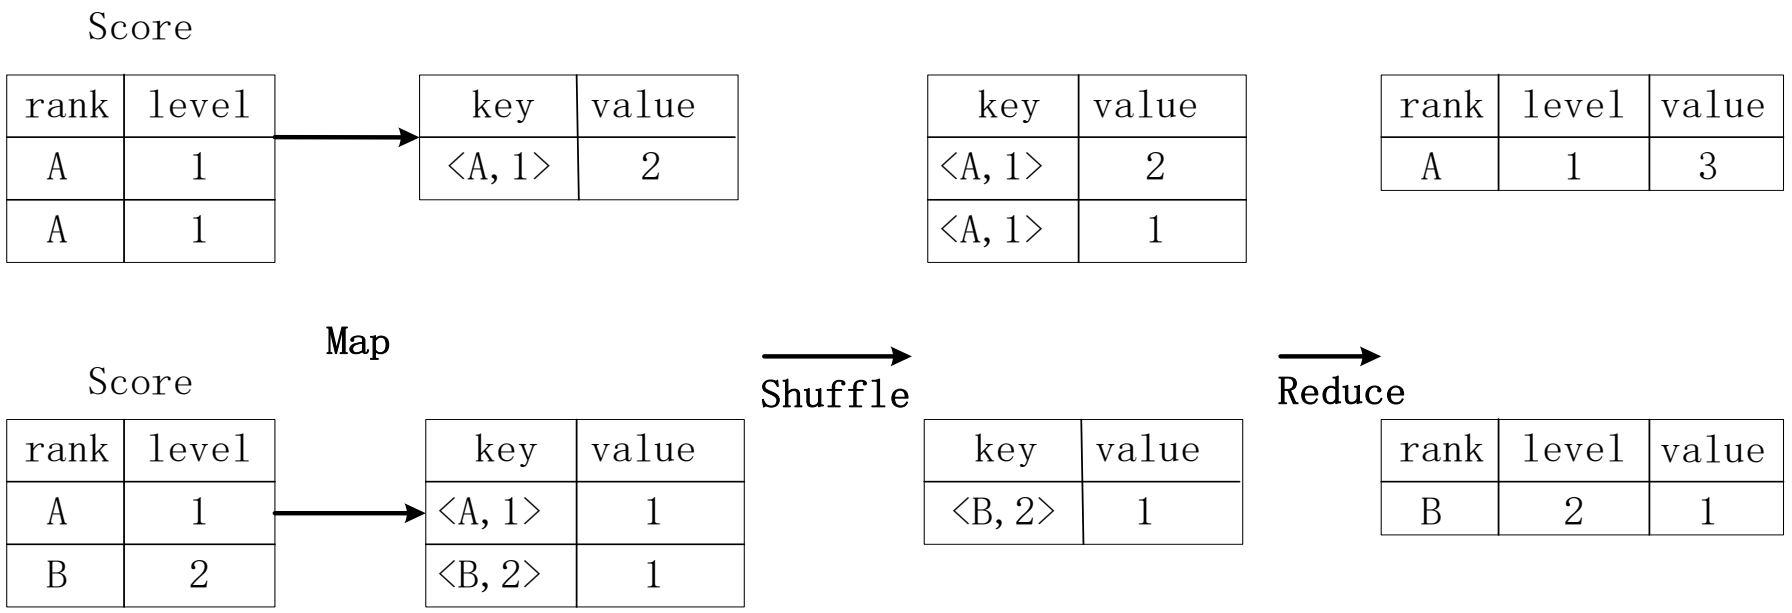


SQL语句转换成MapReduce作业—Join操作的实现



SQL语句转换成MapReduce作业—group by操作的实现

- 存在一个分组（Group By）操作，其功能是把表Score的不同片段按照rank和level的组合值进行合并，计算不同rank和level的组合值分别有几条记录：select rank, level ,count(*) as value from score group by rank, level



上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

Thank You

