数据挖掘和机器学习技术简介

丁玥

上海交通大学计算机学院

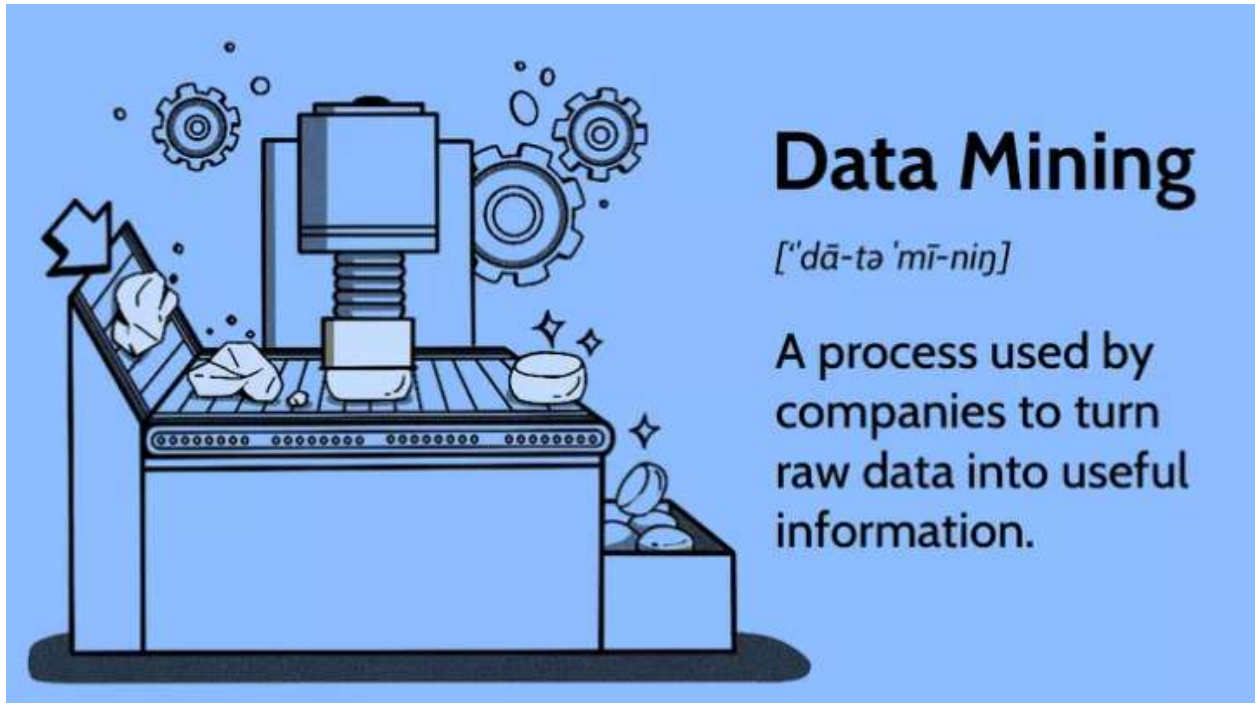
dingyue@sjtu.edu.cn

2026年秋季

饮 水 思 源 • 爱 国 荣 校

数据挖掘是搜索和分析大量原始数据以识别模式和提取有用信息的过程

- 将这些发现转化为业务见解和预测
- 数据挖掘超越了搜索过程，因为它使用数据来评估未来的可能性并制定可行的分析



数据挖掘的早期发展的关键阶段

- **早期发展（20世纪70年代-80年代）**：
  - 早期概念起源于统计学和数据库领域。1970年，统计学家和经济学家提出了关联规则
- **概念形成（20世纪90年代初）**：
  - 1991年，Jesse Shapiro首次使用“数据挖掘”一词。1994年，ACM SIGKDD（Special Interest Group on Knowledge Discovery and Data Mining）成立，标志着数据挖掘正式成为一个独立研究领域
- **技术进步（20世纪90年代中期）**：
  - 数据挖掘技术开始快速发展，包括分类、聚类、关联规则学习等算法，同时也出现了许多数据挖掘工具和软件（如Weka）
- **商业应用（20世纪90年代末至21世纪初）**：
  - 数据挖掘在商业领域的应用开始增多，特别是在零售、金融和电信行业。企业也开始利用数据挖掘进行市场分析、客户细分、信用评分和欺诈检测。

数据挖掘案例——沃尔玛超市





挖掘有价值的信息！

顾客ID	购买商品列表（商品ID:名称:数量）	交易次数	总消费金额
C001	P001:牛奶:2, P002:面包:1, P003:鸡蛋（盒）:1	2	117.50
C002	P004:洗发水:1, P005:牙膏:2	1	120.00
C003	P006:苹果（斤）:3, P001:牛奶:1	1	45.80

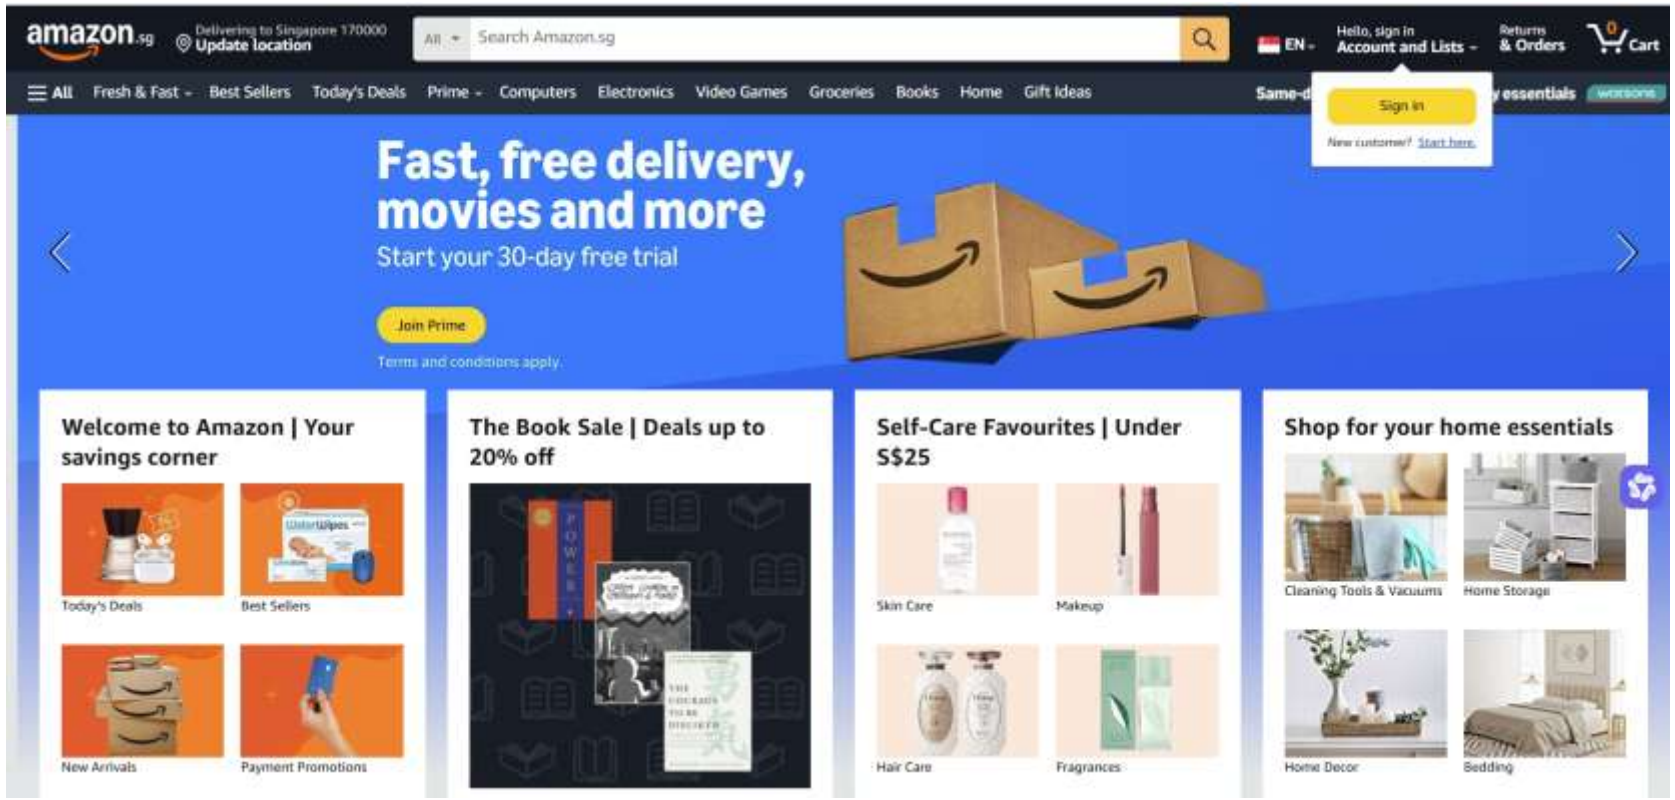
沃尔玛的“零售都市传说”：啤酒与尿布

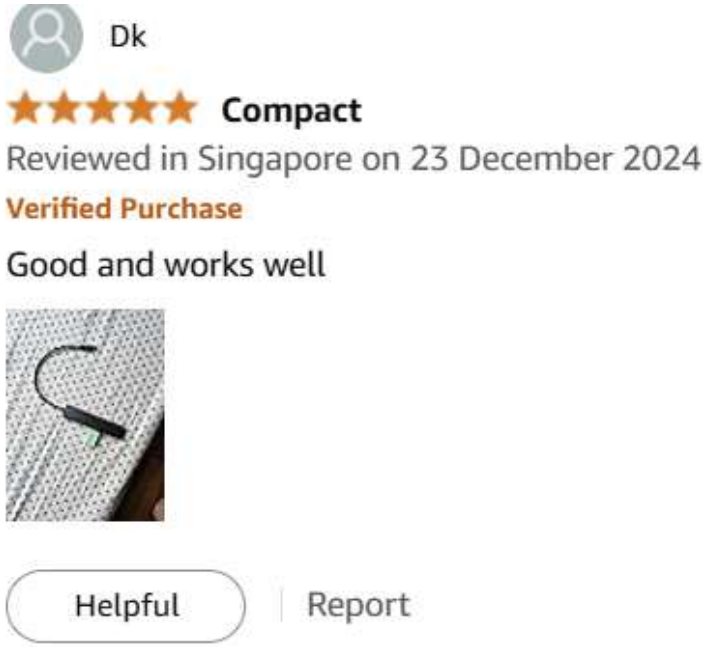
20世纪90年代，美国有婴儿的家庭中通常由年轻的父亲负责购买尿布，他们会在买尿布时顺带为自己购买啤酒。沃尔玛超市尝试将啤酒与尿布摆放在相同的区域，并通过一次销售两件商品而获得更好的销售收入

- **有人质疑其真实性**
- **不可否认的沃尔玛数据基因**：1969年启用计算机跟踪库存，1974年实现分销中心与商场计算机库存控制，1983年普及条形码扫描，1987年建立卫星系统实现实时数据声音传输。现今沃尔玛拥有全球最大数据仓库，存储65周连锁店销售详录

数据挖掘案例——亚马逊“信息公司”

亚马逊可以称之为一家“信息公司”：不仅从每个用户的购买行为中获得信息，还将每个用户在其网站上的所有行为都记录下来：包括页面停留时间、用户是否查看评论、每个搜索的关键词、浏览的商品等等。

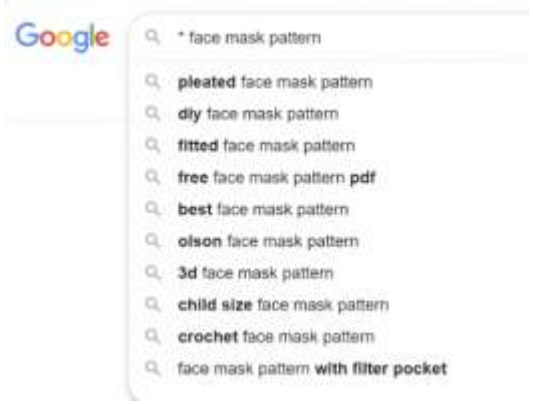




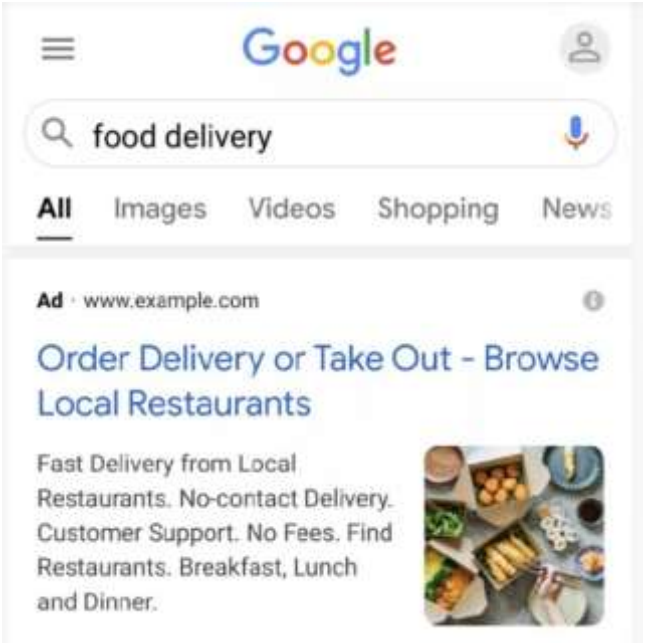
数据驱动型文化：对数据价值的高度敏感和重视，凭借强大的数据挖掘能力使亚马逊远超传统运营方式。

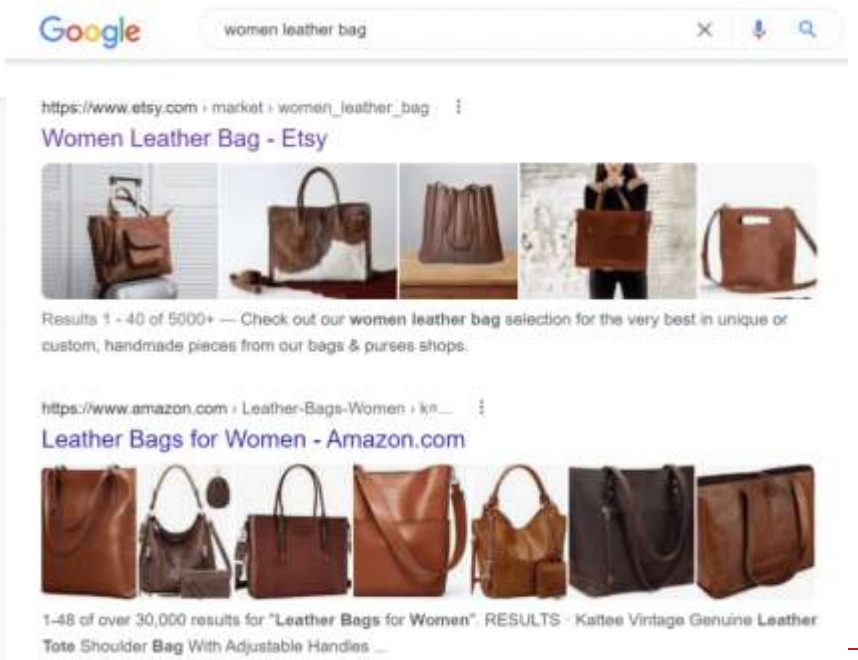
数据挖掘案例——谷歌的意图

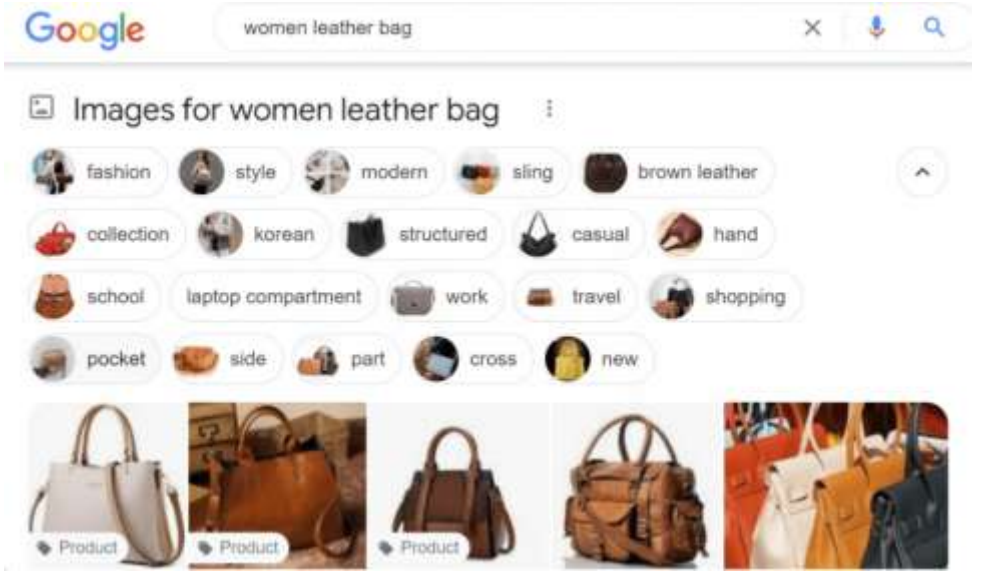
如果说有一家科技公司准确定义了“大数据”概念的话，那一定是谷歌。根据搜索研究公司comScore的数据，仅2012年3月一个月的时间，谷歌处理的搜索词条数量就高达122亿条。



谷歌意图：谷歌不仅存储了搜索结果中出现的网络连接，还会储存用户搜索关键词的行为，它能够精准地记录下人们进行搜索行为的时间、内容和方式。这些数据能够让谷歌优化广告排序，并将搜索流量转化为盈利模式。换言之，谷歌能在你意识到自己要找什么之前预测出你的意图。





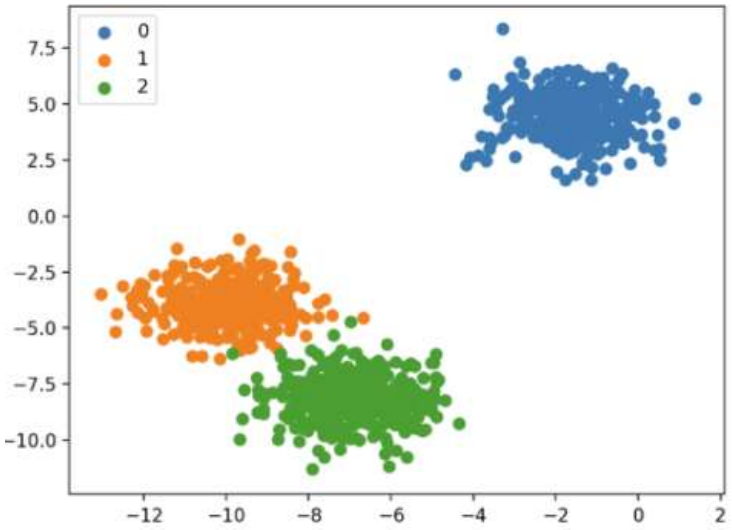


现代数据挖掘技术

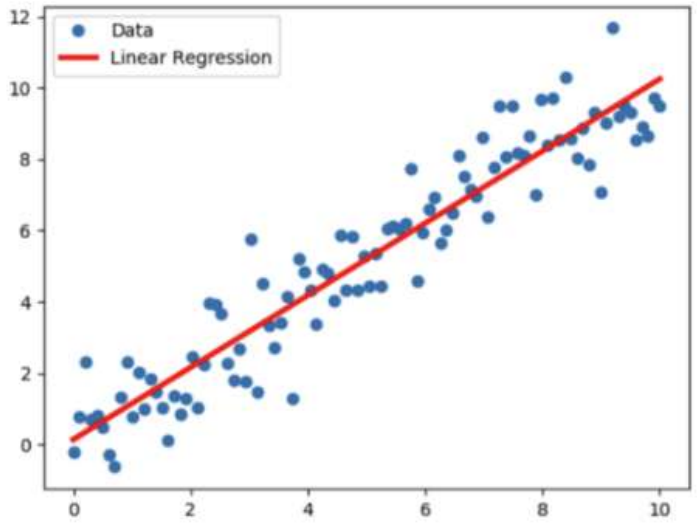
- **大数据时代**
  - 互联网和社交媒体的兴起，数据量呈指数级增长，大数据技术成为数据挖掘的重要组成部分
  - 分布式计算框架（如Hadoop和Spark）的发展使得处理大规模数据成为可能
- **深度学习和人工智能的融合**
  - 深度学习技术在图像识别、自然语言处理等领域取得突破，这些技术也被应用于数据挖掘
  - 数据挖掘与人工智能的结合越来越紧密，推动了自动化特征提取、模式识别和预测分析的发展
- **跨学科融合**
  - 数据挖掘与生物信息学、社会科学、环境科学等多个学科领域交叉融合

典型的数据挖掘任务

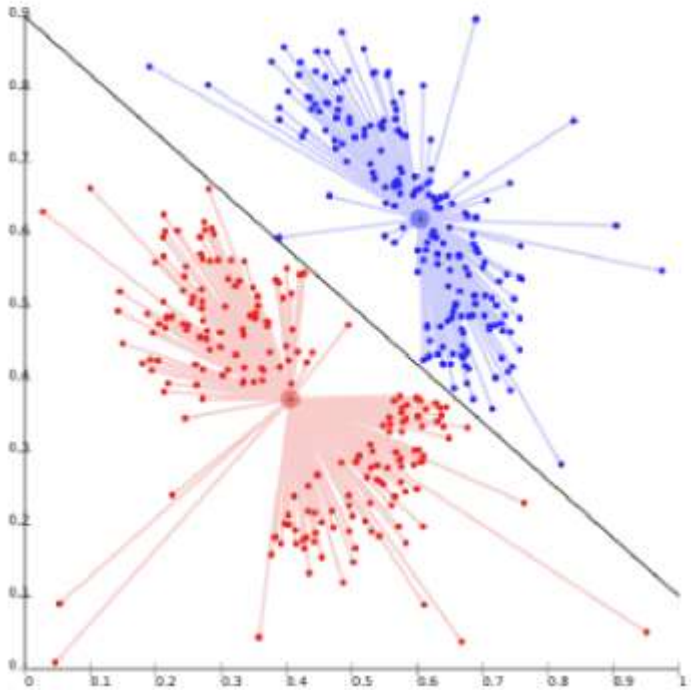
分类



回归



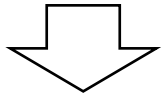
聚类



典型的数据挖掘任务

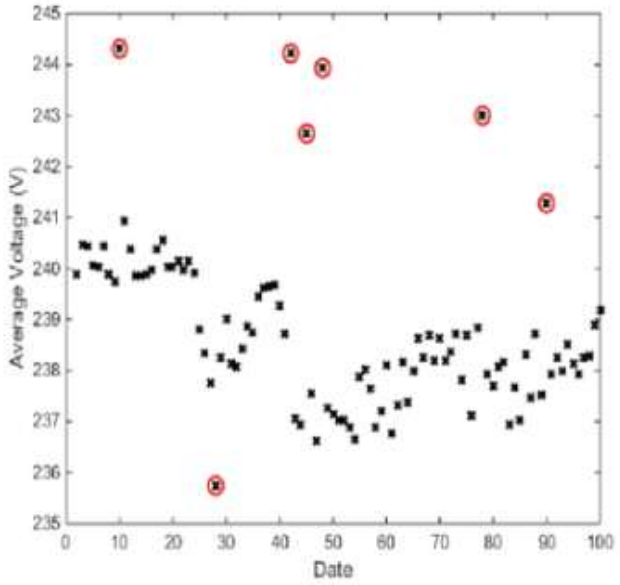
频繁模式挖掘

订单号	商品序列
1	牛奶、面包、尿布
2	可乐、面包、尿布、啤酒
3	牛奶、尿布、啤酒、鸡蛋
4	面包、牛奶、尿布、啤酒
5	面包、牛奶、尿布、可乐

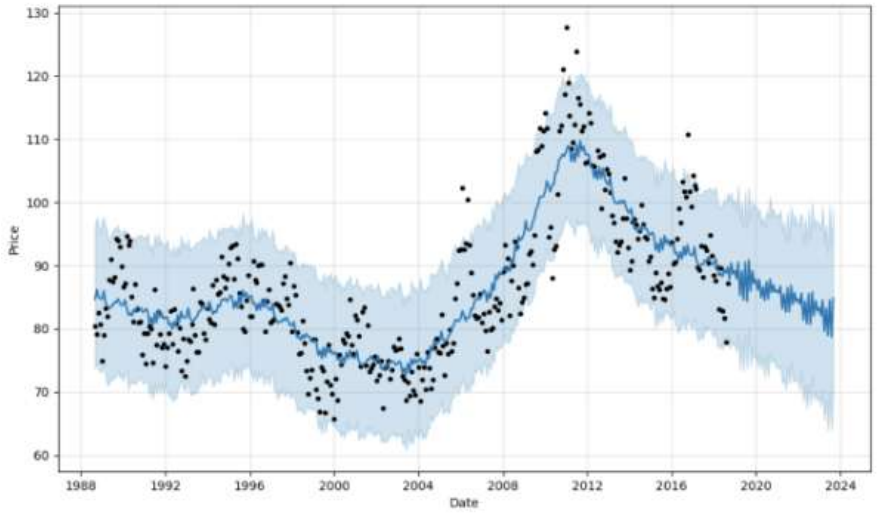


订单号	商品序列
1	3、1、2
2	3、2、5
3	3、1、5
4	3、1、2、5
5	3、1、2

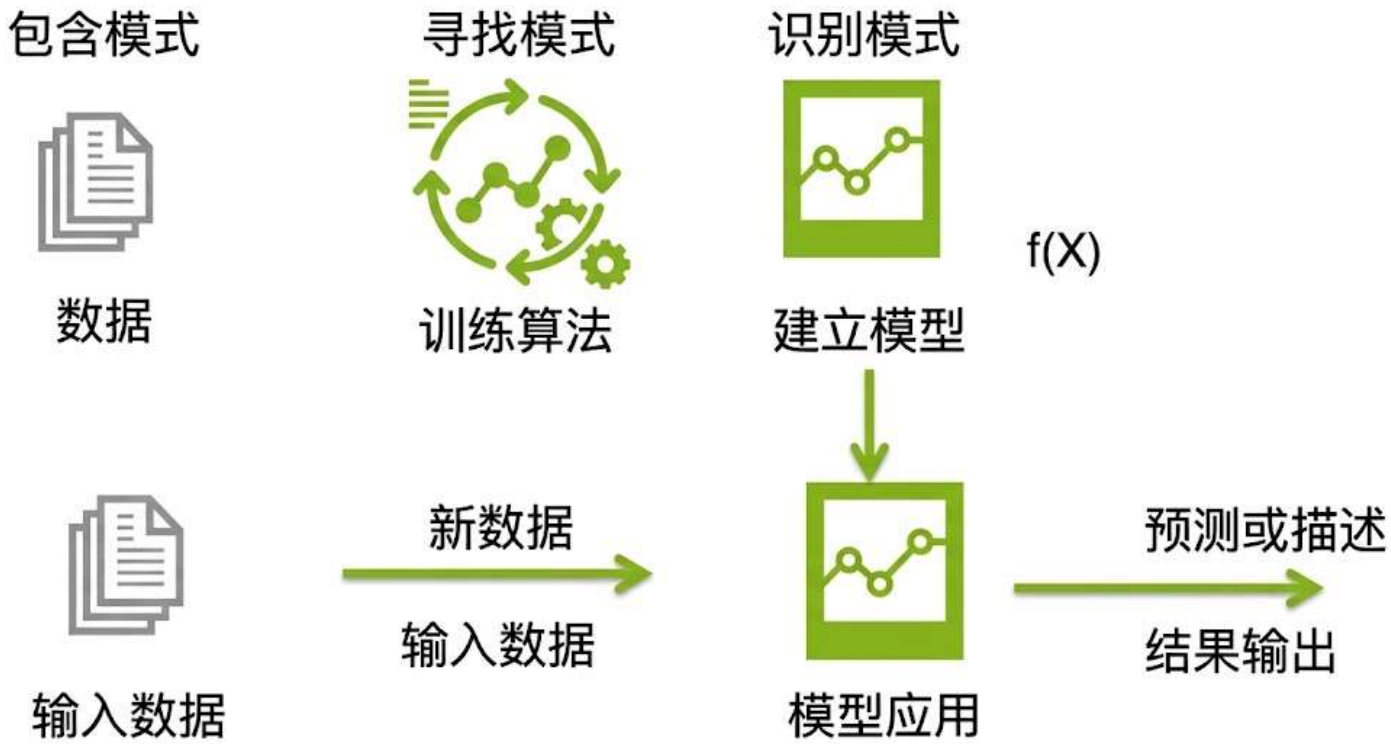
异常检测



时间序列分析

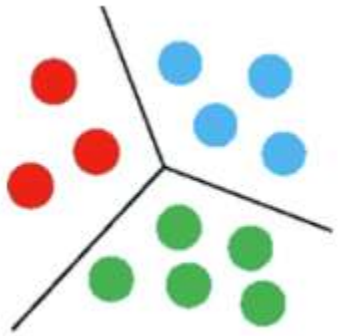


- 机器学习 (Machine Learning, ML) 通过数据和算法让计算机模拟人类的学习方式，从而在没有明确编程指令的情况下，自主识别模式并做出预测或决策



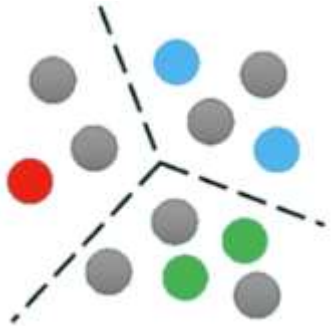
机器学习的基本概念

有监督学习 (Supervised Learning)

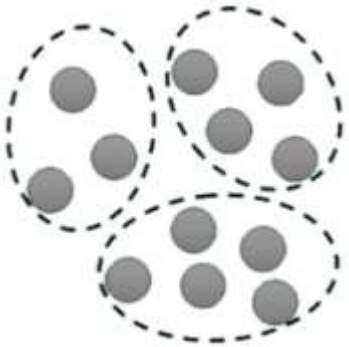


- 从数据源中定义标签与特征
- 通过算法对数据进行训练，找到特征变量与输出之间的联系
- 一旦训练完成，通常表现为在算法足够准确或稳定时，将算法应用于新数据

半监督学习 (部分标签)



无监督学习 (Unsupervised Learning)



- 算法接收未打标签的数据
- 算法根据数据推断出数据结构与模式
- 算法会识别那些表现出相似行为的数据组

强化学习 (Reinforcement Learning)





- 该算法针对环境定义动作
- 收到动作的奖励后，算法会逼近最大化可用的总奖励
- 随着时间的流逝，算法对其自身进行校正，并不断优化最佳操作序列

人类学习 v.s. 机器学习



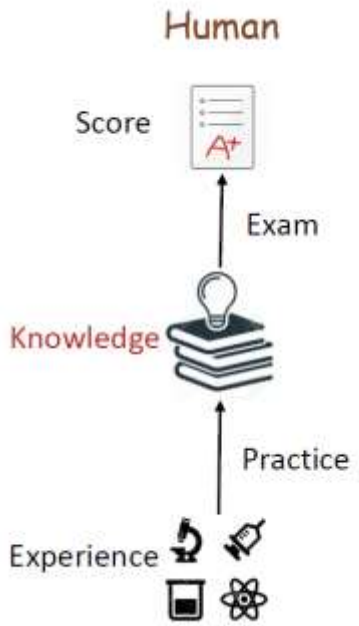
Knowledge

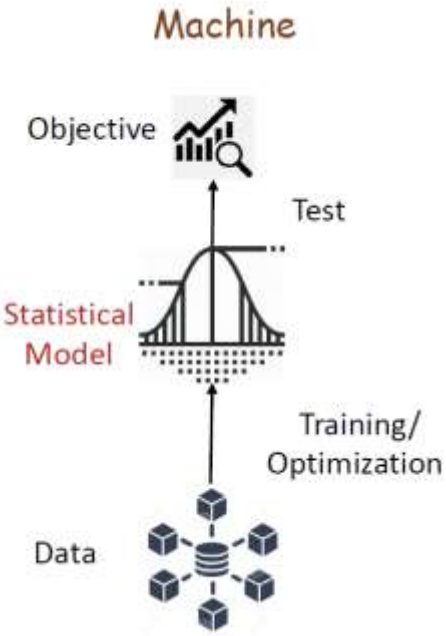
Practice



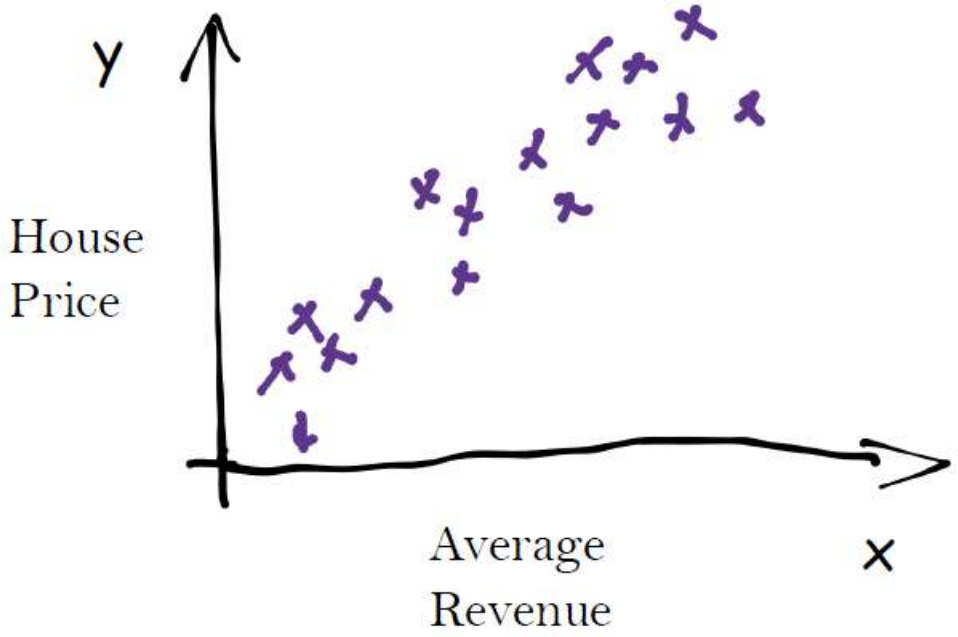
Exam







机器学习的关键要素



Elements:

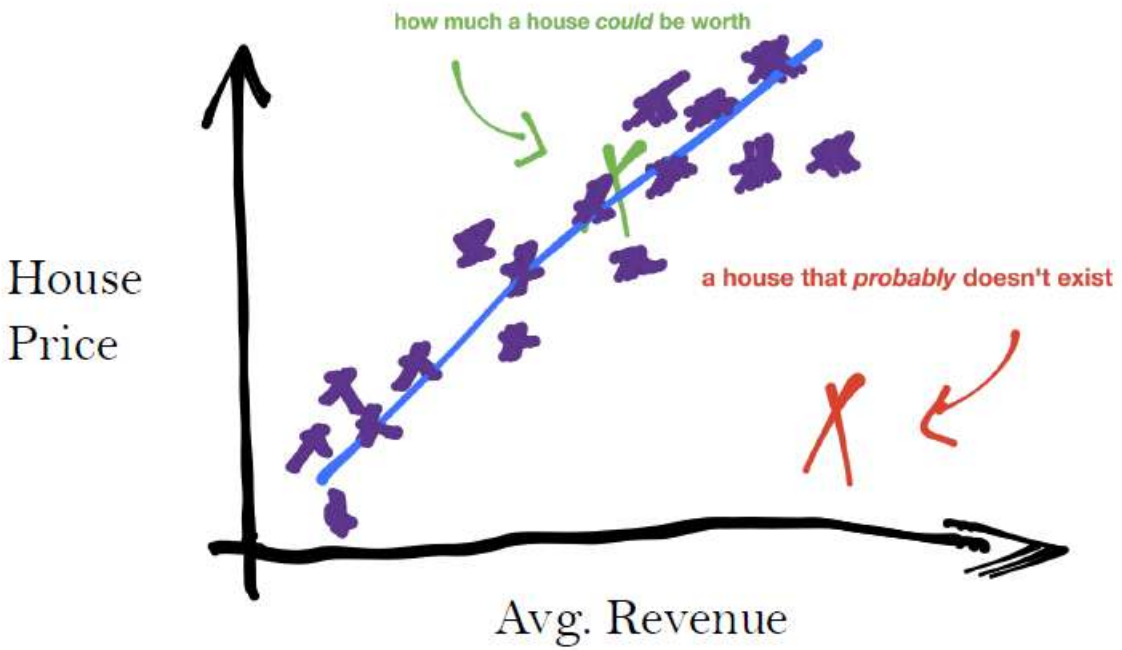
#1 Data (Experience)

$D = \{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \ldots, (x^{(N)}, y^{(N)})\}$

机器学习的关键要素

We **cannot** learn from data

We **can** learn from data + *hypothesis*



Elements:

#1 Data (Experience)

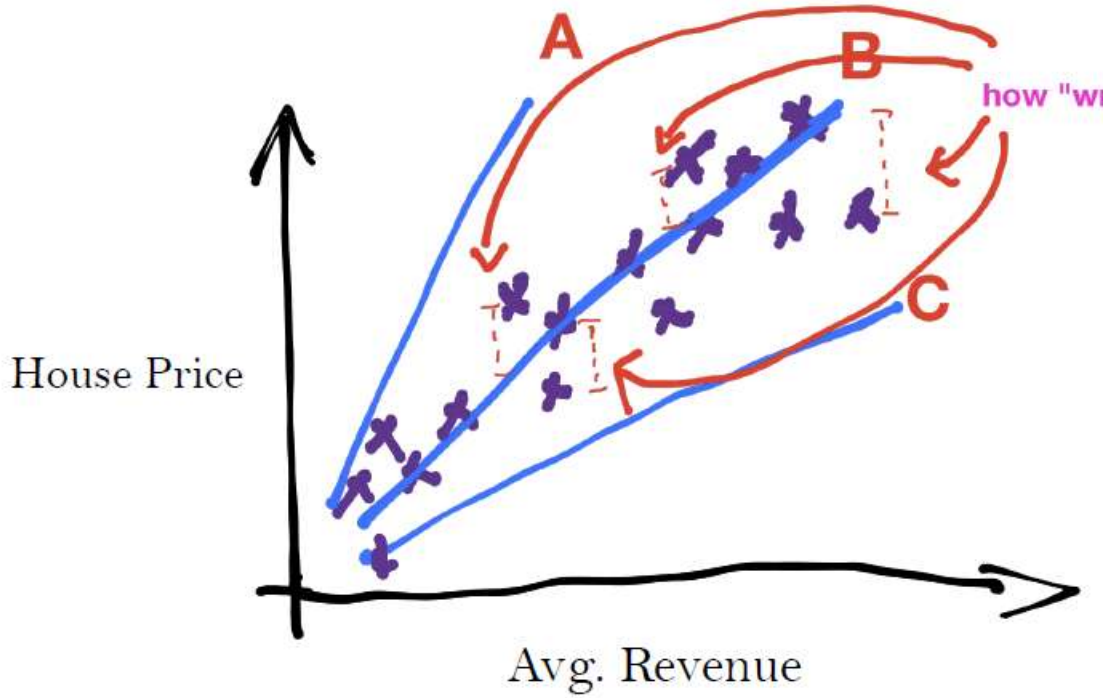
#2 Model(Hypothesis)

$$\hat{y} = g(x|\theta) + \epsilon$$

e.g. $\hat{y} = \boldsymbol{w}x + \boldsymbol{b}$
where θ (e.g., W and b) denotes the parameters

What hypothesis do we make about this data?

机器学习的关键要素



Elements:

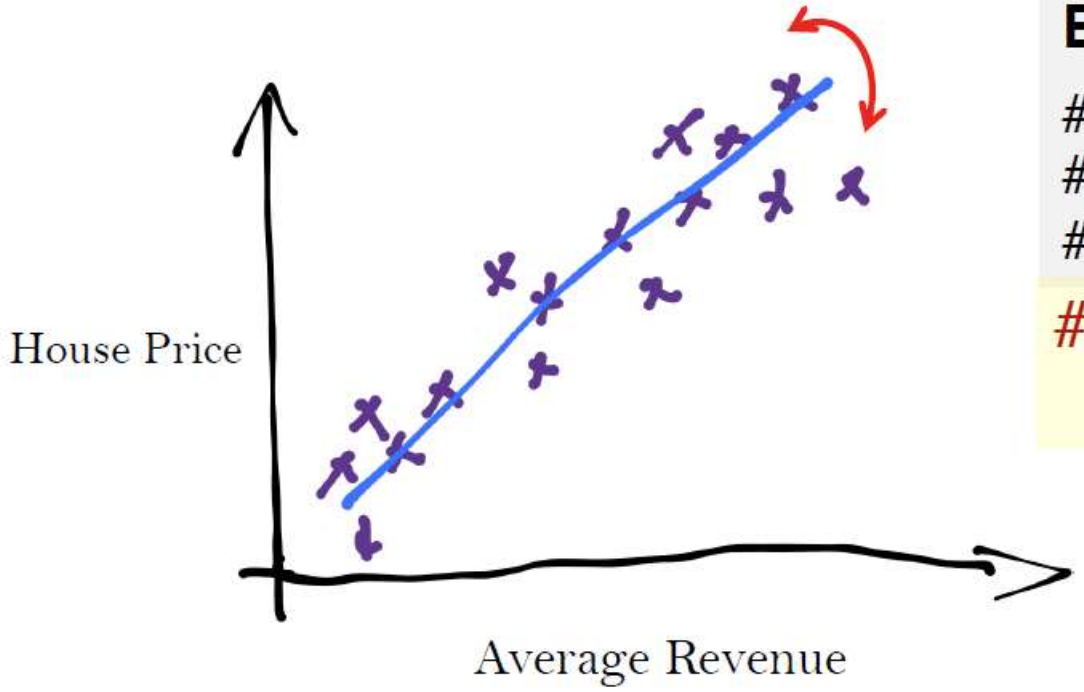
#1 Data (Experience)
#2 Model (Hypothesis)

#3 Loss Function (Objective)

$$\mathcal{L}(\theta|\mathcal{D}) = \frac{1}{2}\sum_{n=1}^{N}[\boldsymbol{w}x_n + b - y_n]^2$$

How to evaluate a model? (performance criterion)

机器学习的关键要素

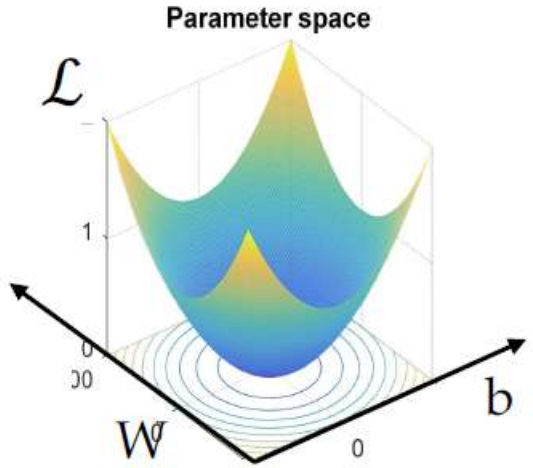


Elements:

#1 Data (Experience)
#2 Model (Hypothesis)
#3 Loss Function (Objective)

#4 Optimization Algorithm (Improvement)

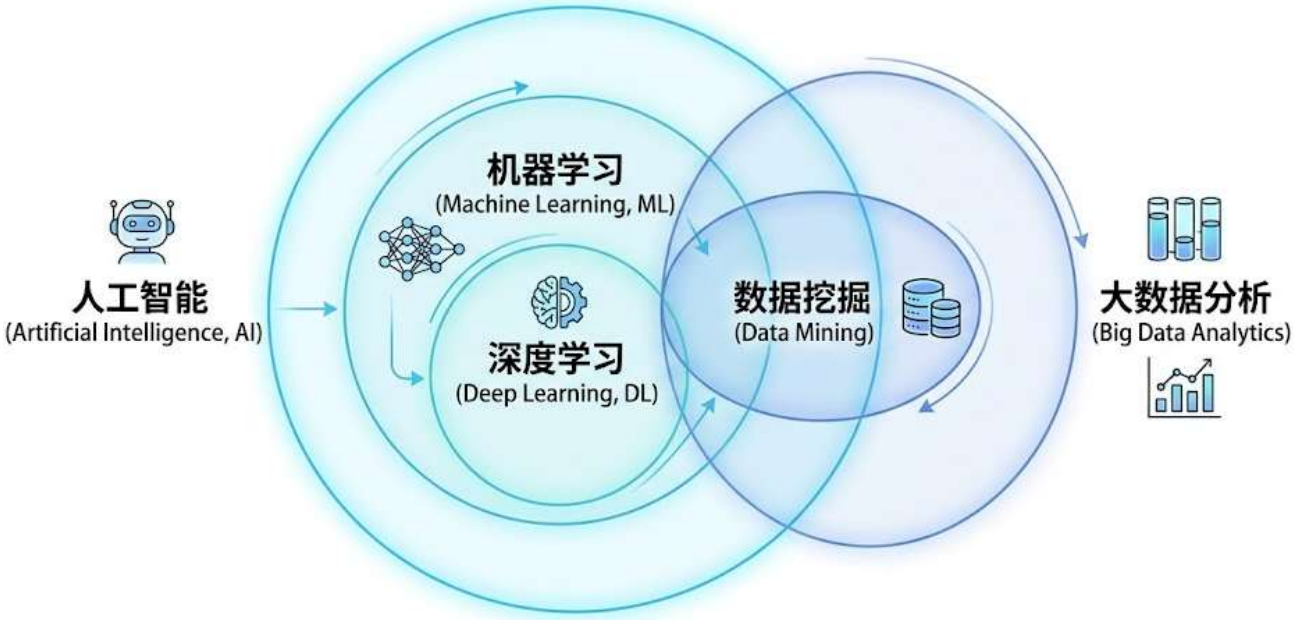
$$\theta^* = \arg\min_{\theta} \mathcal{L}(\theta|\mathcal{D})$$



How to find the optimal model?

机器学习、数据挖掘和大数据之间的关系是怎样的?

- **机器学习**：让计算机在数据中自动学习规律，并能够根据输入进行预测
  - 需要学习模型参数
- **数据挖掘**：从大量的数据中通过算法搜索隐藏于其中信息
  - 更强调在已有数据上的后处理
- **大数据下的机器学习和数据挖掘**
  - 计算模式有所不同，但是算法原理一样



人工智能（Artificial Intelligence, AI）概念的产生

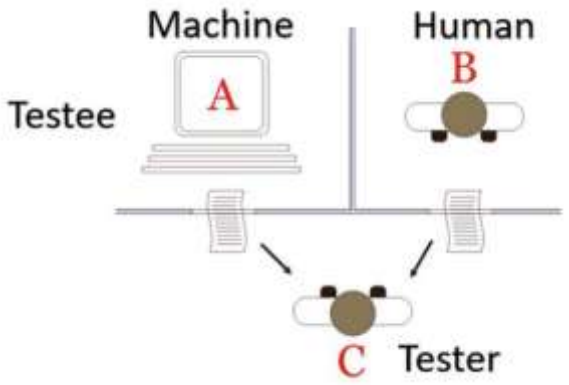


对人工智能问题的思考与探索始于20世纪50年代

- 艾伦图灵(Alan Turing)发表论文《 Computing Machinery and Intelligence 》，提出并尝试回答“**机器能否思考**”这一关键问题：**检验计算机是否具备智能，最好的办法是让它说英语并理解英语**

图灵提出了“模仿游戏” 的概念——图灵测试

- 从此图灵测试成为了**自然语言处理（Natural Language Processing，NLP）**任务的一个重要评测标准

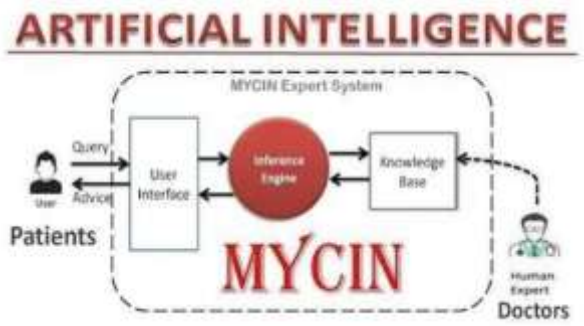


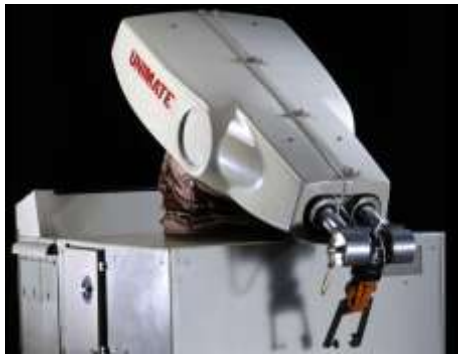
图灵测试：

如果一个人（C）使用测试对象皆理解的语言去询问两个他不能看见的对象任意一串问题，其中一个是正常思维的人（B），另一个是机器（A）。如果经过若干询问以后，C不能得出实质的区别来分辨A与B的不同，则此机器A通过图灵测试。

AI 0.x时代

- 早期的人工智能并无太多的“智能”可言
  - 代表性的技术包括70年代基于专家系统的问诊
  - 早期的工业机器人









随着机器学习技术的兴起，在90年代中后期出现了一些具有里程碑意义的成果

- 1997年，IBM的**深蓝（Deep Blue）**系统击败了人类国际象棋冠军
- 同年，IBM发布了语音识别软件 **ViaVoice**

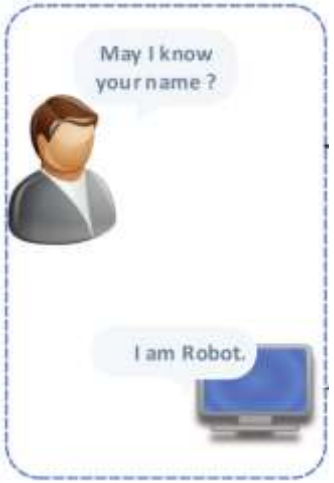




我们可能开始逐渐关注的核心问题变成：AI究竟能够达到人类智能的什么水平？比如自然语言对话、图像识别、语音识别、游戏等常见任务。









AI 1.5时代



- **到了21世纪，随着互联网的发展，互联网科技公司开始将AI技术应用在广告业务及增强用户体验上**
  - Google的网站排名算法PageRank，广告点击排名算法Adwards
  - 2007年，Netflix的电影推荐算法



- **2011年，IBM的Watson开放领域问答系统在全国电视转播的两场《Jeopardy!》比赛中击败了排名最高的两位玩家**
  - 比赛中Watson是离线的，只能使用保存在硬盘中的知识库基本包与扩展包作为自己的知识储备，和人类参赛选手一样



- **2011年，苹果推出SIRI语音助手**

AI 2.0时代：深度学习

2012年，AlexNet凭借在ImageNet上超过90%的准确率夺冠，远超第二名

- ImageNet数据集最初包含了超过1400万张图像，涵盖了超过2万个类别





2015年，随着《深度学习》论文发表，人工智能技术进入了以深度神经网络为基础的时代。基于神经网络的深度学习方法大大提高了计算机在语音识别、图像识别和自然语言处理等领域的性能。

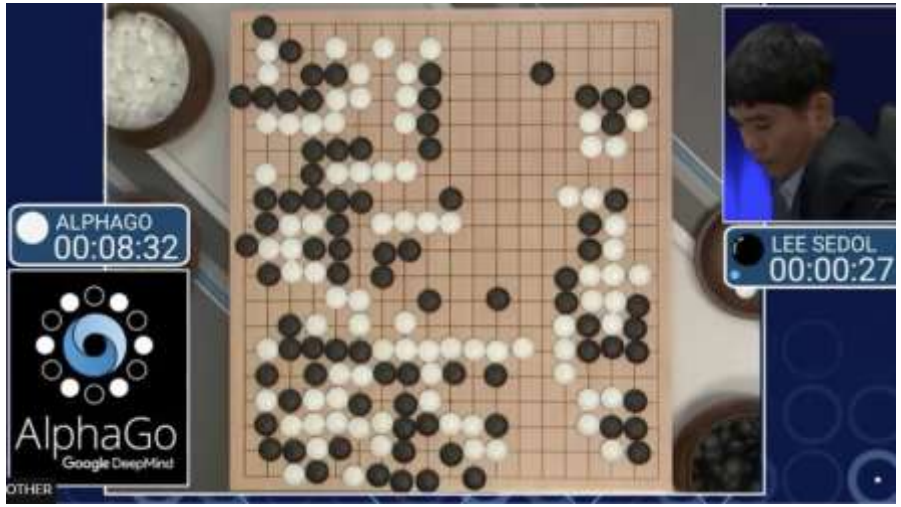




AI 2.5时代：强化学习

深度学习+强化学习的时代

- 2016年，AlphaGo击败人类围棋世界冠军李世石
- 2019年，AlphaStar在游戏《星际争霸 2》中达到了 Grandmaster，超过了99.8%的人类玩家





AI 3.0时代：AI Generated Content (AIGC)

- 2022年底，OpenAI正式发布ChatGPT。随后，以大语言模型(Large Language Model, LLM) 为代表的生成式AI模型的应用与需求呈爆炸式增长

ChatGPT



上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

Thank You

