大数据挖掘技术——频繁模式挖掘

丁玥
上海交通大学计算机学院
dingyue@sjtu.edu.cn

2026年秋季

饮 水 思 源 • 爱 国 荣 校

频繁模式挖掘

- **频繁模式（Frequent pattern）：是频繁地出现在数据集中的模式**
  - 如子序列或子结构
- **频繁模式挖掘是数据挖掘中的一个重要任务，它旨在从大规模数据集中发现频繁出现的模式、关联、相关结构等**
  - 经常在一起购买什么样的产品——啤酒和尿布？！
  - 购买一台PC以后再买什么？
  - 什么样的DNA对这个新的药物敏感？
- **应用**
  - 购物篮数据分析，跨界营销，目录设计，销售活动分析，Web日志（点击流）分析，DNA序列分析

频繁模式挖掘

- **项（Item）**：项是数据集中的基本单位，例如商品、单词等
- **事务（Transaction）**：一个事务通常指的是数据库中的一个记录，它可以包含多个项（Item）
- **项集（Itemset）**：项集是项的集合，例如{牛奶，面包}
- **支持度（Support）**：出现该项集的事务数在总事务数中的占比
- **频繁项集（Frequent Itemset）**：如果某个项集的**支持度**大于等于用户设定的最小支持度阈值（min_support），则称该集合为频繁项集

订单编号	购买的商品
1	牛奶、面包、尿布
2	可乐、面包、尿布、啤酒
3	牛奶、尿布、啤酒、鸡蛋
4	面包、牛奶、尿布、啤酒
5	面包、牛奶、尿布、可乐

频繁模式分析

- **关联规则（Association Rule）**：一种蕴含关系，形如A→B的表达式，其中A和B是项集，**且A和B没有共同的项**
  - 规则的强度可以用支持度和置信度来度量
  - 可以从频繁项集中生成关联规则，然后使用置信度阈值来评估规则的强度
  - 在生成关联规则后，剪枝过程用于移除那些不满足最小置信度或提升度阈值的规则，以减少规则的数量并提高规则的质量。
- **置信度（Confidence）**：关联规则A→B的置信度是指**同时包含A和B的事务数与只包含A的事务数之比**

频繁模式挖掘

订单编号	购买的商品
1	牛奶、面包、尿布
2	可乐、面包、尿布、啤酒
3	牛奶、尿布、啤酒、鸡蛋
4	面包、牛奶、尿布、啤酒
5	面包、牛奶、尿布、可乐

{牛奶} 的**支持度**为 4/5=0.8

{牛奶、面包} 的**支持度**为 3/5=0.6

{牛奶->啤酒} 的**置信度**为2/4 = 0.5（*实际计算的是在买了牛奶的事务中同时又买了啤酒的占比是多少*）

$$confidence(A \Rightarrow B) = P(B \mid A) = P(A \cup B) / P(A)$$

{啤酒->牛奶} 的**置信度**为 2/3 = 0.67 *(实际计算的是在买了啤酒的事务中同时又买了牛奶的占比是多少)*

提升度：商品A的出现，对商品B的出现概率提升的程度

提升度(A→B)=置信度(A→B) / 支持度(B)

{牛奶->啤酒}的提升度=0.5/(3/5)=0.83

提升度的三种可能：

提升度(A→B)>1：代表有提升；

提升度(A→B)=1：代表有没有提升，也没有下降；

提升度(A→B)<1：代表有下降。

Apriori算法是一种用于关联规则学习的经典算法

- 由Rakesh Agrawal和Ramakrishnan Srikant在1994年提出。它主要用于挖掘数据集中频繁项集和生成关联规则
- Apriori算法的核心思想是利用已有的频繁项集来生成更长的候选项集，然后通过数据集的扫描来验证这些候选项集是否频繁

Apriori算法的步骤

第 1 步：设置最小支持度阈值

第 2 步：寻找满足最小支持度的单件商品

第 3 步：从第 2 步找到的所有满足最小支持度的单件商品中，进行两两组合，寻找满足最小支持度的两件商品组合

第 4 步：从第 3 步找到的所有满足最小支持度的两件商品，以及第 2 步找到的满足最小支持度的单件商品进行组合，寻找满足最小支持度的三件商品组合

第 5 步：以此类推，找到所有满足最小支持度的商品组合

Apriori算法挖掘频繁模式的例子

Database

Tid	Items
1	A, C, D
2	B, C, E
3	A, B, C, E
4	B, E

1st scan

C_1

Itemset	sup
{A}	0.5
{B}	0.75
{C}	0.75
{D}	0.25
{E}	0.75

L_1

Itemset	Sup
{A}	0.5
{B}	0.75
{C}	0.75
{E}	0.75

最小支持度 =0.5

最大长度=3

Itemset
{A, B}
{A, C}
{A, E}
{B, C}
{B, E}
{C, E}

2nd scan

C_2

Itemset	sup
{A, B}	0.25
{A, C}	0.5
{A, E}	0.25
{B, C}	0.5
{B, E}	0.75
{C, E}	0.5

L_2

Itemset	sup
{A, C}	0.5
{B, C}	0.5
{B, E}	0.75
{C, E}	0.5

3rd scan

C_3

Itemset	sup
{A, B, C}	0.25
{A, C, E}	0.25
{B, C, E}	0.5

L_3

Itemset	sup
{B, C, E}	0.5

C_k: 长度为k的候选集

L_k：长度为k的频繁项集

关联规则分析的例子

交易ID	商品集合
1	牛奶, 面包, 黄油
2	面包, 黄油, 酸奶
3	牛奶, 面包, 酸奶, 黄油
4	牛奶, 酸奶
5	面包, 黄油

步骤 1：生成频繁项集。使用Apriori算法找到支持度大于0.4的频繁项集

频繁1项集：
{牛奶}，支持度 = 3/5 = 0.6
{面包}，支持度 = 4/5 = 0.8
{黄油}，支持度 = 4/5 = 0.8
{酸奶}，支持度 = 3/5 = 0.6

频繁2项集：
{牛奶, 面包}，支持度 = 2/5 = 0.4
{牛奶, 黄油}，支持度 = 2/5 = 0.4
{面包, 黄油}，支持度 = 4/5 = 0.8
{面包, 酸奶}，支持度 = 2/5 = 0.4

频繁3项集：
{牛奶, 面包, 黄油}，支持度 = 2/5 = 0.4

步骤 2：从频繁项集中逐一生成规则，计算置信度，阈值为0.7

规则1：面包 → 黄油
规则2：黄油 → 面包
规则3：牛奶，面包 → 黄油
规则4：牛奶，黄油 → 面包
规则5：面包，黄油 → 牛奶

面包 → 黄油
“面包和黄油”的置信度 = 4/4 = 1，满足条件。

其他规则均不符合条件

https://spark.apache.org/docs/latest/mllib-frequent-pattern-mining.html

- FP-growth算法，对Apriori算法进行了改进，提升了计算效率

```
from pyspark.ml.fpm import FPGrowth

df = spark.createDataFrame([
    (0, [1, 2, 5]),
    (1, [1, 2, 3, 5]),
    (2, [1, 2])
], ["id", "items"])

fpGrowth = FPGrowth(itemsCol="items", minSupport=0.5, minConfidence=0.6)
model = fpGrowth.fit(df)

# Display frequent itemsets.
model.freqItemsets.show()

# Display generated association rules.
model.associationRules.show()

# transform examines the input items against all the association rules and summarize the
# consequents as prediction
model.transform(df).show()
```

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

Thank You

