大数据挖掘技术——聚类算法

丁玥
上海交通大学计算机学院
dingyue@sjtu.edu.cn

2026年秋季

饮 水 思 源 • 爱 国 荣 校

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

目 录

1 聚类算法K-means

2 Scikit-learn和Spark MLlib



上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

目 录



1 聚类算法K-means

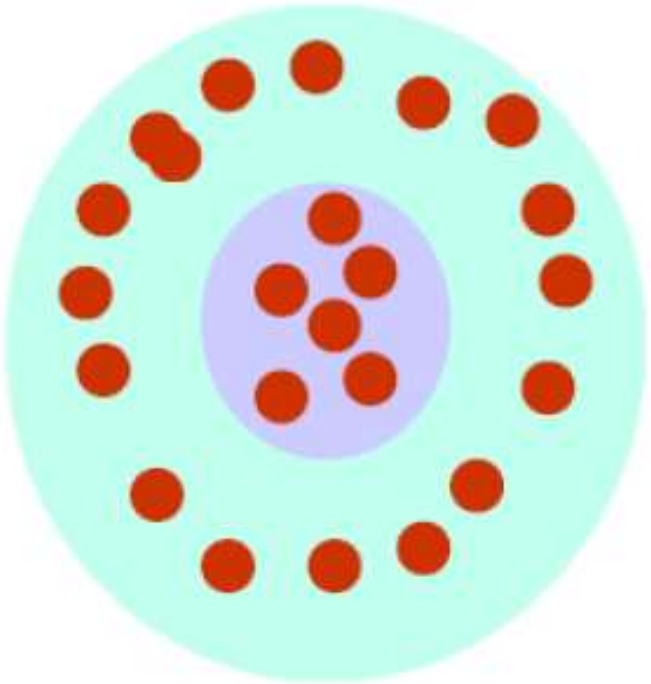
2 Scikit-learn和Spark MLlib

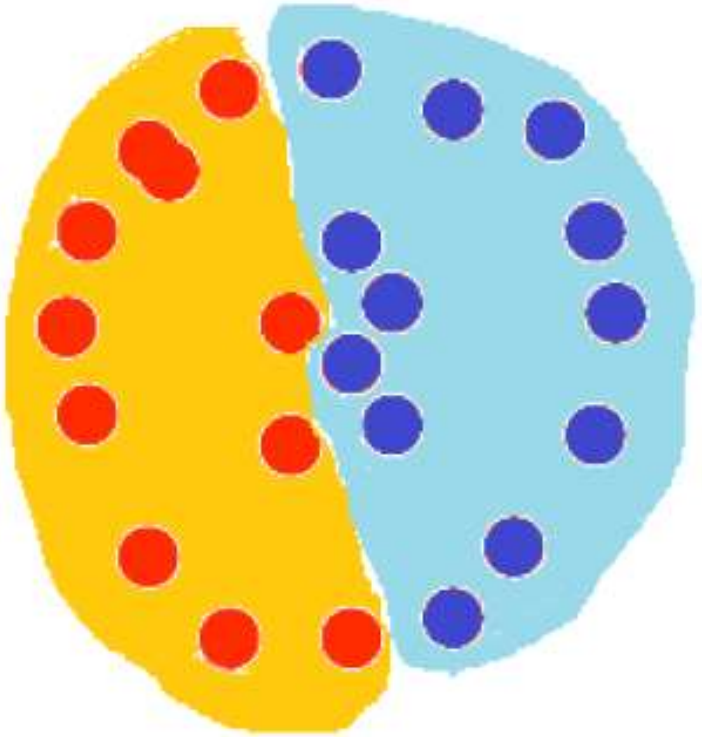
什么是聚类?

- 把数据对象(或观测)划分成子集的过程：**可以将聚类看作是试图找到数据中的自然分组**
- 聚类可以发现数据点之间的潜在关系，了解不同类别之间有哪些共同的特征或特性：**簇内对象彼此相似，簇外彼此相异**



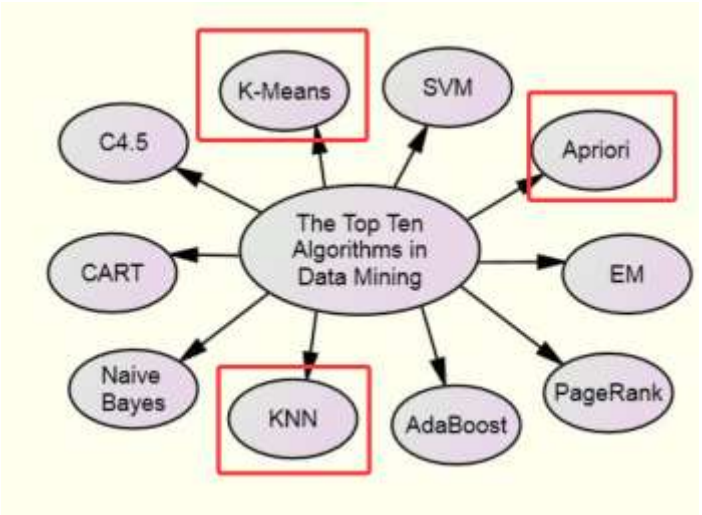
- 问题：下面两种聚类方式哪个更好?





- *K*-means算法是数据挖掘的“十大”最具影响力的算法之一



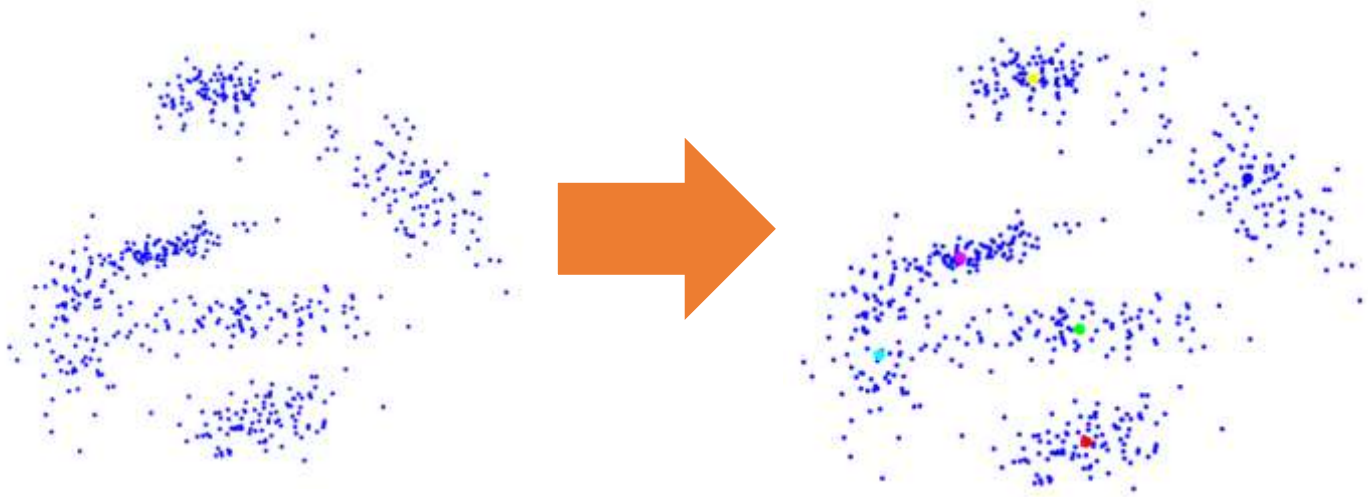


- 从机器学习的视角看，*K*-means属于无监督学习算法
  - 没有类的标记信息
  - 从数据本身来学习其中隐含的pattern

- ***K*-means（MacQueen，1967）是一种划分聚类算法**
- **设数据集D为**$\{ x_1, x_2, x_3, \ldots, x_n \}$,

  其中 $x_{i \in n}$ 是一个***d***维向量

- ***K*-means算法将给定的数据划分为*k*个簇**
  - 每个簇都有一个簇中心，称为质心（**centroid**）
  - ***k***由用户指定



K-means算法的具体步骤

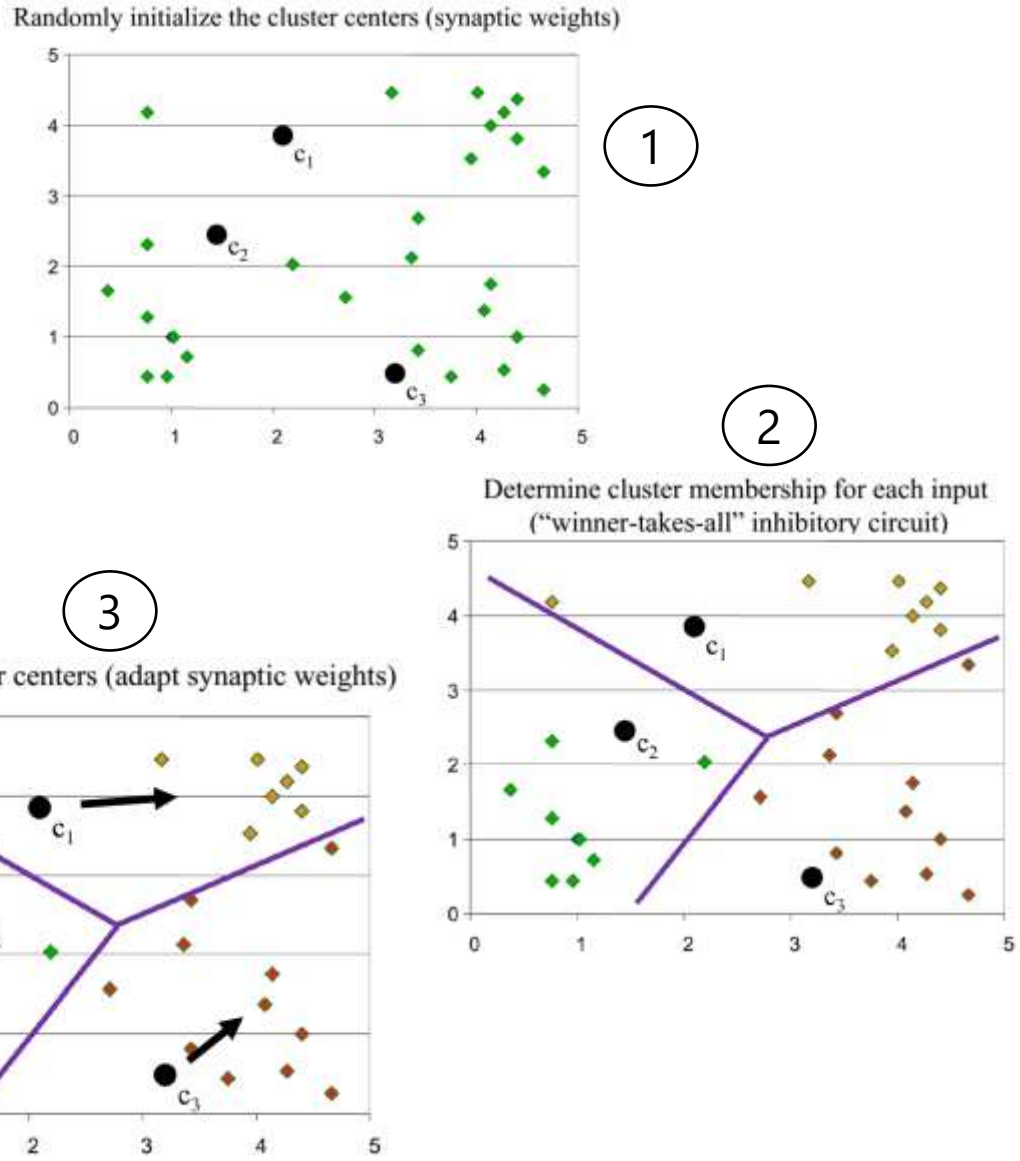
- 1. 选择***k***个（随机）数据点作为初始质心，即簇中心
- 2. 将每个数据点分配给最近的质心
  - 计算每个数据点和所有质心的欧几里得距离:

$$L_2(x, \mu^k) = \|x - \mu^k\| = \sqrt{\sum_{m=1}^{d}(x_i - \mu_m^k)^2}$$

- 3. 使用当前的簇成员关系重新计算质心

$$\mu^k = \frac{1}{C_k}\sum_{x \in C_k} x$$

- 4. 如果未满足收敛标准，则重复步骤2和3



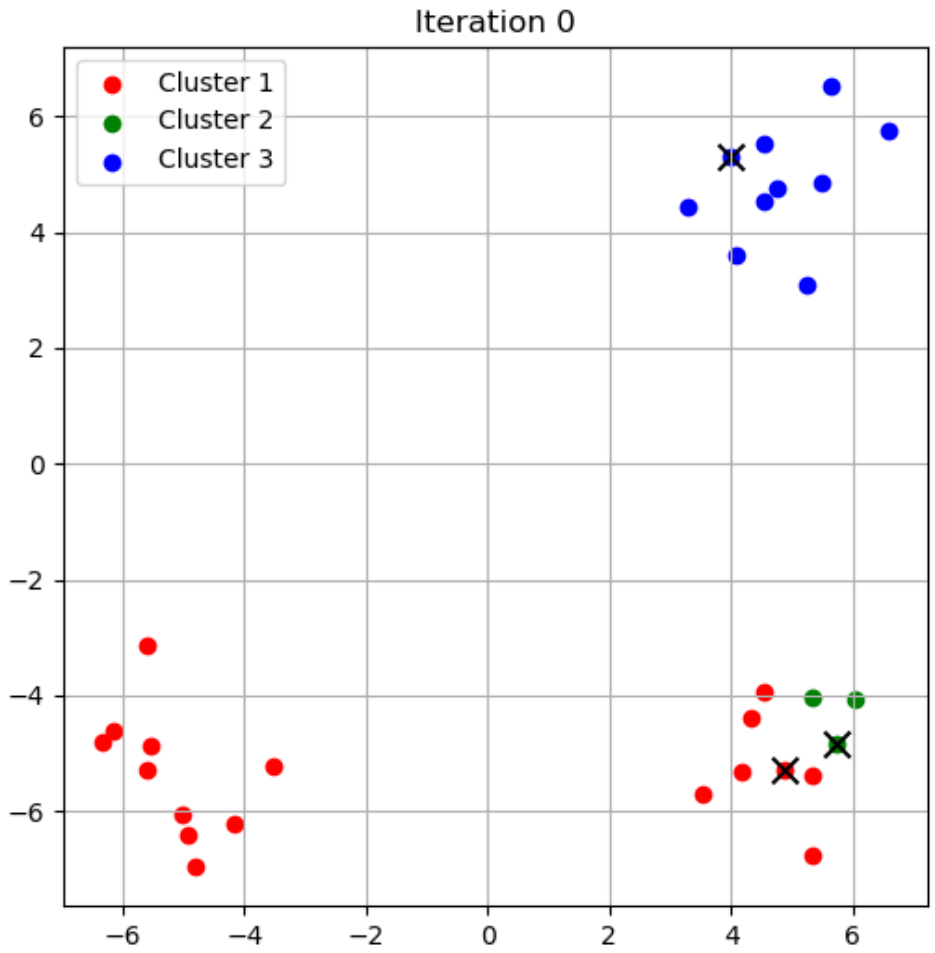
K-means算法的收敛条件

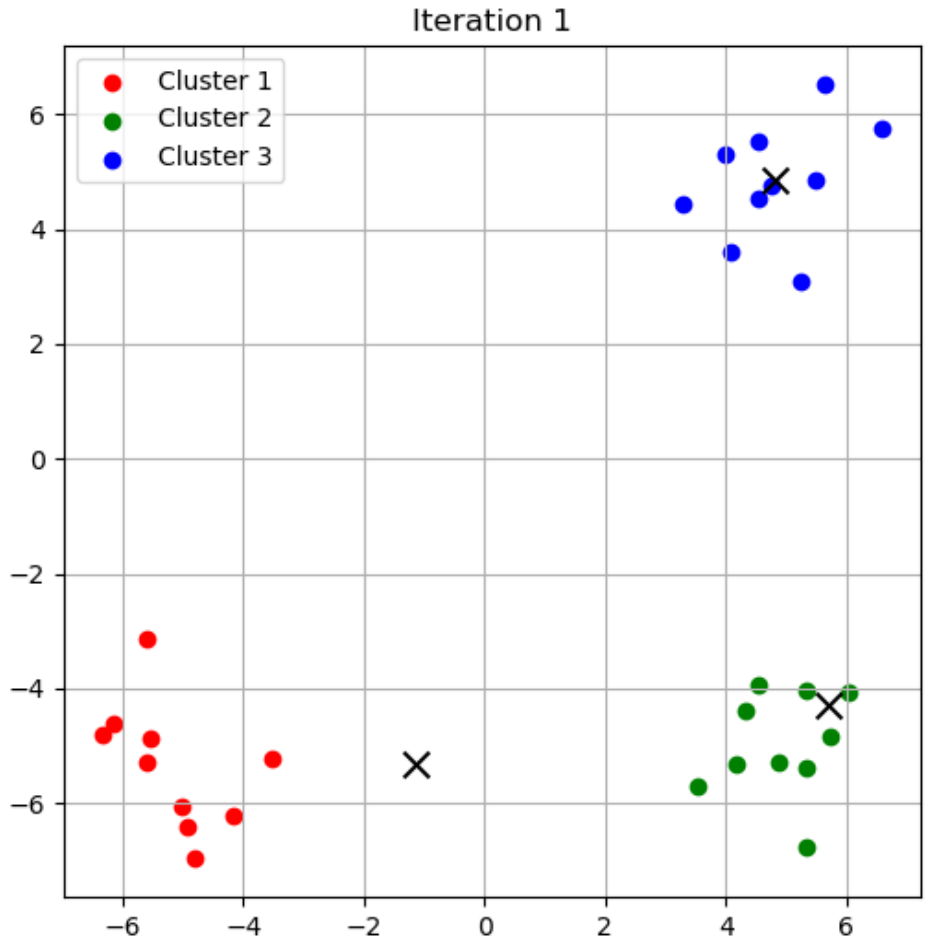
- 数据点被重新分配到不同簇的次数为零（或小于一个阈值），或者
- 质心的变化为零（或小于一个阈值），或者
- 总平方误差（Sum of Squared Error, SSE）的小于一个阈值：

$$\min_{\{\mu^k\}_{k=1}^K} \sum_{k=1}^{K} \sum_{x \in C_k} L(x - \mu^k) \qquad \mu^k = \frac{1}{C_k} \sum_{x \in C_k} x$$

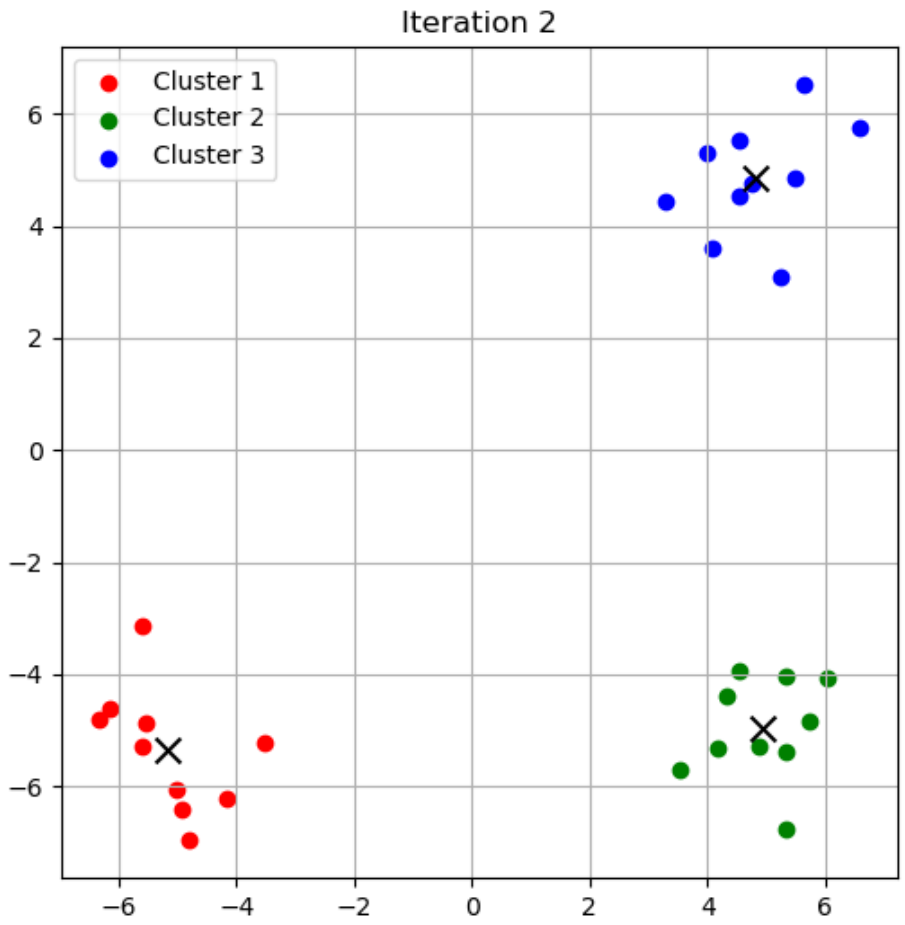
- 寻找全局最优解是NP-hard问题
  - NP问题指答案容易验证的问题：给定一个候选解可以快速检查它是否正确，例如数独
  - NP-hard问题指**至少跟 NP 中最难的问题一样难**的问题：没法快速检查“对不对”，例如TSP问题
- ***K*-means算法保证会收敛到一个局部最优解**

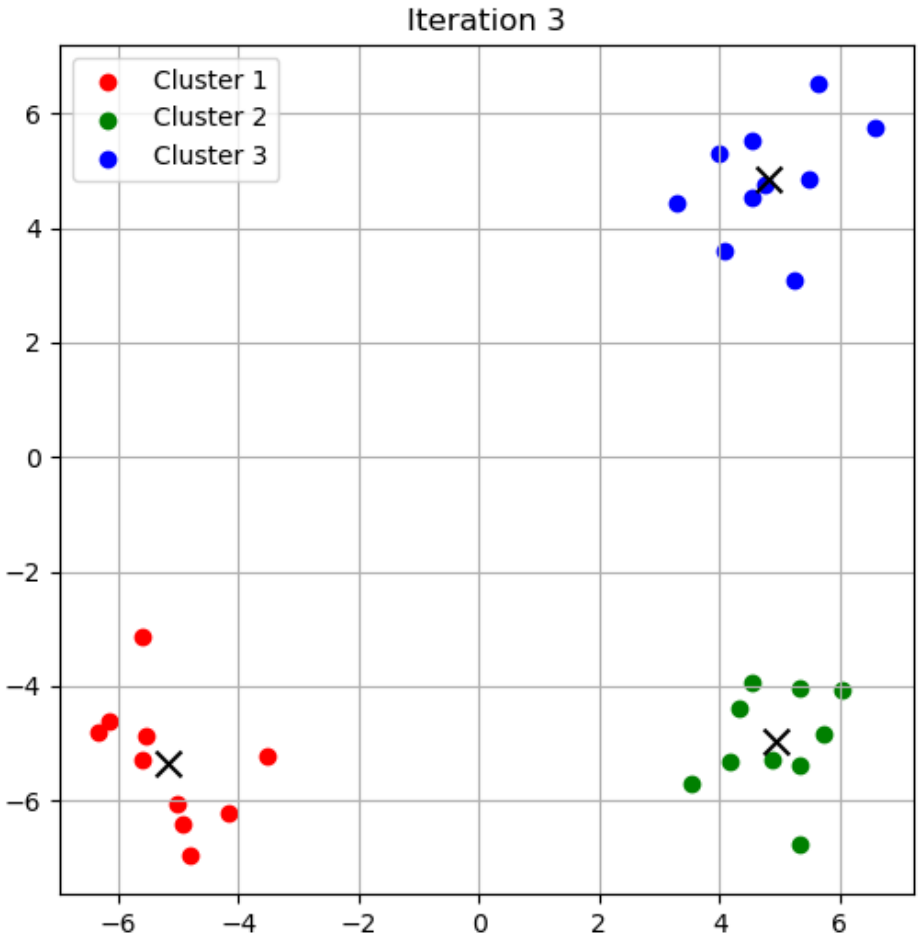
K-means算法完整计算示例：30个数据点，k=3





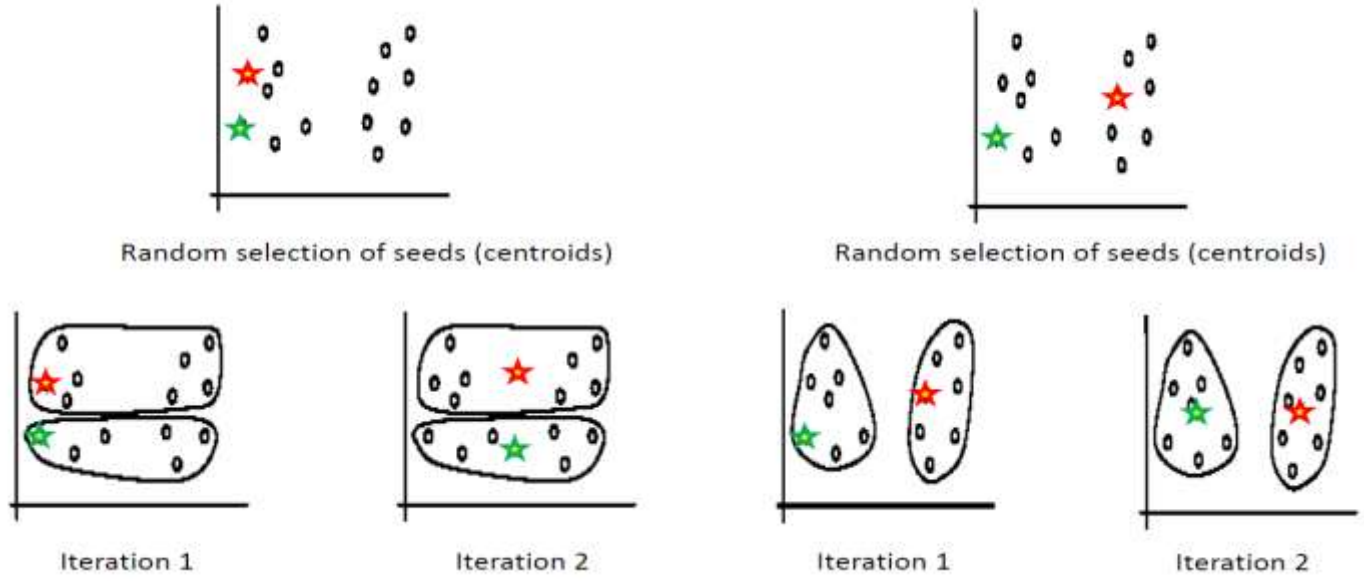
K-means算法完整计算示例：30个数据点，k=3





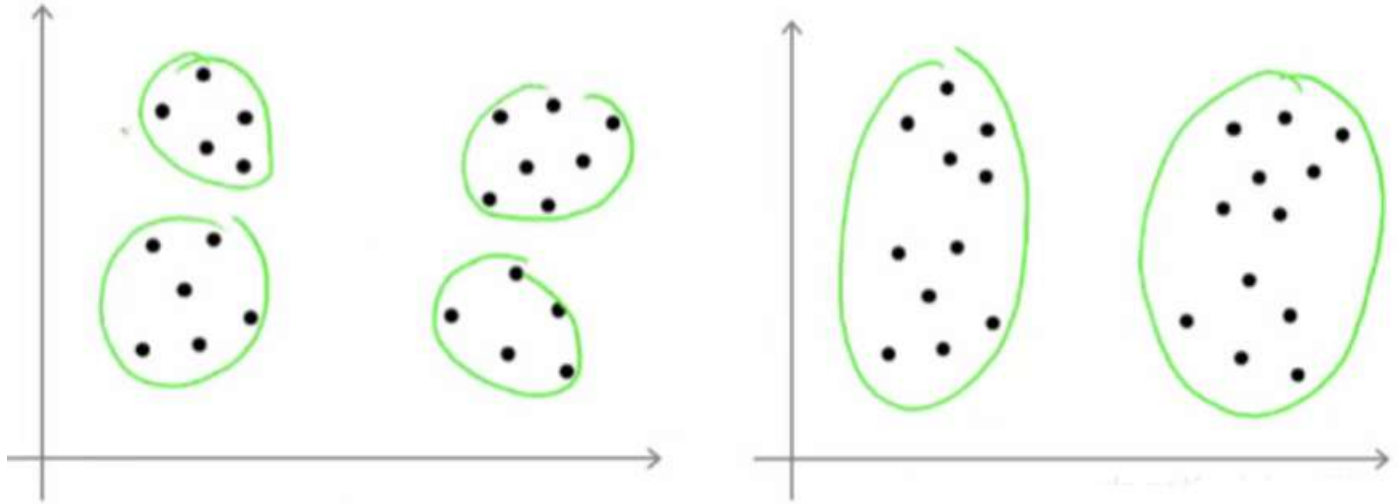
K-means算法的几个问题讨论

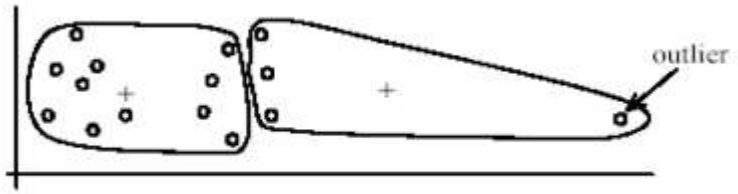
- 算法对初始质心位置很敏感
- 有可能产生比较差的结果
- 可能的改进办法：加入启发式算法或者其他算法策略来得到可能的更好的seed



K-means算法的几个问题讨论

- 如何确定K的值?
  - 很遗憾，没有确定的做法。通常凭经验，以及多次尝试不同的K，看聚类的结果是否具有较好的解释性
- 对异常点敏感





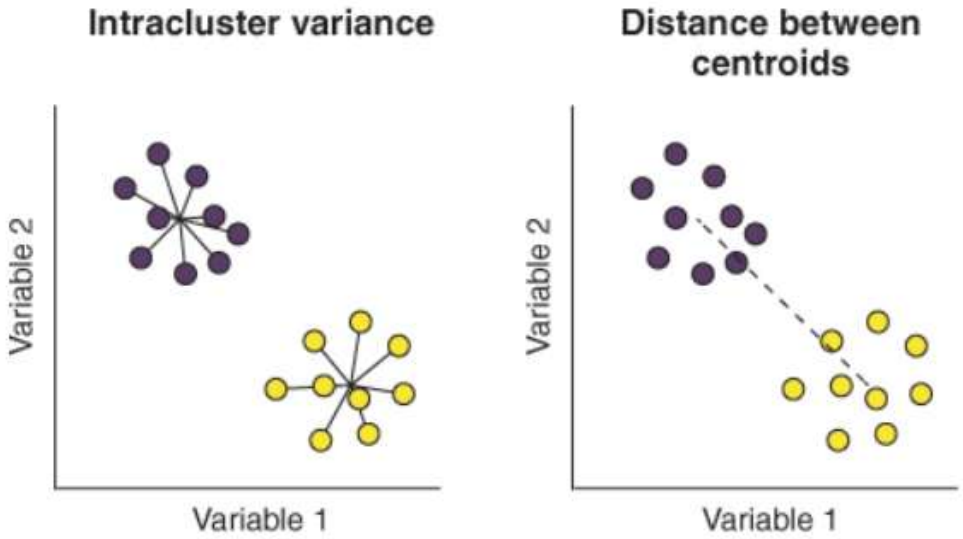
(A): Undesirable clusters



(B): Ideal clusters

如何评估聚类效果

- **内在指标：**分析的质量完全取决于数据点之间的关系。当我们没有数据的先验知识或标签时，就可以使用它们
  - **Davies-Bouldin（DB）指数：**基于聚类内样本的紧密程度和聚类之间的分离程度来衡量聚类的质量。DB指数的值越小，表示聚类效果越好，也就是说聚类**内部的样本更紧密**，而**聚类之间的分离度更高。**

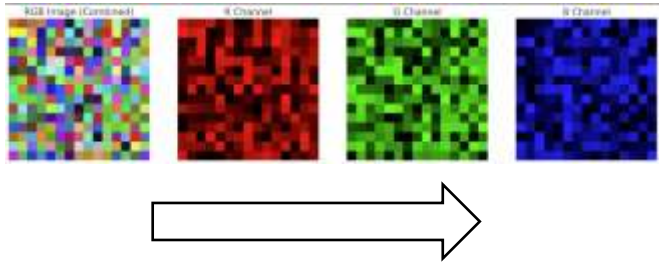


聚类算法*K*-means

K-means的应用：图片压缩

- 每种颜色都会有一个对应RGB值，比如黑色是[0,0,0]，白色是[255,255,255]
- 相同分辨率的情况下，一张纯色图片是比一张五彩斑斓的图片要小得多







	R	G	B	值		R	G	B	值		R	G	B	值
黑色	0	0	0	#000000	黄色	255	255	0	#FFFF00	浅灰蓝色	176	224	230	#B0E0E6
象牙黑	41	36	33	#292421	金黄色	227	207	87	#E3CF57	皇家蓝	65	105	225	#4169E1
灰色	192	192	192	#C0C0C0	橘黄	255	153	18	#FF9912	石板蓝	106	90	205	#6A5ACD
冷灰	128	138	135	#808A87	dougello	235	142	85	#EB8E55	天蓝	135	206	235	#87CEEB
石板灰	112	128	105	#708069	forum gold	255	227	132	#FFE384					
煤灰色	128	128	105	#808069	全黄色	255	215	0	#FFD700	青色	0	255	255	#00FFFF



一张分辨率为100*100的图片，其实就是由10000个RGB值组成。所以我们要做的就是对于这10000个RGB值聚类成*K*个簇，然后**使用每个簇内的质心点来替换簇内所有的RGB值**，这样在不改变分辨率的情况下使用的颜色减少了，图片大小也就会减小了（但是会不鲜艳）

K-means的应用：图像分割

- 把一张图像切成有意义的区域，让每个像素都“知道”自己属于什么对象或区域



0: Background/Unknown
1: Person
2: Purse
3: Plants/Grass
4: Sidewalk
5: Building/Structures













上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

目 录

1 聚类算法K-means

2 Scikit-learn和Spark MLlib



Scikit-learn

- Scikit-learn是基于python的机器学习库，内含分类、回归、聚类等多个机器学习算法

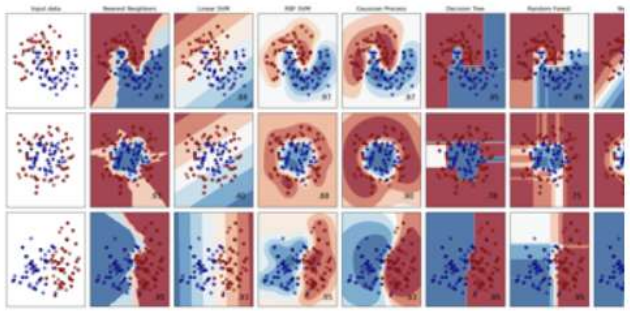
scikit-learn

Machine Learning in Python

Classification

Identifying which category an object belongs to.

Applications: Spam detection, image recognition.
Algorithms: Gradient boosting, nearest neighbors, random forest, logistic regression, and more...

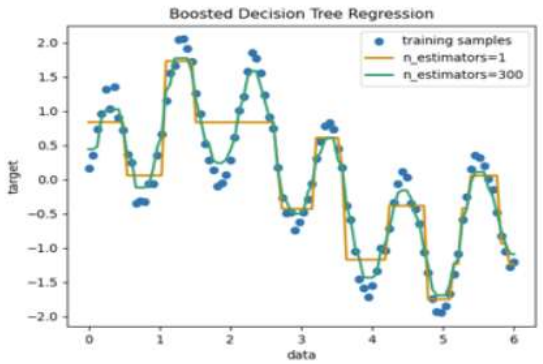


Examples

Regression

Predicting a continuous-valued attribute associated with an object.

Applications: Drug response, Stock prices.
Algorithms: Gradient boosting, nearest neighbors, random forest, ridge, and more...

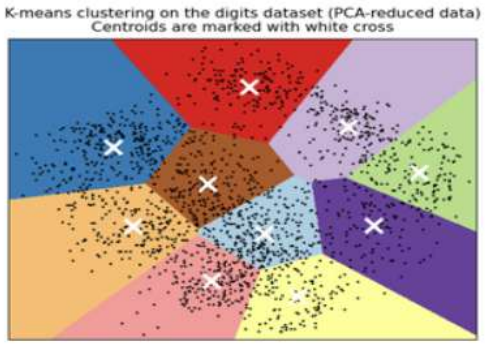


Examples

Clustering

Automatic grouping of similar objects into sets.

Applications: Customer segmentation, Grouping experiment outcomes
Algorithms: k-Means, HDBSCAN, hierarchical clustering, and more...



Examples

Scikit-learn实现*K*-means的示例代码

- https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html

Examples

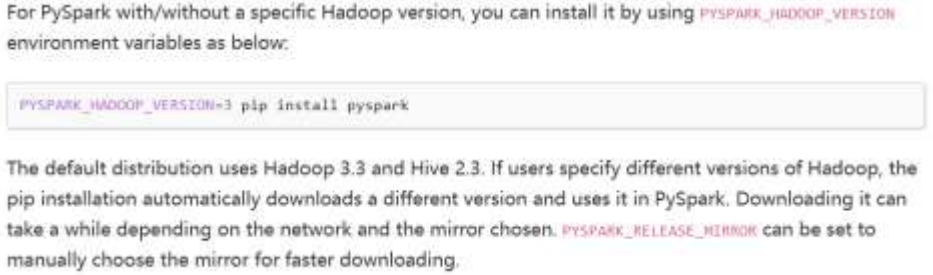
```
>>> from sklearn.cluster import KMeans
>>> import numpy as np
>>> X = np.array([[1, 2], [1, 4], [1, 0],
...               [10, 2], [10, 4], [10, 0]])
>>> kmeans = KMeans(n_clusters=2, random_state=0, n_init="auto").fit(X)
>>> kmeans.labels_
array([1, 1, 1, 0, 0, 0], dtype=int32)
>>> kmeans.predict([[0, 0], [12, 3]])
array([1, 0], dtype=int32)
>>> kmeans.cluster_centers_
array([[10.,  2.],
       [ 1.,  2.]])
```

PySpark 是Spark的Python API

- https://spark.apache.org/docs/latest/api/python/index.html
- **PySpark适合数据科学和机器学习任务，Spark则适合使用Java和Scala语言的开发者**

使用PySpark

- **如果已安装Spark，那么PySpark作为Spark的一部分不需要单独安装**
- 如果在独立的Python环境中直接使用PySpark，则需要单独安装PySpark
- https://spark.apache.org/docs/latest/api/python/getting_started/install.html
- 注意安装的Python版本、PySpark版本和Hadoop版本之间的适配



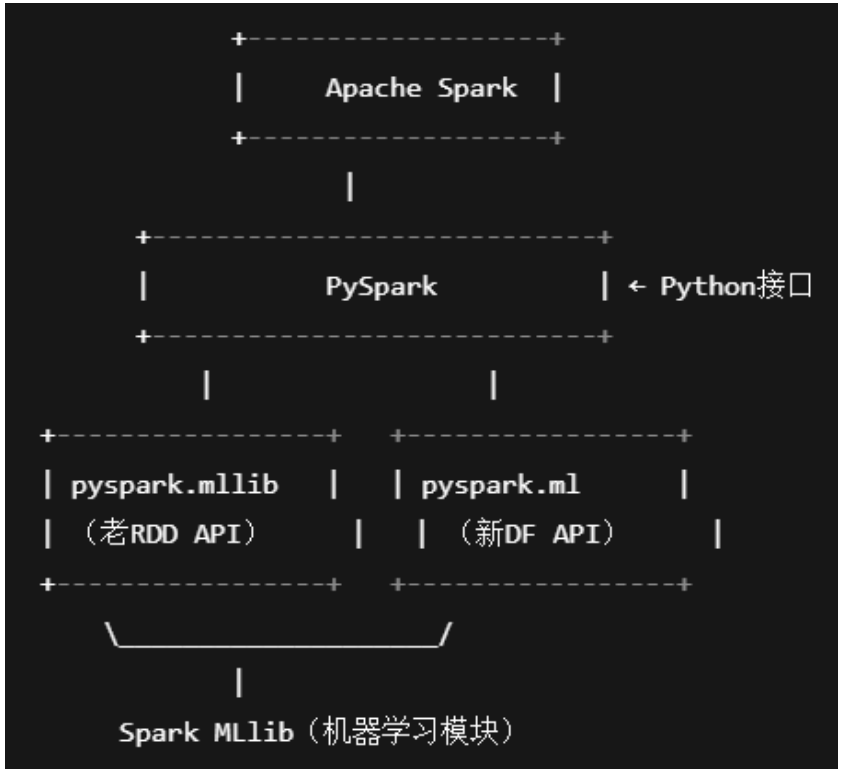




Spark MLlib

- Spark MLlib是Spark中用于机器学习的模块
- MLlib包含了非常丰富的机器学习算法：分类、回归、聚类、协同过滤、主成分分析等等
- 在PySpark中可以通过pyspark.ml或 pyspark.mllib来调用 Spark MLlib的机器学习模块
  - 例如，from pyspark.ml.classification import LogisticRegression
  - PySpark还提供Spark的其他功能例如SQL，通过pyspark.sql实现
  - Mllib提供了两套API，分别是ml（新，基于DataFrame）和mllib（旧，基于RDD，未来逐渐废弃，不推荐）

MLlib is Apache Spark's scalable machine learning library.



Spark Mllib实现*K*-means的示例代码

- https://spark.apache.org/docs/latest/ml-clustering.html#k-means

```
from pyspark.ml.clustering import KMeans
from pyspark.ml.evaluation import ClusteringEvaluator

# Loads data.
dataset = spark.read.format("libsvm").load("data/mllib/sample_kmeans_data.txt")

# Trains a k-means model.
kmeans = KMeans().setK(2).setSeed(1)
model = kmeans.fit(dataset)

# Make predictions
predictions = model.transform(dataset)

# Evaluate clustering by computing Silhouette score
evaluator = ClusteringEvaluator()

silhouette = evaluator.evaluate(predictions)
print("Silhouette with squared euclidean distance = " + str(silhouette))

# Shows the result.
centers = model.clusterCenters()
print("Cluster Centers: ")
for center in centers:
    print(center)
```

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

Thank You

