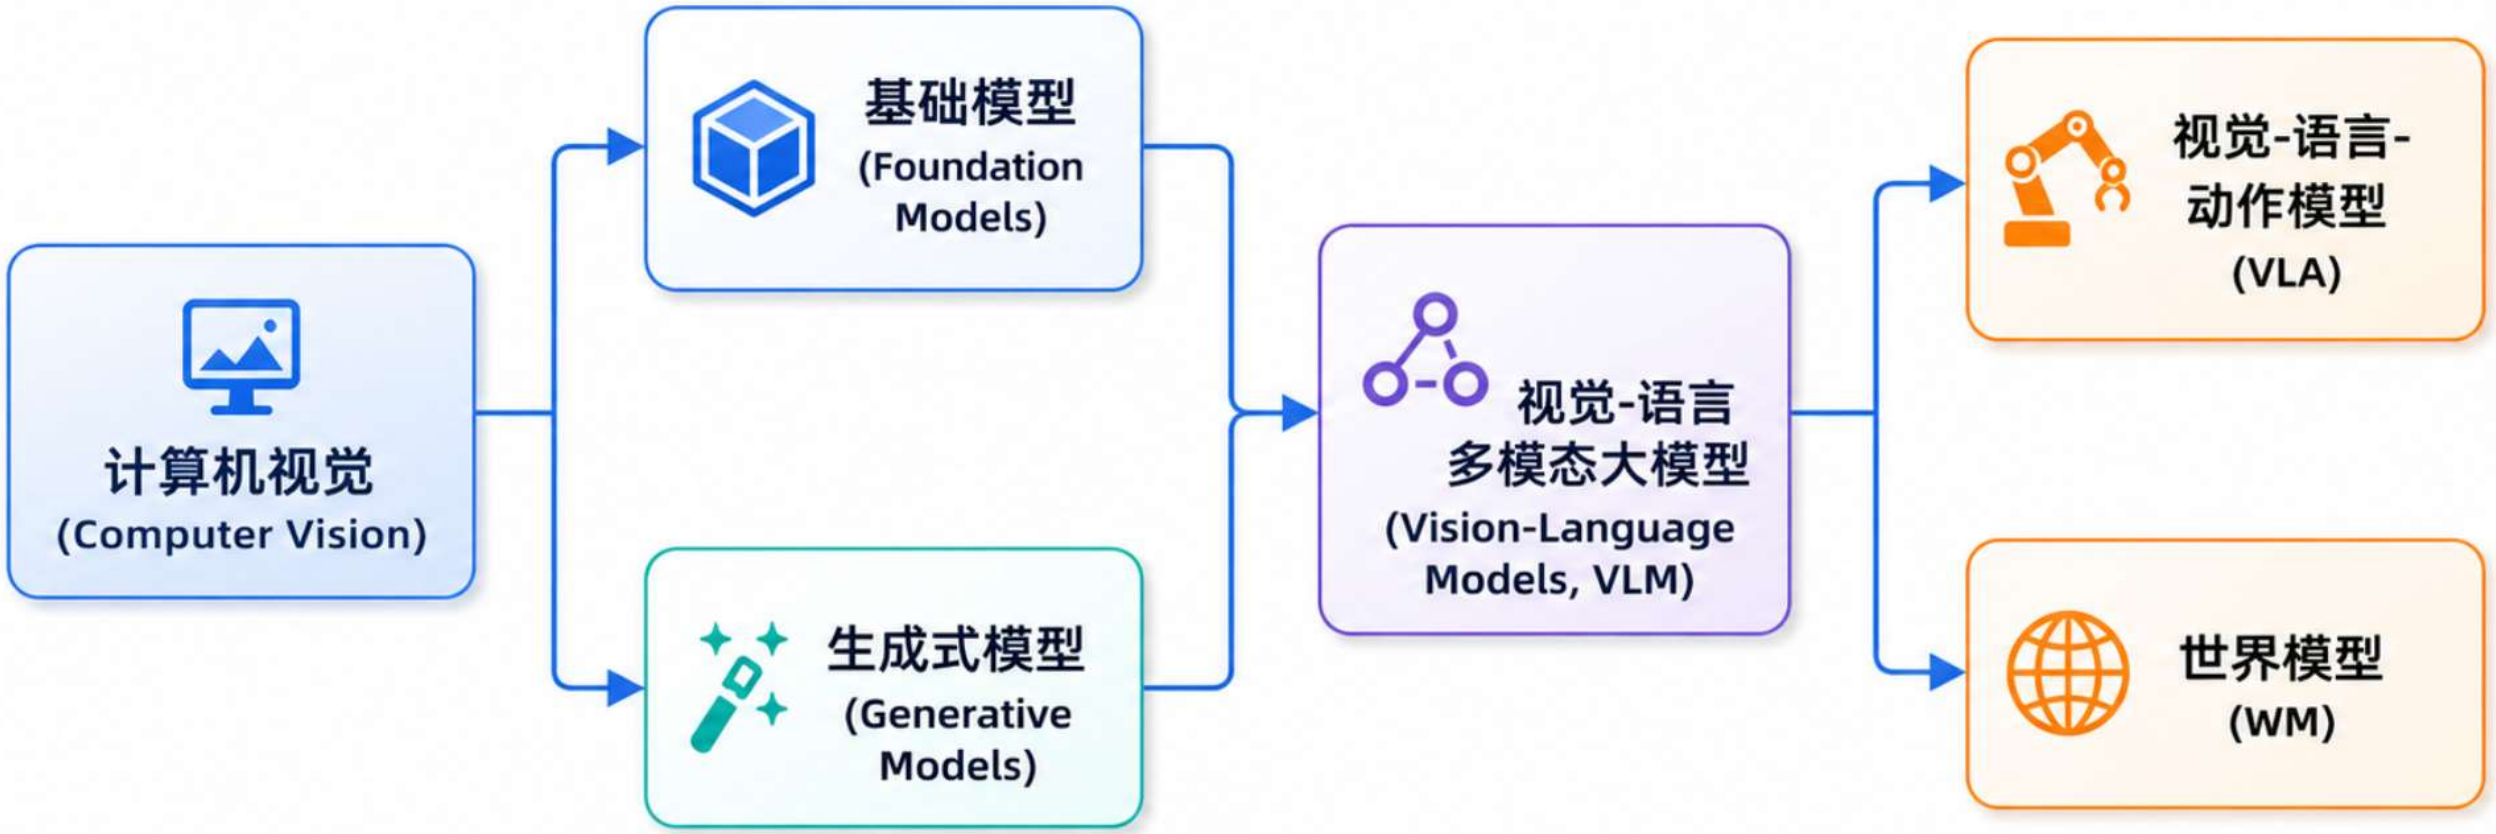
# 视觉基础模型和多模态大模型

丁玥
上海交通大学计算机学院
dingyue@sjtu.edu.cn

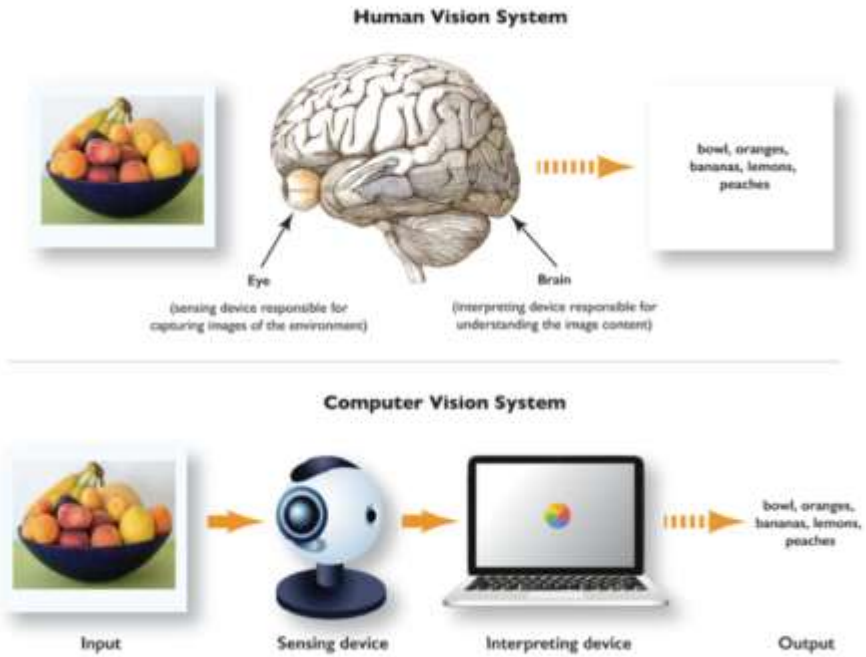
2026年春季

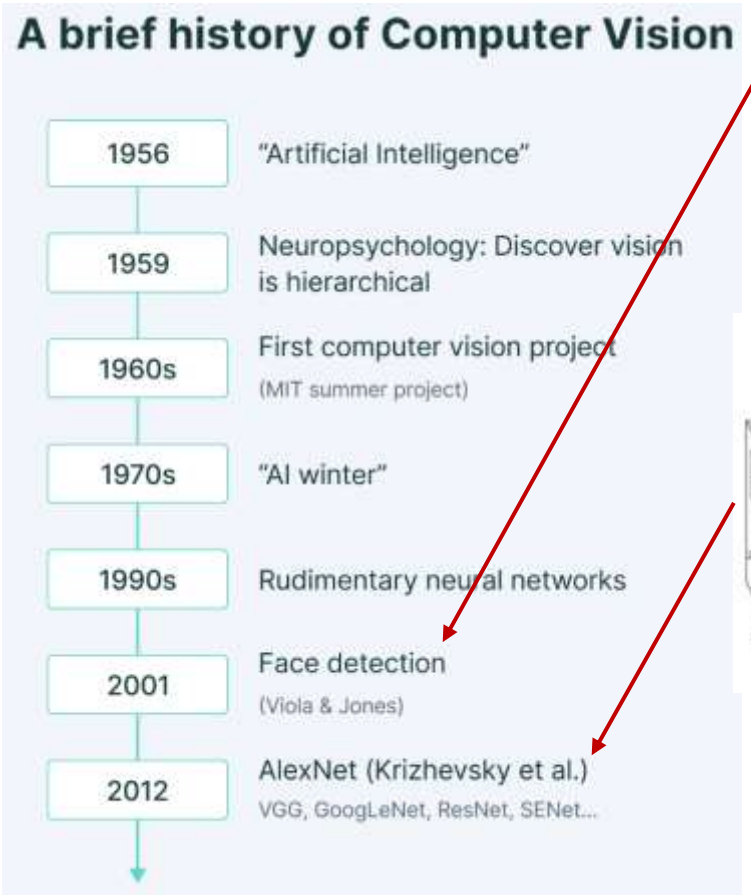
饮 水 思 源 • 爱 国 荣 校


计算机视觉
(Computer Vision)
基础模型
(Foundation Models)
生成式模型
(Generative Models)
视觉-语言
多模态大模型
(Vision-Language Models, VLM)
视觉-语言-动作模型
(VLA)
世界模型
(WM)

# 计算机视觉（Computer Vision）

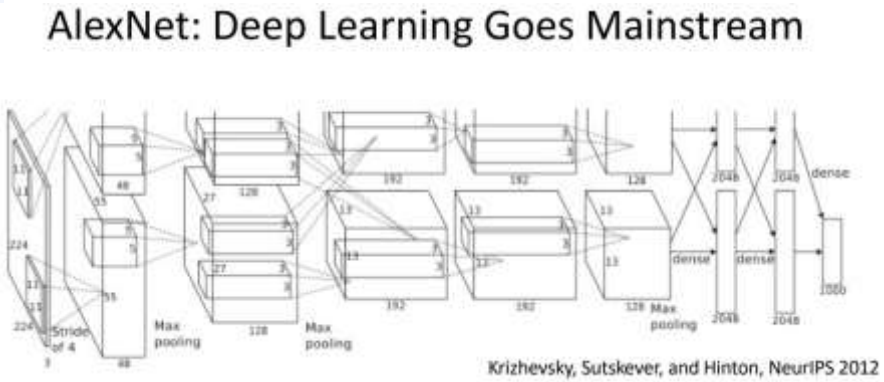
- 通俗地讲，计算机视觉技术是指如何教会计算机（使用摄像头）观察世界，以及（使用算法）理解和解释周围的世界












## 计算机内图像的表示方法



彩色图像



灰度图像



二值图像




用**RGB三个分量**（R：Red，G：Green，B：Blue）即红、绿、蓝三原色来表示真彩色，R分量，G分量，B分量的**取值范围均为0~255**

R (Red)

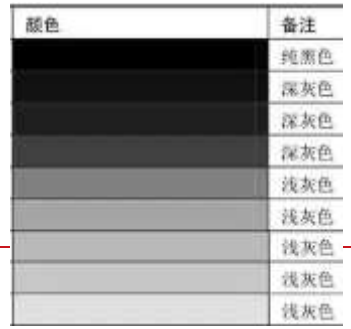
| | | |
|---|---|---|
| 255 | 240 | 240 |
| 255 | 0 | 80 |
| 255 | 0 | 0 |

G (Green)

| | | |
|---|---|---|
| 0 | 160 | 80 |
| 255 | 255 | 160 |
| 0 | 255 | 0 |

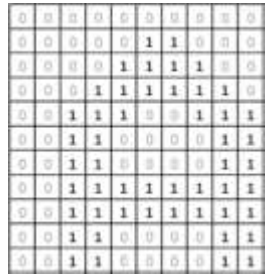
B (Blue)

| | | |
|---|---|---|
| 0 | 80 | 160 |
| 0 | 0 | 240 |
| 255 | 255 | 255 |

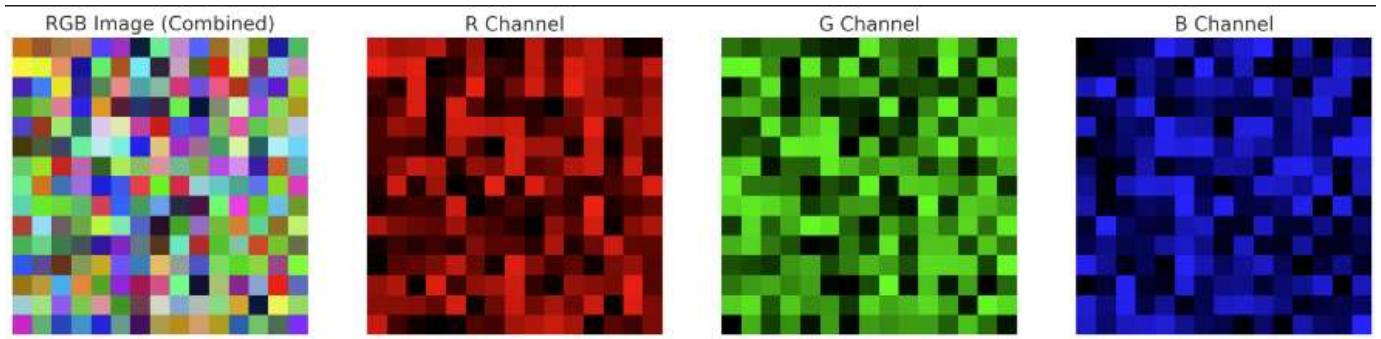



用数值区间[0，255]来表示。其中，**数值“255”表示纯白色，数值“0”表示纯黑色**，其余的数值表示从纯白到纯黑之间不同级别的灰度

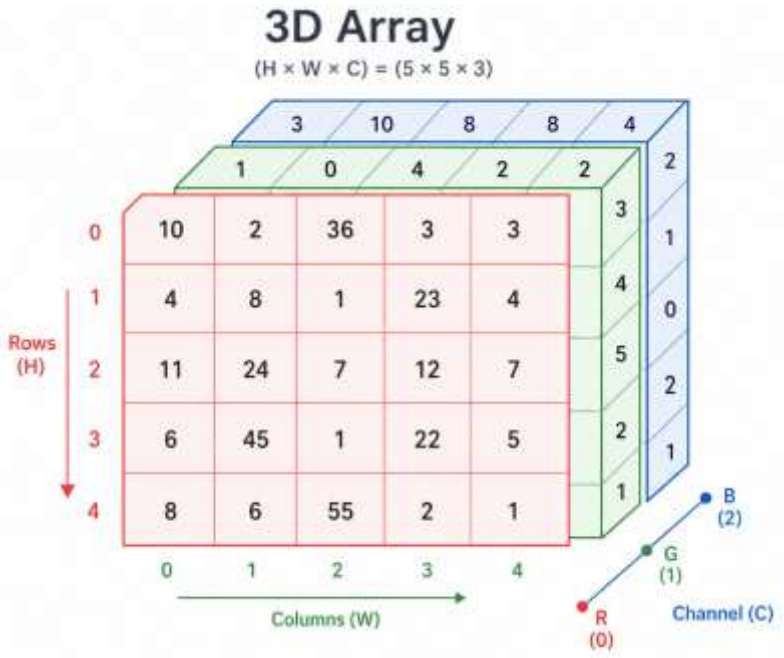
图像的像素点矩阵中的每个像素点的**灰度值为0（黑色） 或者255（白色）**，也就是让整个图像呈现只有黑和白的效果。





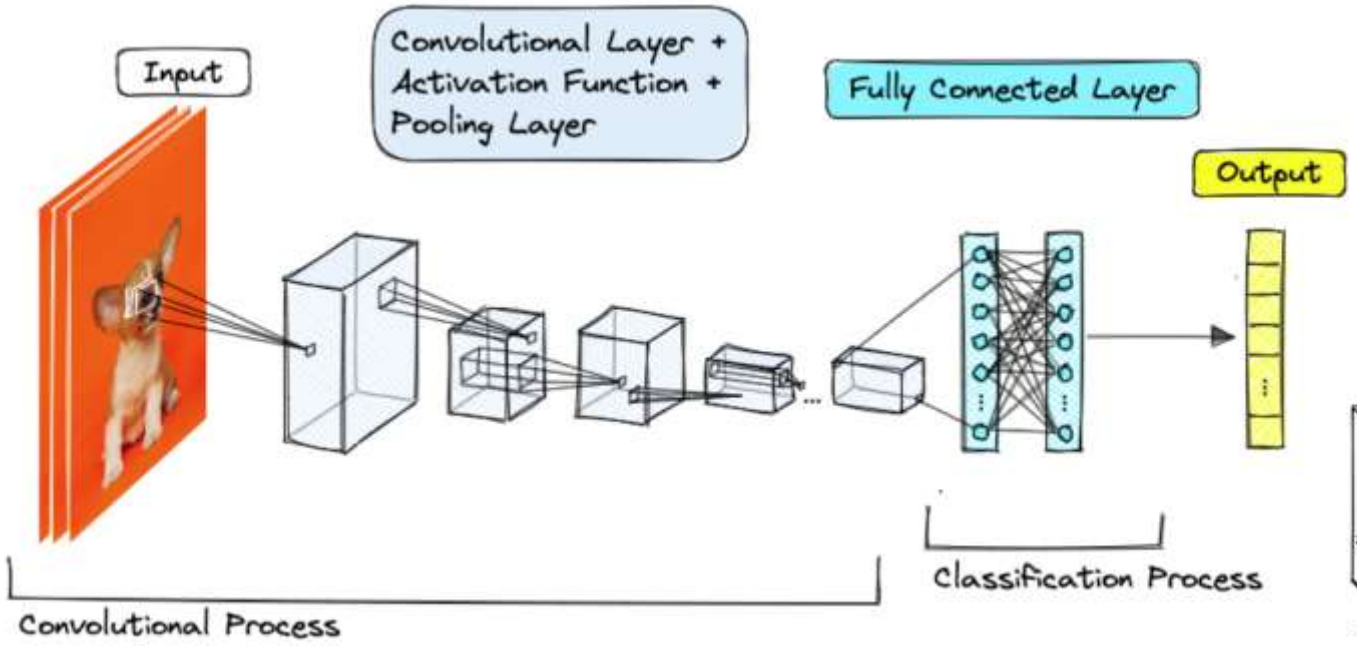



因此，对于计算机而言，**它所“看到”的图像都是（三维）矩阵**，计算机视觉技术都是基于矩阵的计算

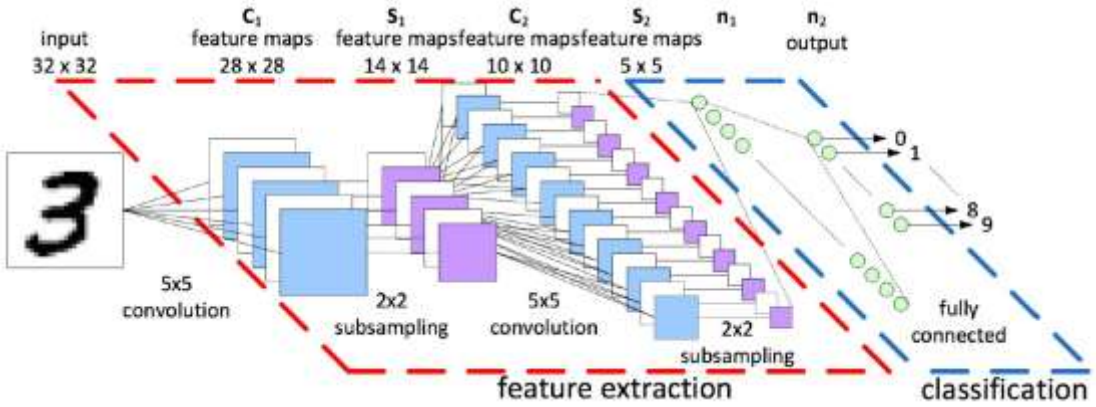



**显然，仅通过查看像素矩阵并不会为我们提供有关图像的任何信息**

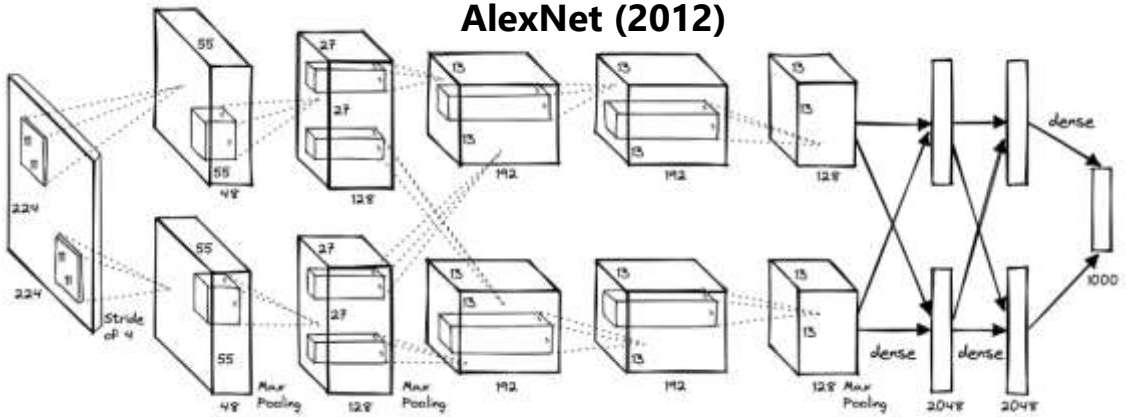
## 计算机视觉技术如何解决现实问题？以（基于深度学习模型的）图像分类为例




LeNet-5 (1998)

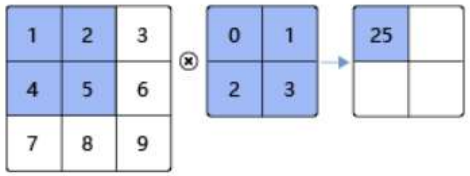



AlexNet (2012)

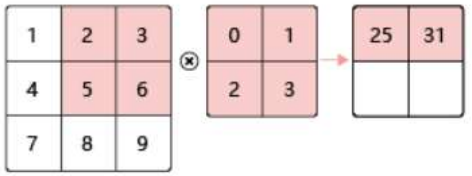


# Recap：卷积神经网络CNN

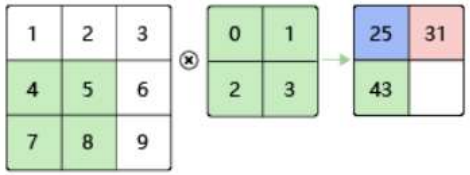
## (1) 卷积 Convolution



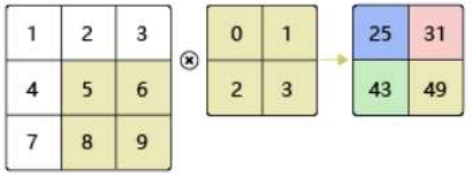

(a) 0x1+1x2+2x4+3x5=25



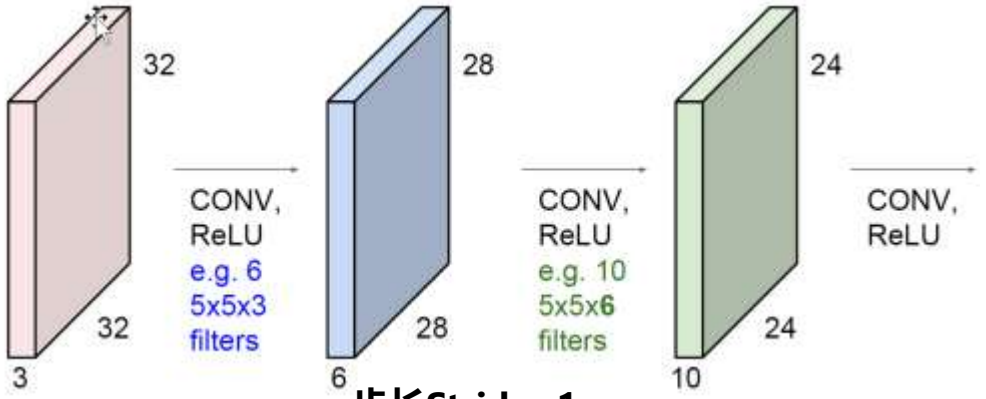

(b) 0x2+1x3+2x5+3x6=31




(c) 0x4+1x5+2x7+3x8=43

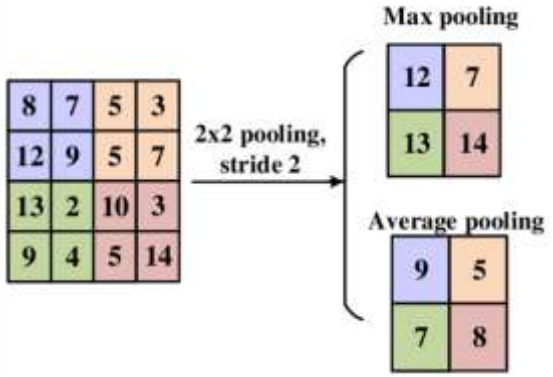



(d) 0x5+1x6+2x8+3x9=49




步长Stride=1

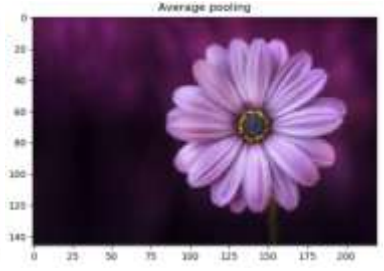
## (2) 池化 Pooling







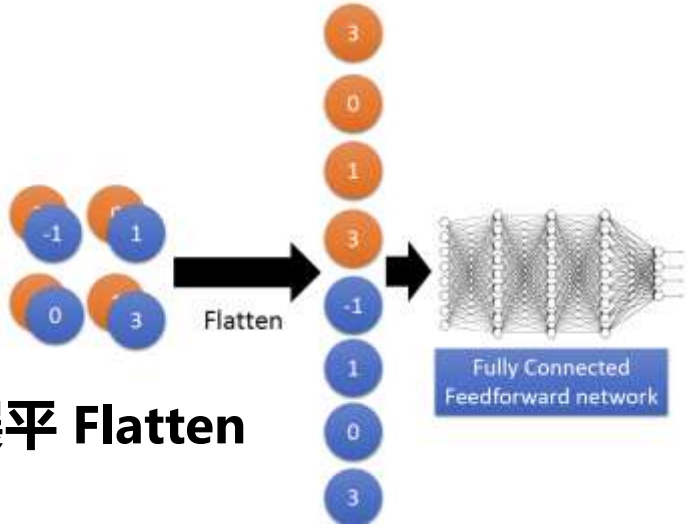



## (3) 填充 Padding

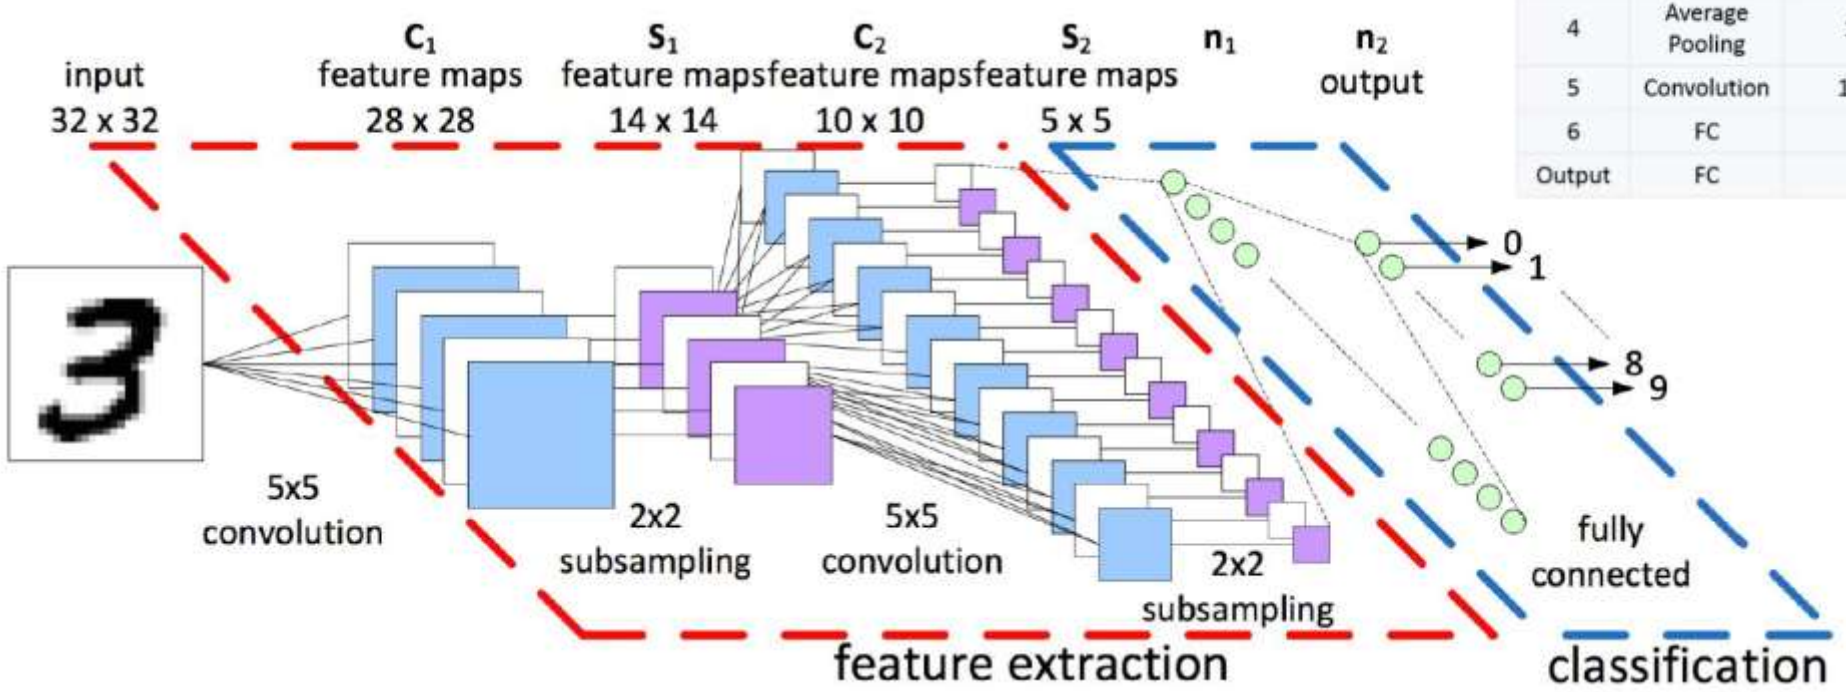


## (4) 展平 Flatten



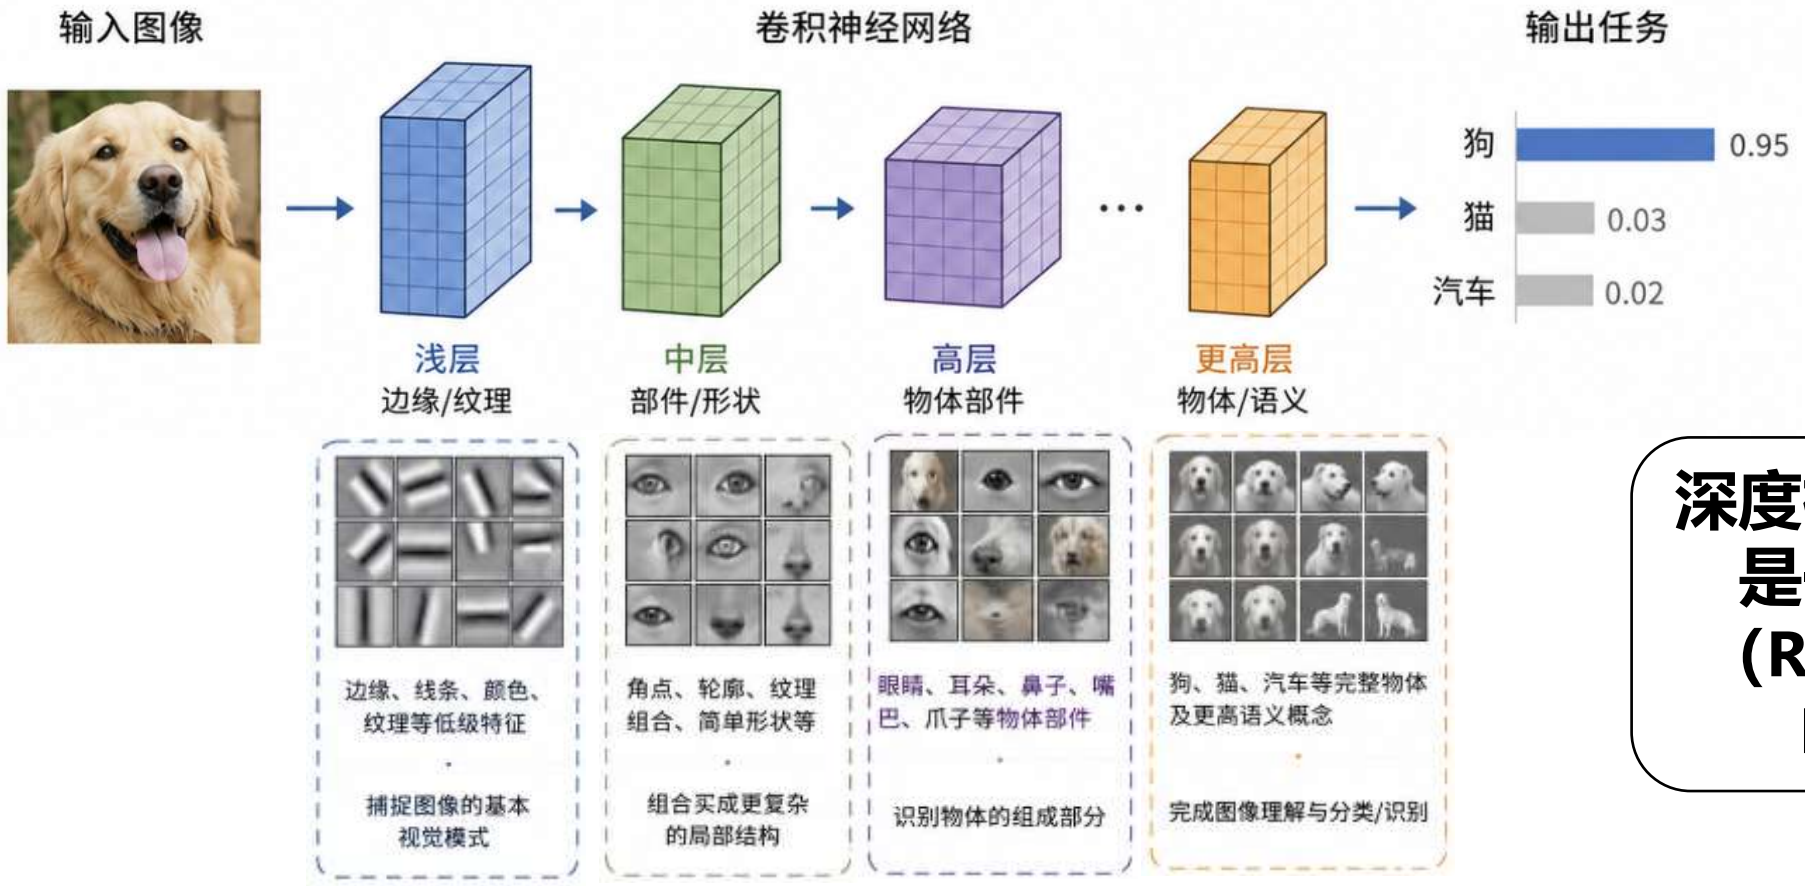
## 用于MNIST手写识别的经典卷积神经网络结构LeNet-5（1998）

| Layer | | Feature Map | Size | Kernel Size | Stride | Activation |
|---|---|---|---|---|---|---|
| Input | Image | 1 | 32x32 | - | - | - |
| 1 | Convolution | 6 | 28x28 | 5x5 | 1 | tanh |
| 2 | Average Pooling | 6 | 14x14 | 2x2 | 2 | tanh |
| 3 | Convolution | 16 | 10x10 | 5x5 | 1 | tanh |
| 4 | Average Pooling | 16 | 5x5 | 2x2 | 2 | tanh |
| 5 | Convolution | 120 | 1x1 | 5x5 | 1 | tanh |
| 6 | FC | - | 84 | - | - | tanh |
| Output | FC | - | 10 | - | - | softmax |





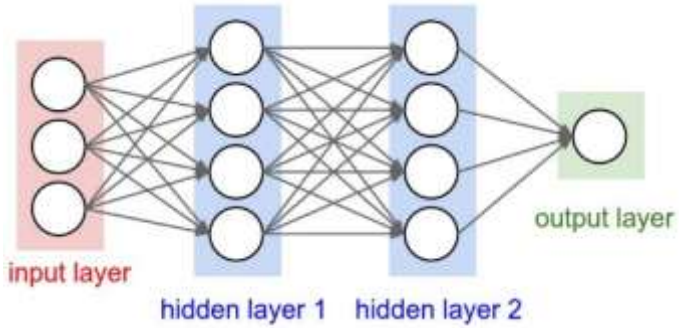

## 深度神经网络在对图像的学习过程中到底学到了什么?



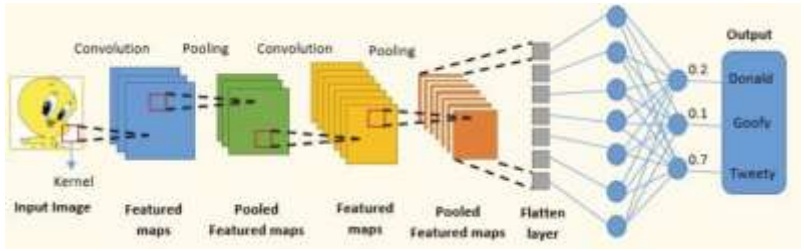

**深度神经网络实质上是一种表征学习(Representation Learning)**

从像素到语义：层层抽象，学习图像的多层次表示

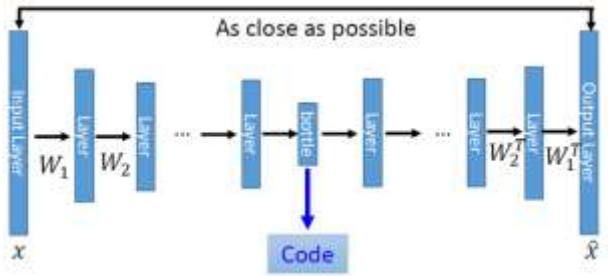
- 从技术的角度看，似乎深度学习时代已经把自然语言处理（NLP）和计算机视觉（CV）两个领域的进度拉到相近的水平，那参照NLP领域，是不是CV领域也要进入Transformer时代了?



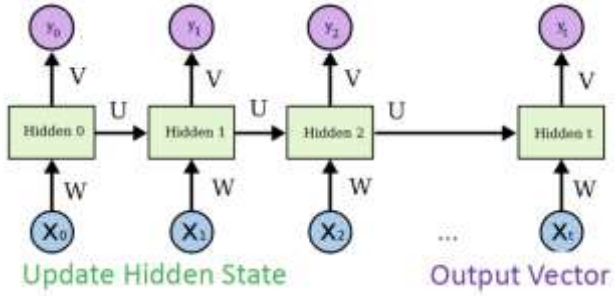

多层感知机MLP




卷积神经网络CNN

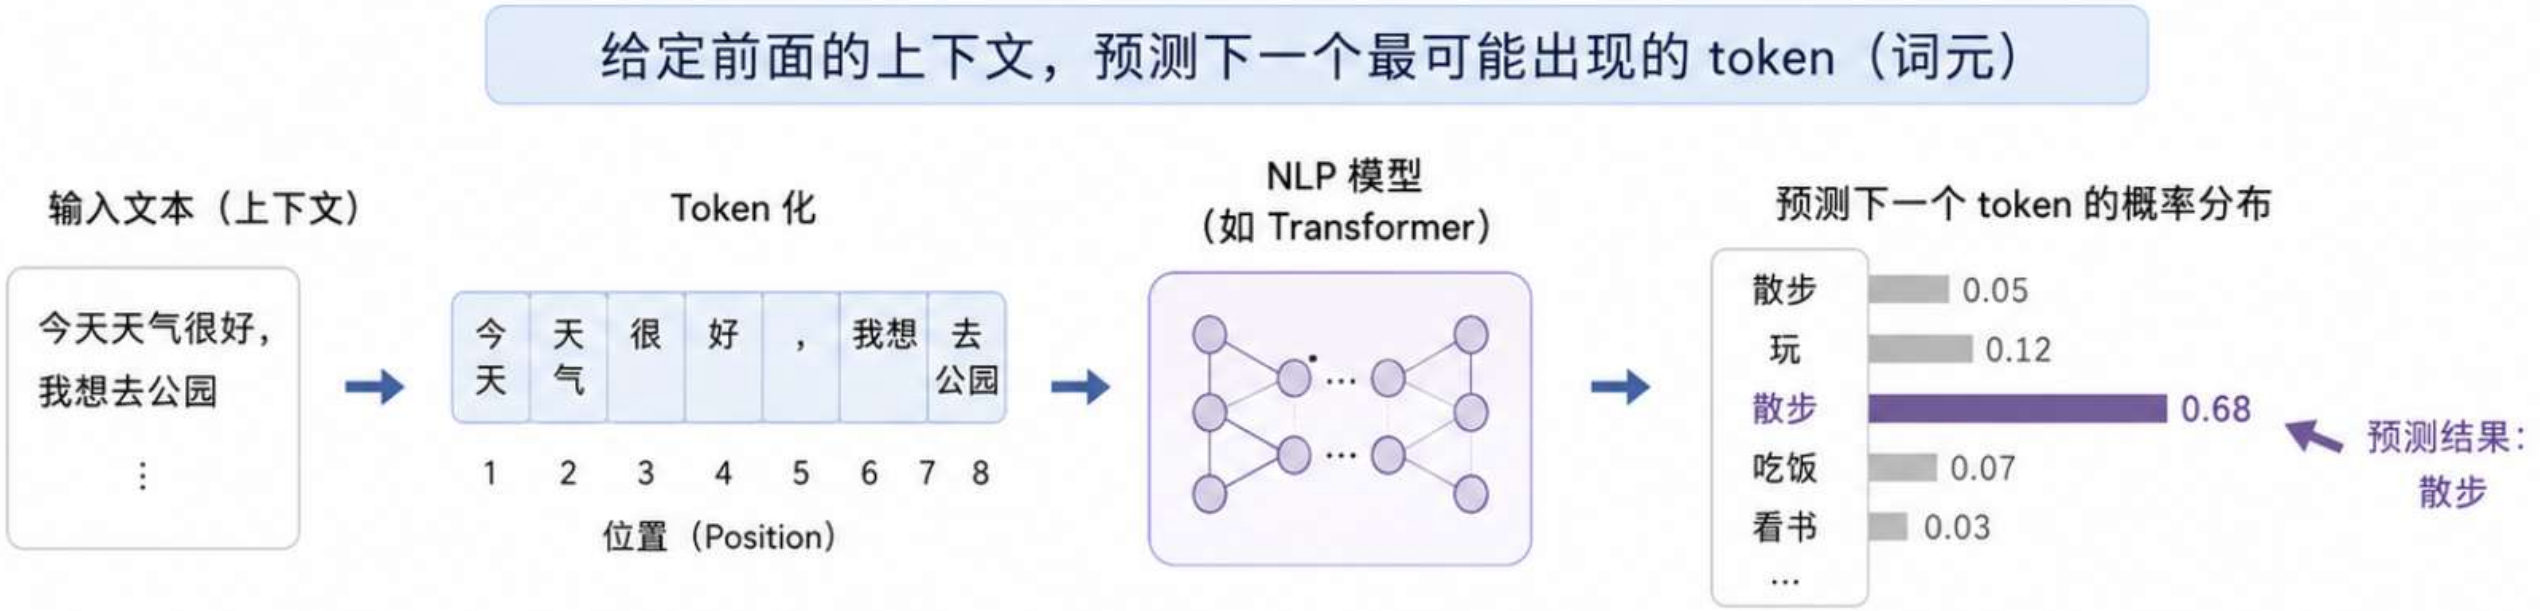



自编码器AutoEncoder




循环神经网络RNN

- 且慢，CV领域似乎要复杂得多
- Recap: NLP模型的核心任务是Next Token Prediction

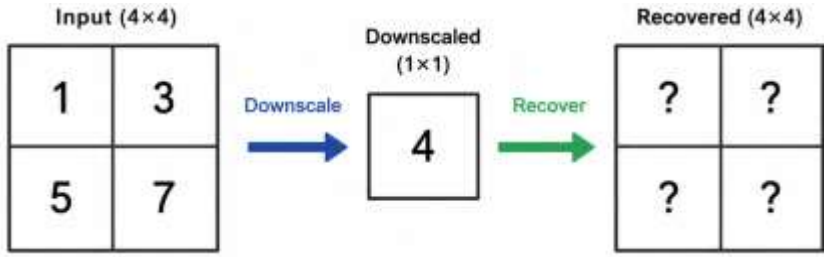


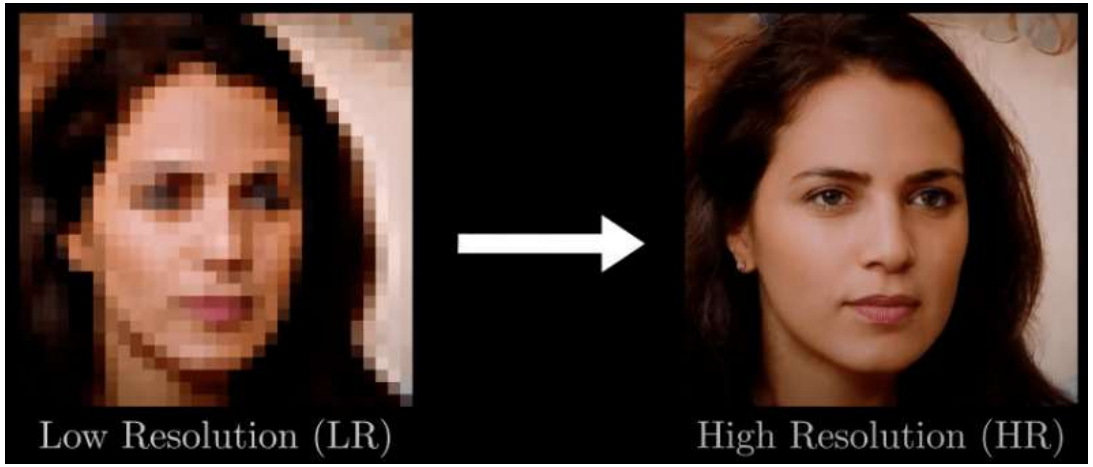
- CV的任务复杂，目标各不相同，无法用一个统一的模式来囊括

# 底层视觉——像素级任务

**图像超分辨率**，Image Super Resolution（SR）：提高图像的分辨率，使之更加清晰

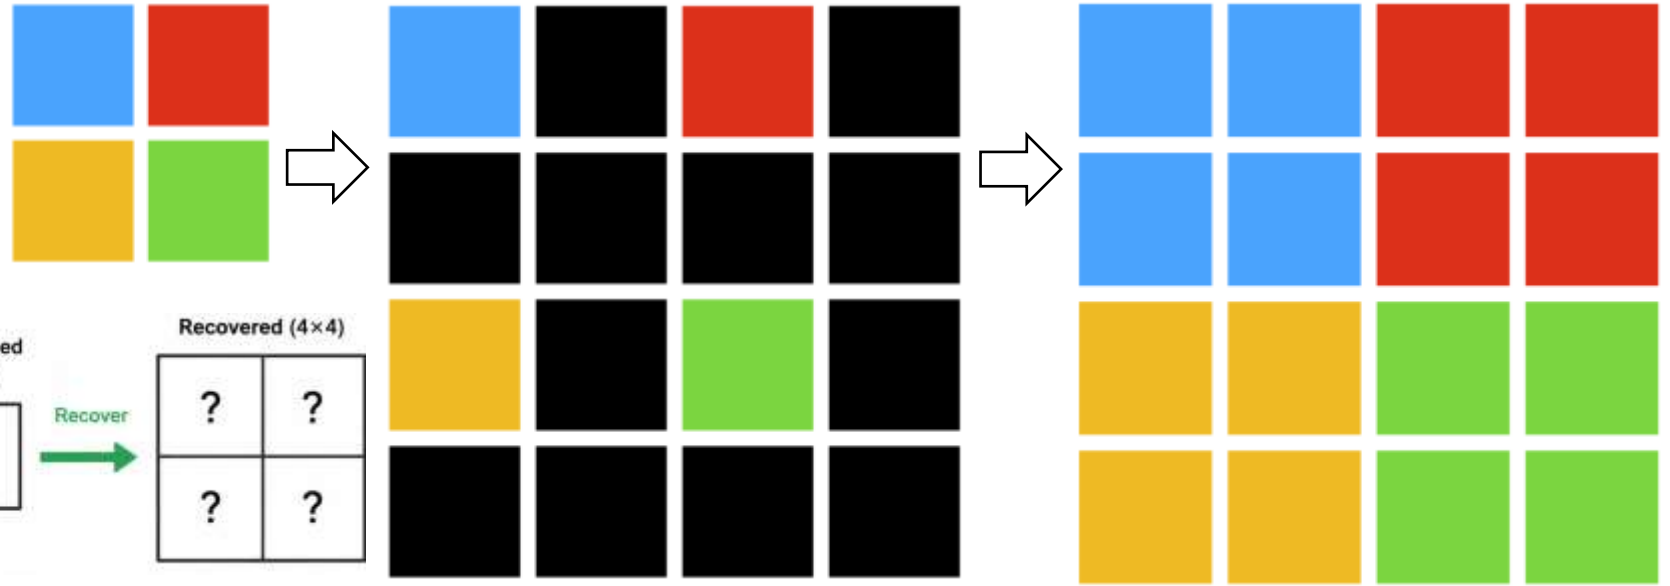
***不适定（ill-posed）问题***

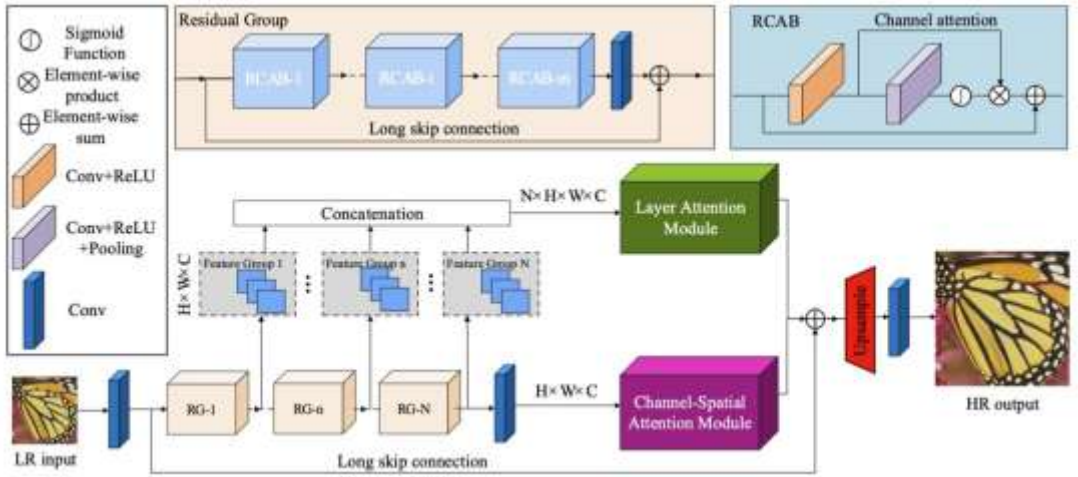



How?

Good?





# 底层视觉——像素级任务

包括图像超分辨在内，**图像去噪**、**去马赛克**、**去雾**、**上色**、**修复**等都是图像复原任务，原理上很接近

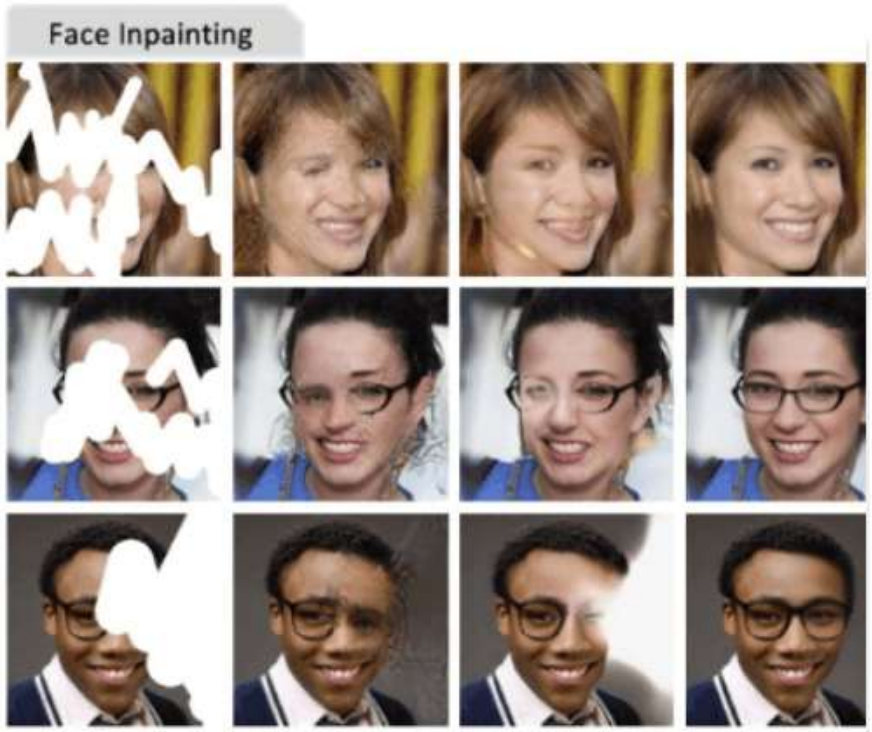










# 底层视觉——像素级任务

**图像分割**（Segmentation），基于图像中像素的特征将一个图像分割成多个部分或区域



0: Background/Unknown
1: Person
2: Purse
3: Plants/Grass
4: Sidewalk
5: Building/Structures

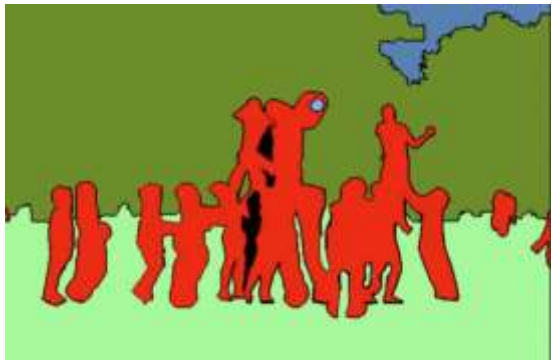


目标检测 vs. 图像分割

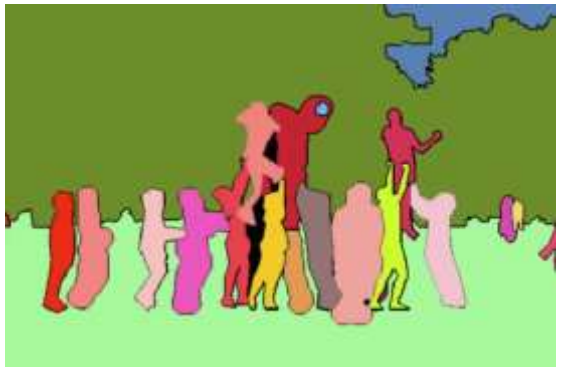
**语义分割**，对图像中的每个像素打上类别标签，比如把图像分为人（红色）、树木（深绿）、草地（浅绿）、天空（蓝色）标签

**实例分割**，目标检测+语义分割，如果以人为目标，*实例分割区分同类的不同实例*（使用不同颜色区分不同人），语义分割不区分

**全景分割**，实例检测+语义分割，要是对图中的*所有物体包括背景都要进行检测和分割，区分不同实例*（使用不同颜色）







# 底层视觉——像素级任务

**图像抠图**（Matting），找出每一个像素属于前景和背景的概率

| | | | | | | |
|---|---|---|---|---|---|---|
| 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 255 | 0 | 0 | 0 | 0 | 0 | 0 |
| 255 | 0 | 0 | 0 | 0 | 0 | 0 |
| 255 | 0 | 0 | 0 | 0 | 0 | 0 |
| 255 | 0 | 0 | 0 | 0 | 0 | 0 |
| 255 | 0 | 0 | 0 | 0 | 0 | 0 |
| 255 | 0 | 0 | 0 | 0 | 0 | 0 |
| 255 | 0 | 0 | 0 | 0 | 0 | 0 |
| 255 | 255 | 0 | 0 | 0 | 0 | 0 |
| 255 | 255 | 0 | 0 | 0 | 0 | 0 |
| 255 | 255 | 0 | 0 | 0 | 0 | 0 |
| 255 | 255 | 0 | 0 | 0 | 0 | 0 |
| 255 | 255 | 255 | 255 | 0 | 0 | 0 |
| 255 | 255 | 255 | 255 | 255 | 255 | 255 |
| 255 | 255 | 255 | 255 | 255 | 255 | 255 |
| 255 | 255 | 255 | 255 | 255 | 255 | 255 |
| 255 | 255 | 255 | 255 | 255 | 255 | 255 |

分割 vs. 抠图

| | | | | | | |
|---|---|---|---|---|---|---|
| 104 | 8 | 2 | 0 | 0 | 0 | 0 |
| 137 | 16 | 2 | 0 | 0 | 0 | 0 |
| 168 | 21 | 3 | 0 | 0 | 0 | 0 |
| 192 | 35 | 5 | 1 | 0 | 0 | 0 |
| 210 | 51 | 4 | 0 | 0 | 0 | 0 |
| 223 | 69 | 5 | 0 | 0 | 0 | 0 |
| 233 | 95 | 5 | 0 | 0 | 0 | 0 |
| 241 | 122 | 11 | 1 | 0 | 0 | 0 |
| 248 | 150 | 18 | 1 | 0 | 0 | 0 |
| 251 | 172 | 22 | 1 | 0 | 0 | 0 |
| 253 | 192 | 35 | 9 | 0 | 0 | 0 |
| 254 | 216 | 94 | 35 | 10 | 1 | 1 |
| 255 | 243 | 214 | 169 | 106 | 48 | 18 |
| 255 | 250 | 246 | 246 | 228 | 189 | 129 |
| 255 | 254 | 252 | 255 | 255 | 250 | 236 |
| 255 | 255 | 255 | 255 | 255 | 255 | 255 |
| 255 | 255 | 255 | 255 | 255 | 255 | 255 |

$$I_i = \alpha_i F_i + (1 - \alpha_i) B_i$$ (Composition Equation)



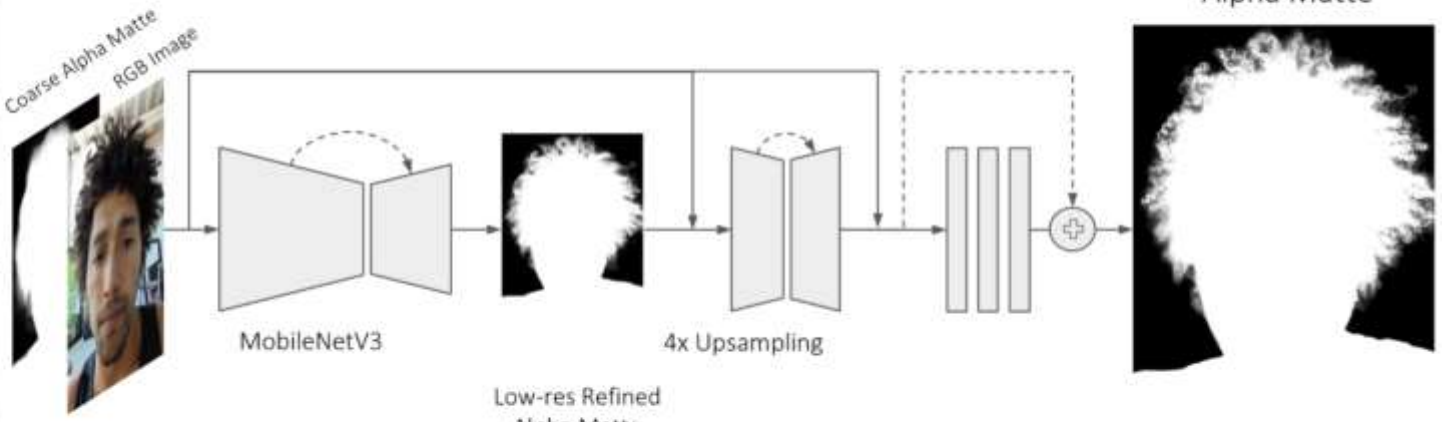
Input image $I$ | Foreground $F$ | Alpha Matte | Background $B$



RGB Image



Coarse Alpha Matte



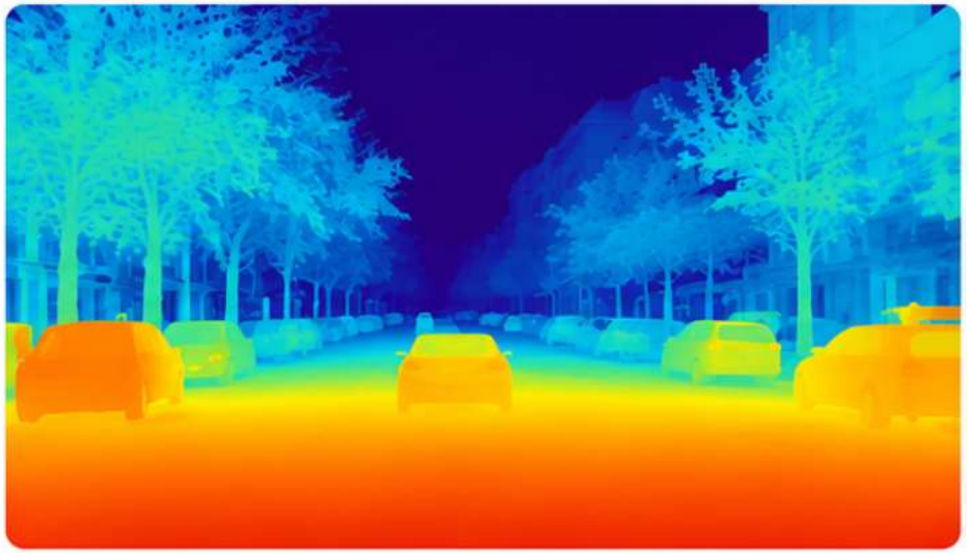
# 底层视觉——像素级任务

目标：为图像中每个像素预测其到相机的相对深度（距离）

1. 输入图像



2. 深度估计结果（相对深度）




深度可视化（颜色表示相对距离）

远 近

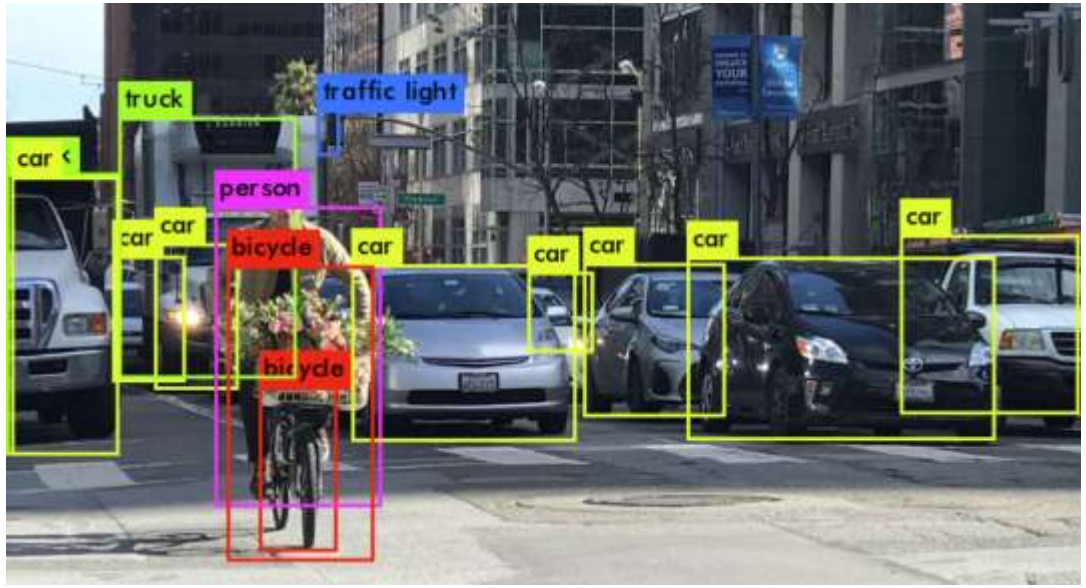
- 颜色越偏蓝/紫，表示离相机越远
- 颜色越偏黄/红，表示离相机越近

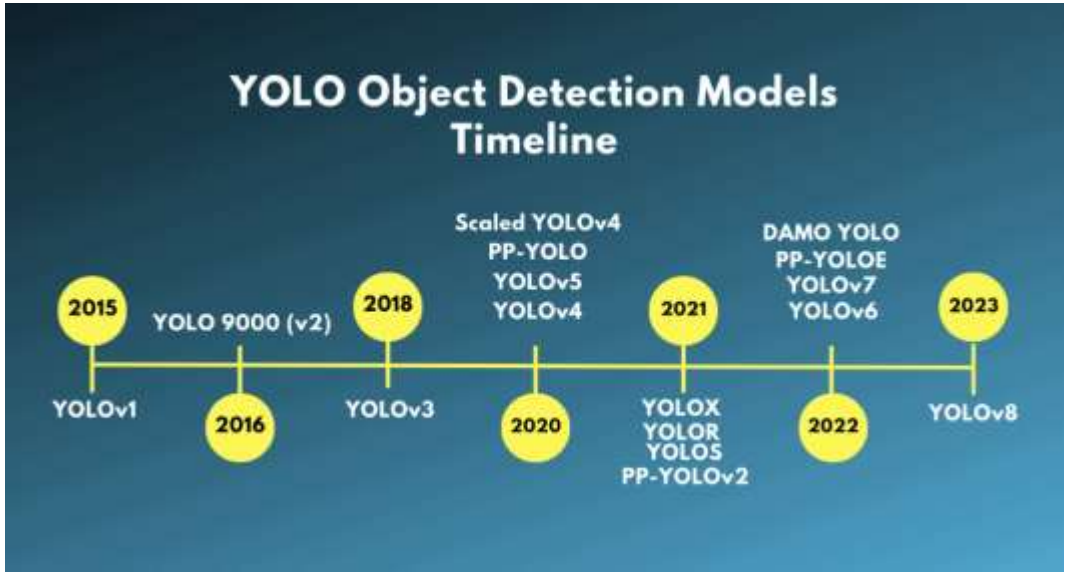
输出：与输入图像尺寸相同的深度图（H × W），每个像素一个深度值（相对值）

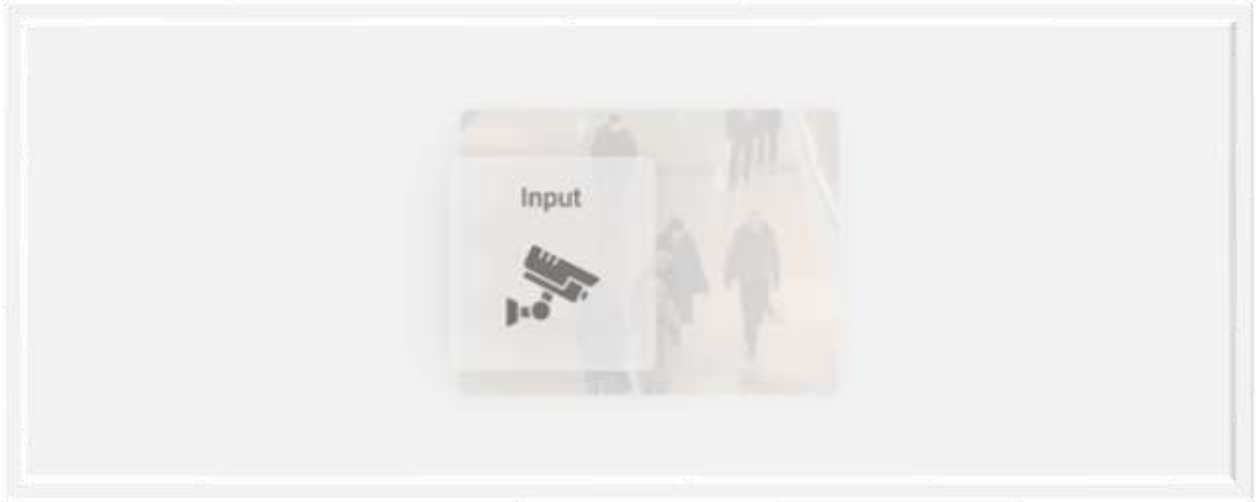
# 实例/区域级视觉任务

**目标检测**（Object Detection）的任务是找出图像中所有感兴趣的目标（物体），确定它们的类别和位置，是计算机视觉领域的核心问题之一。

*——由于各类物体有不同的外观、形状和姿态，加上成像时光照、遮挡等因素的干扰，目标检测一直是计算机视觉领域最具有挑战性的问题。*

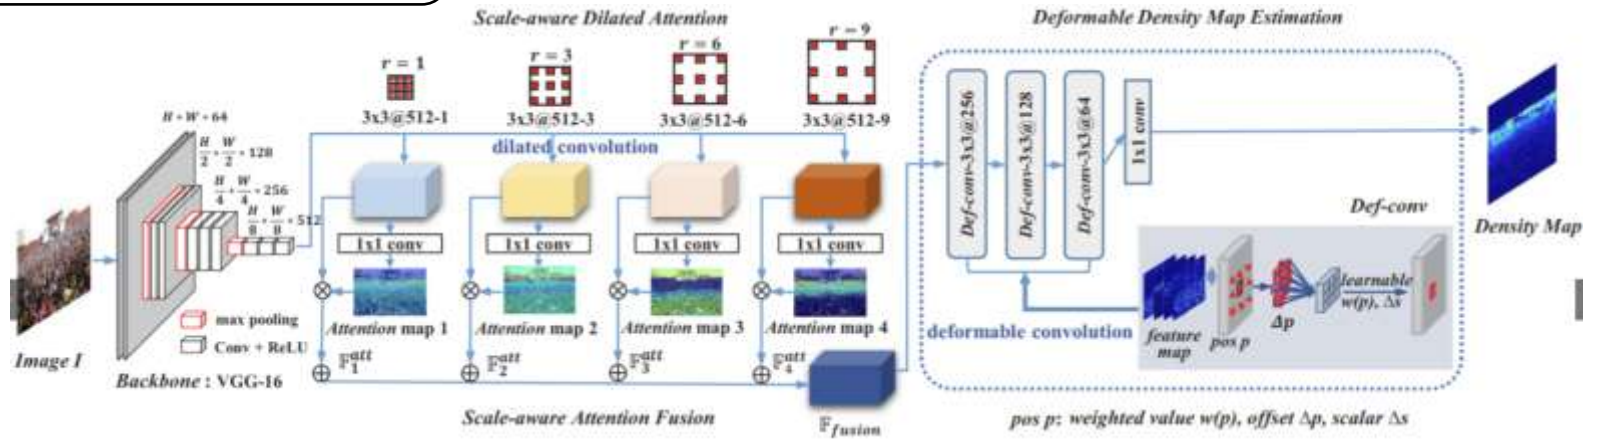


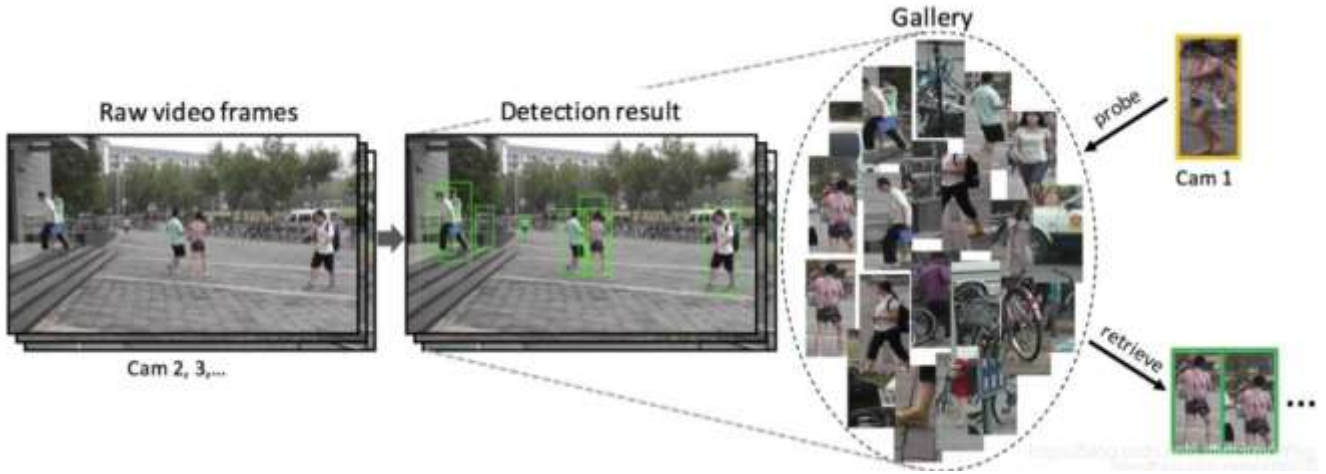
# 实例/区域级视觉任务

**人群计数**，估计图像或视频中人群的数量、密度或分布






**行人重识别**（Person Re-identification，Re-ID），通过计算机视觉技术检索不同摄像头下的同一个目标人物



**人体姿态估计**（Human Pose Estimation, HPE），根据图像和视频等输入数据来定位人体部位并建立人体表现形式，可以应用于活动识别、训练机器人等





**人脸识别**



**情绪识别**



**3D场景重建：** 利用图像中物体的二维信息来推算出物体的三维结构



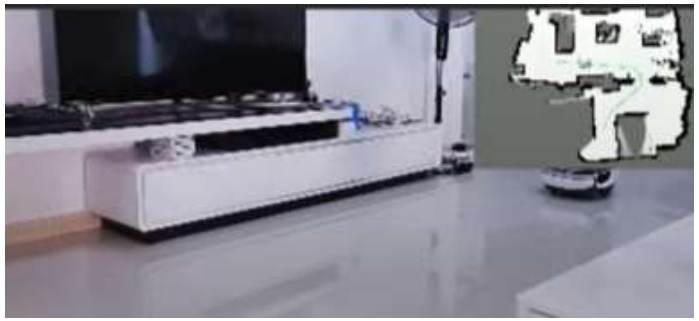
AR/VR 游戏场景的3D建模



在线看房

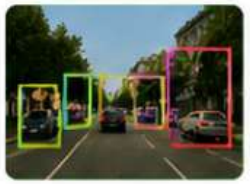
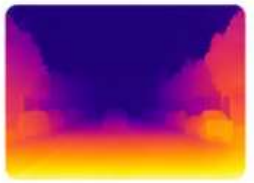


自行车、机器人导航





# 计算机视觉

| | 图像分类 | 目标检测 | 语义分割 | 实例分割 | 深度估计 | 图像生成 |
|---|---|---|---|---|---|---|
| 输入图像 |  |  |  |  |  |  |
| 预测目标（输出形式） | 一个类别标签 |  |  |  |  |  |
| 预测目标（示例） | “汽车” | 多个框 + 类别 + 置信度 | 每个像素的类别 | 每个实例的像素掩码 | 每个像素的深度值 | 生成符合条件的新图像 |
| 评价指标（示例） | Top-1 Acc<br>Top-5 Acc | mAP<br>（精确率/召回率） | mIoU<br>（平均交并比） | mAP_mask<br>（掩码 mAP） | Abs Rel<br>RMSE<br>$\delta < 1.25$ | FID<br>IS |

## 无法用统一模型囊括

- 输出形式不同（标签 / 框 / 像素级 / 掩码 / 数值 / 坐标 / 图像）
- 语义目标不同（类别 / 位置 / 区域 / 实例 / 距离 / 结构 / 视觉内容）
- 评价指标不同
- 需要针对性结构设计、损失函数和训练数据

## 需要针对性模型设计

- 任务驱动的网络结构
- 任务专属的损失函数
- 任务特定的数据标注
- 任务定制的后处理与推理策略

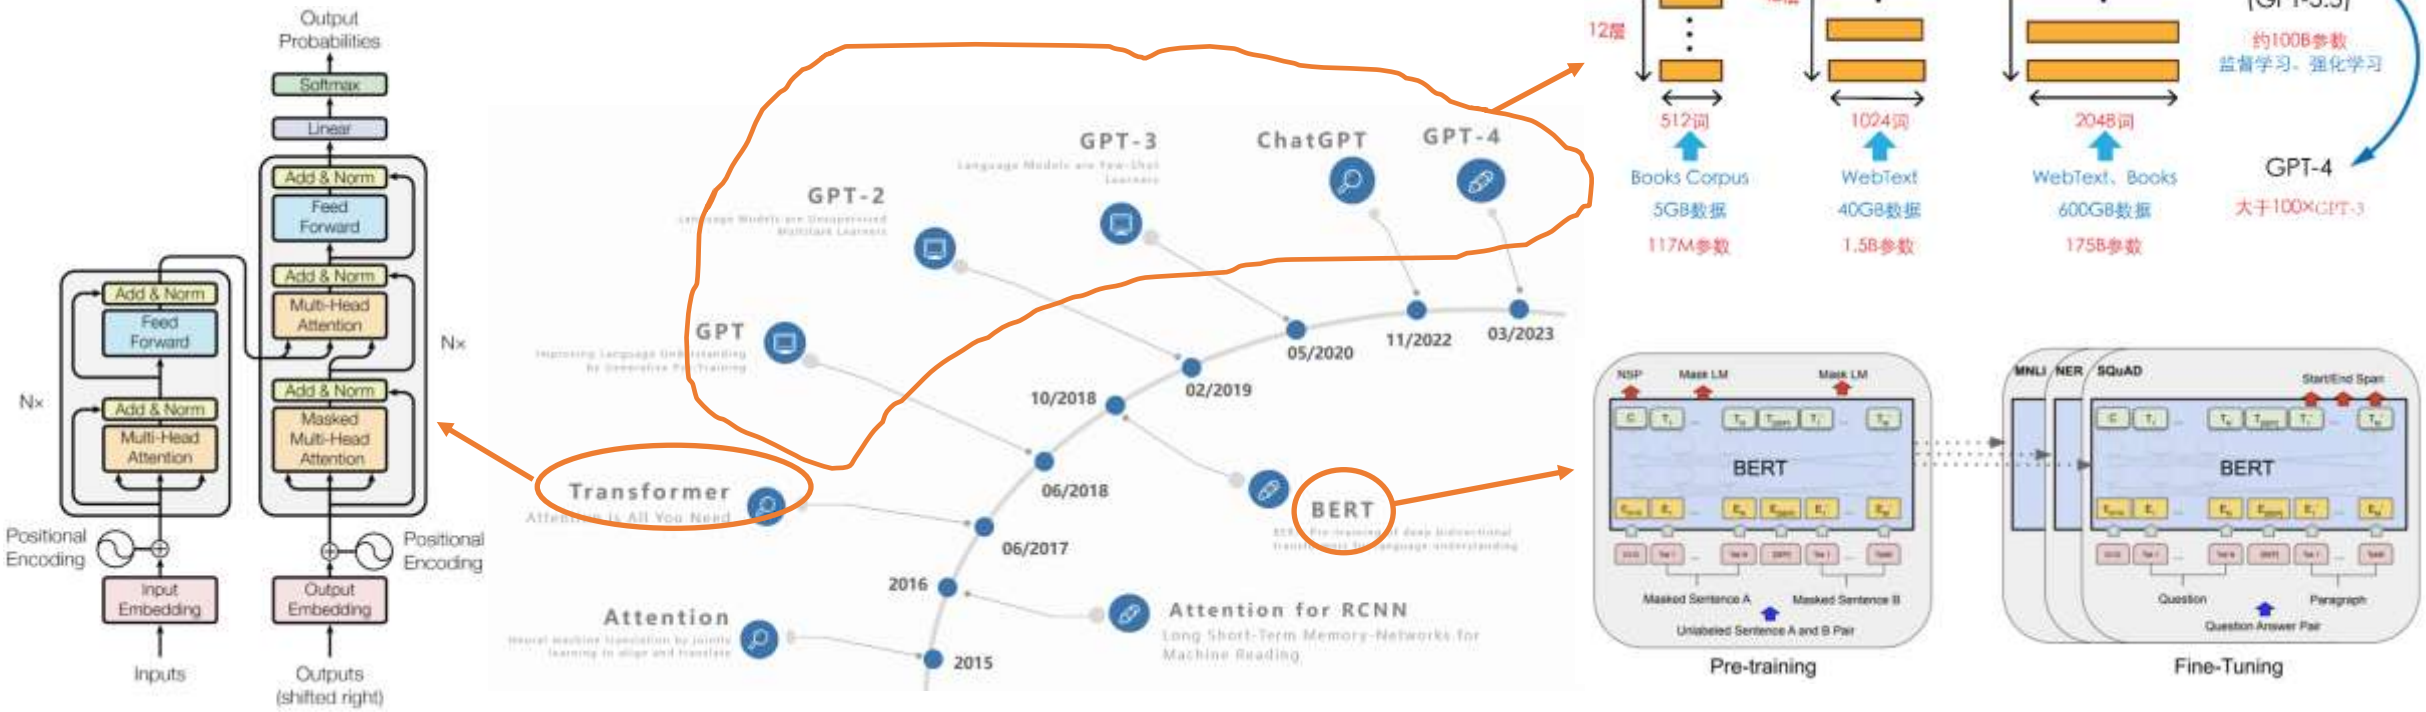
### 结论

计算机视觉任务的多样性决定了没有一个统一模型可以解决所有问题。

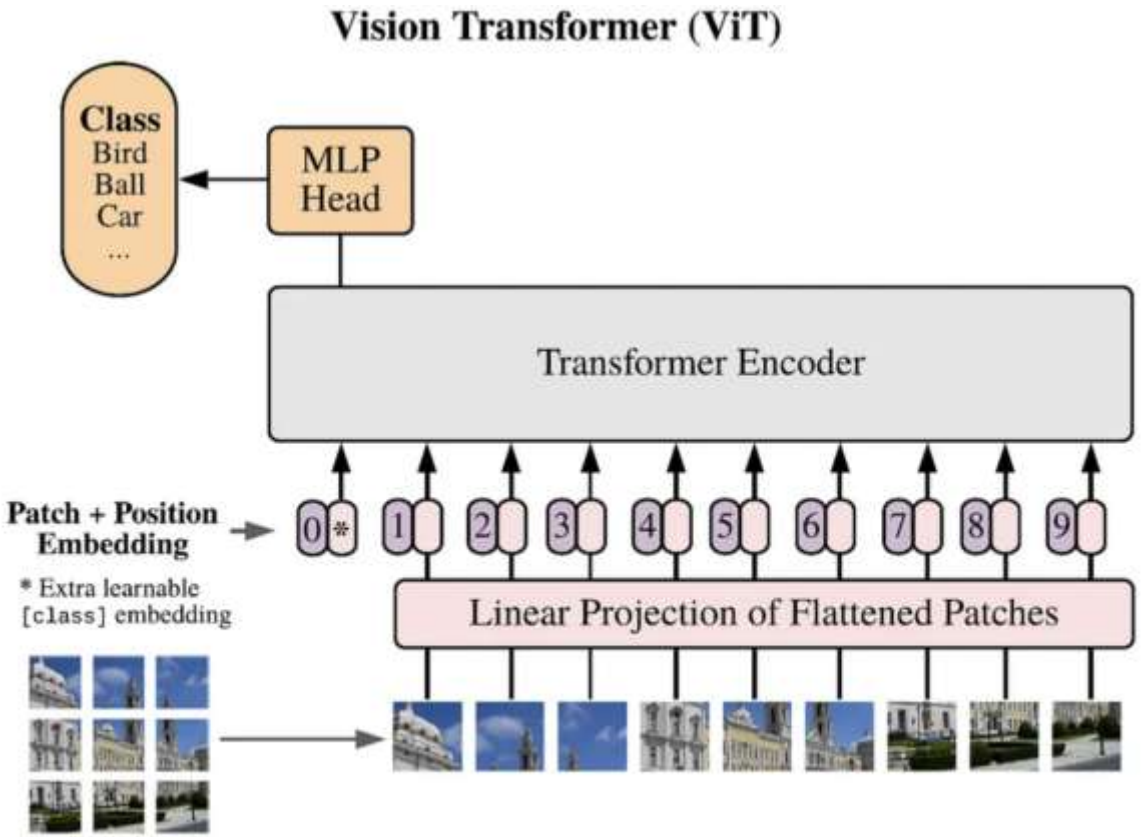
# 基础模型（Foundation Models）

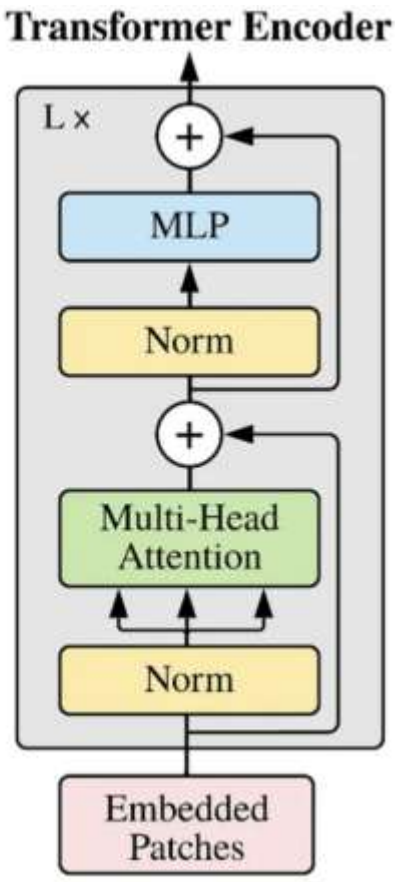
# Recap：基于Transformer的预训练模型

- 基于attention机制的Transformer架构奠定了现代大模型的基础
- 那么把Transformer用在CV领域行不行?
  - 当时CV领域CNN是绝对主流



## ViT: Transformer在图像数据上的最佳实践




Published as a conference paper at ICLR 2021

AN IMAGE IS WORTH 16X16 WORDS:
TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE

Alexey Dosovitskiy*,†, Lucas Beyer*, Alexander Kolesnikov*, Dirk Weissenborn*,
Xiaohua Zhai*, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer,
Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, Neil Houlsby*,†
*equal technical contribution, †equal advising
Google Research, Brain Team
{adosovitskiy, neilhoulsby}@google.com

不同参数量的ViT

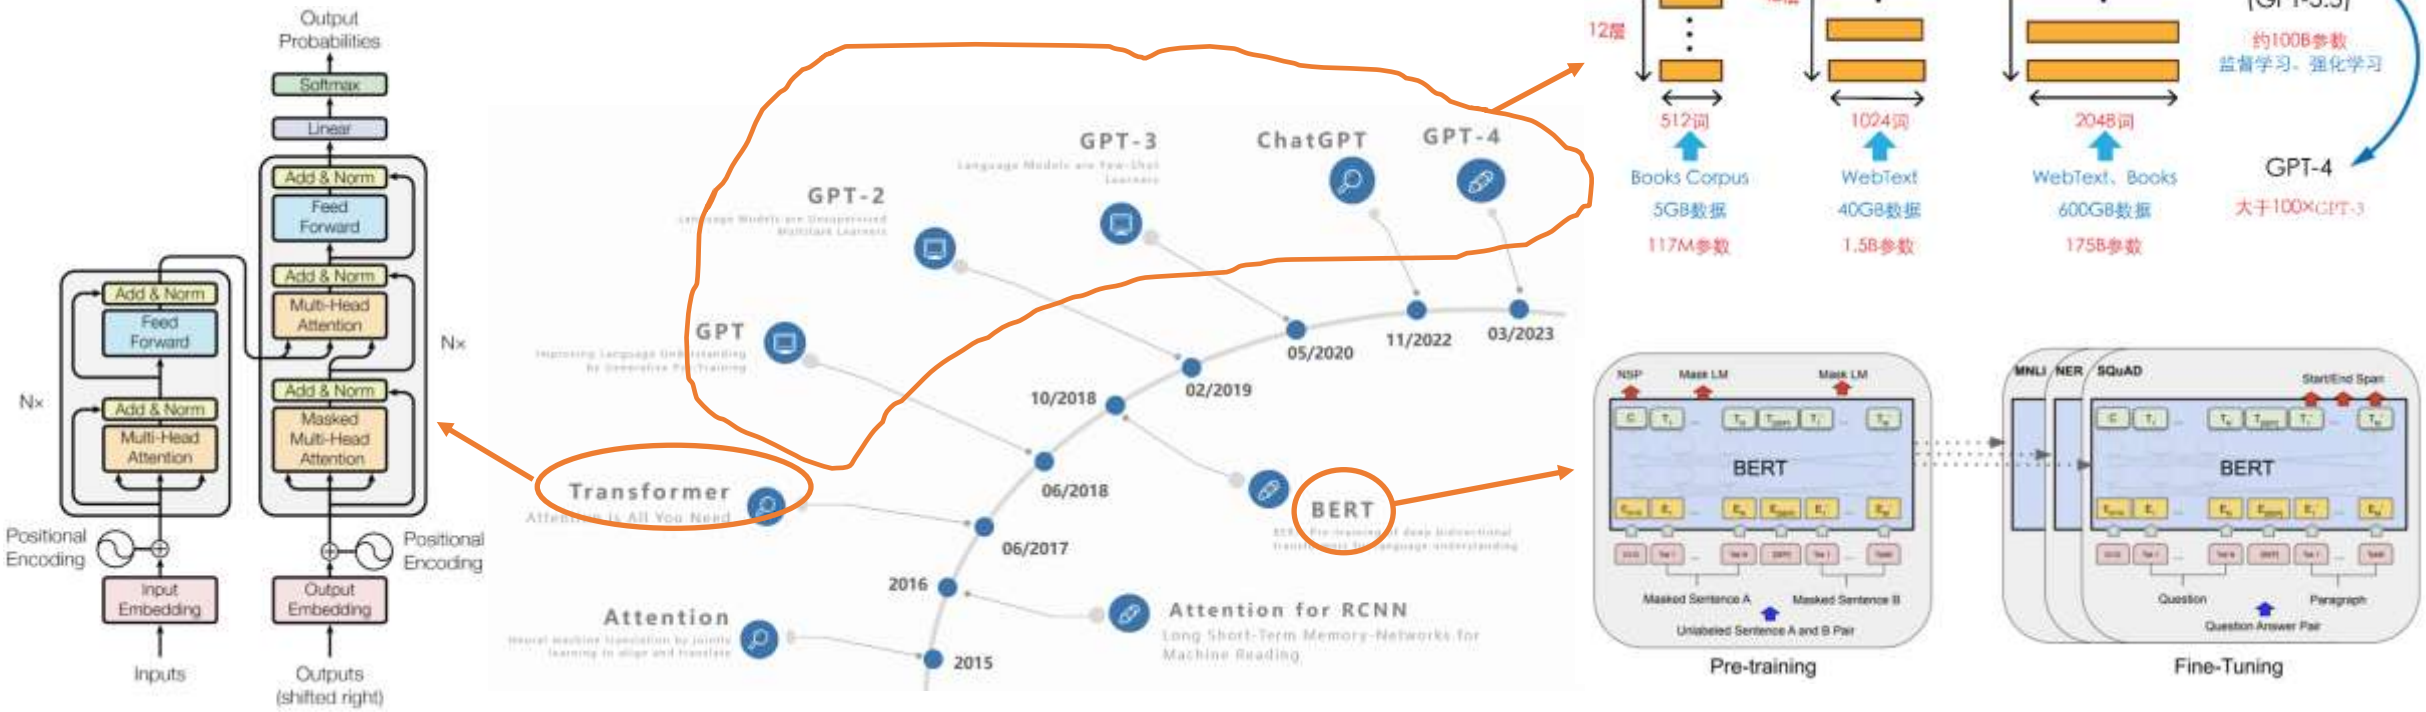
| Model | Layers | Hidden size $D$ | MLP size | Heads | Params |
|---|---|---|---|---|---|
| ViT-Base | 12 | 768 | 3072 | 12 | 86M |
| ViT-Large | 24 | 1024 | 4096 | 16 | 307M |
| ViT-Huge | 32 | 1280 | 5120 | 16 | 632M |

Table 1: Details of Vision Transformer model variants.

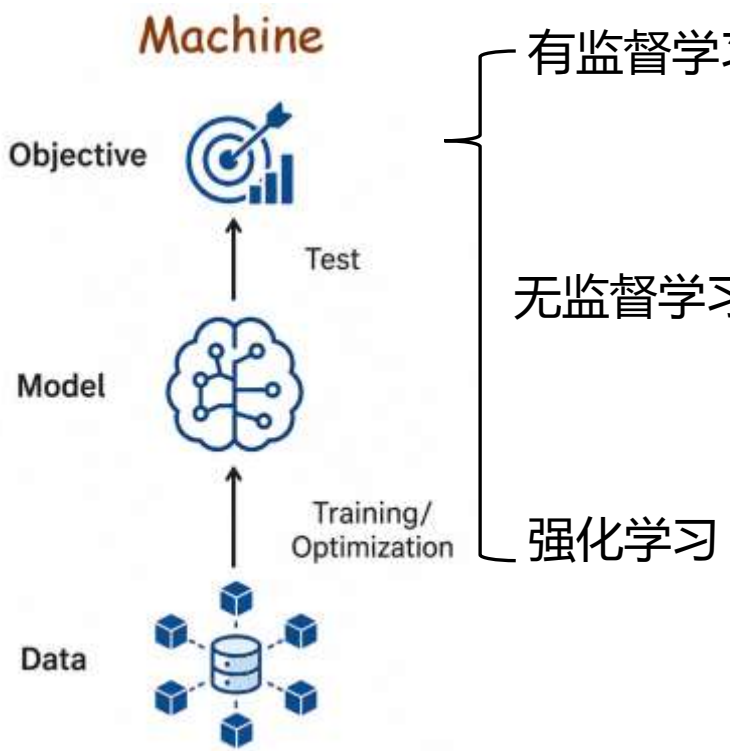
图像切成小块Patch，相互之间“交流”，能够更好地**关注到整个图像的全局关系。**ViT在更大的数据集和更大规模的参数模型下性能更好——符合Scaling的特点

# Recap：基于Transformer的预训练模型

- 我们再回到这一页，ViT验证了Transformer在CV领域的能力，那么按照这个路线，能否在CV领域使用自监督学习，从而获得具有图像理解能力的模型?



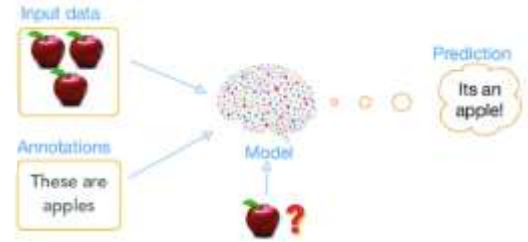
## 机器学习的主要范式

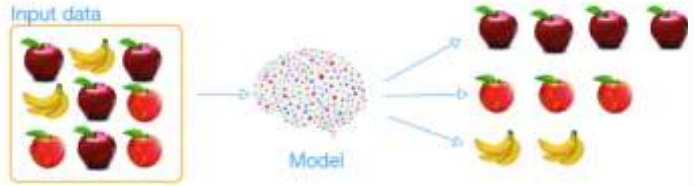


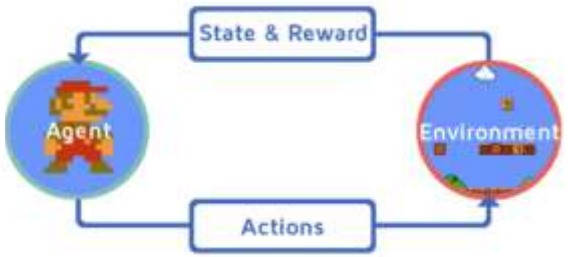

有监督学习

无监督学习

强化学习

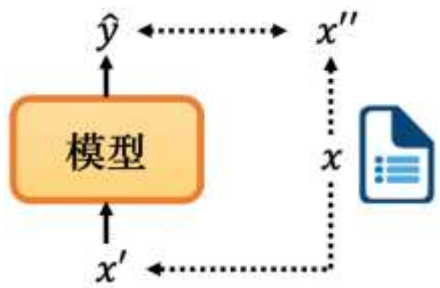


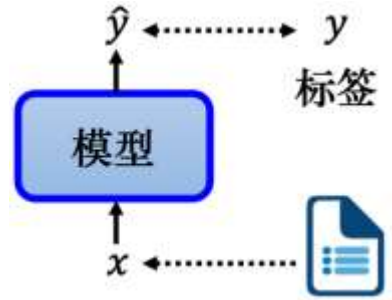









## 自监督训练对视觉任务很重要

大规模的、高质量的标注数据集是**很难收集**的，**成本也非常高**



AWARD WINNER

Yann LeCun

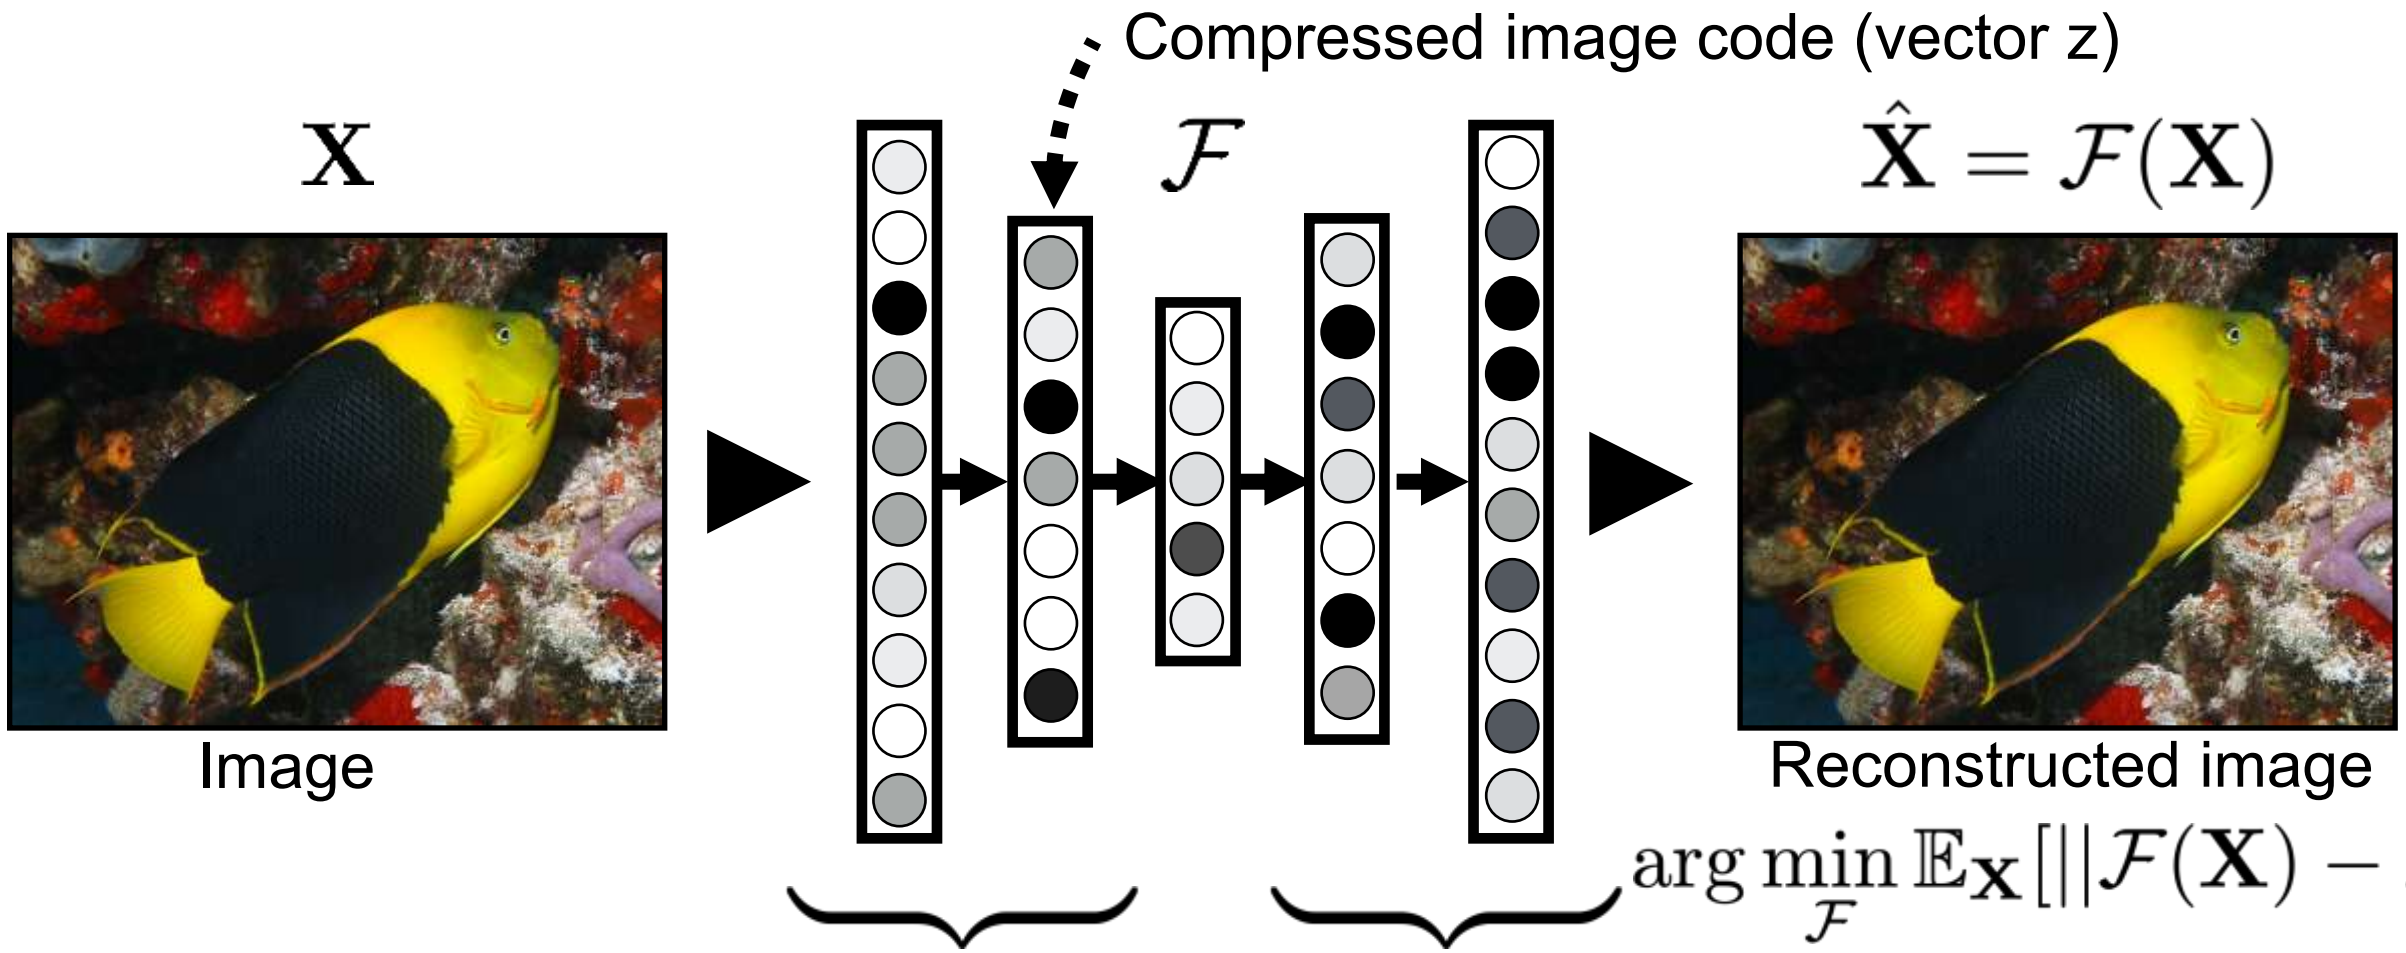
ACM A. M. Turing Award (2018)

人类利用预测和推理等能力从现有信息中推断未来。即使提供不完整的前提，例如文本中缺少片段或图像被遮挡，我们仍然可以使用常识来推断结果——这是机器所缺乏的能力。

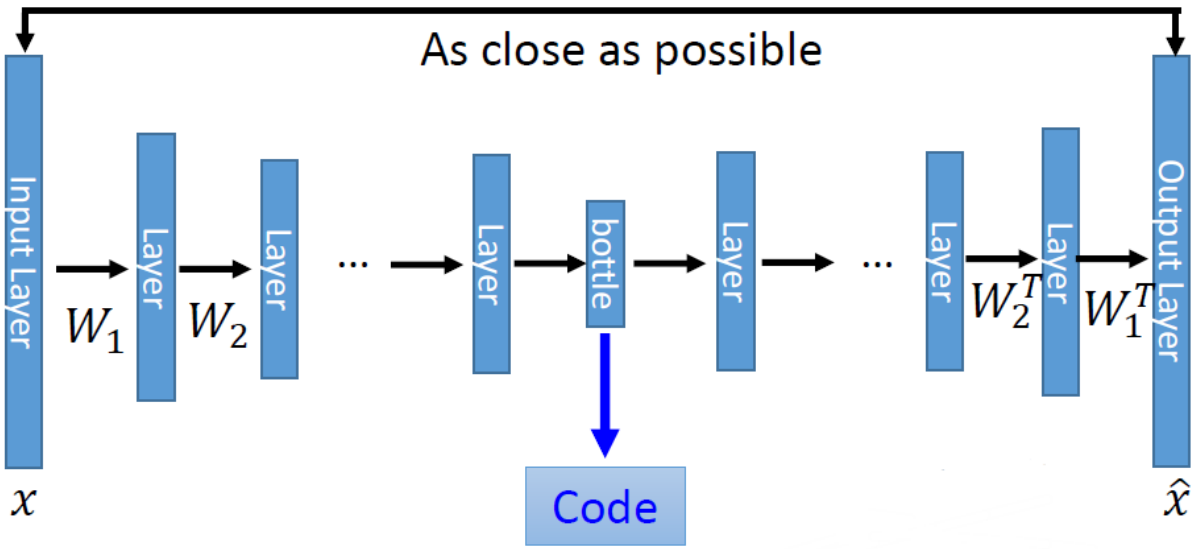


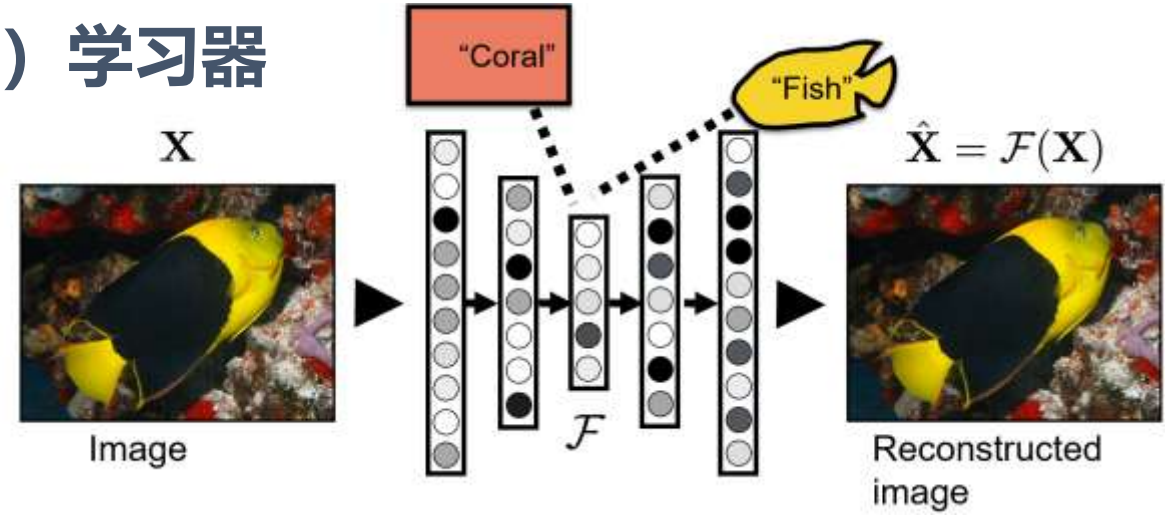

**视觉模型的自监督学习怎么做？能否获得通用的能力？**

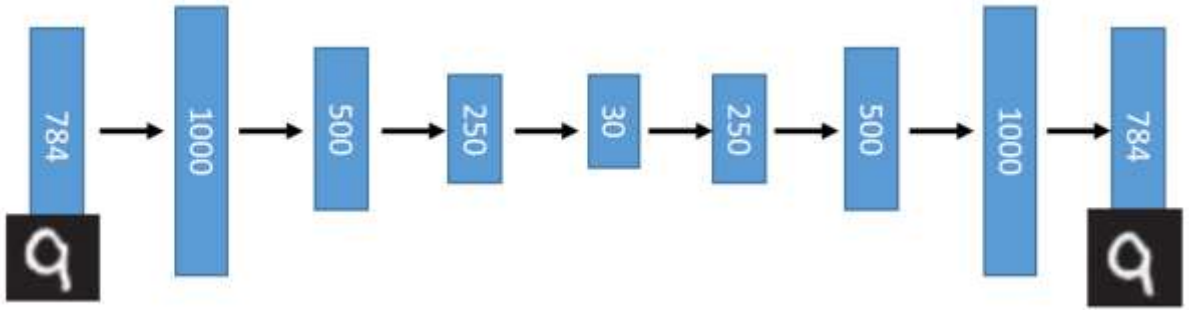
## 自编码器（AutoEncoder）是典型的自监督学习模型

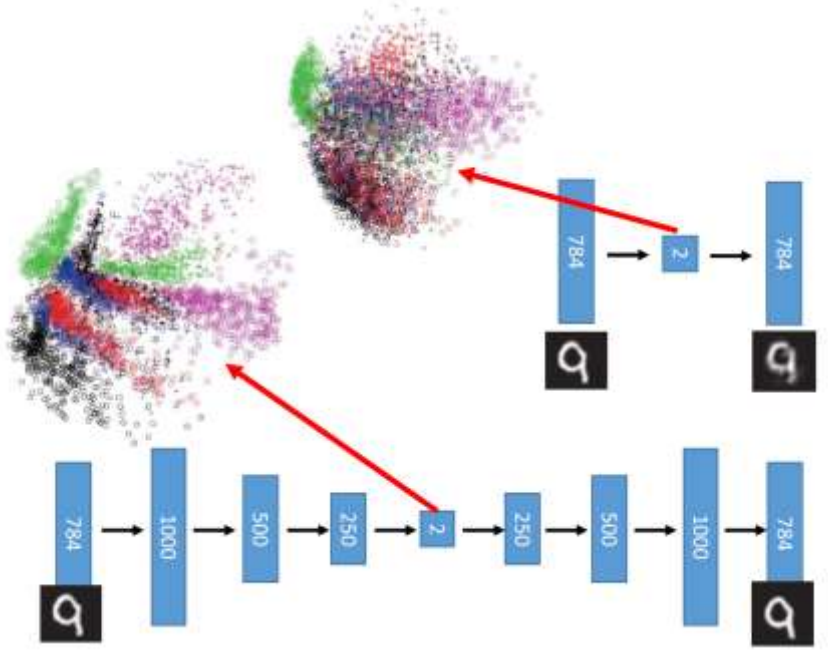


## 自编码器是强大的表征（Representation）学习器



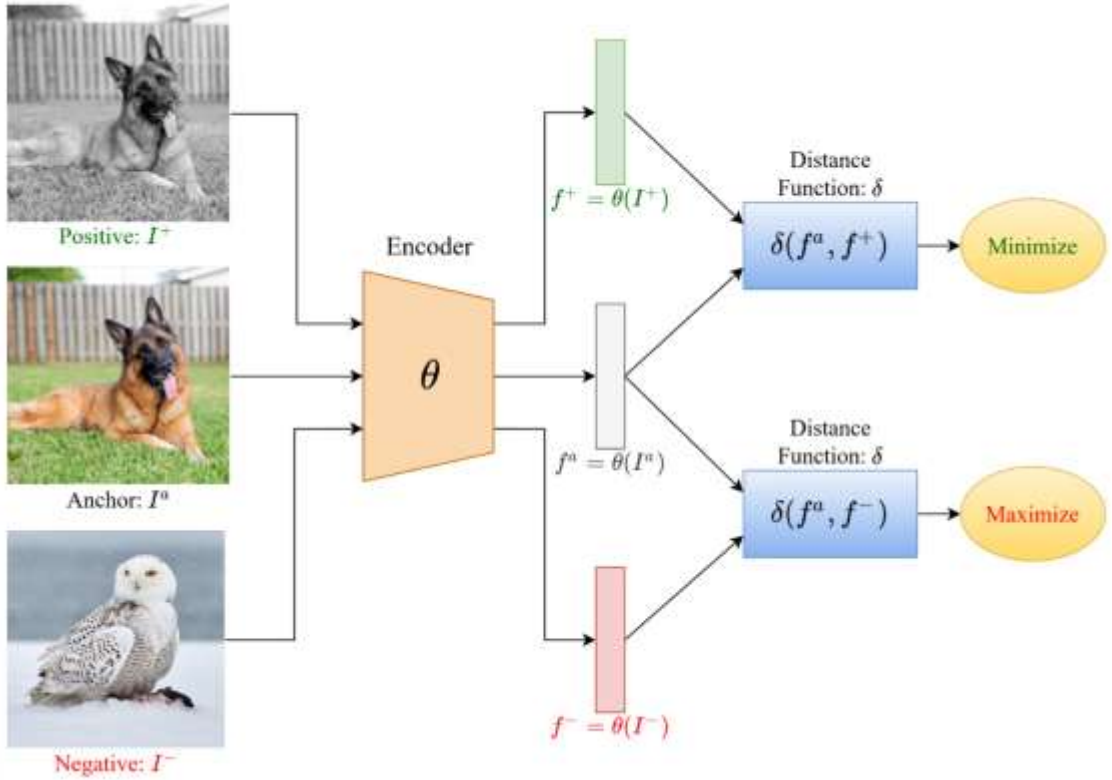



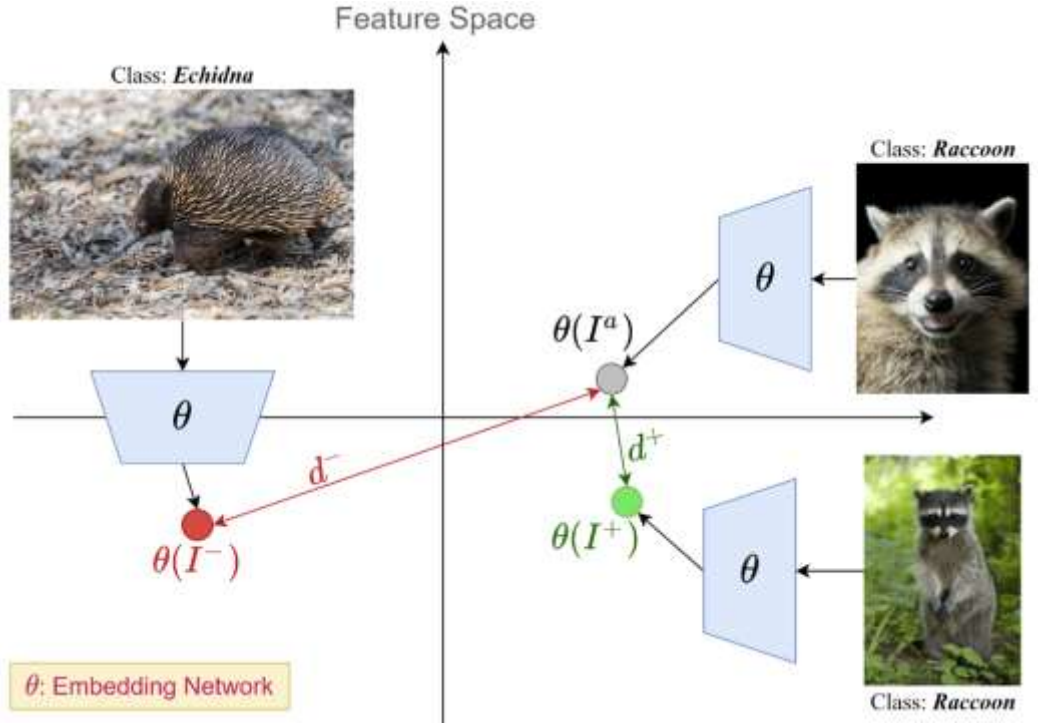



## 视觉对比学习（Contrastive learning）方法

- 使用图像本身作为标签，预训练之后用于下游任务——**能够学习到很强的编码器**
- 如何学习——通过定义**正负样本**，使图像的正样本之间距离拉近，不同图像间距离拉远

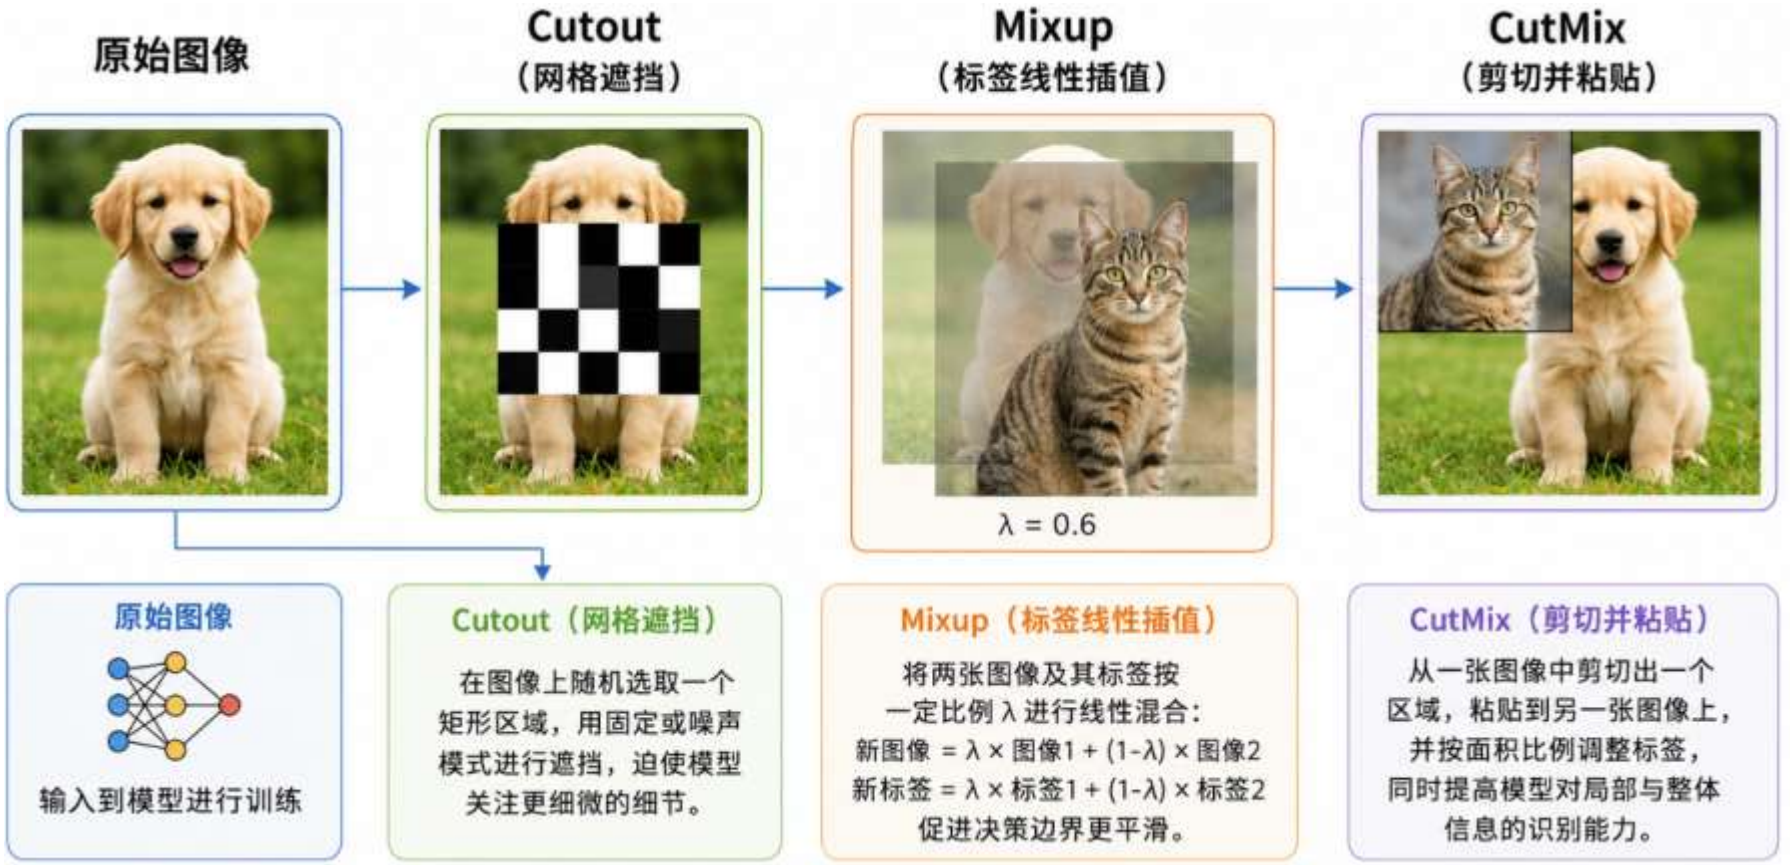


## 对比学习中如何构造正负样本数据——数据增广（Data Augmentation）

- 方法有很多，很直观且容易实现——提升了数据量的同时也不需要数据标注



# 视觉自监督对比学习

## ① 构造视图（数据增强）

图像 1



增强视图
（正样本对）





图像 2







## ② 编码到表示空间

编码器 $f(\cdot)$

共享参数

编码器 $f(\cdot)$



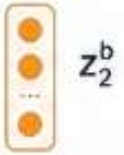
$z_1^a$



$z_1^b$



$z_2^a$



$z_2^b$

## ③ 计算相似度

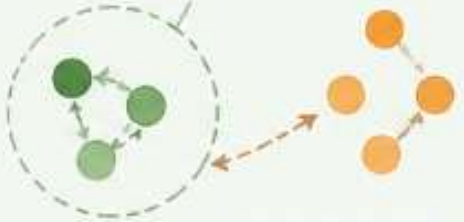
| | $z_1^a$ | $z_1^b$ | $z_2^a$ | $z_2^b$ |
|---|---|---|---|---|
| $z_1^a$ | 1 | 0.2 | 0.1 | 0.1 |
| $z_1^b$ | 0.2 | 1 | 0.1 | 0.2 |
| $z_2^a$ | 0.1 | 0.1 | 1 | 0.3 |
| $z_2^b$ | 0.1 | 0.2 | 0.3 | 1 |

正样本（同一图像的不同视图）
相似度应高（拉近）

负样本（不同图像的视图）
相似度应低（拉远）

## ④ 对比学习目标

同一图像的视图
（拉近）



不同图像的视图
（拉远）

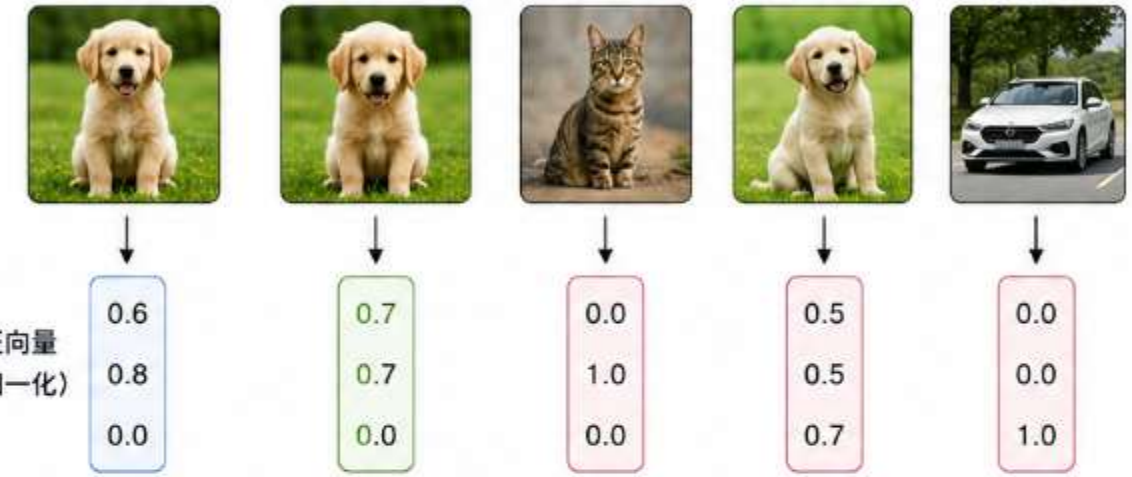
优化目标（如 InfoNCE Loss）

最大化正样本对的相似度，
最小化负样本对的相似度。

# 视觉自监督对比学习

## 优化目标：InfoNCE loss

$$\mathcal{L}_i = -\log \frac{\exp(\text{sim}(z_i, z_i^+)/\tau)}{\exp(\text{sim}(z_i, z_i^+)/\tau) + \sum_{j=1}^{K} \exp(\text{sim}(z_i, z_j^-)/\tau)}$$




1. 计算余弦相似度（点积，由于向量已归一化）

| 相似度（锚点 x 与 ...） | $x^+$（正样本） | $x_1^-$（猫） | $x_2^-$（小狗） | $x_3^-$（汽车） |
|---|---|---|---|---|
| x（锚点） | 0.98 | 0.80 | 0.70 | 0.00 |

2. 除以温度 $\tau = 0.1$

| 相似度 / τ | 9.8 | 8.0 | 7.0 | 0.0 |
|---|---|---|---|---|

3. 计算 InfoNCE Loss

$$L = -\log \frac{\exp(\text{sim}(x, x^+)/\tau)}{\sum_{j \in \{x^+, x_1^-, x_2^-, x_3^-\}} \exp(\text{sim}(x, x_j)/\tau)}$$

代入数值：

$$L = -\log \frac{e^{9.8}}{e^{9.8} + e^{8.0} + e^{7.0} + e^{0.0}}$$

计算分子和分母：

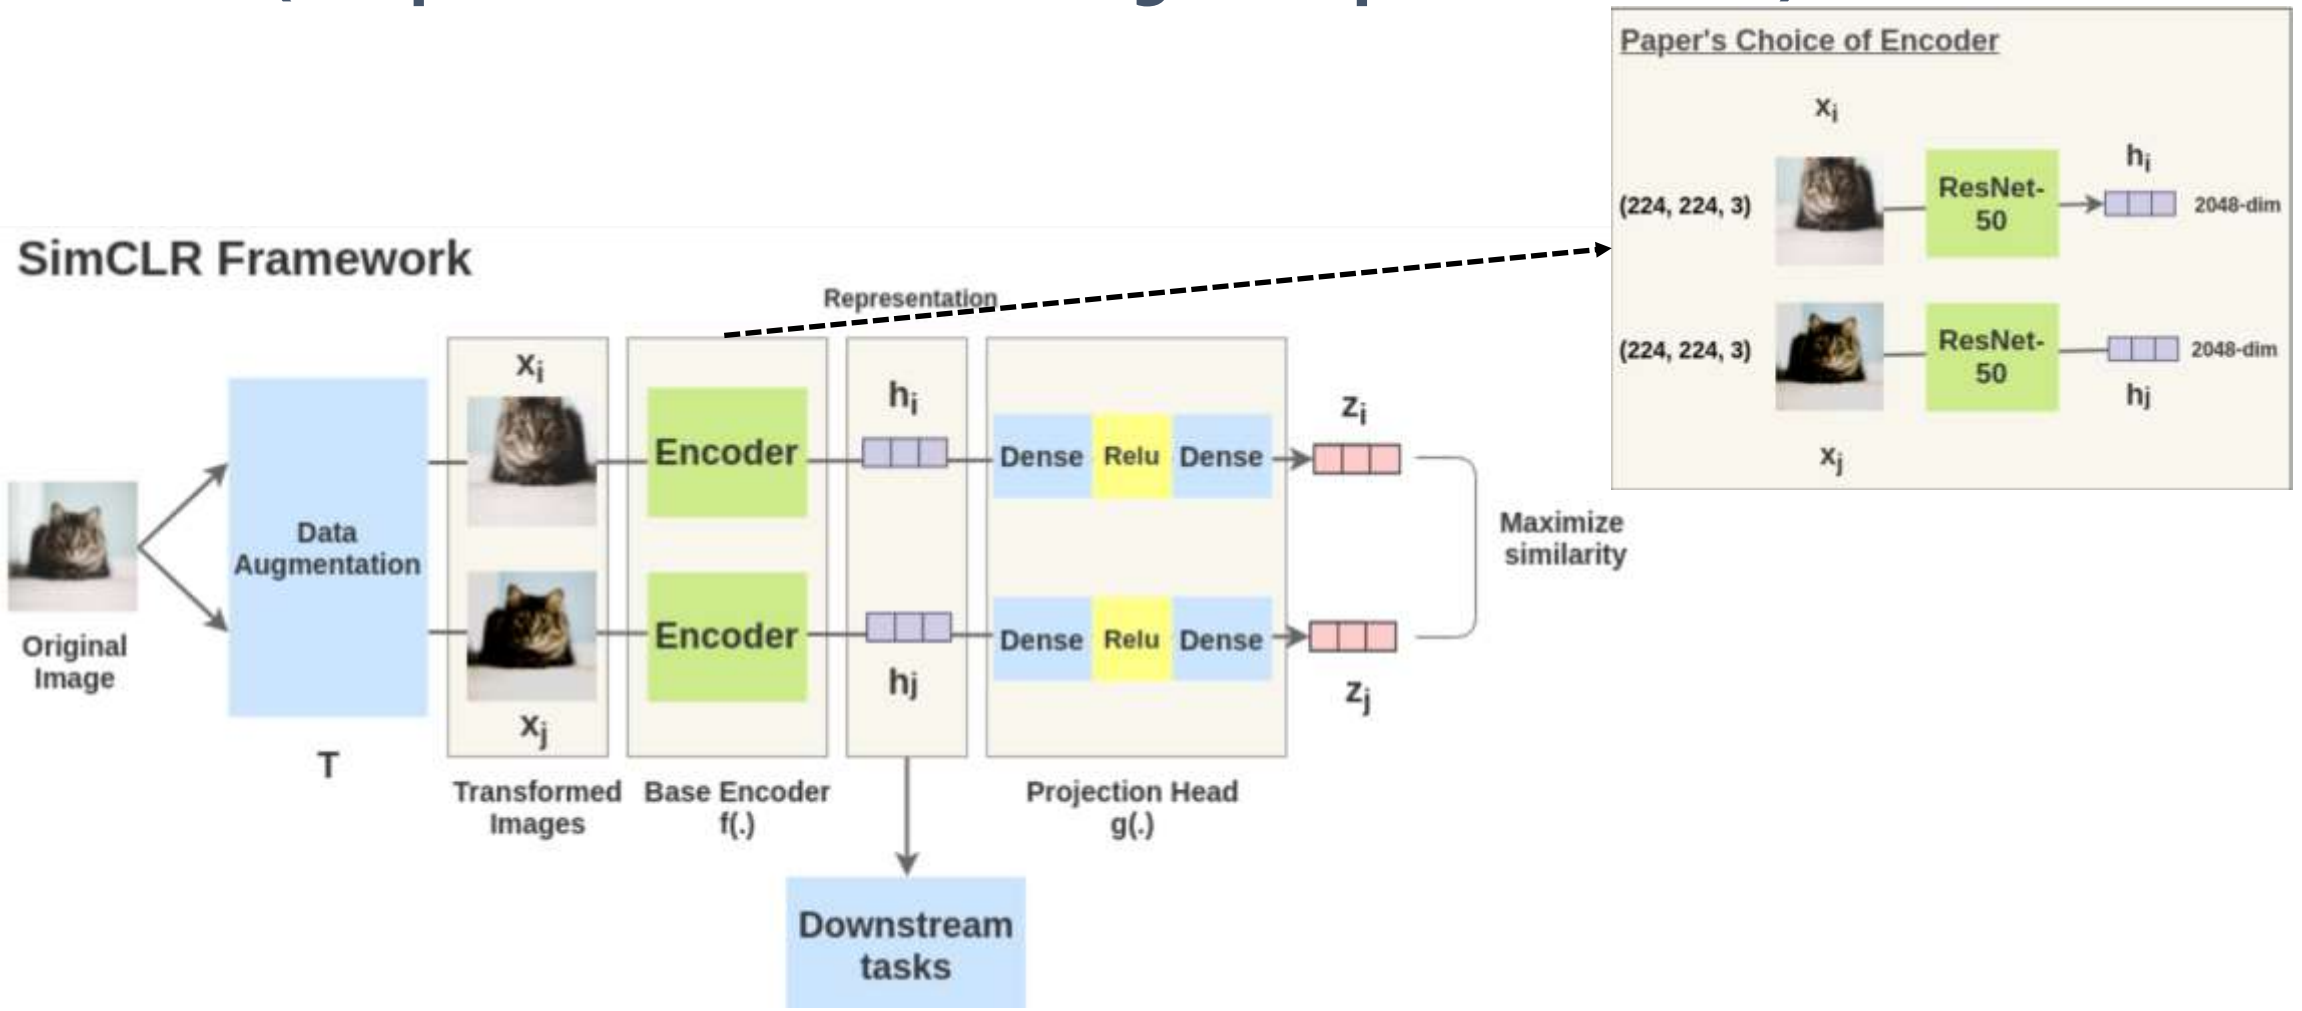
分子 $= e^{9.8} = 17970.9$

分母 $= 17970.9 + 2980.9 + 1096.6 + 1 = 22049.4$

$$\frac{17970.9}{22049.4} = 0.8157$$

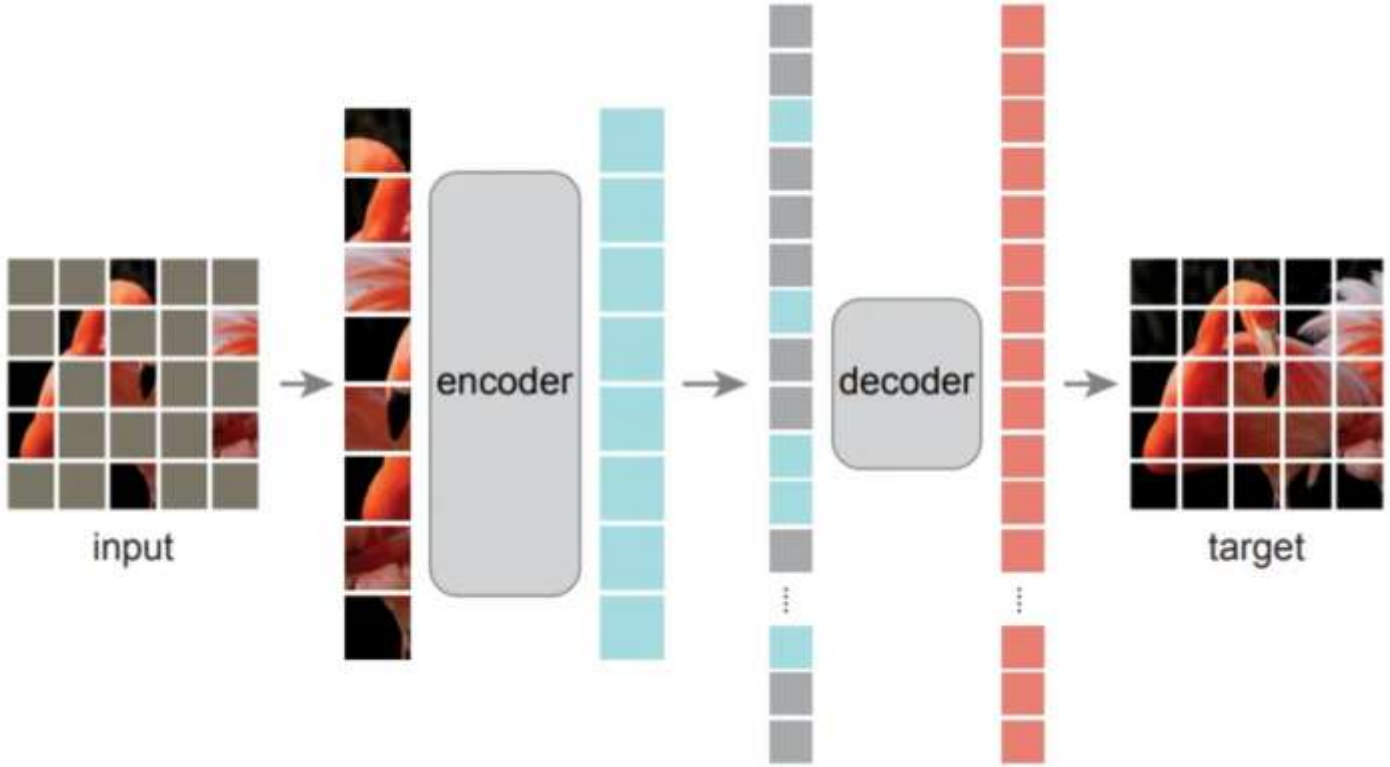
$L = -\log(0.8157) = 0.203$

## SimCLR (Simple Contrastive Learning of Representations)



## Masked AutoEncoders (MAE): AE+BERT in CV

- 对图像随机mask掉的区域更大（**达到75%的面积**）
- Encoder只应用在可见的patch上，mask tokens在encoder之后才引
- MAE预训练在**目标检测和分割任务**上的效果非常好



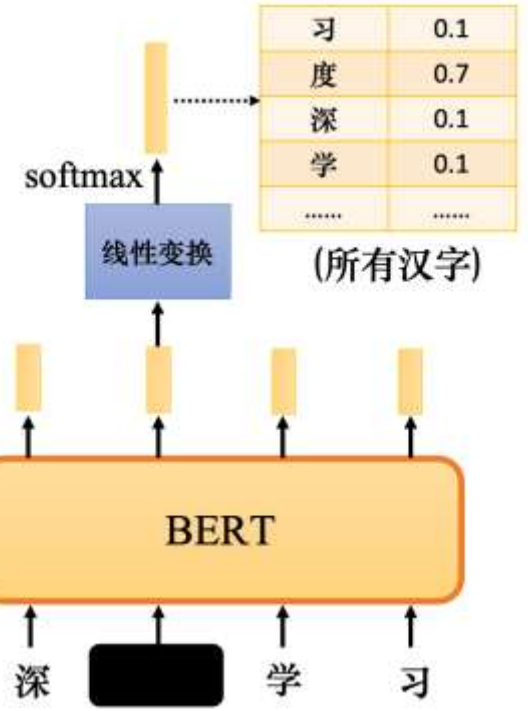




Figure 1. **Our MAE architecture**. During pre-training, a large random subset of image patches (*e.g.*, 75%) is masked out. The encoder is applied to the small subset of *visible patches*. Mask tokens are introduced *after* the encoder, and the full set of encoded patches and mask tokens is processed by a small decoder that reconstructs the original image in pixels. After pre-training, the decoder is discarded and the encoder is applied to uncorrupted images (full sets of patches) for recognition tasks.

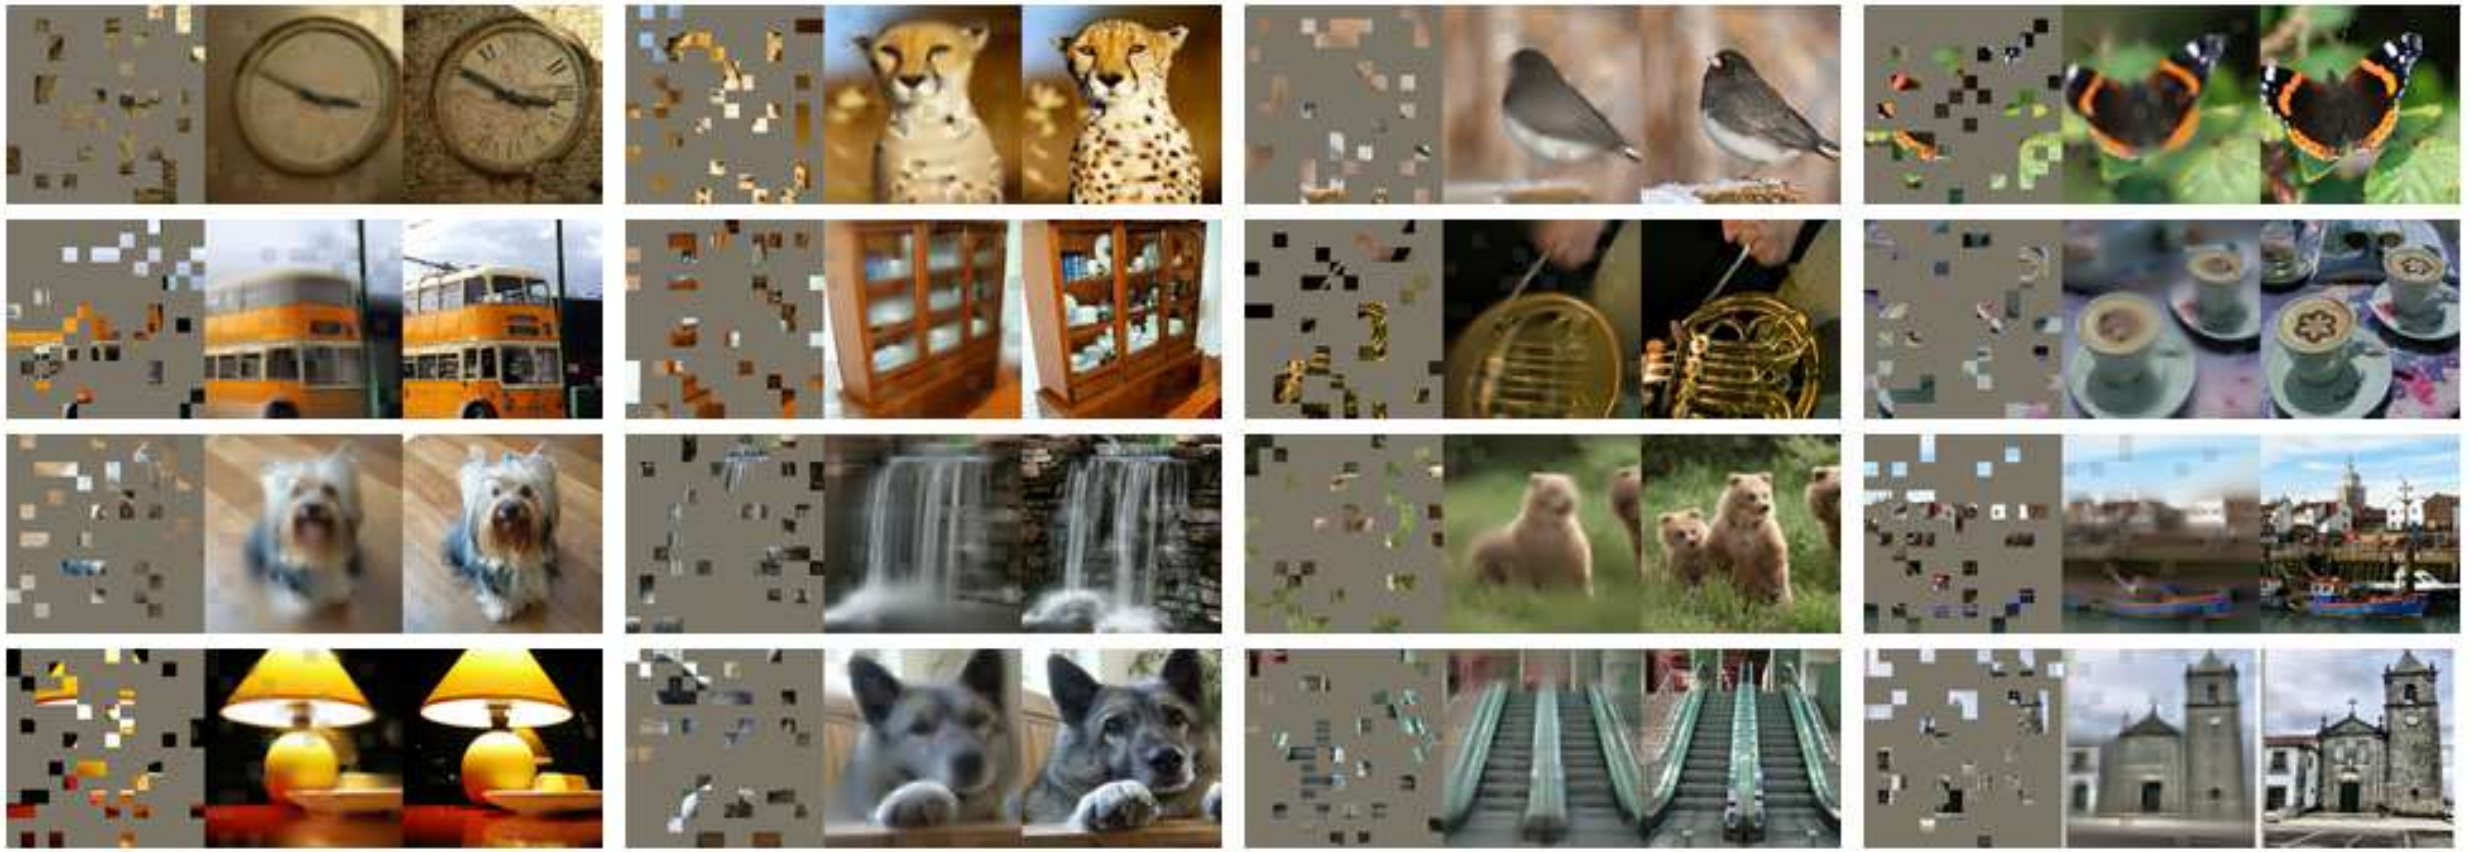
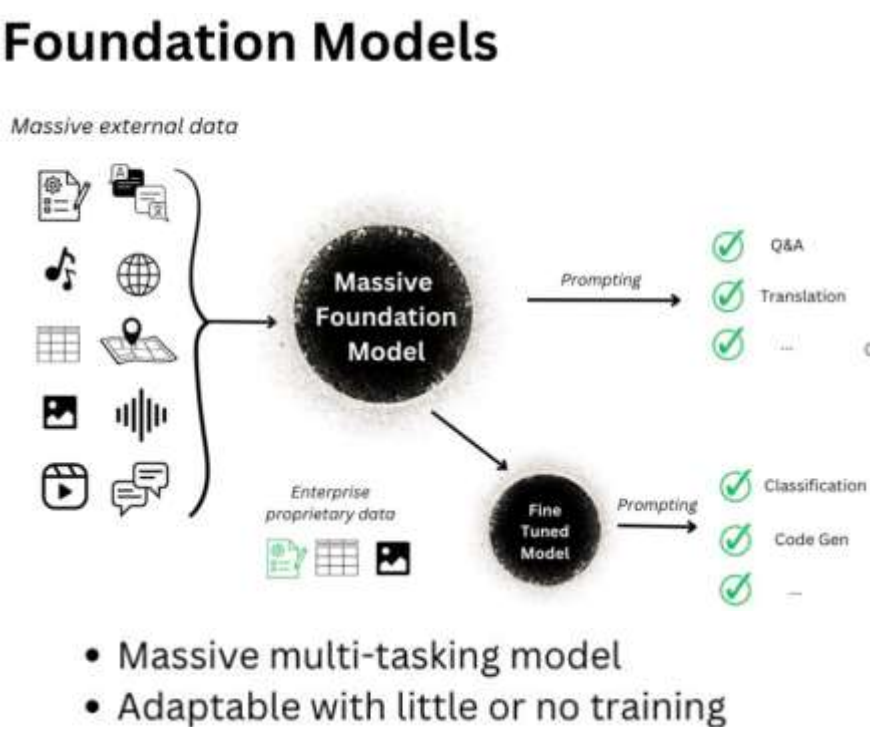


Figure 2. Example results on ImageNet *validation* images. For each triplet, we show the masked image (left), our MAE reconstruction† (middle), and the ground-truth (right). The masking ratio is 80%, leaving only 39 out of 196 patches. More examples are in the appendix.

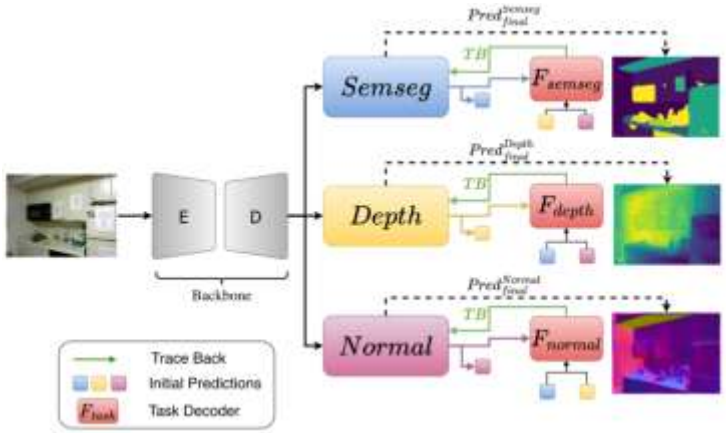
- 基础模型（Foundation Model）：一种强大的预训练AI模型，经过海量数据的训练，能够快速适应多种任务，是构建特定AI应用的基础




VS.




计算机视觉领域的任务差异大，虽然有多任务（通常是密集预测）学习框架，但是远达不到基础模型的能力




对于视觉基础模型，我们实际上把模型对通用能力的学习转变成了通用特征提取能力的学习

# DINO：*self-**di**stillation with **no** labels*

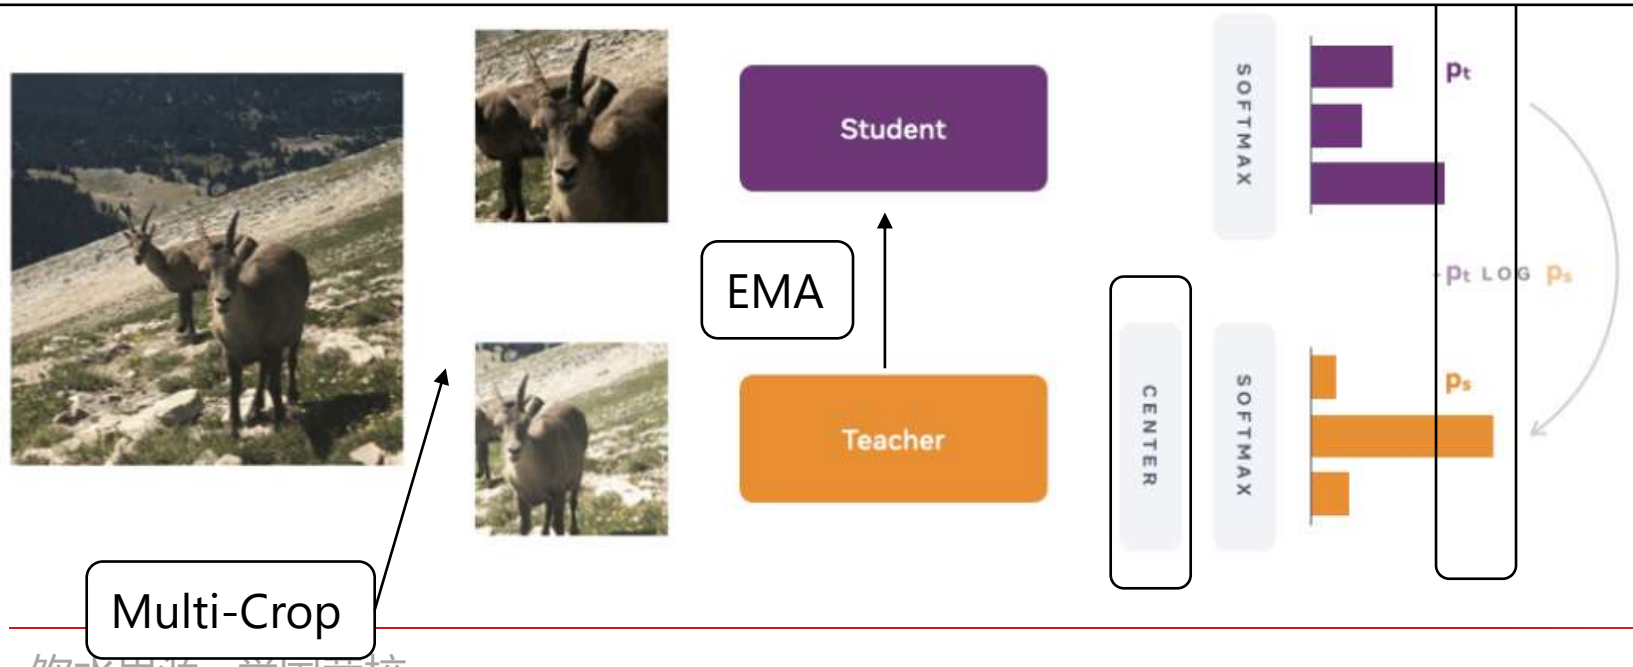
- 基于ViT架构的视觉基础模型的尝试与探索

**Emerging Properties in Self-Supervised Vision Transformers**

Mathilde Caron[1,2] Hugo Touvron[1,3] Ishan Misra[1] Hervé Jegou[1]
Julien Mairal[2] Piotr Bojanowski[1] Armand Joulin[1]

[1] Facebook AI Research [2] Inria* [3] Sorbonne University

**Global Views（2个）**：分辨率较大，包含图像的主要大面积区域。**同时输入给 Teacher 和 Student**
**Local Views（多个）**：分辨率较小，只包含图像的局部区域。**只输入给 Student**
通过“局部到全局”的策略强迫 Student 能够通过局部的碎片去匹配 Teacher 看出的全局语义，极大增强了模型对局部与整体关系的理解。




**Teacher和Student是孪生神经网络，即结构一样，只更新student网络的参数，Teacher则通过Student网络的参数的指数移动平均来平滑更新**

**Building upon existing techniques**

- Multi-Crop data augmentation strategy
- Teacher–Student knowledge distillation
- Momentum Encoder parameter updates
- Centering training
- Cross-entropy-based contrastive loss

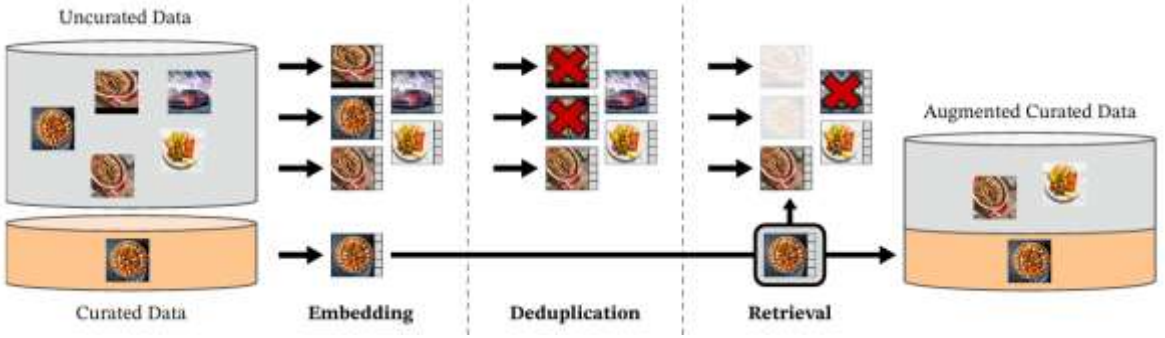
**更多的是靠工程技术，非算法创新**
**取得自监督学习媲美监督学习的性能**

# （视觉）基础模型

## DINOv2: Learning Robust Visual Features without Supervision

Maxime Oquab**, Timothée Darcet**, Théo Moutakanni**,
Huy V. Vo*, Marc Szafraniec*, Vasil Khalidov*, Pierre Fernandez, Daniel Haziza,
Francisco Massa, Alaaeldin El-Nouby, Mahmoud Assran, Nicolas Ballas, Wojciech Galuba,
Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat,
Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jegou, Julien Mairal[1],
Patrick Labatut*, Armand Joulin*, Piotr Bojanowski*

### Motivation of DINOv2:构建类似ChatGPT的CV基础模型




(1) 构建了一个 1.42 亿规模（142M-scale）的数据集，并提出了一个自动化的数据集构建框架
(2) 引入了图像块掩码（patch masking）及相应的损失函数
(3) 结合了正则化技术
(4) 实施了几项额外的工程优化

## DINOv3

Oriane Siméoni* Huy V. Vo* Maximilian Seitzer* Federico Baldassarre* Maxime Oquab*
Cijo Jose Vasil Khalidov Marc Szafraniec Seungeun Yi Michaël Ramamonjisoa
Francisco Massa Daniel Haziza Luca Wehrstedt Jianyuan Wang
Timothée Darcet Théo Moutakanni Leonel Sentana Claire Roberts
Andrea Vedaldi Jamie Tolan John Brandt[1] Camille Couprie
Julien Mairal[2] Hervé Jégou Patrick Labatut Piotr Bojanowski
*Meta AI Research* [1] *WRI* [2] *Inria*

### Motivation of DINOv3: Scaling

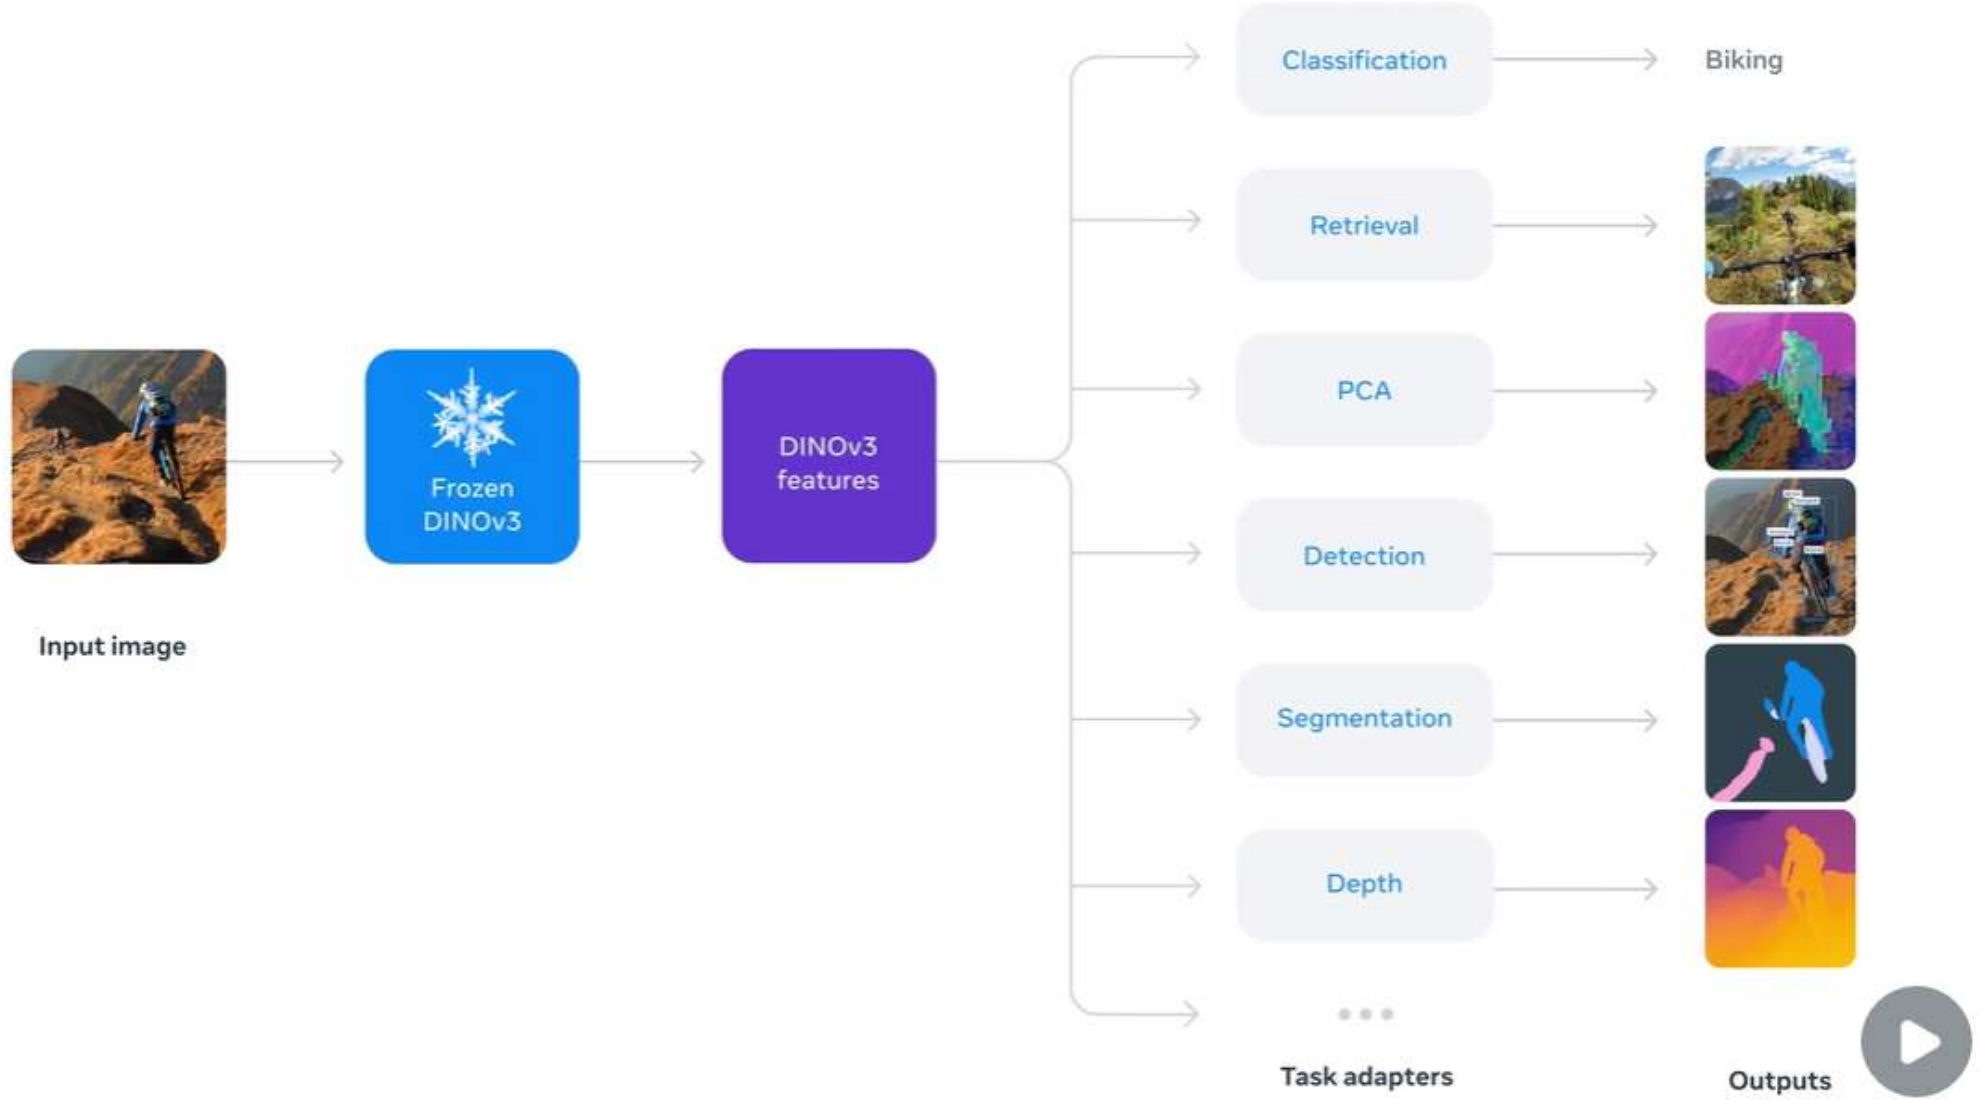
Datasets：142M→1689M(1.7B)

Model：1.1B→1689M(1.7B)

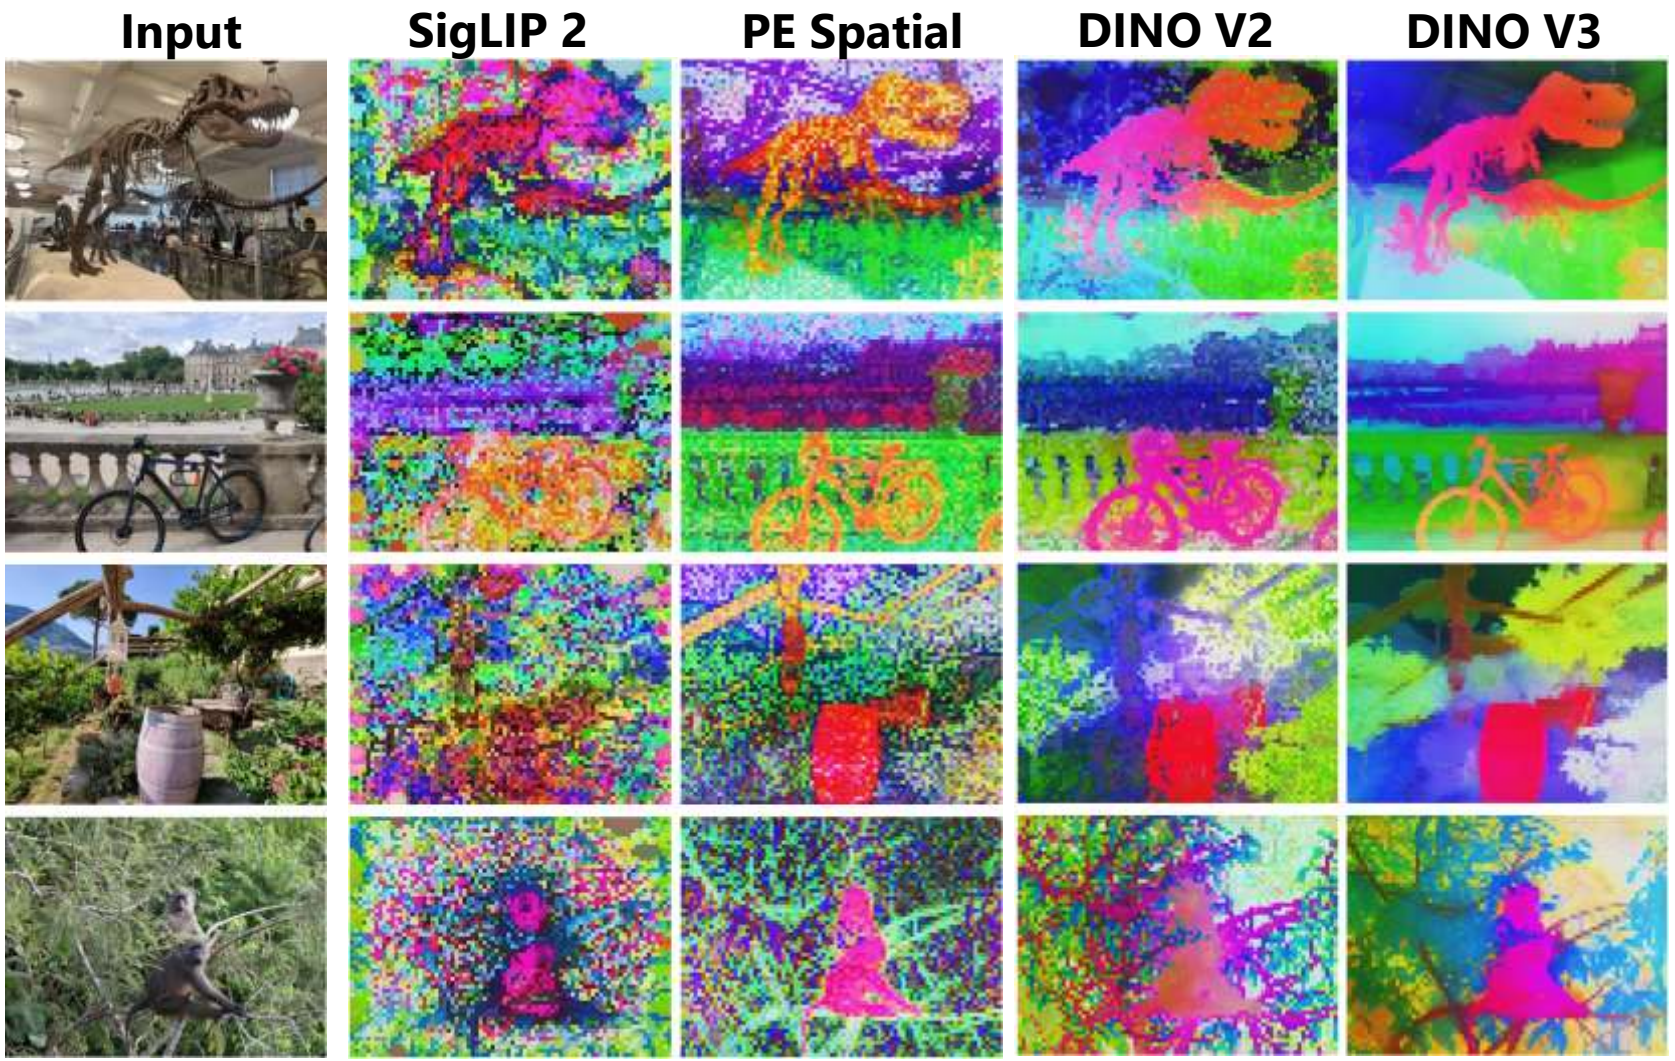
加入了一种增强特征表示的图像块级（Patch-level）一致性损失，从而产生精细的稠密特征

| Teacher model | DINOv2 | DINOv3 |
|---|---|---|
| Backbone | ViT-giant | ViT-7B |
| #Params | 1.1B | 6.7B |
| #Blocks | 40 | 40 |
| Patch Size | 14 | 16 |
| Pos. Embeddings | Learnable | RoPE |
| Registers | 4 | 4 |
| Embed. Dim. | 1536 | 4096 |
| FFN Type | SwiGLU | SwiGLU |
| FFN Hidden Dim. | 4096 | 8192 |
| Attn. Heads | 24 | 32 |
| Attn. Heads Dim. | 64 | 128 |
| DINO Head MLP | 4096-4096-256 | 8192-8192-512 |
| DINO Prototypes | 128k | 256k |
| iBOT Head MLP | 4096-4096-256 | 8192-8192-384 |
| iBOT Prototypes | 128k | 96k |

## DINOv3


Input image
Frozen DINOv3
DINOv3 features
Classification
Retrieval
PCA
Detection
Segmentation
Depth
Task adapters
Biking
Outputs

# （视觉）基础模型




输入图像的Dense Feature比较

经过PCA投影到RGB后呈现的效果

对于两种输入size，1280×960和1120×840，patch大小分别魏16和14，得到的feature map的大小为80*60

# 视觉基础模型

- Meta在2023年4月6日发布了视觉领域的里程碑式的模型——Segment Anything Model (SAM)

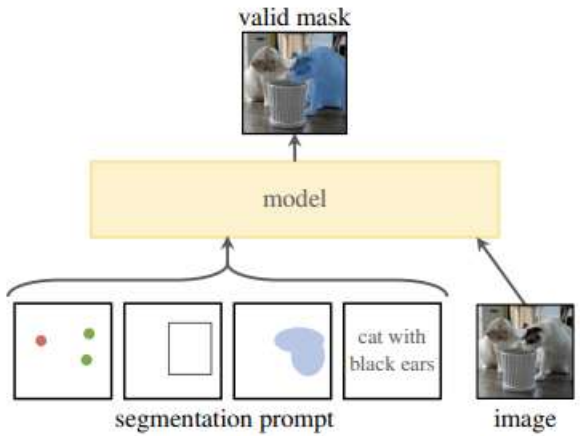




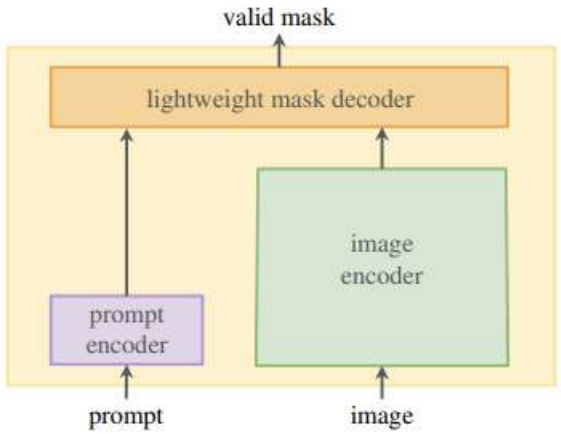



## Segment Anything Model（SAM）

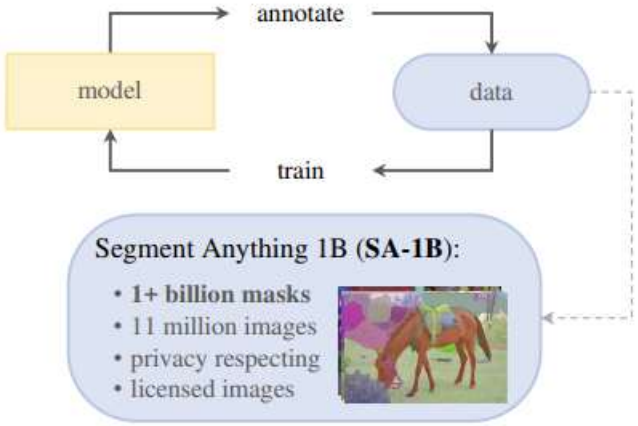
- 模型在训练时被设计为**交互性的可提示模型（a）**，因此可以通过零样本学习转移到新的图像分布和任务中
- SAM的模型架构主要包含三个部分（b）：图像编码器、提示编码器、以及掩码解码器
- 使用了有史以来最大的分割数据集Segment Anything 1-Billion mask dataset（SA-1B）（c），其内包含了**1100万张图像**，总计超过**10亿张掩码图**




(a) **Task**: promptable segmentation




(b) **Model**: Segment Anything Model (**SAM**)

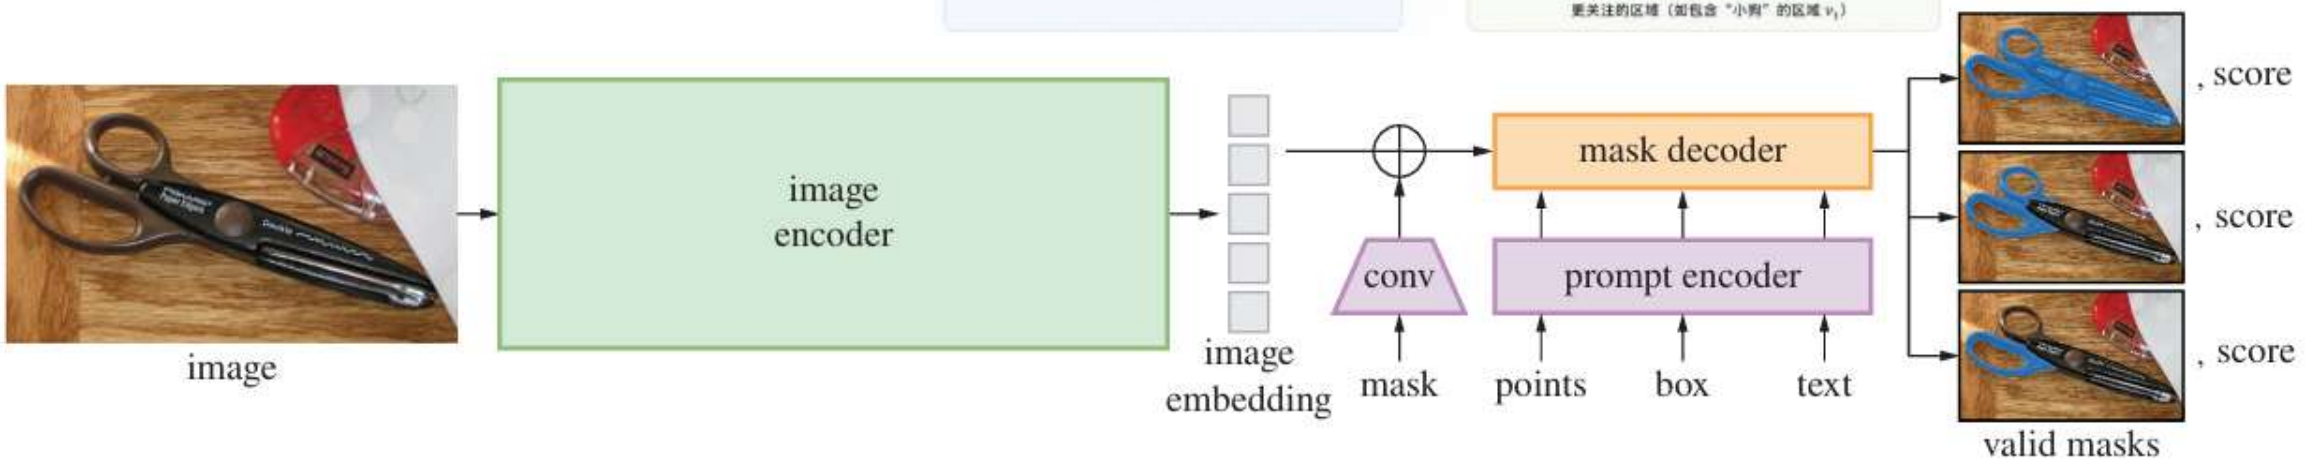



(c) **Data**: data engine (top) & dataset (bottom)

## 复杂的编码器提取图像特征，解码器设计为轻量级

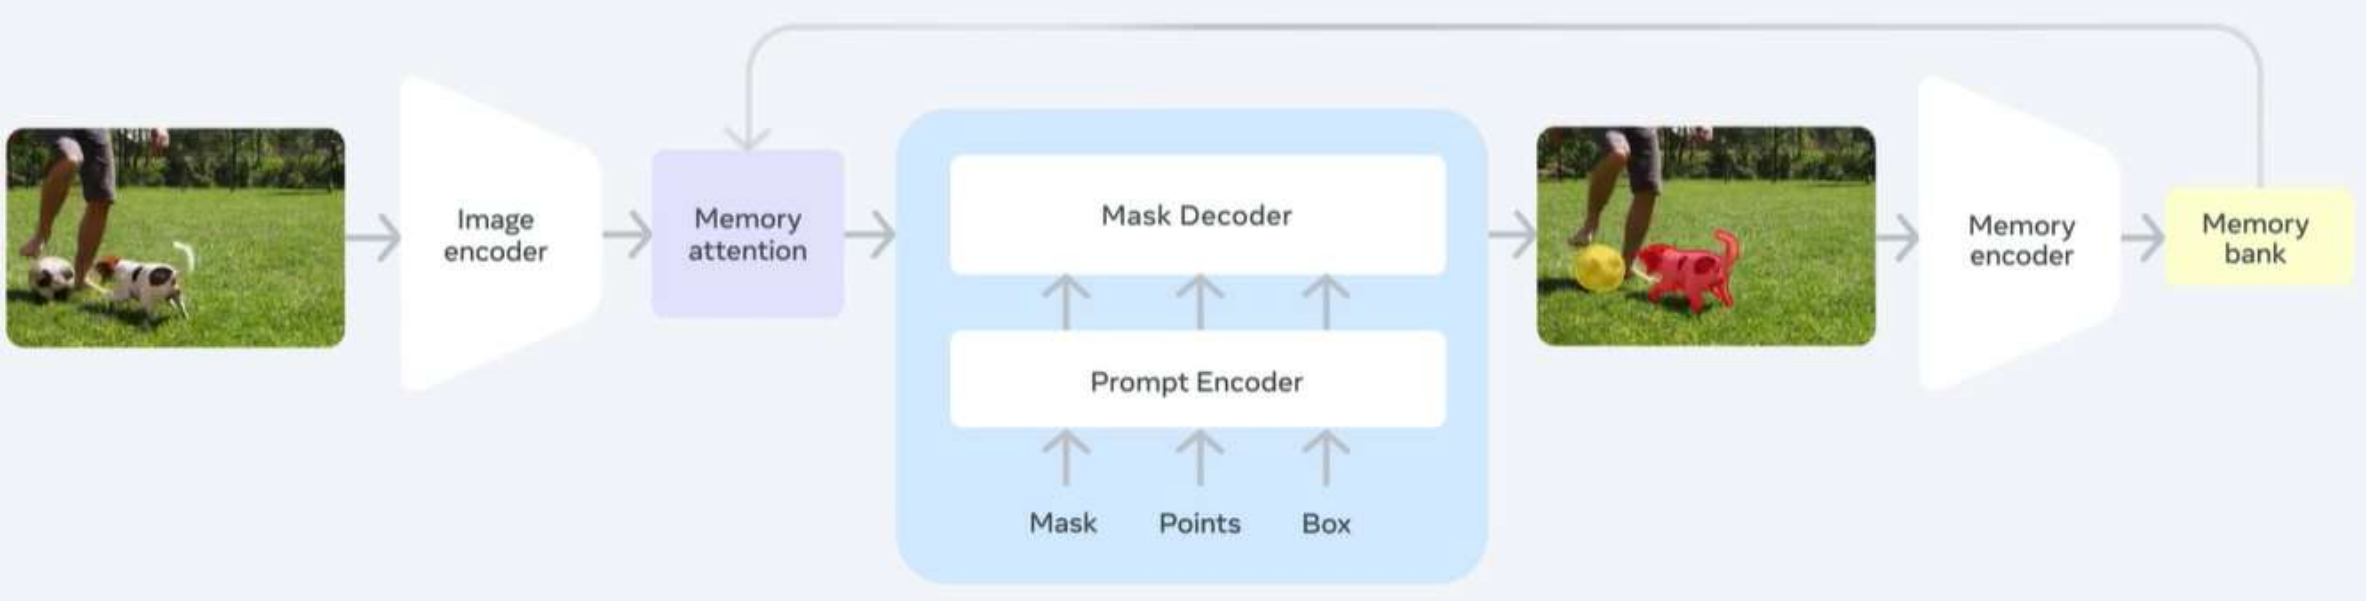
- Encoder仍然采用ViT架构
- 基于MAE的掩码预训练
- CLIP（稍后介绍）文本编码器
- Mask Decoder引入双向注意力



## Meta在2024年7月29日发布了SAM 2

- 编码器架构升级，**采用了Hiera，层级式视觉Transformer**
- 从图像分割扩展到支持交互式提示的**视频分割**
- 引入了一个**记忆系统**
  - **内存编码器（Memory Encoder）**：将当前帧预测的掩码与图像特征进行融合
  - **内存库（Memory Bank）**:用于存储历史帧的特征和预测信息
  - **内存注意力（Memory attention）**： 让当前帧的特征去“查询”内存库中过去帧的特征与预测结果



Published as a conference paper at ICLR 2026

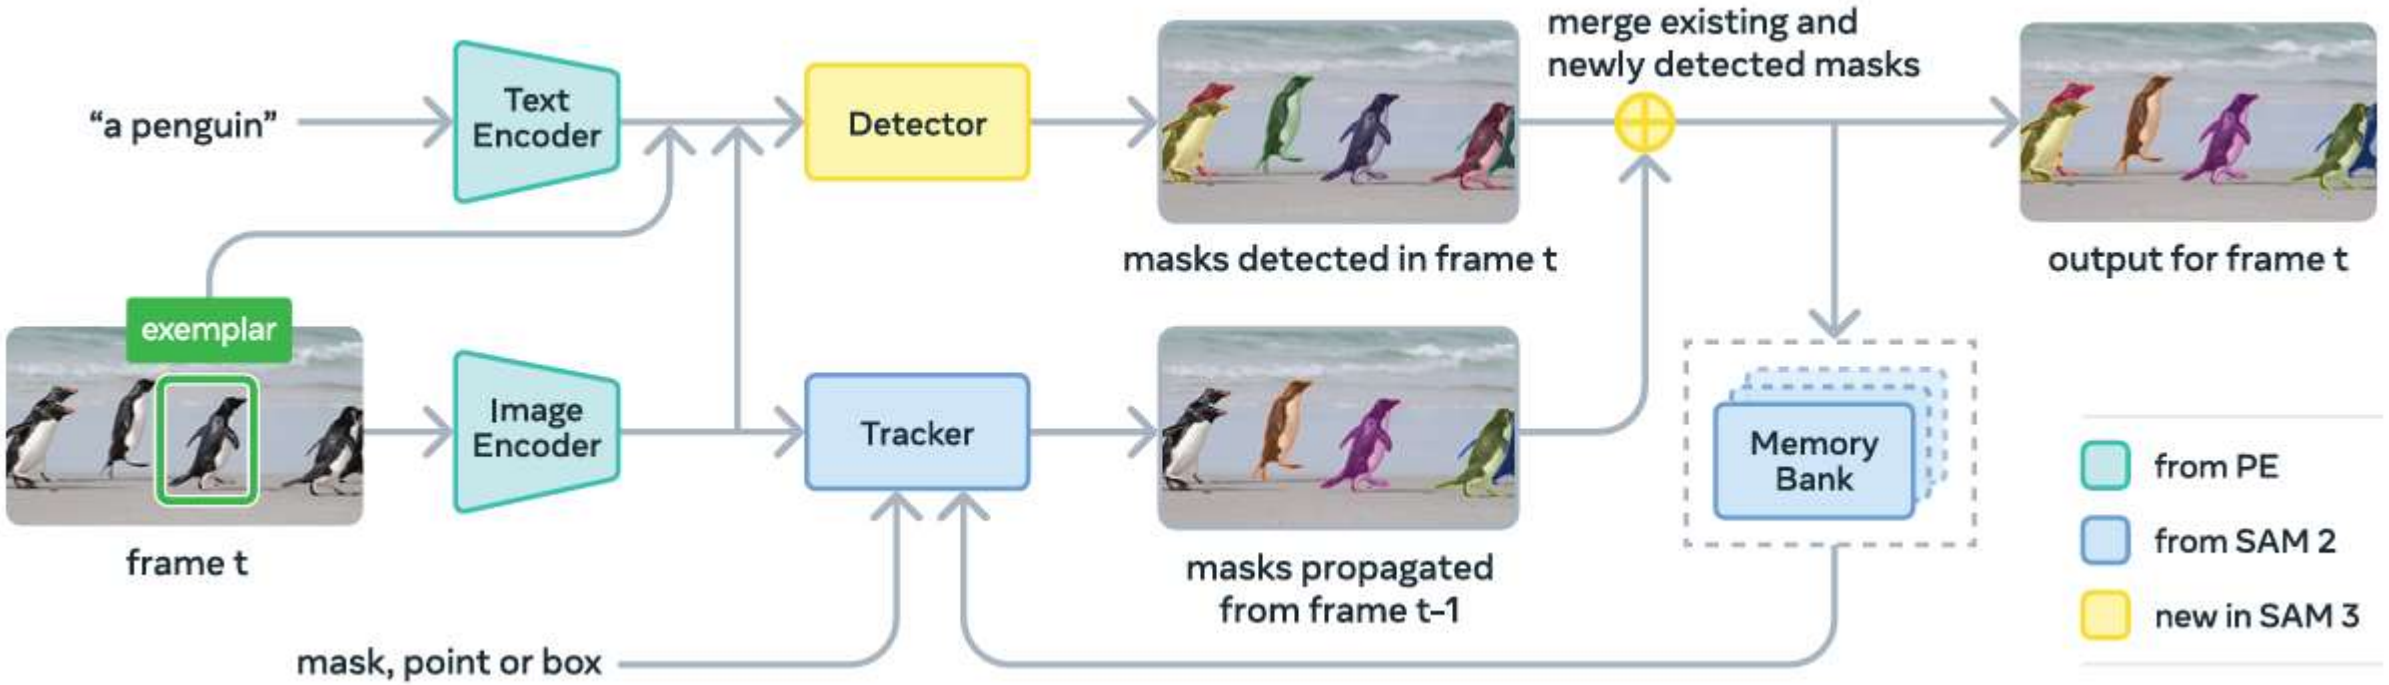
## META在2025年11月发布了SAM 3

- 支持开放词汇的文本短语或者图像示例进行检测分割
- 共享感知的编码器（Shared Perception Encoder, PE）
  - 统一的感知编码和模态对齐
- 检测器（Detector）和追踪器（Tracker）

SAM 3: SEGMENT ANYTHING WITH *Concepts*

Nicolas Carion*, Laura Gustafson*, Yuan-Ting Hu*, Shoubhik Debnath*, Ronghang Hu*, Didac Suris*, Chaitanya Ryali*, Kalyan Vasudev Alwala*, Haitham Khedr*, Andrew Huang, Jie Lei, Tengyu Ma, Baishan Guo, Arpit Kalla, Markus Marks, Joseph Greer, Meng Wang, Peize Sun, Roman Rädle, Triantafyllos Afouras, Effrosyni Mavroudi, Katherine Xu°, Tsung-Han Wu°, Yu Zhou°, Liliane Momeni°, Rishi Hazra°, Shuangrui Ding°, Sagar Vaze°, Francois Porcher°, Feng Li°, Siyuan Li°, Aishwarya Kamath°, Ho Kei Cheng°, Piotr Dollár†, Nikhila Ravi†, Kate Saenko†, Pengchuan Zhang†, Christoph Feichtenhofer†

Meta Superintelligence Labs https://ai.meta.com/sam3

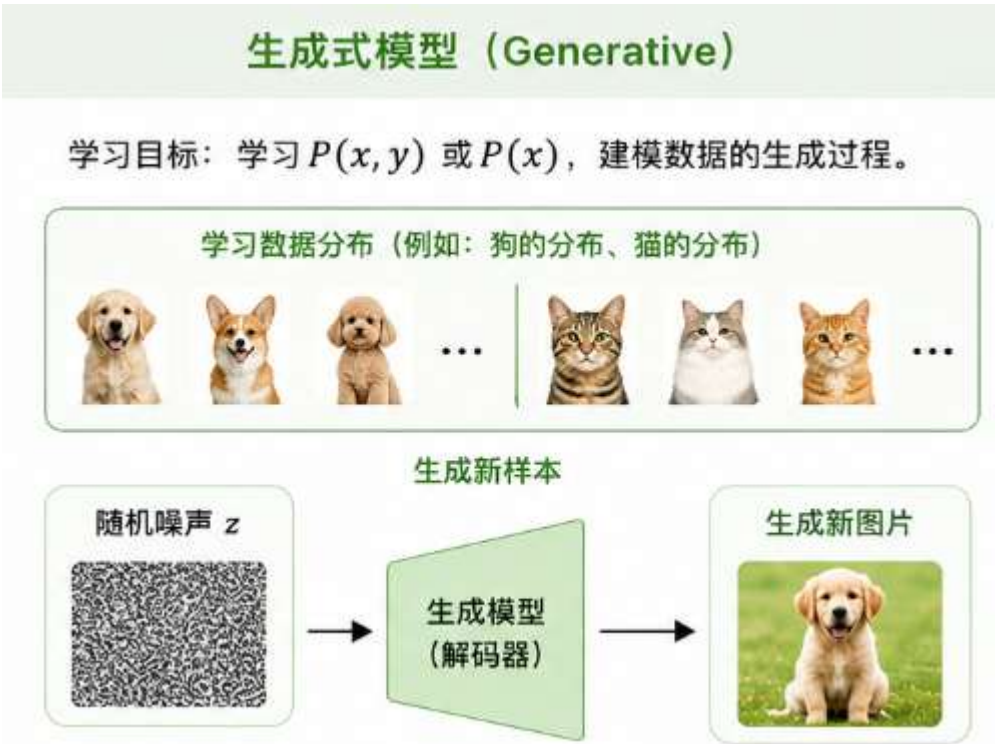


# 生成式模型（Generative Model）

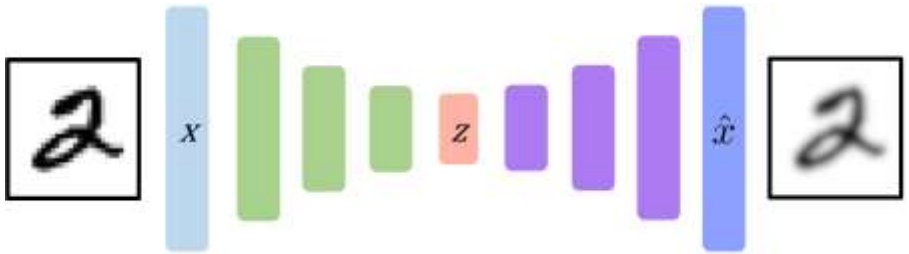
# 生成式模型

- 判别式模型（Discriminative Model）和生成式模型（Generative Model）是两类不同的机器学习模型。前者回答“这是什么？”；后者则回答"这个世界是什么样的？"



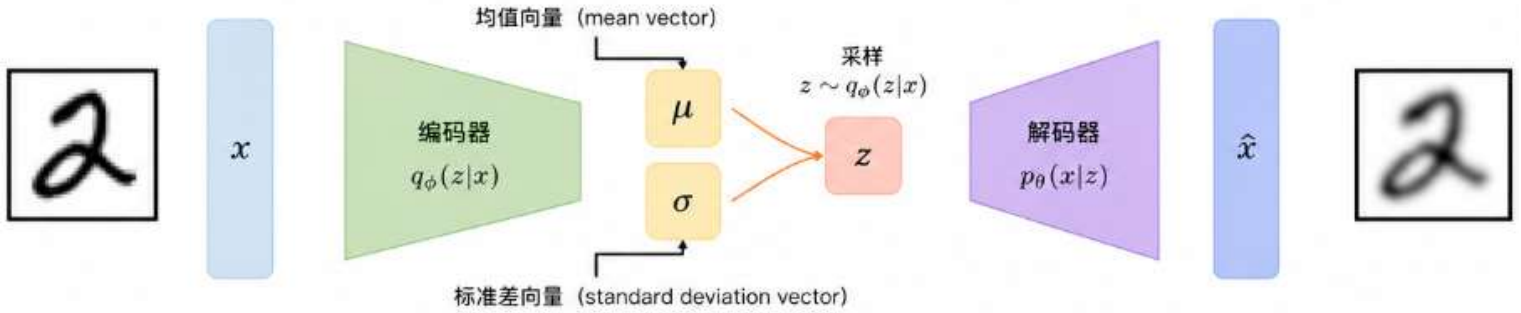
- 如何是模型具备“生成”的能力?
- AE就可以改造成生成式模型




$$\mathcal{L}(x,\hat{x}) = \|x-\hat{x}\|^2$$

**AE，只能重建，学习到输入的中间表征，没有生成能力**

**Variational AE (VAE)：把隐空间（latent vector）变为连续空间**



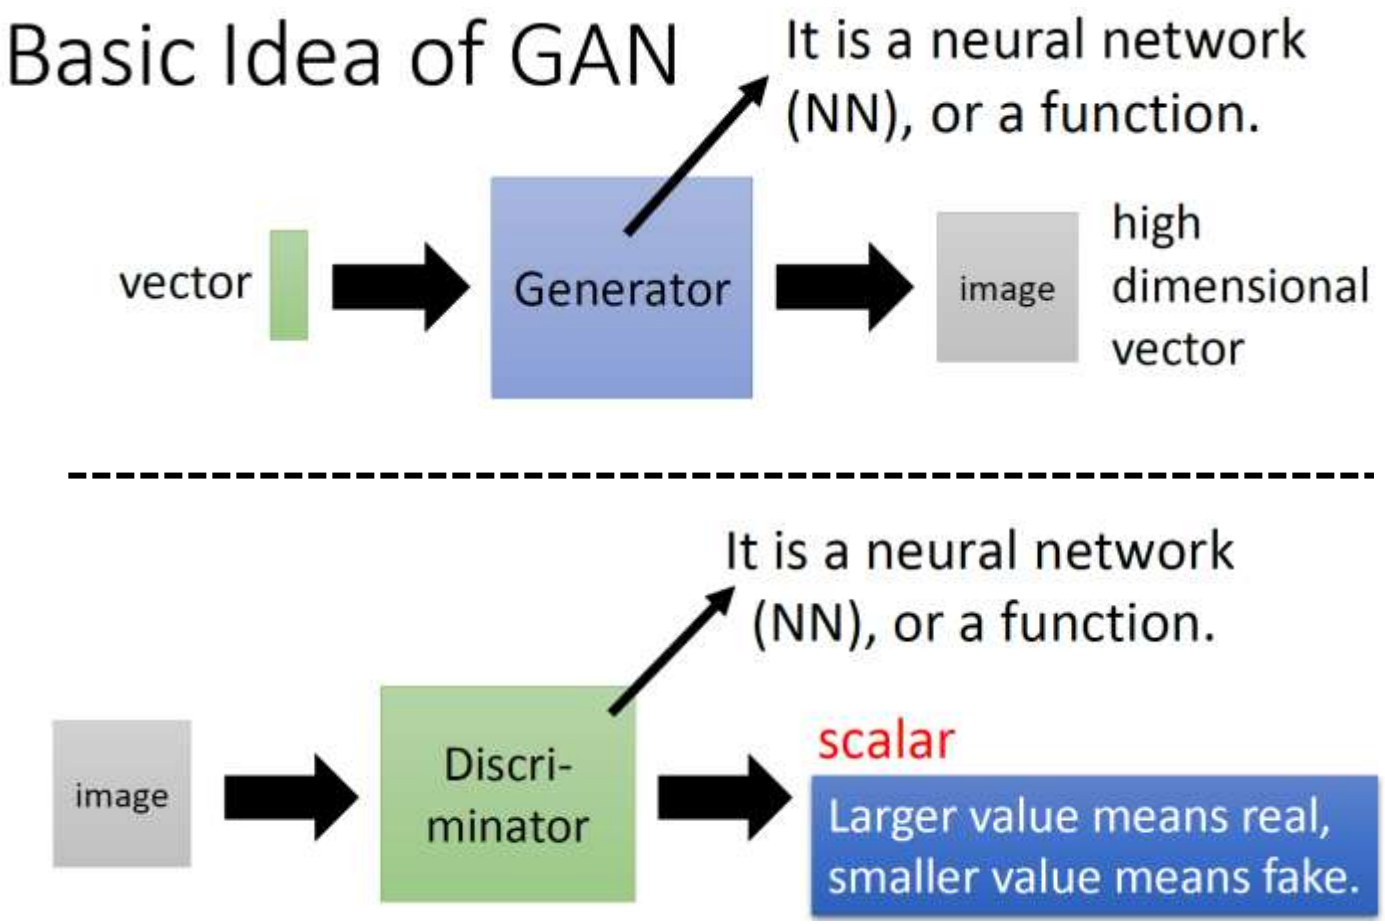

$$\Rightarrow z = \mu + \sigma \odot \varepsilon$$

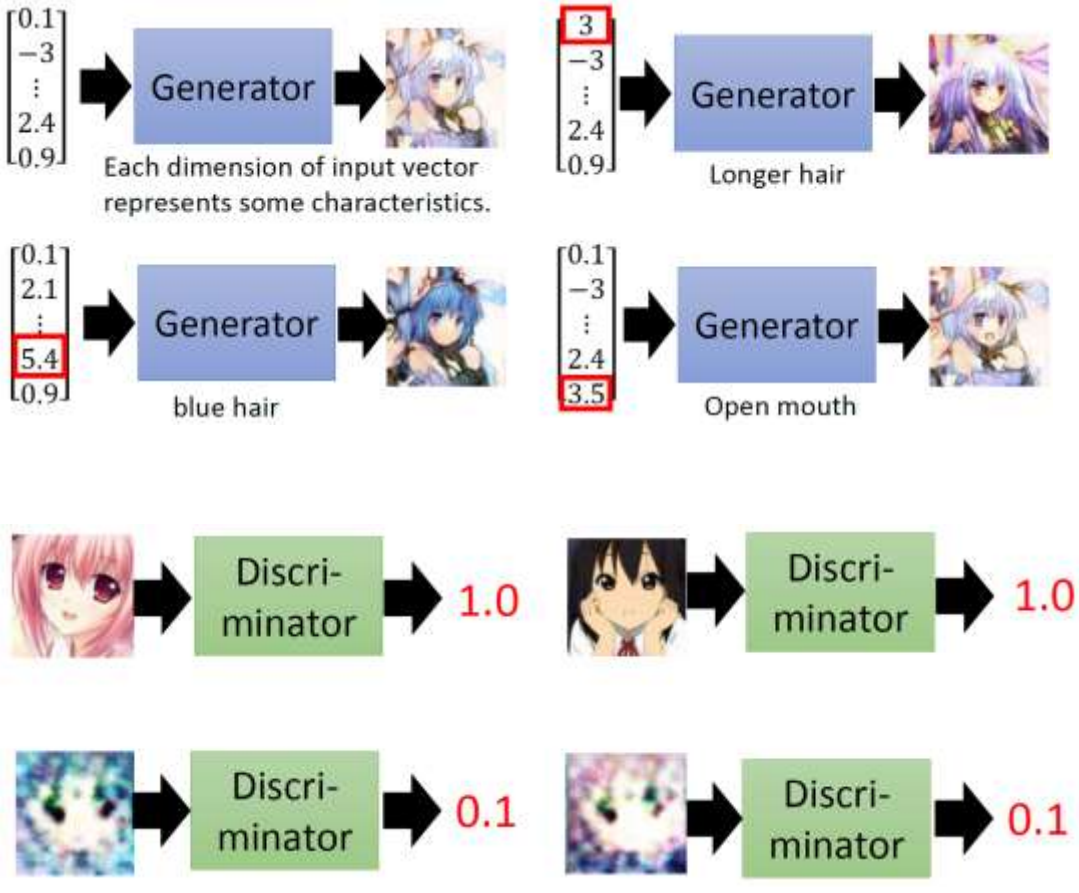
where $\varepsilon \sim \mathcal{N}(0,1)$

$$\max_{\theta,\phi} \mathcal{L}(x;\theta,\phi) = \mathrm{E}_{q_\phi(z|x)}\left[\log p_\theta(x|z)\right] - \mathrm{KL}\left(q_\phi(z|x) \,\|\, p(z)\right)$$
$$\equiv -\mathrm{E}_{q_\phi(z|x)}\left[-\log p_\theta(x|z)\right] + \mathrm{KL}\left(q_\phi(z|x) \,\|\, p(z)\right)$$

- 第一项（重构损失）：$-\log p_\theta(x|z)$，使重构更准确；
- 第二项（KL 正则）：使 $q_\phi(z|x)$ 接近标准正态先验 $p(z) = \mathcal{N}(0, I)$。

## Generative Adversarial Networks (GANs)，曾经是非常火的研究方向

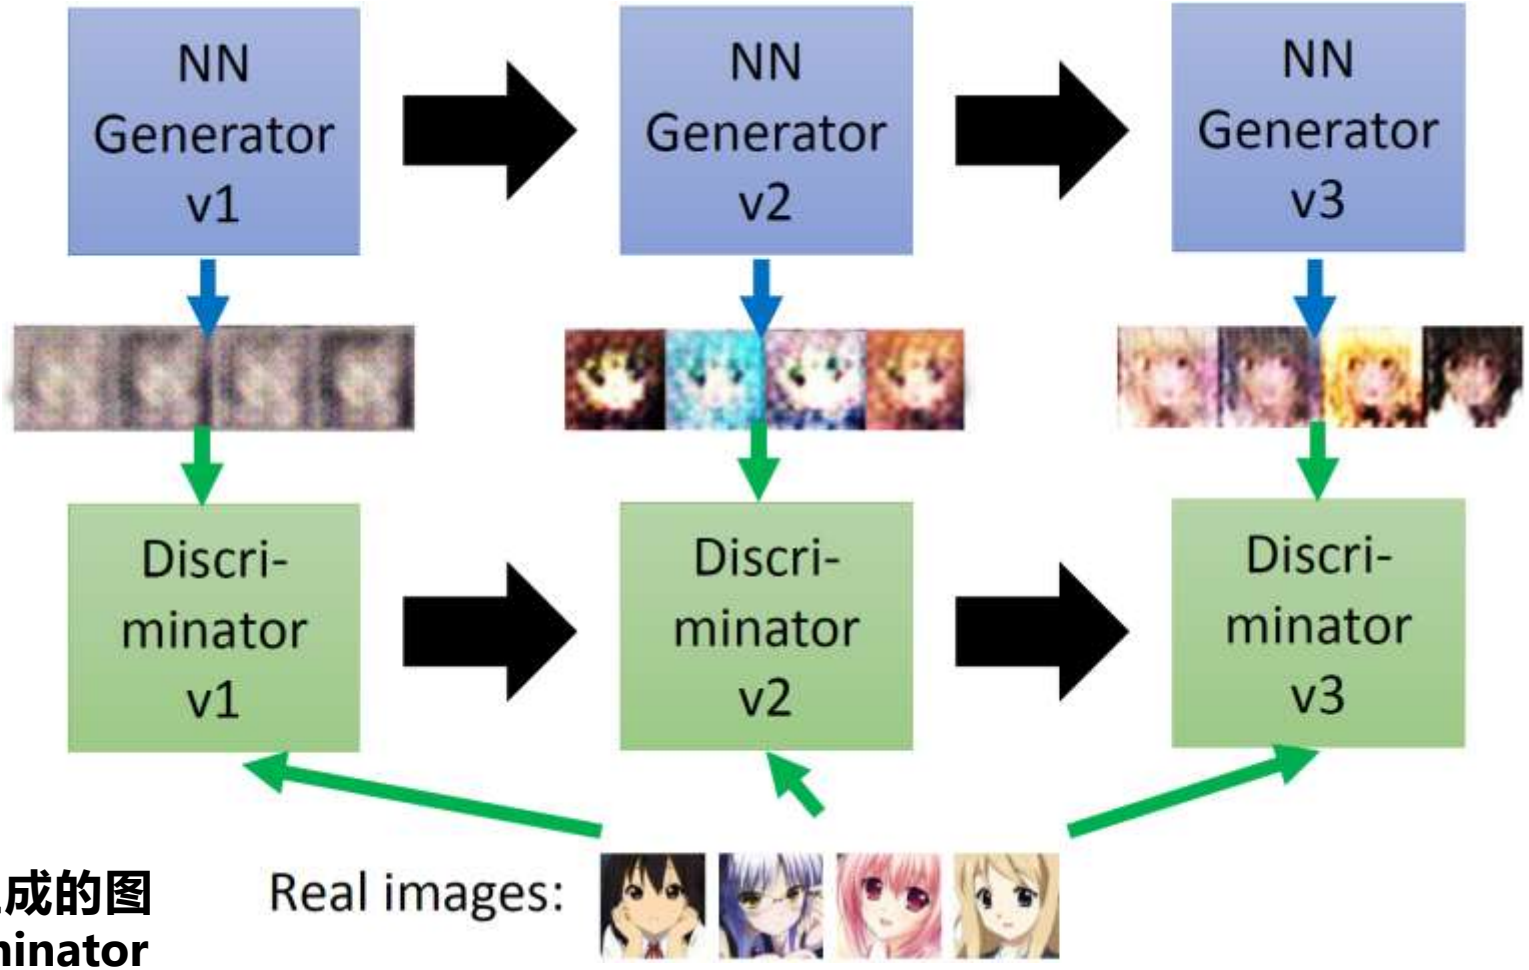


## GAN的想法来自于囚徒困境

**Prisoner's dilemma payoff matrix**

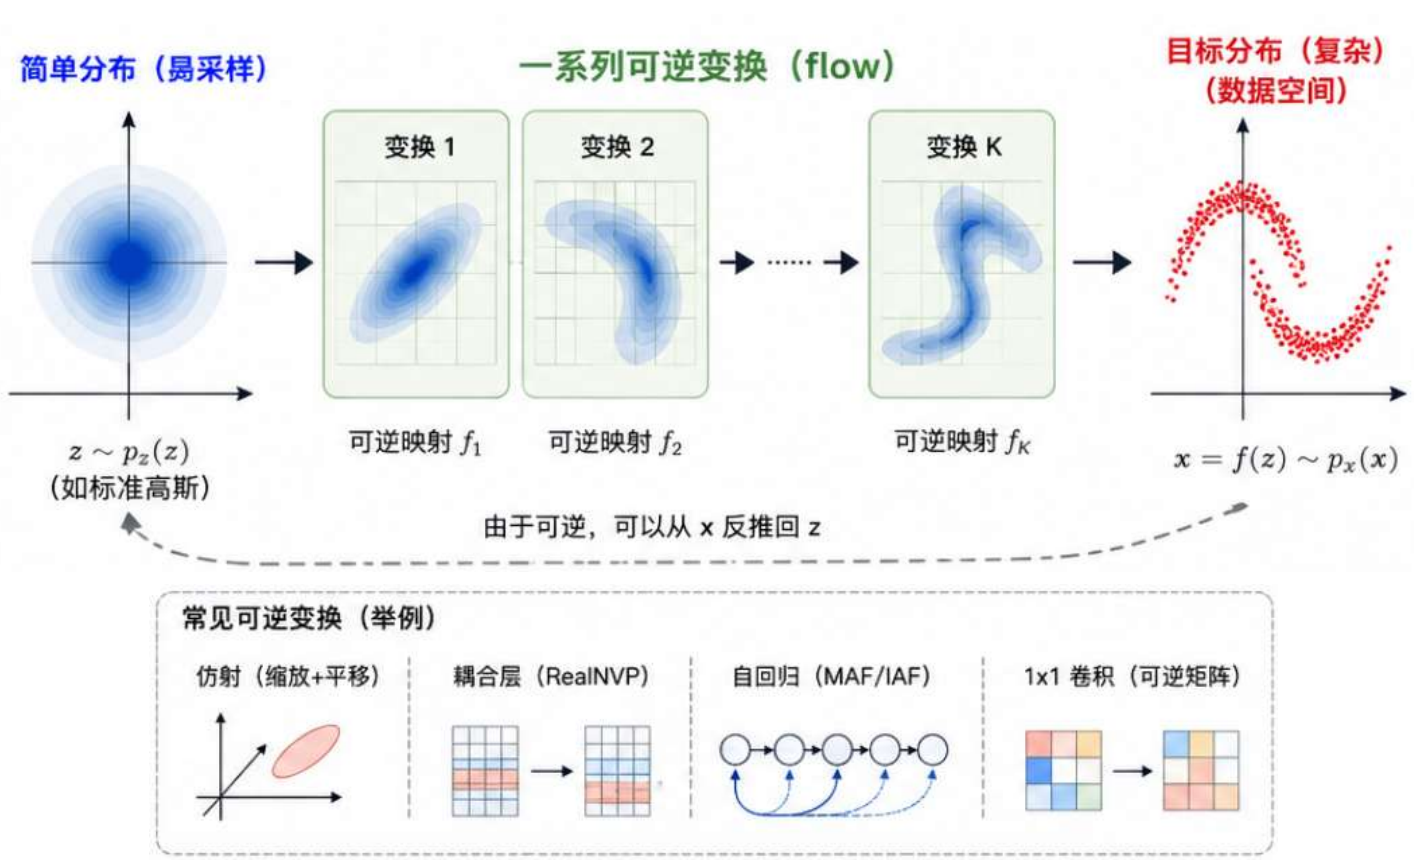
| A \ B | B stays silent | B betrays |
|---|---|---|
| A stays silent | -1, -1 | 0, -3 |
| A betrays | -3, 0 | -2, -2 |

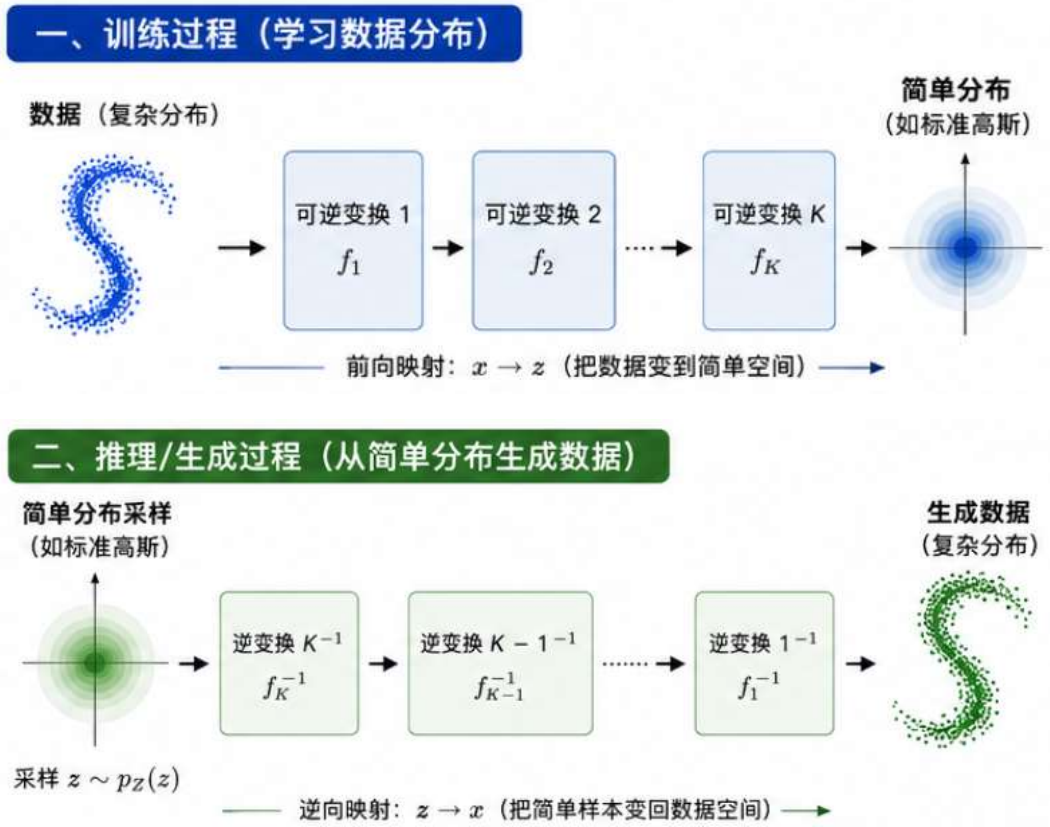



**若干轮的训练以后，Generator生成的图像能够以一半的概率“骗过”Discriminator**

## Normalizing Flow（归一化流）

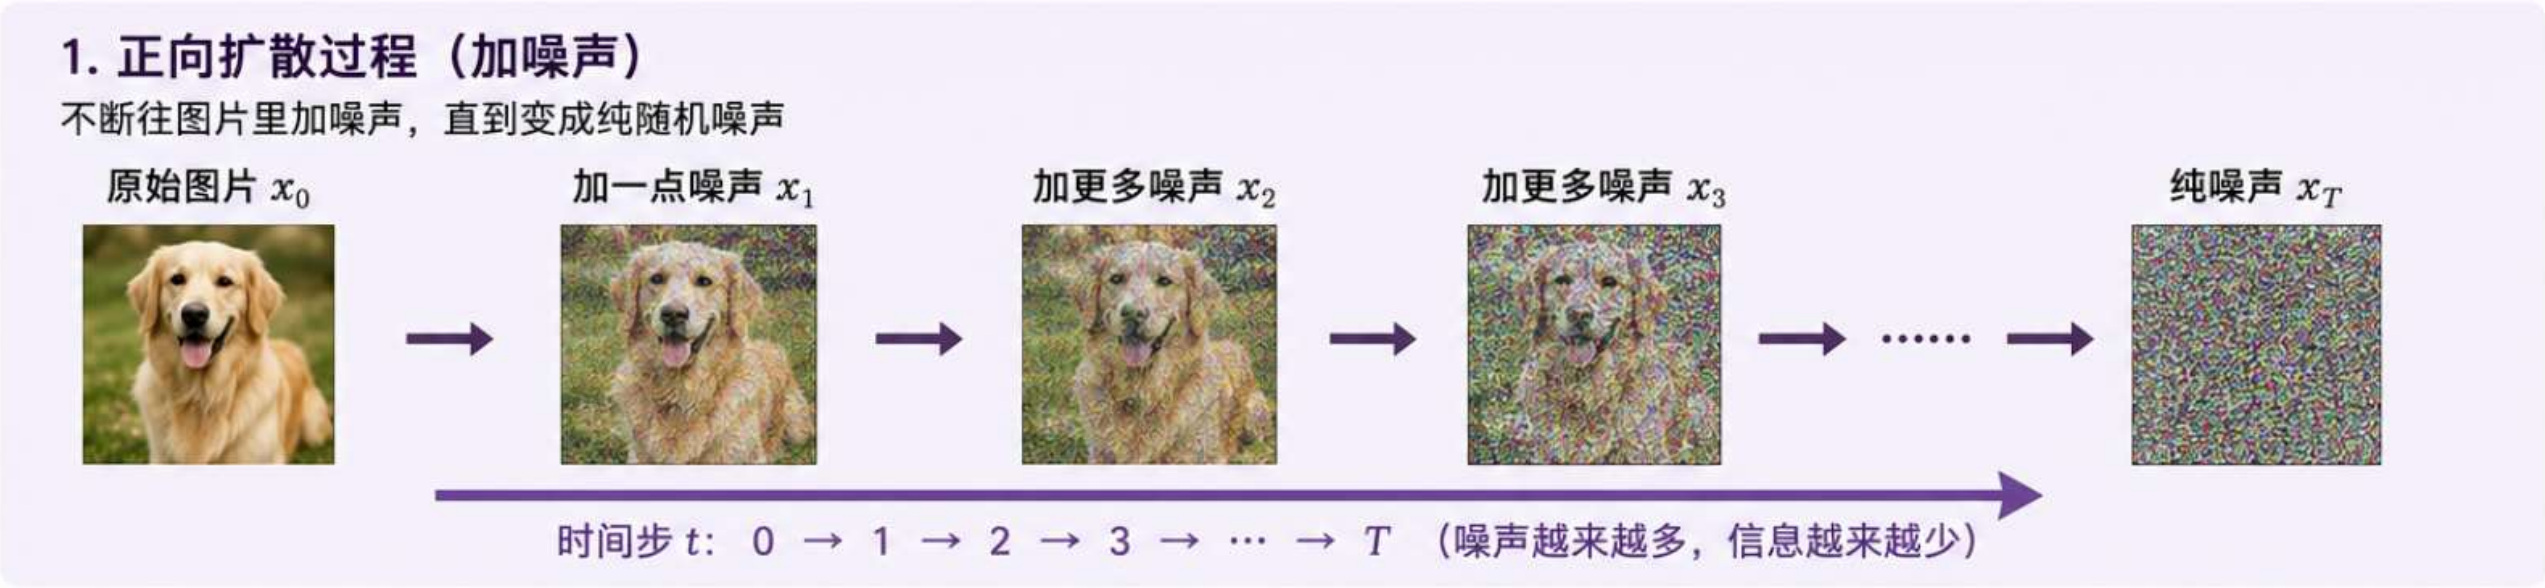
- 通过一系列的可逆的变换，把一个简单的分布“变形”成一个复杂的目标分布



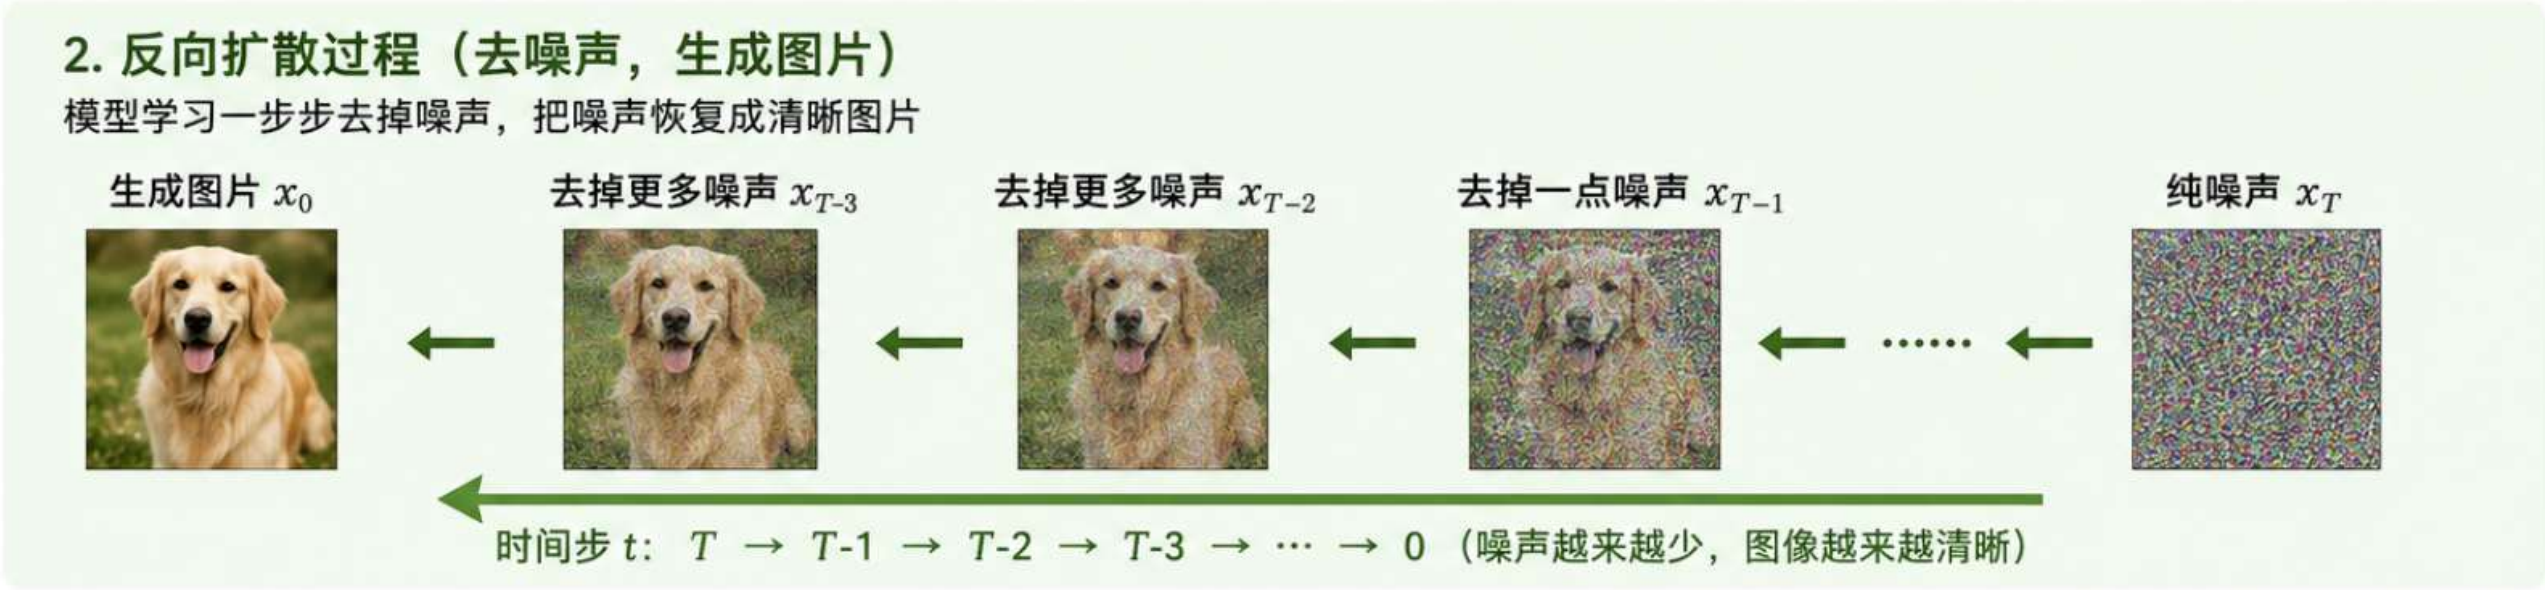



## Diffusion Model（扩散模型）

- 扩散的概念——想象一下在房间里喷香水，那么香气会逐渐弥漫整个房间
- 类似的，往图像中不断加入噪声，最终图像会变成纯随机噪声，这个过程叫正向扩散过程 Forward diffusion

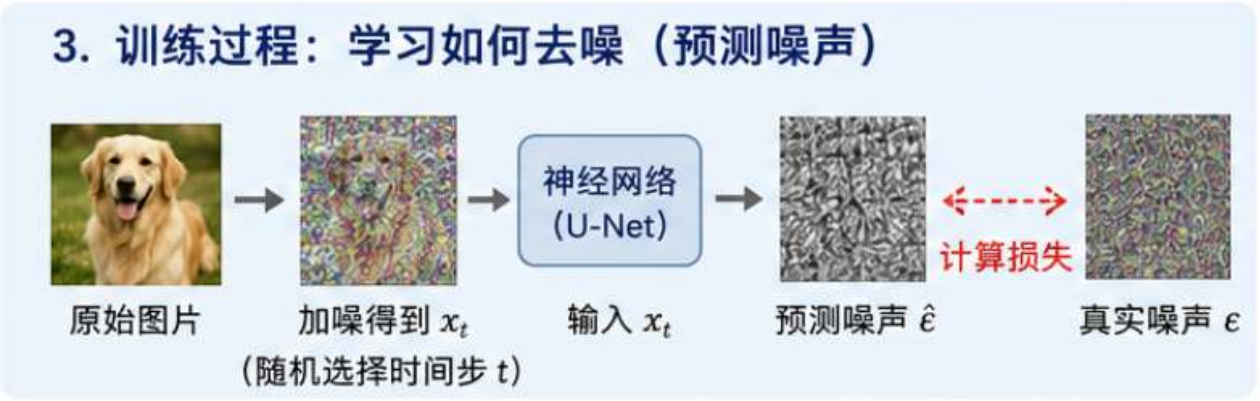


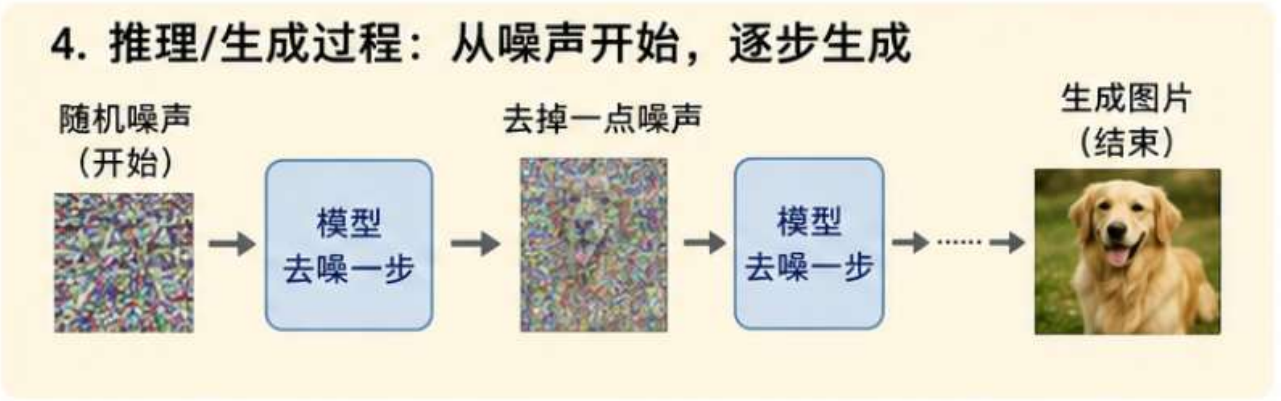
- 推理（生成图片）时则相反，一步一步去掉噪声来得到图片，这个过程称之为反向扩散过程 Reverse diffusion



## 因此，扩散模型训练的目标是预测噪声

- 需要设置一个足够长的步数（1000），以确保图像基本上会被加噪成高斯噪声
- 训练时候只在任意时刻t随机采样，因为高斯分布的线性叠加性质可直接得到t步加噪结果
- 推理时，由于训练好的神经网络能够根据当前图像预测出噪声，所以能够一步一步从图像中去除噪声



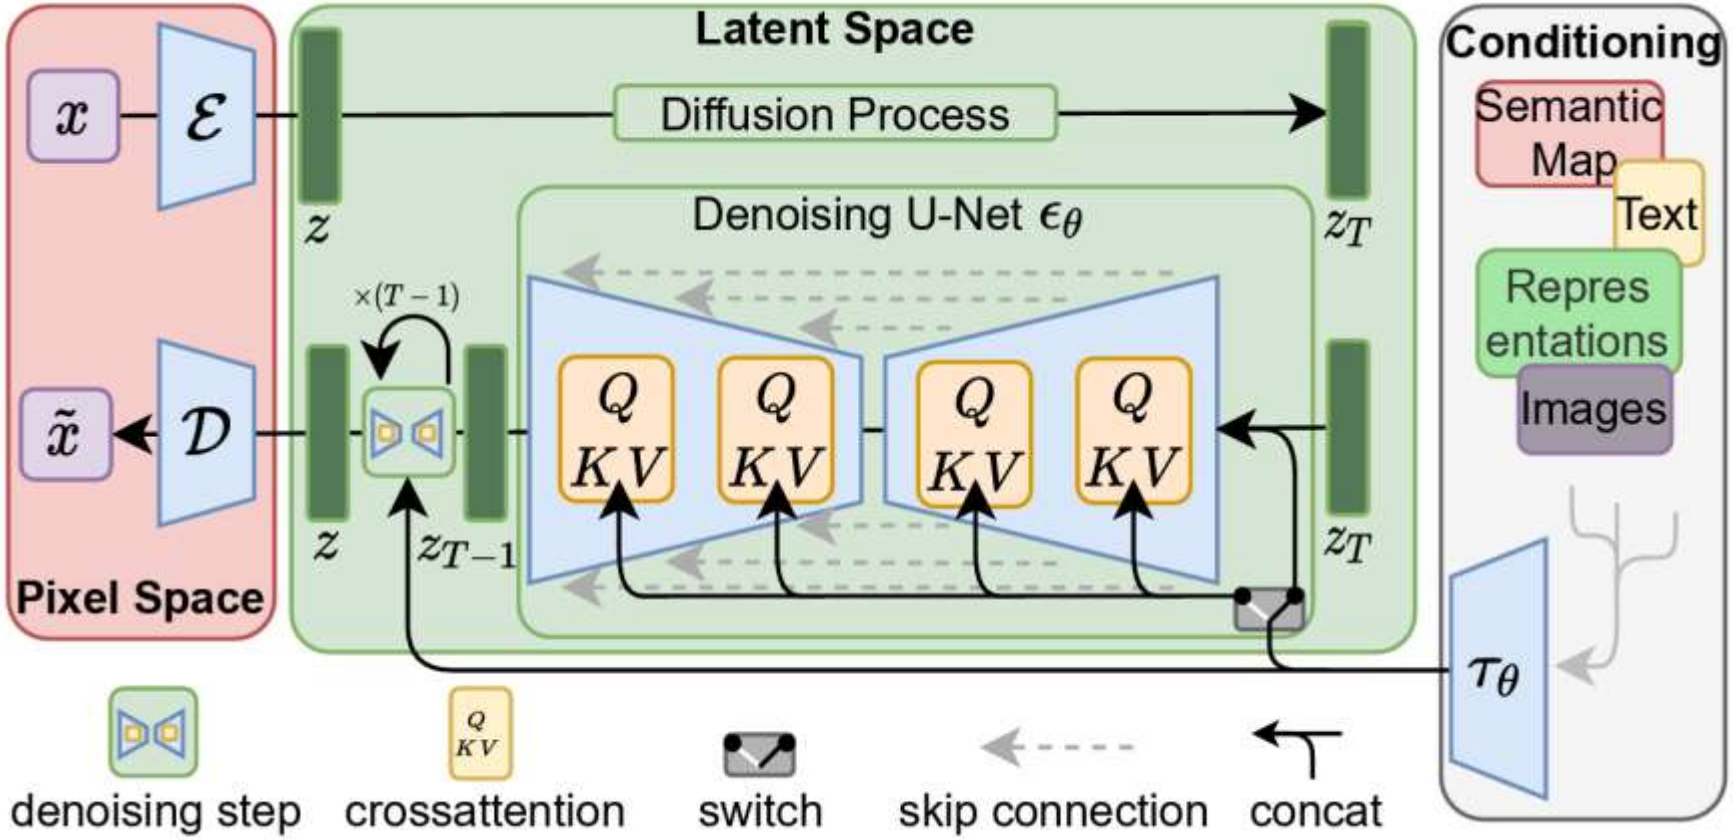




**扩散模型的优点：生成图像的过程稳定且质量高，类似于草稿→细节→润色→成稿的过程**

**缺点：生成的过程非常慢**

## 潜在扩散模型（Latent Diffusion Model）和文本引导生成

- Stable Diffusion



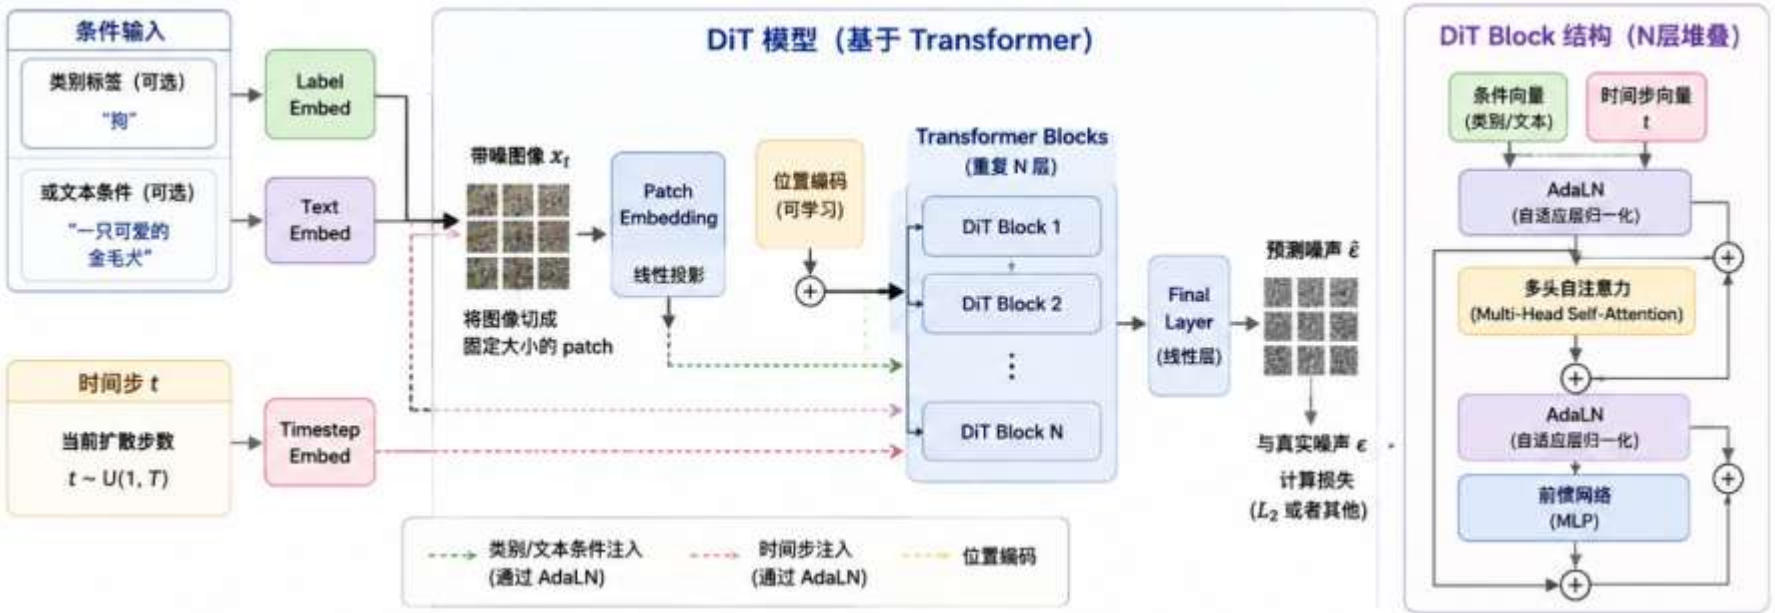

（1）图像的像素空间太大，使用VAE（VQ-VAE）将图像压缩到潜空间中计算，在解码回像素空间

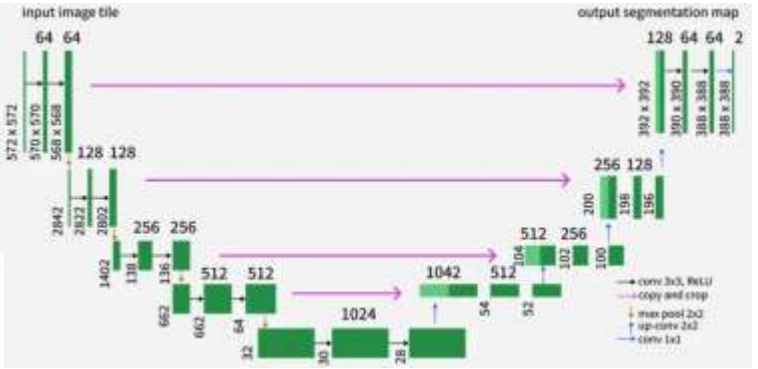
（2）条件控制器，允许文本输入，控制图像生成（让模型听懂人话）

（3）交叉注意力融合

## 骨干网络的架构升级——从U-Net到Transformer

- U-Net基于传统卷积网络，在面对宏大的全局构图、复杂的长文本语义理解时，显得有些力不从心
- 想要通过Scaling law获得性能提升，还得是Transformer架构
- DiT: Diffusion Transformer




U-Net

Scalable Diffusion Models with Transformers

William Peebles*
UC Berkeley

Saining Xie
New York University

DiT为什么这么强？大模型效应、统一架构、时空通吃

# 现代的扩散模型

## Flow Matching（流匹配）

- 扩散模型的痛点是加噪路径曲折、采样步数多
- Flow matching通过学习速度场，在“纯噪声”和“真实图片”之间找到高速公路

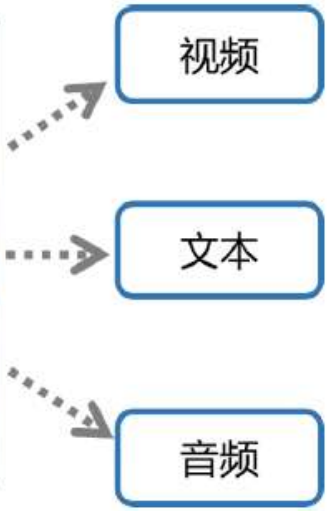
# 视觉-语言多模态大模型（VLM）

# 为什么需要多模态

## 模态（Modality）：信息的来源或者感知通道

- 单一模态：文本（Text）、图像（Image）、语音（Audio）、视频（Video）……
- 多模态：包含多种不同类型信息的集合或交互方式



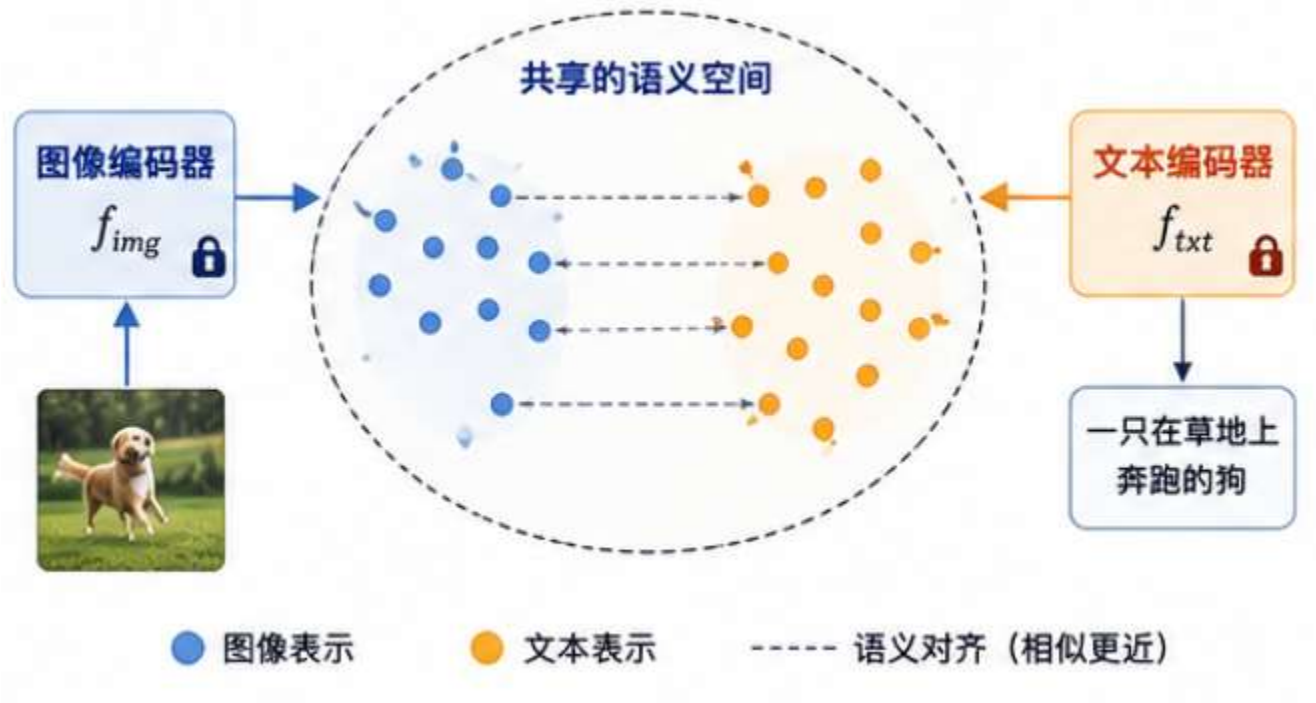



**人类对事物的认知是基于多模态信息融合的**

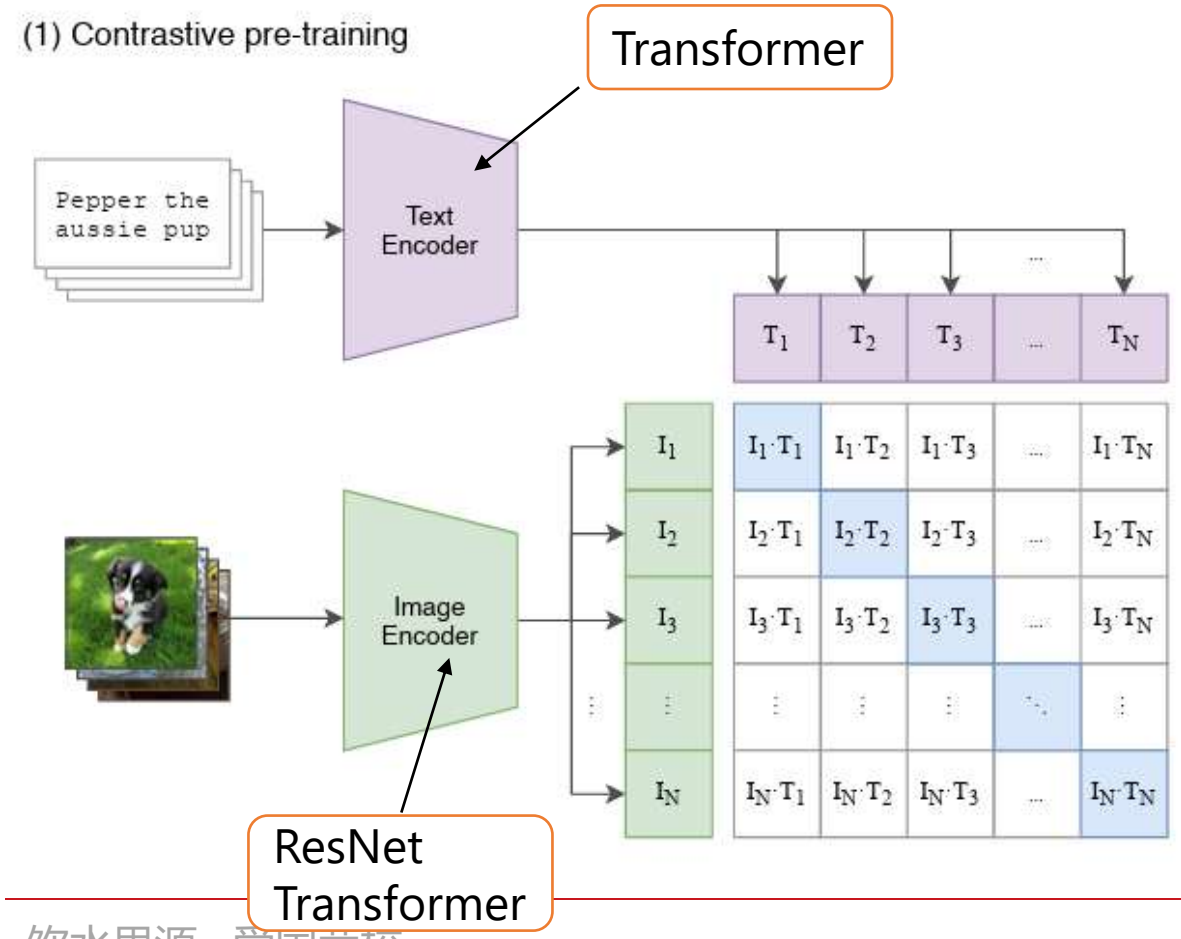
教育学研究表明，人类接受知识是通过多种方式的，其中**视觉占83%，听觉占11%，嗅觉占3.5%**

认知神经学研究表明，一类感官刺激可能会作用于其他感官通道，这种现象被称为**“联觉”**

- 如果不同的模态各自通过不同的网络来提取特征，那么在训练完以后就很难做到在语义空间中的对应关系



**Contrastive Language-Image Pre-training （CLIP），对比语言-图像预训练，OpenAI 2021**
**CLIP是最有代表性的多模态理解模型，同期的类似工作还有谷歌提出的ALIGN**

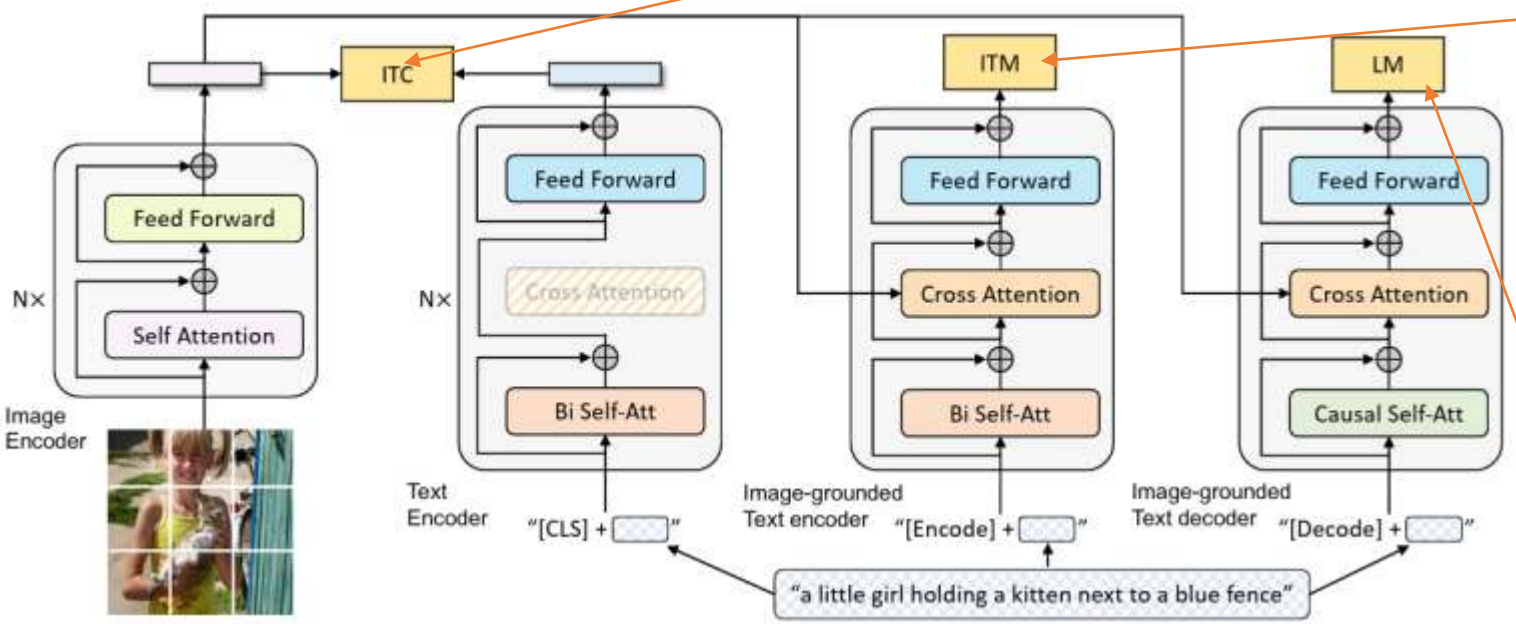


**CLIP通过图文对比学习来建模，但是没有直接融合两个模态的数据，其思想类似于“后期融合”**

**BLIP则直接对多模态特征进行早期融合**

BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation

Junnan Li Dongxu Li Caiming Xiong Steven Hoi
Salesforce Research
https://github.com/salesforce/BLIP




ITC（image-text contrastive）类似于CLIP中的对比学习

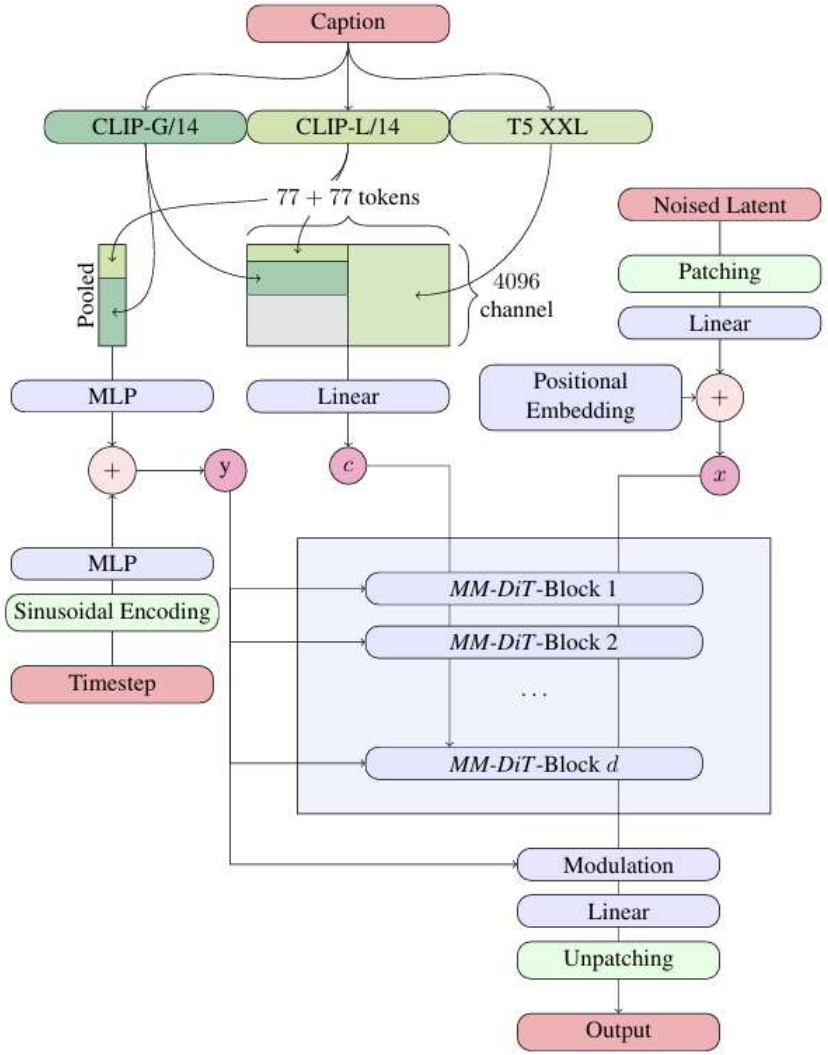
ITM（image-text matching）融合了两种模态的特征，用融合后的特征做二值分类

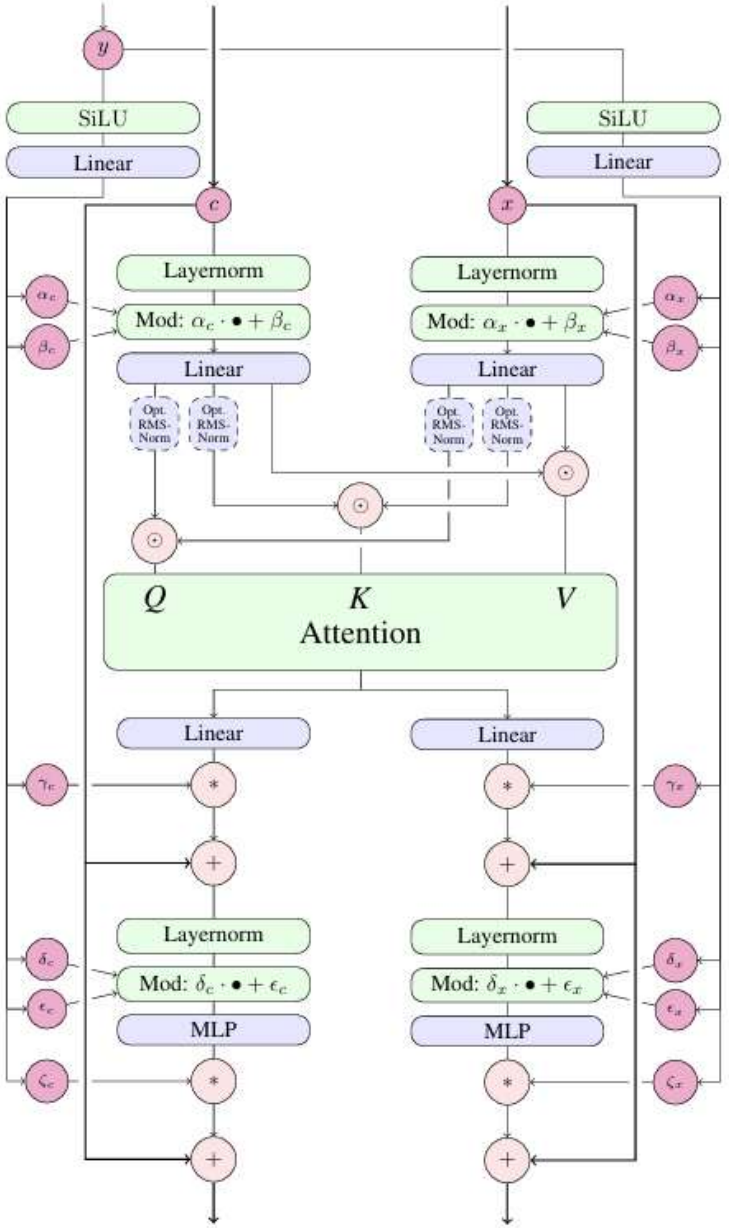
LM（language modeling）同样融合了两种模态的特征，但它的目标是通过图像生成文本，类似给定图像特征作为prompt

**后续工作：BLIP-2，使用冻结的图像和文本编码器，提出Q-Former拼接特征，增加ITG图文生成目标**

饮水

## Stable Diffusion 3:









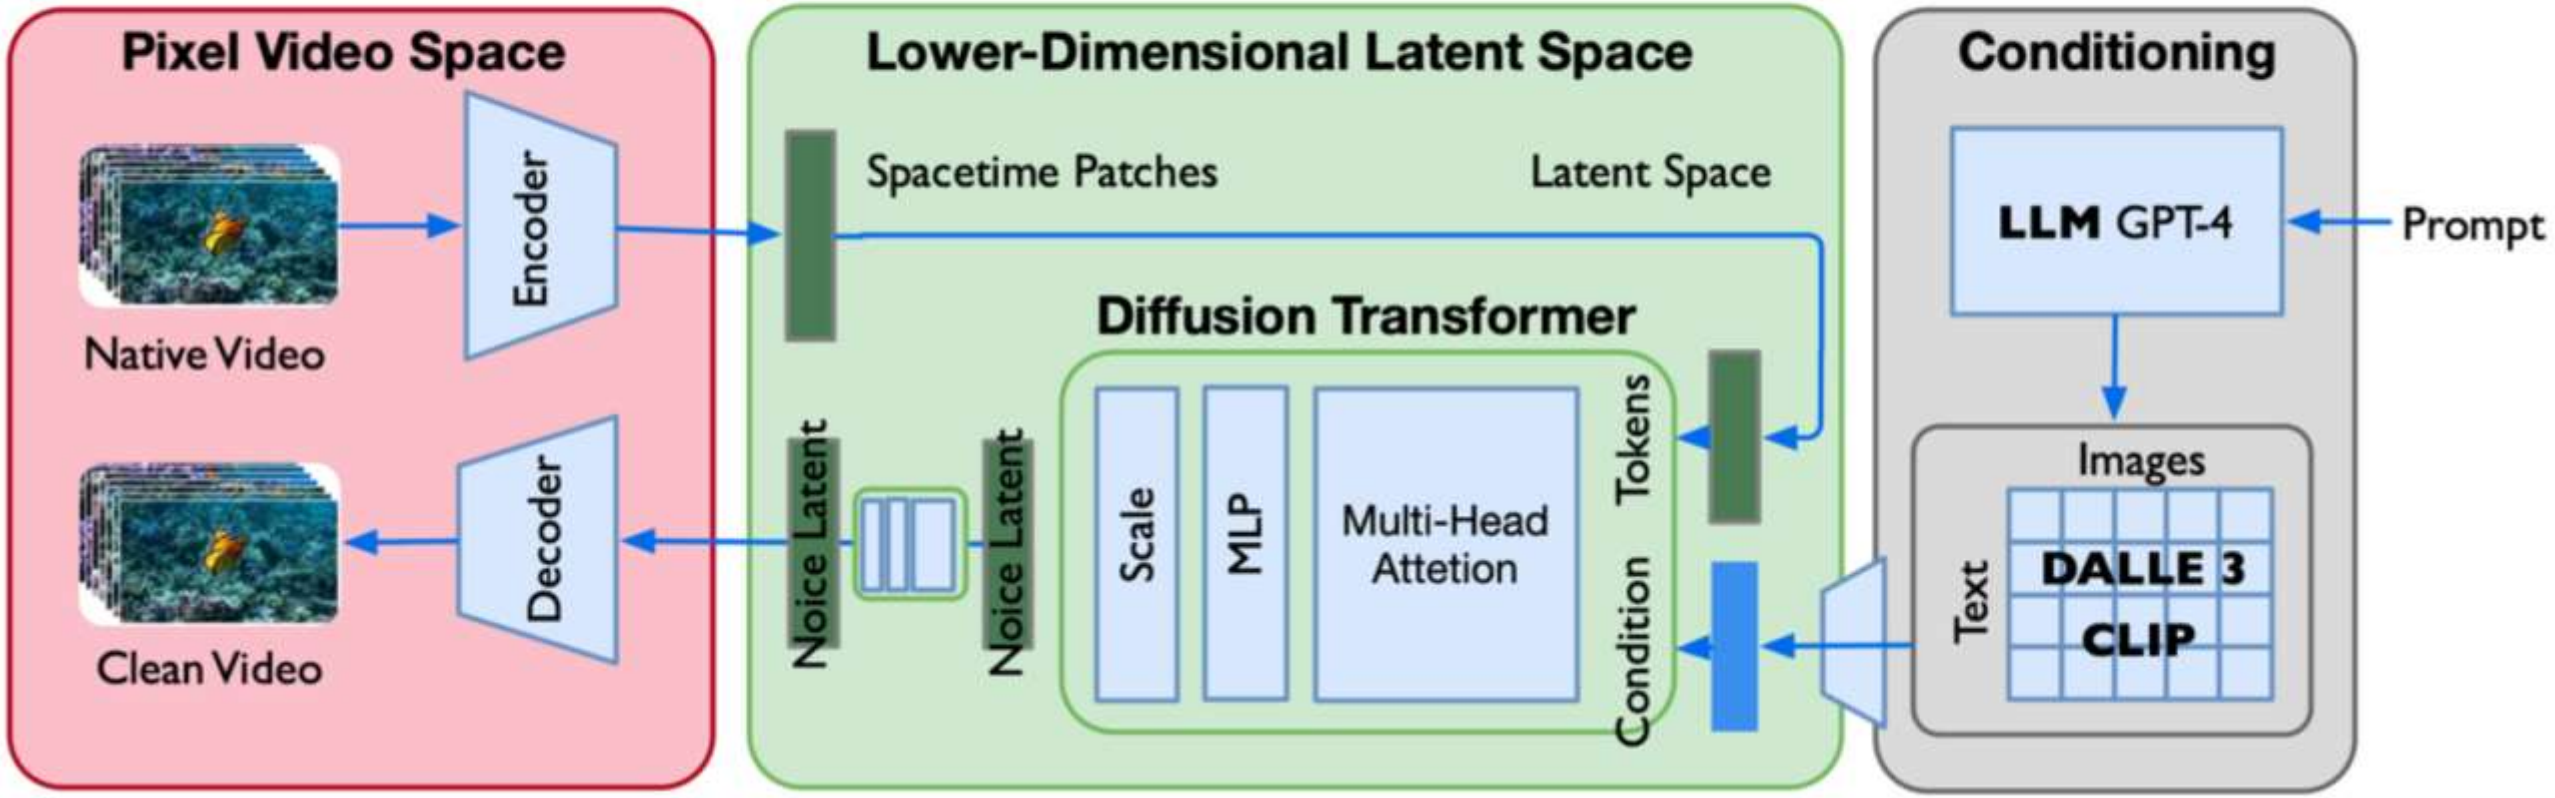
## SORA：视频生成



# SORA

Step 1 : 使用DALLE 3 (CLIP) 把文本和图像对 <text, image>联系起来；
Step 2 : 视频数据切分为 Patches 通过VAE编码器压缩成低维空间表示；
Step 3 : 基于 Diffusion Transformer 从图像语义生成，完成文本语义到图像语义进行映射；
Step 4 : DiT生成的低维空间表示，通过VAE解码器恢复成像素级的视频数据。

$$SORA = [VAE\ encoder + DiT\ (DDPM) + VAE\ decoder + CLIP]$$



## SORA能否理解现实世界以及物理规则?



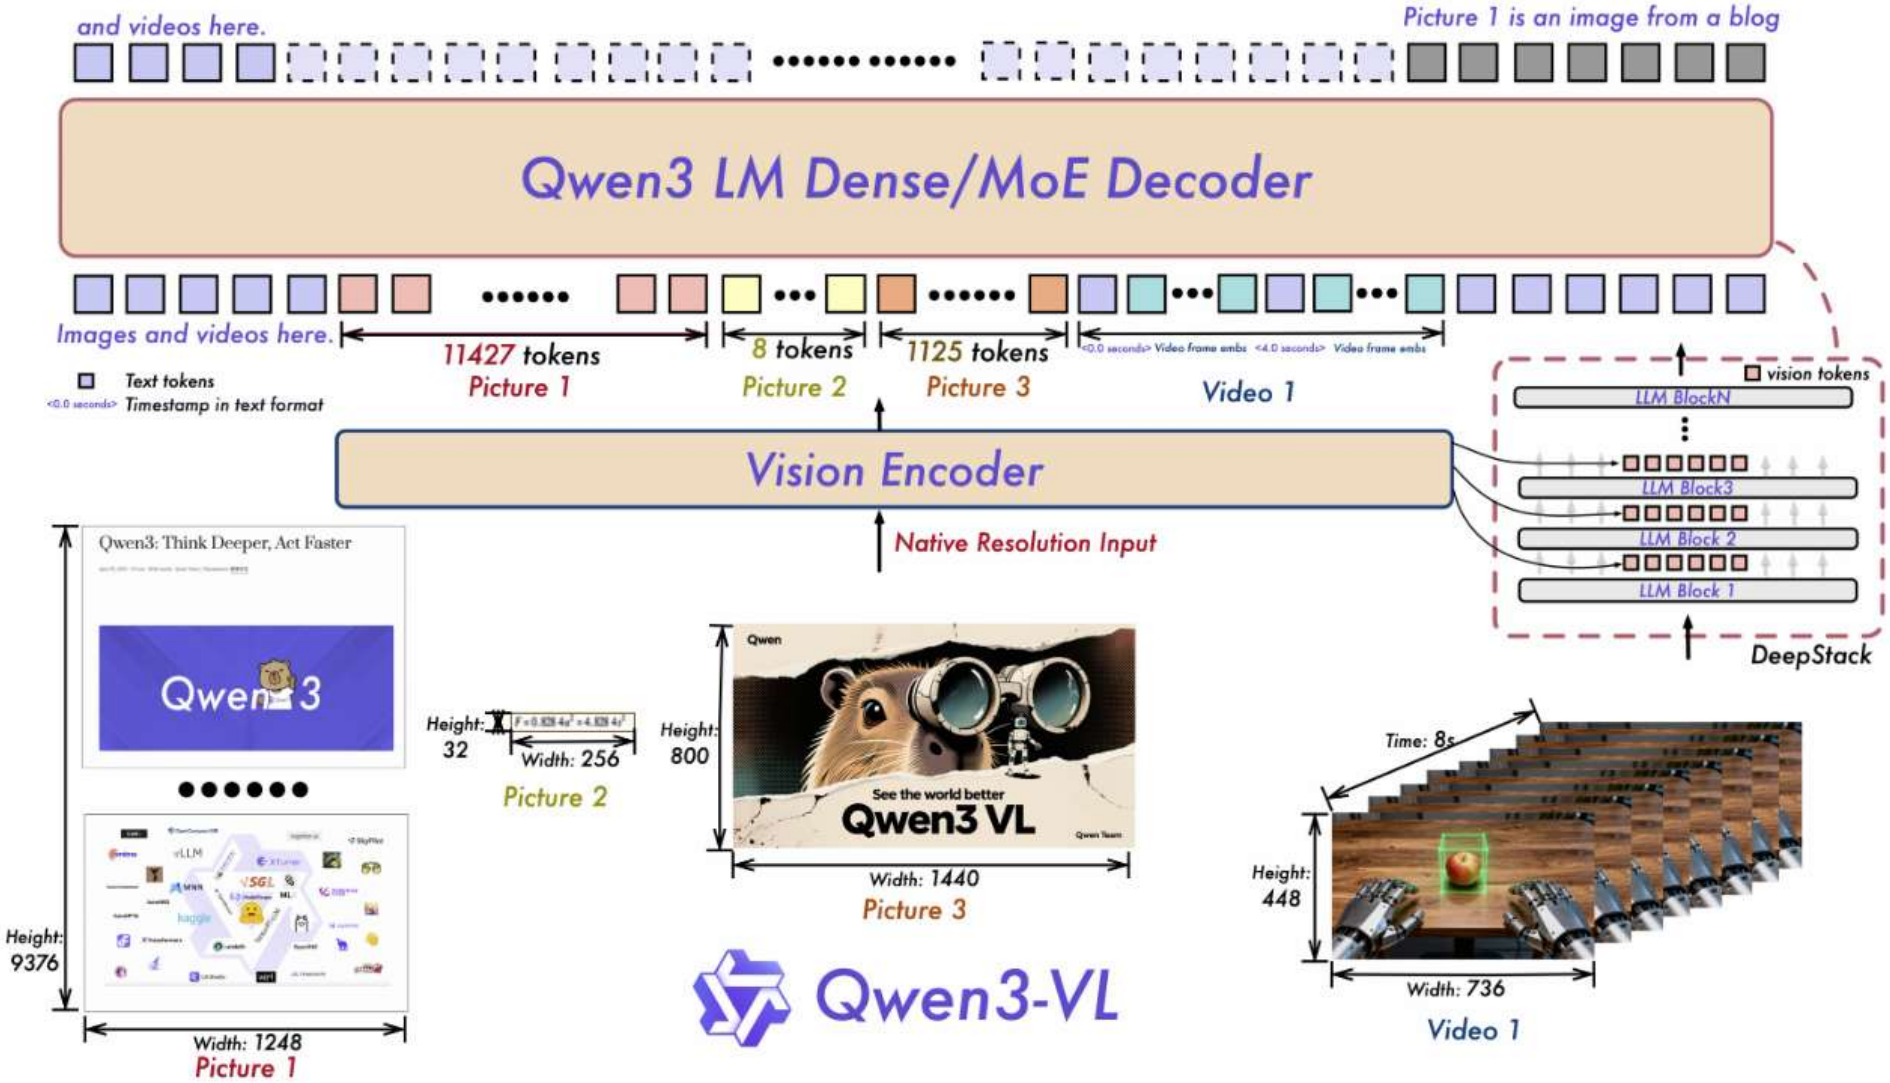
## SORA2 Prompt: man does a cannonball off diving board



更好的物理规律的理解、视音频同步

国内豆包Seedance，优化DiT融合单元、解决多镜头一致性问题，用于短剧生成等

# 多模态大模型统一感知




经典的 **Vision Encoder → Projector → LLM** 三段式设计

动态分辨率、位置编码 **Interleaved-MRoPE**具有更强的空间-时间建模

DeepStack用到多层特征，类似于Skip connection，利用ViT不同深度的特征，提高视觉和语言之间的对齐能力

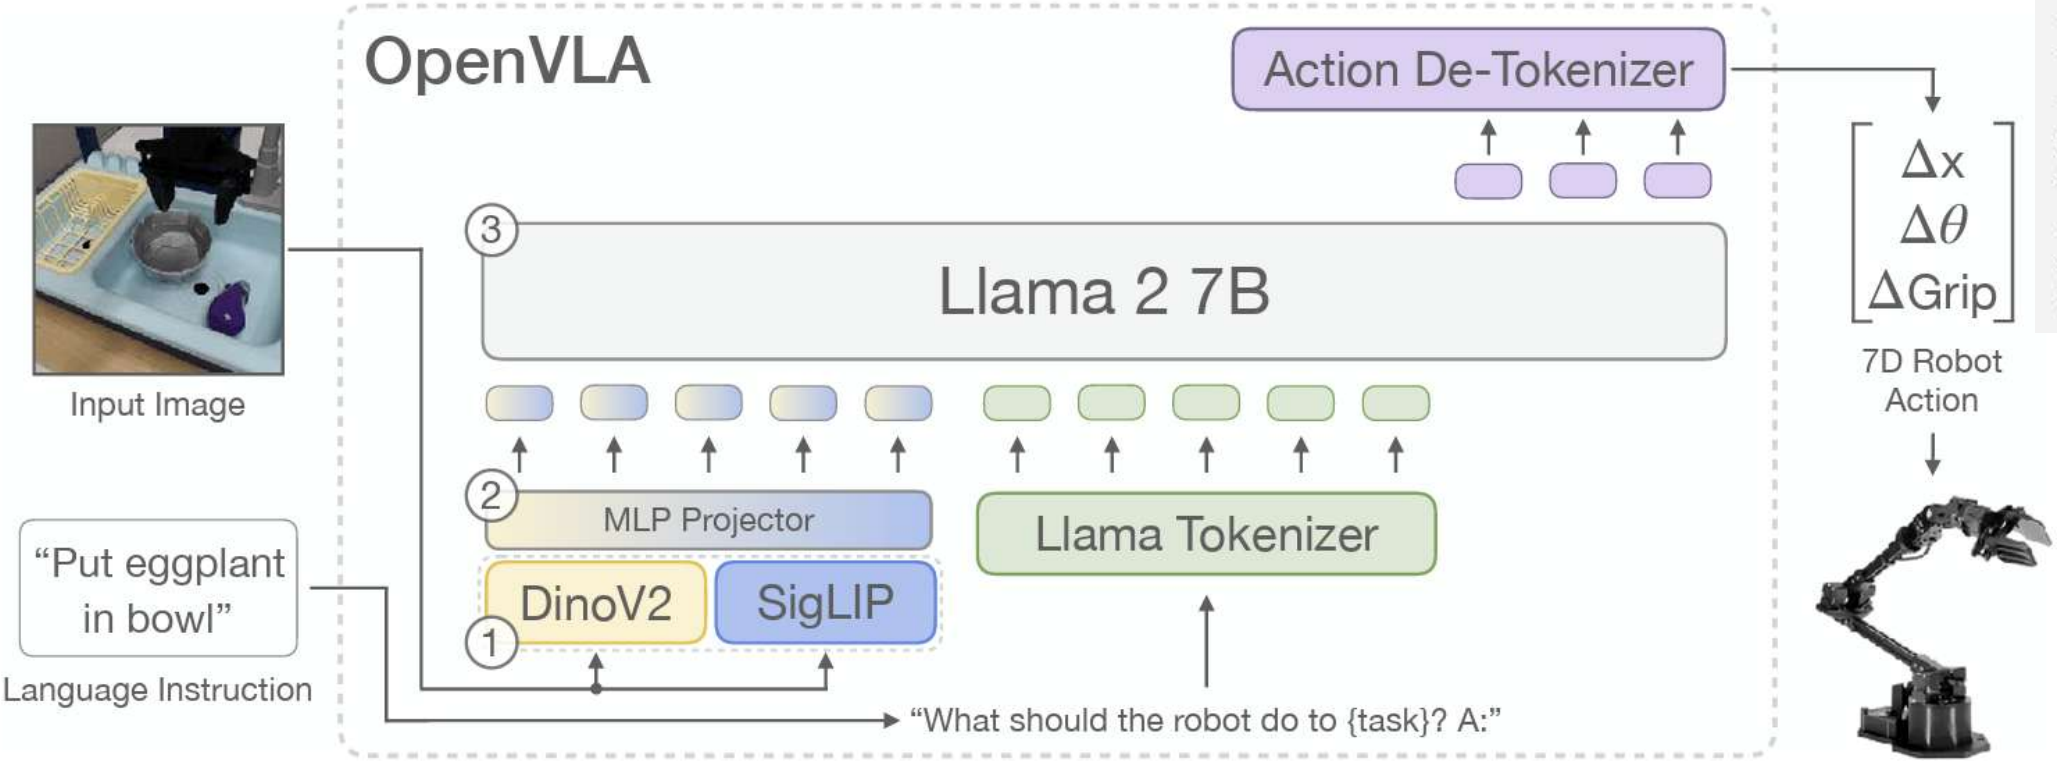
多图理解和视频理解、支持256K上下文

MoE Decoder稀疏激活

**四阶段训练：视觉预训练（Vision Encoder）、跨模态对齐（Porjector）、大规模图文联合训练（整个VLM）、指令微调**

# 具身智能和世界模型（前沿介绍）

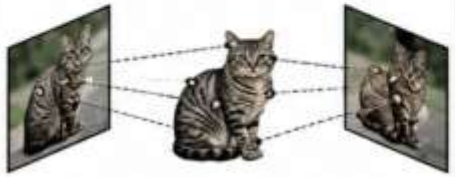
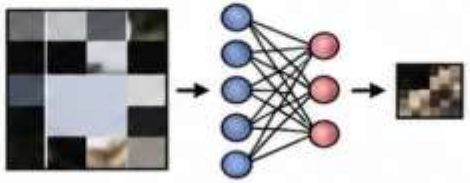
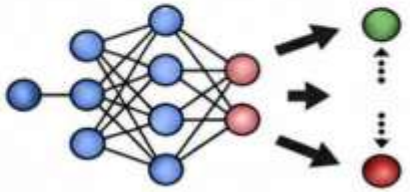
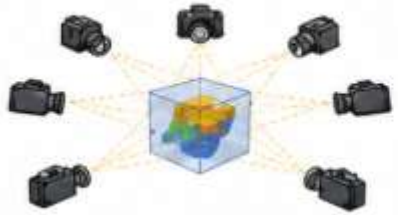
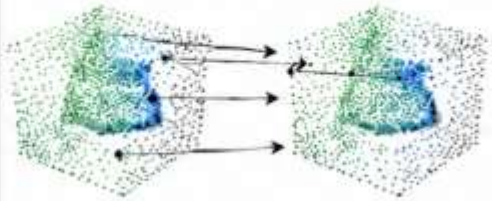
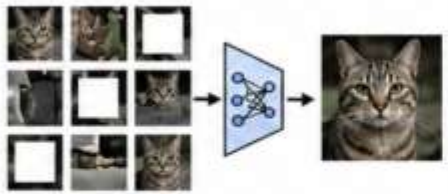
- 多模态技术为具身智能提供了感知和理解的关键能力，具身则实现了落地应用
- Vision-Language-Action（VLA）



具身智能导航：


Task Goal is a image , and be decomposed into a main text goal and sub text goals by Vision-Lanuage Model
Stage Loop until goal are detected and judged as correct
4. Low-level Execution Loop
Reach Midterm Goal?
NO
YES
If Shorterm Goal in Obstacle, avoid it
Else Execute action
if forward, project Shorterm Goal
Shorterm Goal
select Action in: left, forward, right
Sliding Window FMM on A*path
Agent Position through A*path to Midterm Goal
1. Physical Perception
observation history
2D seg
raw
floor
goal
obj
masks
3D foundation model
Pointcloud with Oriented Bounding Box
Stage Spatial Semantic list
update
Global Spatial Semantic list
3. Multi-layer Valuemap Planning
Midterm Goal
= argmax(MVM)
Global Spatial Semantic List
{cap: door, exp: 0, pos: (x1,y1)}, value: 0.7,
{cap: cabinet, exp: 1, pos: (x3,y3)}, value: 0.8,
Multi-layer Valuemap
Mode: Explore,
Direction: Forward
2. Vision-Language Model
Target Image
Current Obs.
Global Spatial Semantic List
[{cap: door, explore: No, position: front},
{cap: carpet, explore: No, position: front},
...]
Please choose one Navigation mode in {Explore, Find, Judge}, and if you choose {Explore}, choose a direction in {Left, Forward, Right}. Give a Value for each Objects which hasn't been expolred.
Prompts
< VLM > :
Considering the goal hasn't been found and not visible, the Navigation mode will be {Explore}, and I suggest to explore the {Forward} region.
[{cap:door, exp:0, position: in the front, value: 0.7},...]

## 目前对于世界模型的定义仍然不统一

| | 重建 = 世界模型 | 预测下一步 = 世界模型 | 可以运行 = 世界模型 |
|---|---|---|---|
| 重建（静态） |  DINO 是世界模型 |  JEPA 是世界模型 |  Dreamer 是世界模型 |
| 物体/3D（空间） |  NeRF 是世界模型 |  Scene Flow 是世界模型 |  MuJoCo 是世界模型 |
| 像素/视频（感知） |  MAE 是世界模型 |  Video Diffusion 是世界模型 |  Snake 游戏运行 = 世界模型 |

“世界模型（World Model）”被公认为是当前通往通用人工智能（AGI）和高级具身智能的最核心钥匙

其核心是让 AI 在大脑中构建的一个“物理世界的模拟器”，在行动之前先推演，进行前瞻性搜索

难点：理解物理规律

## 李飞飞的世界模型：一个提示词，无限高质量3D场景渲染



上海交通大學

SHANGHAI JIAO TONG UNIVERSITY

# 谢谢！

饮 水 思 源　爱 国 荣 校